

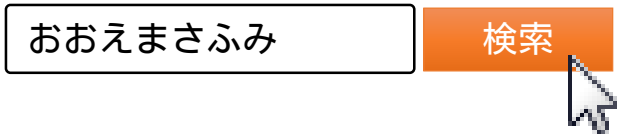
100Gを使い切るNAOJ SDN

大江 将史 <masa@fumi.org>
天文データセンター
国立天文台

自己紹介

- 大江将史　（おおえ　まさふみ）

  http://fumi.org/



- 所属：自然科学研究機構 国立天文台

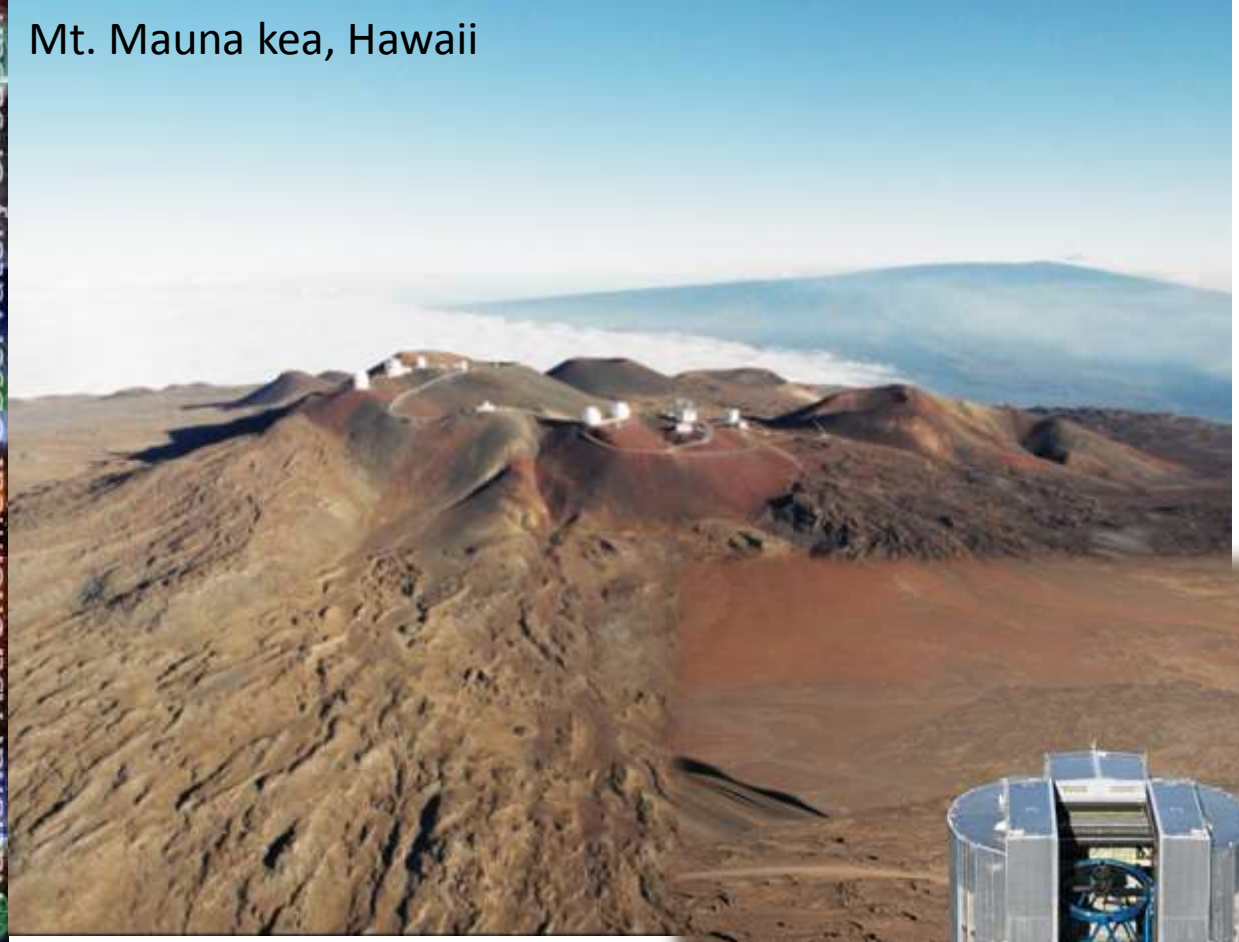
  天文データセンター　助教

- なにしてるのか？
  - 専門は、ネットワークセキュリティ、衛星通信、無線通信など
  - 天文と情報ネットワークの融合に関する研究等
  - 国立天文台のネットワーク運用や設計等

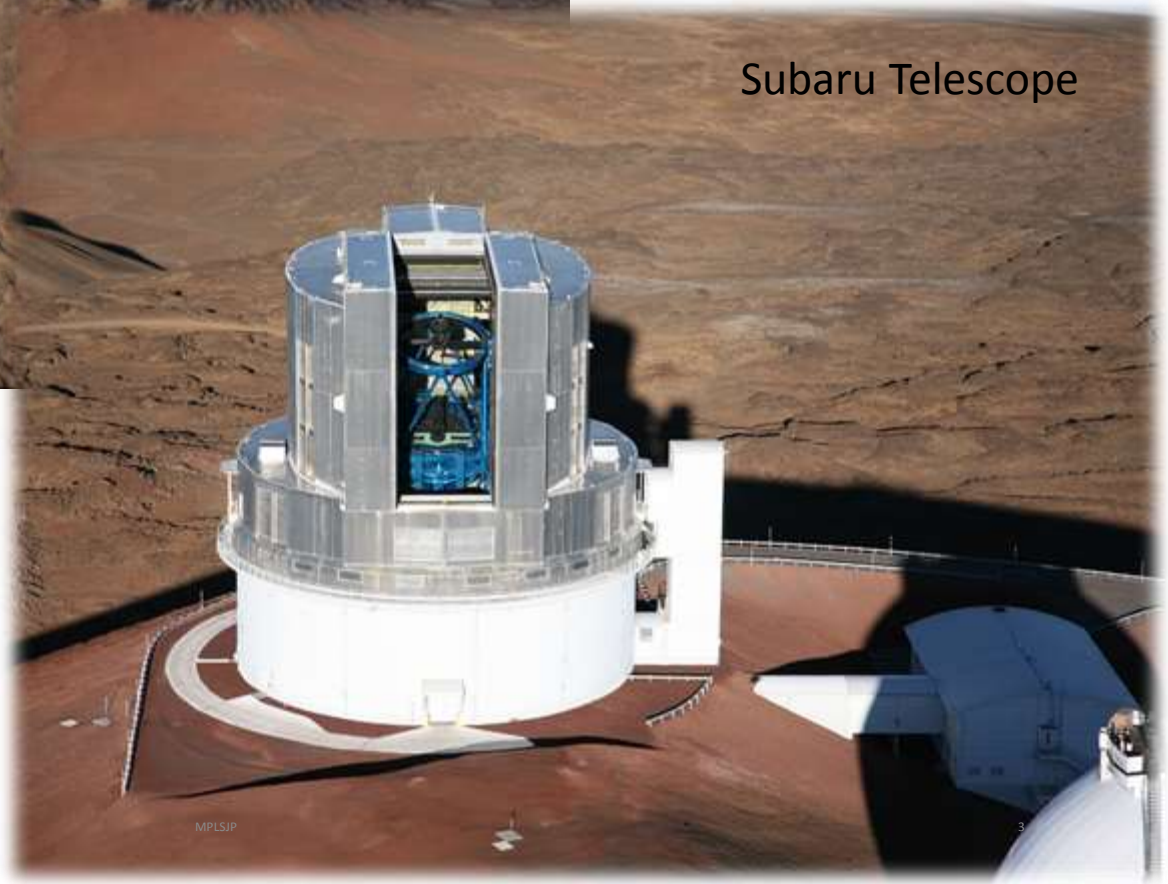
➔「星を見るのにデータセンタ？ネットワーク？」

その疑問はごもっともです.

Mt. Mauna kea, Hawaii



Subaru Telescope

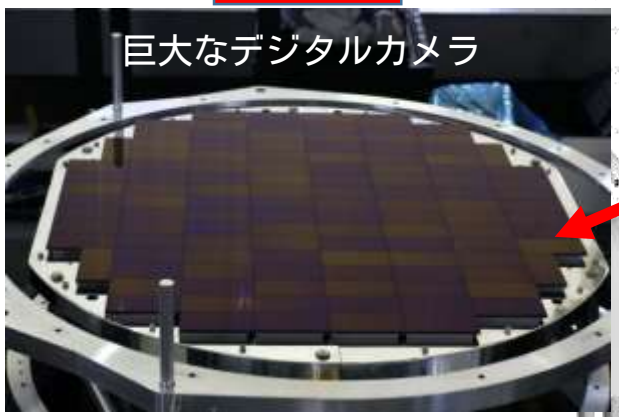


National Astronomical Observatory of Japan
National Institutes of Natural Sciences

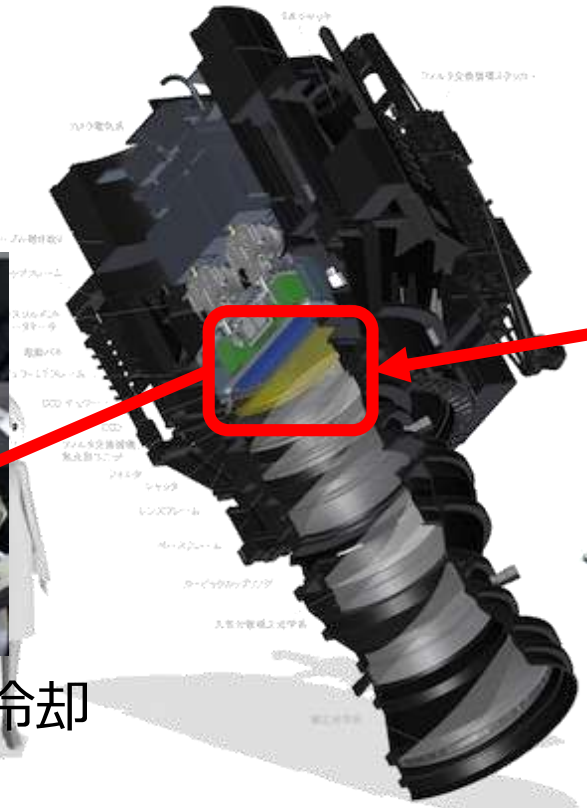
天文学とデジタル化の事例

複数のデータセンターにてアーカイブ
コンピュータで解析
データ公開

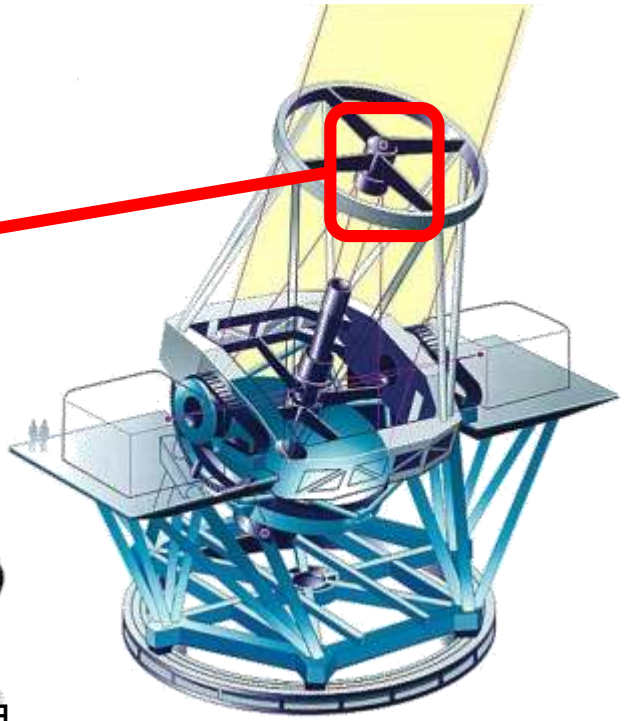
天体のデジタルデータ



高感度CCD -100℃に冷却
合計約8億7000万画素



すばる望遠鏡のあたらしい目
HSC: Hyper-Suprime-Cam



すばる望遠鏡

コンピュータとネットワークなしには天文学は成り立たない



今日のテーマ

- 天文学におけるデジタル・データ
  - 様々な観測機器からデータが生まれる
- ネットワークの果たす役割
- ネットワークに関する研究開発事例

さまざま種類のトラフィック

水沢～大手町～三鷹

1）スーパーコンピュータ:アテルイ

- 特徴
  - 水沢観測所（岩手県奥州市）に設置500TFlops級のCray社のスーパーコンピューターシステム
    - 2014年度に 1PFlops級へアップグレード





1）スーパーコンピュータ:アテルイ

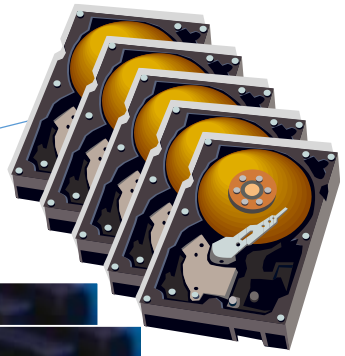
- 計算ジョブ（最長8時間）の間隔でデータが出力
  - ジョブ完了➔水沢から三鷹へデータ送信
  - ジョブ継続➔再度ジョブ投入

  ➔8時間単位で，ネットワークに負荷がかかる可能性



HPC計算ノード群
(水沢)

IPネットワーク



ストレージ
ノード群(三鷹)



専用計算ノード群
(三鷹)



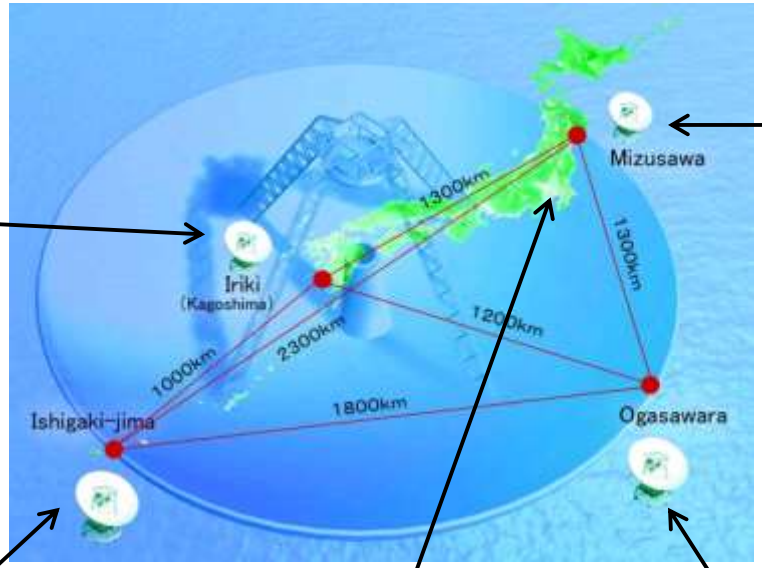
汎用計算サーバ群
(三鷹)

2） VERA: VLBI Exploration of Radio Astrometry

VERA is a VLBI array to explore the 3-D structure of the Milky Way Galaxy



IRIKI(入来), KAGOSHIMA





MIZUSAWA(水沢), IWATE



ISHIGAKIJIMA(石垣島), OKINAWA

Correlation center



MITAKA(三鷹), TOKYO



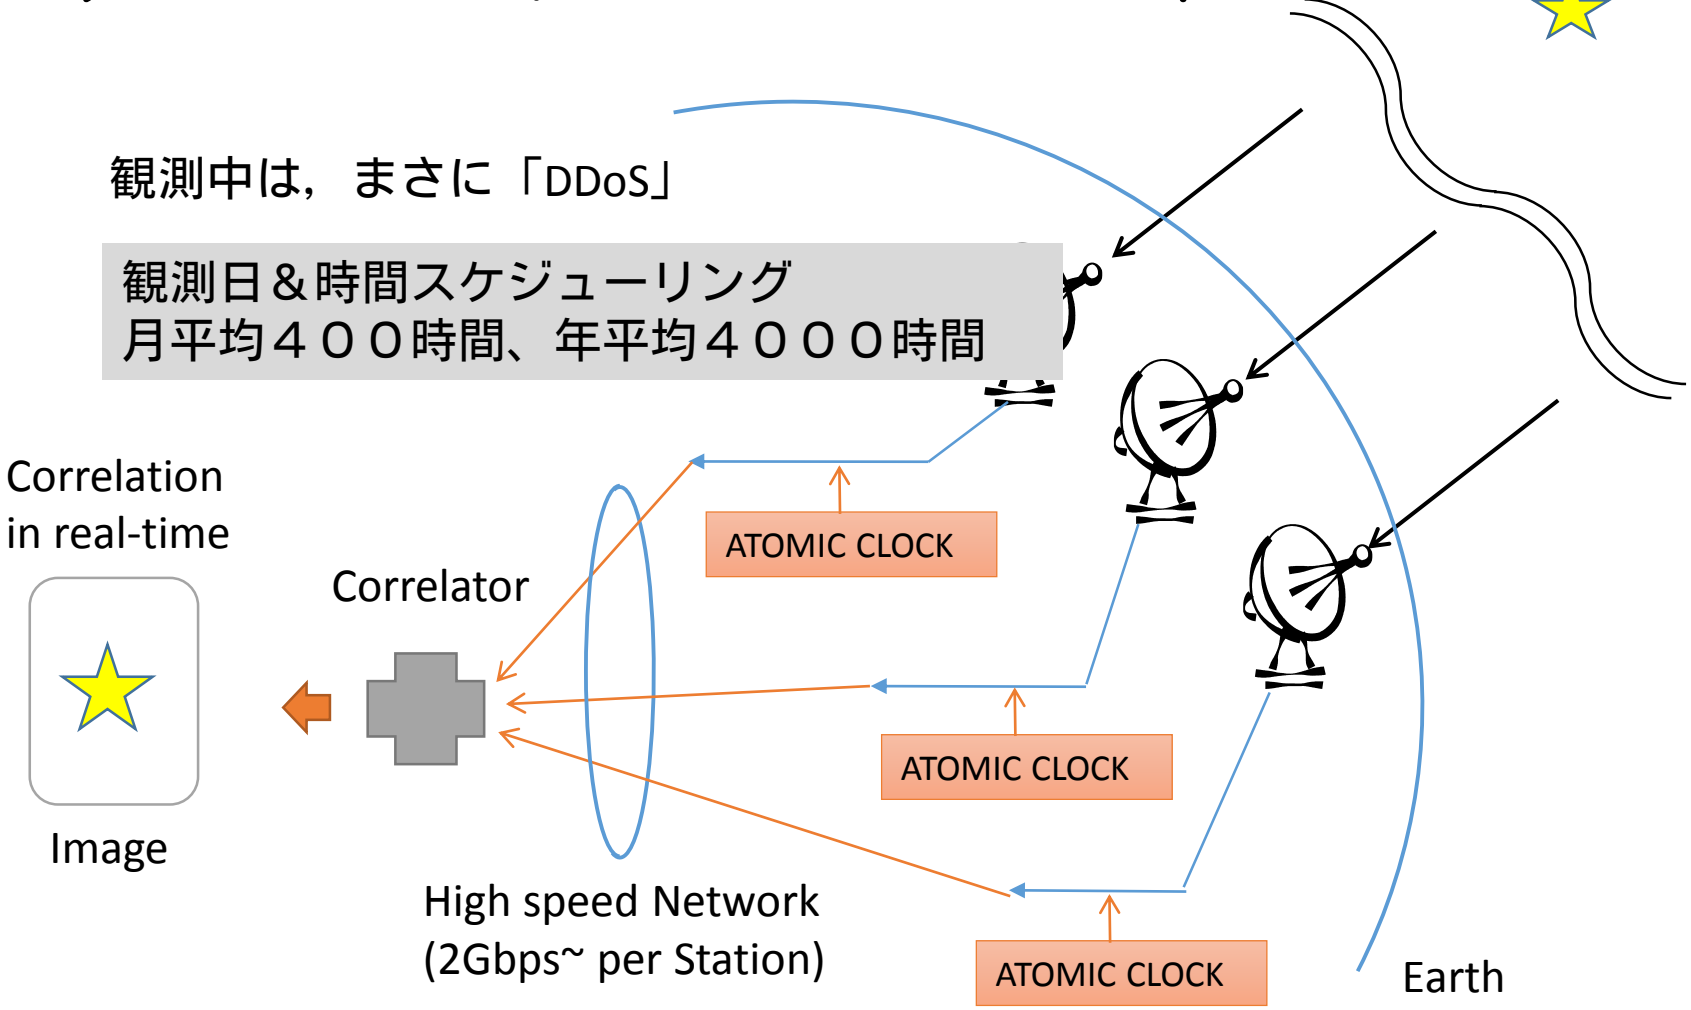
OGASAWARA(小笠原), TOKYO

望遠鏡（山口・茨城・他）

2）e-VLBI：ネットワークで結ぶVLBI

観測中は，まさに「DDoS」

観測日＆時間スケジューリング
月平均４００時間、年平均４０００時間

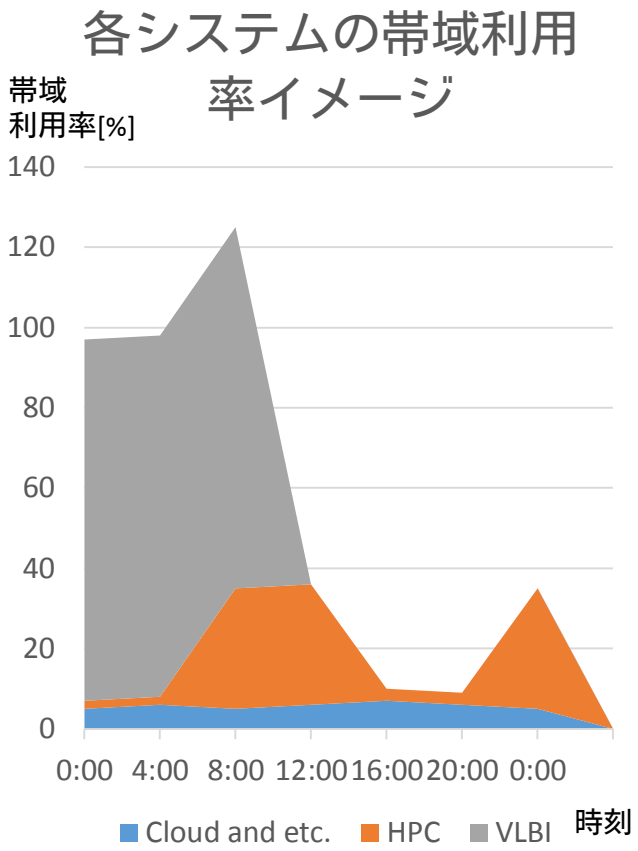


そのほか

- クラウドシステム
  - プライベートクラウドサービスを4拠点で運用
    - 「実機より速い」が合言葉
    - 三鷹地区・大手町地区・水沢地区・岡山地区に分散したクラウドシステム
    - iSCSIネットワーク・VMノード
- コンテンツ配信
  - デジタル4次元シアター(4D2U)のコンテンツ提供
    - スパコンや観測成果に基づく科学コンテンツの配信
  - アウトリーチ：観測所と学校を結んで最先端の科学にふれる
    - ＨＤビデオ双方向中継（１から多地点）
    - 天文現象の中継（皆既日食・彗星など）

さまざまなプロパティを持つトラフィックが広域網を流れる

- スパコン
  - 水沢の計算ノードからの結果出力を，三鷹の恒久ストレージへ効率よく伝送
    - ノンリアルタイム・利用者の利用傾向に基づく帯域の占有予測
    - 伝送中は高効率化により帯域を占有・ロスは許容されない.
- ＶＬＢＩ
  - 水沢から三鷹へ観測データをバーストトラフィックで伝送
    - スケジュールされた観測時間に連動した帯域確保
    - パケットロスには寛容・通信としてのプライオリティは低い扱い
- クラウド・コンテンツ配信
  - 帯域は，クラウドのマイグレーション，ストレージトラフィック，コンテンツ配信などに強く依存
    - 帯域の変動幅が大きい
    - パケットロスに非寛容.



トラフィックを制御する

今の解決策：必要は発明のナントカ

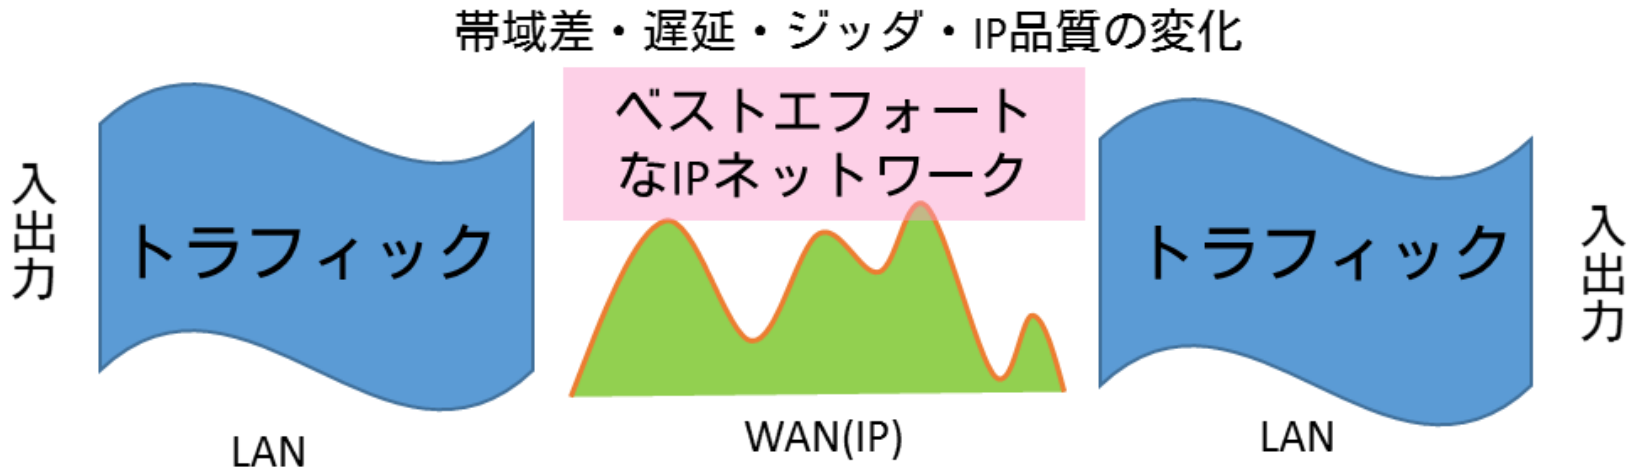
ULTRA計画(2012～)を開始

- 天文学を支えるハイパフォーマンスなネットワークへの要求
  - 天文学専用スパコンシステム
  - VLBI観測システム
  - クラウド・映像中継等々
- 汎用化機器の高性能化
  - 専用機の開発コスト効率の悪化

➔地理的に分散する（天文学）情報システムとＩＰネットワークを効率よく連携させる仕組みが自然科学の発展には必要不可欠

＋計算機の運用ノウハウ習得・高コストパフォーマンスの実現と応用

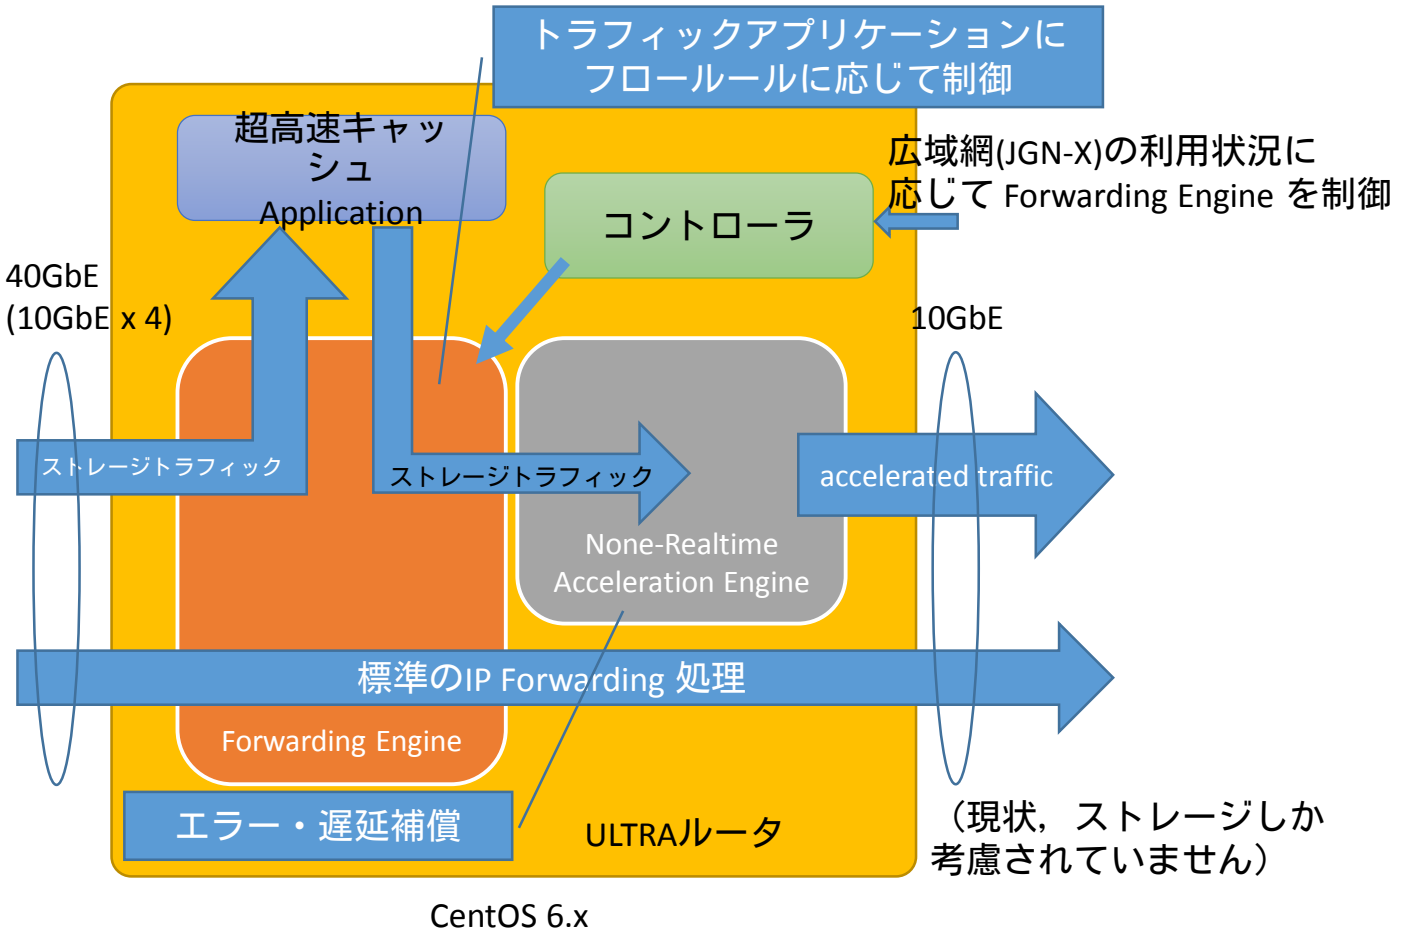
ミドルボックス：
データ伝送の効率化



超高速ストレージキャッシュ・ストレージトラフィックの予測に基づく伝送制御・高効率伝送方式を組み合わせて解決



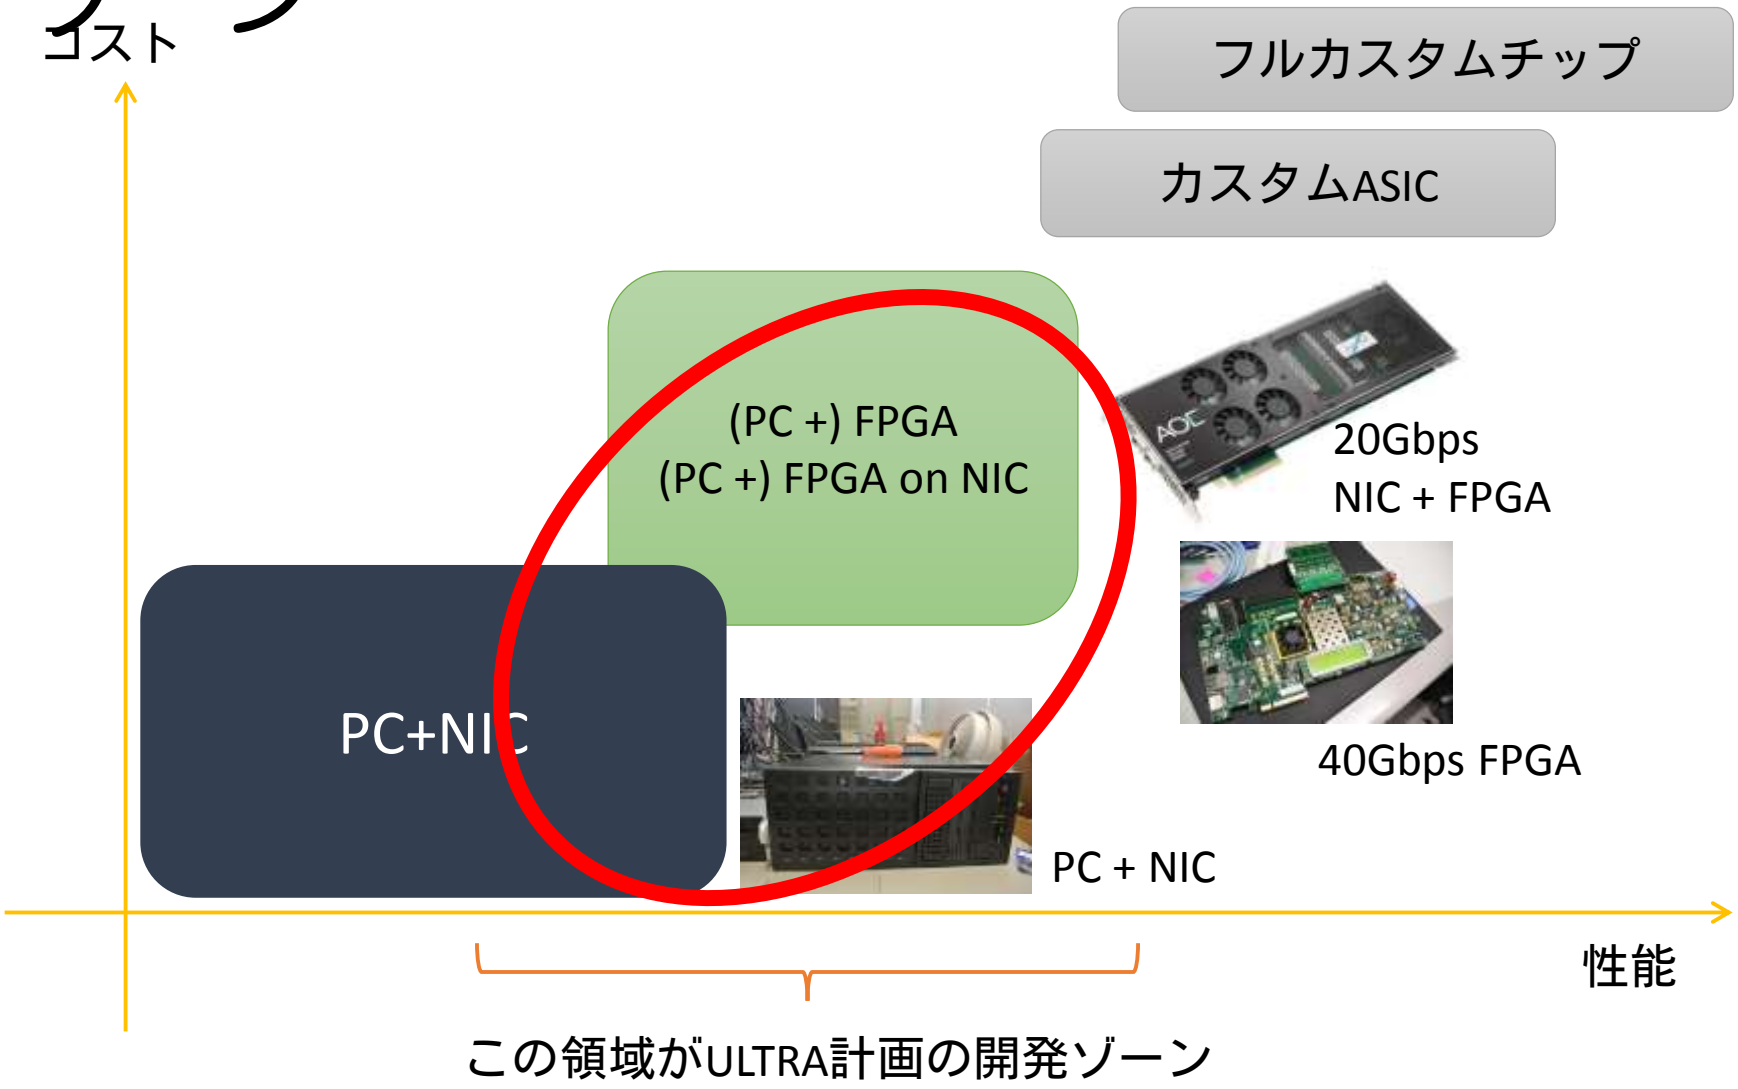
ULTRA200 構成


トラフィックアプリケーションに
フロールールに応じて制御
超高速キャッシュ
Application
広域網(JGN-X)の利用状況に
応じて Forwarding Engine を制御
コントローラ
40GbE
(10GbE x 4)
10GbE
ストレージトラフィック
ストレージトラフィック
accelerated traffic
None-Realtime
Acceleration Engine
標準のIP Forwarding 処理
Forwarding Engine
エラー・遅延補償
ULTRAルータ
（現状，ストレージしか
考慮されていません）
CentOS 6.x

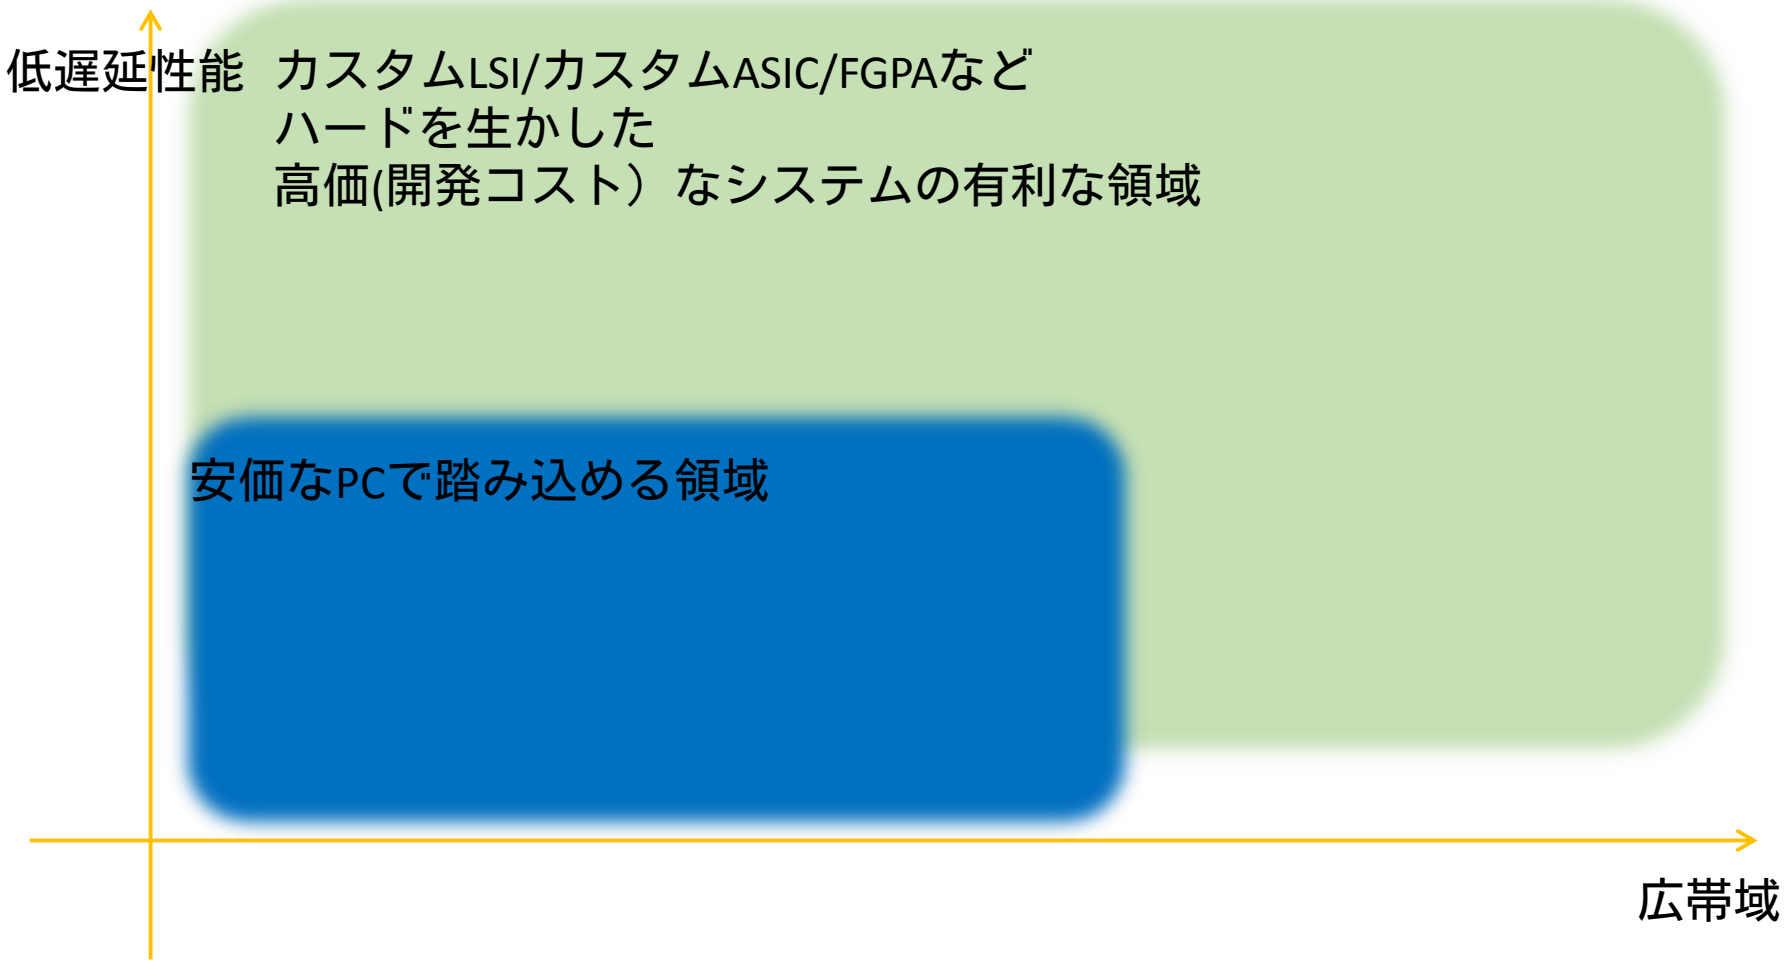
網の高度化ではなく．．
エンドの高度化で．．

- 天文台（一部）は，エンドの高度化でアプローチ
  - ＰＣサーバで十分な性能を叩き出せるという目算
    - ４０ＧｂＥ ＳＳＤフルダンプ箱開発
    - １００ＧｂＥ　Ｌ３ルーターの開発
  - コストパフォーマンスの追及
    - 「挑戦はするけど冒険はしない．」
- 水沢・大手町・三鷹地区に，ミドルボックスを設置し，広域網｛へ，から｝のトラフィックを広域網からもらえるウェザー情報に基づき制御するアプローチをとる．

コストの観点から見る開発・構築ゾーン



コストの観点から見る開発・構築ゾーン



コストの観点から見る開発・構築ゾーン

低遅延性能

カスタムLSI/カスタムASIC/FGPAなど
ハードを生かした
高価(開発コスト）なシステムの有利な領域

- gnodal (>150nsec)
- Cisco (>60/200nsec)
- ARISTA (>500nsec)

安価なPCで踏み込める領域

2011 PCルータ
20Gbps

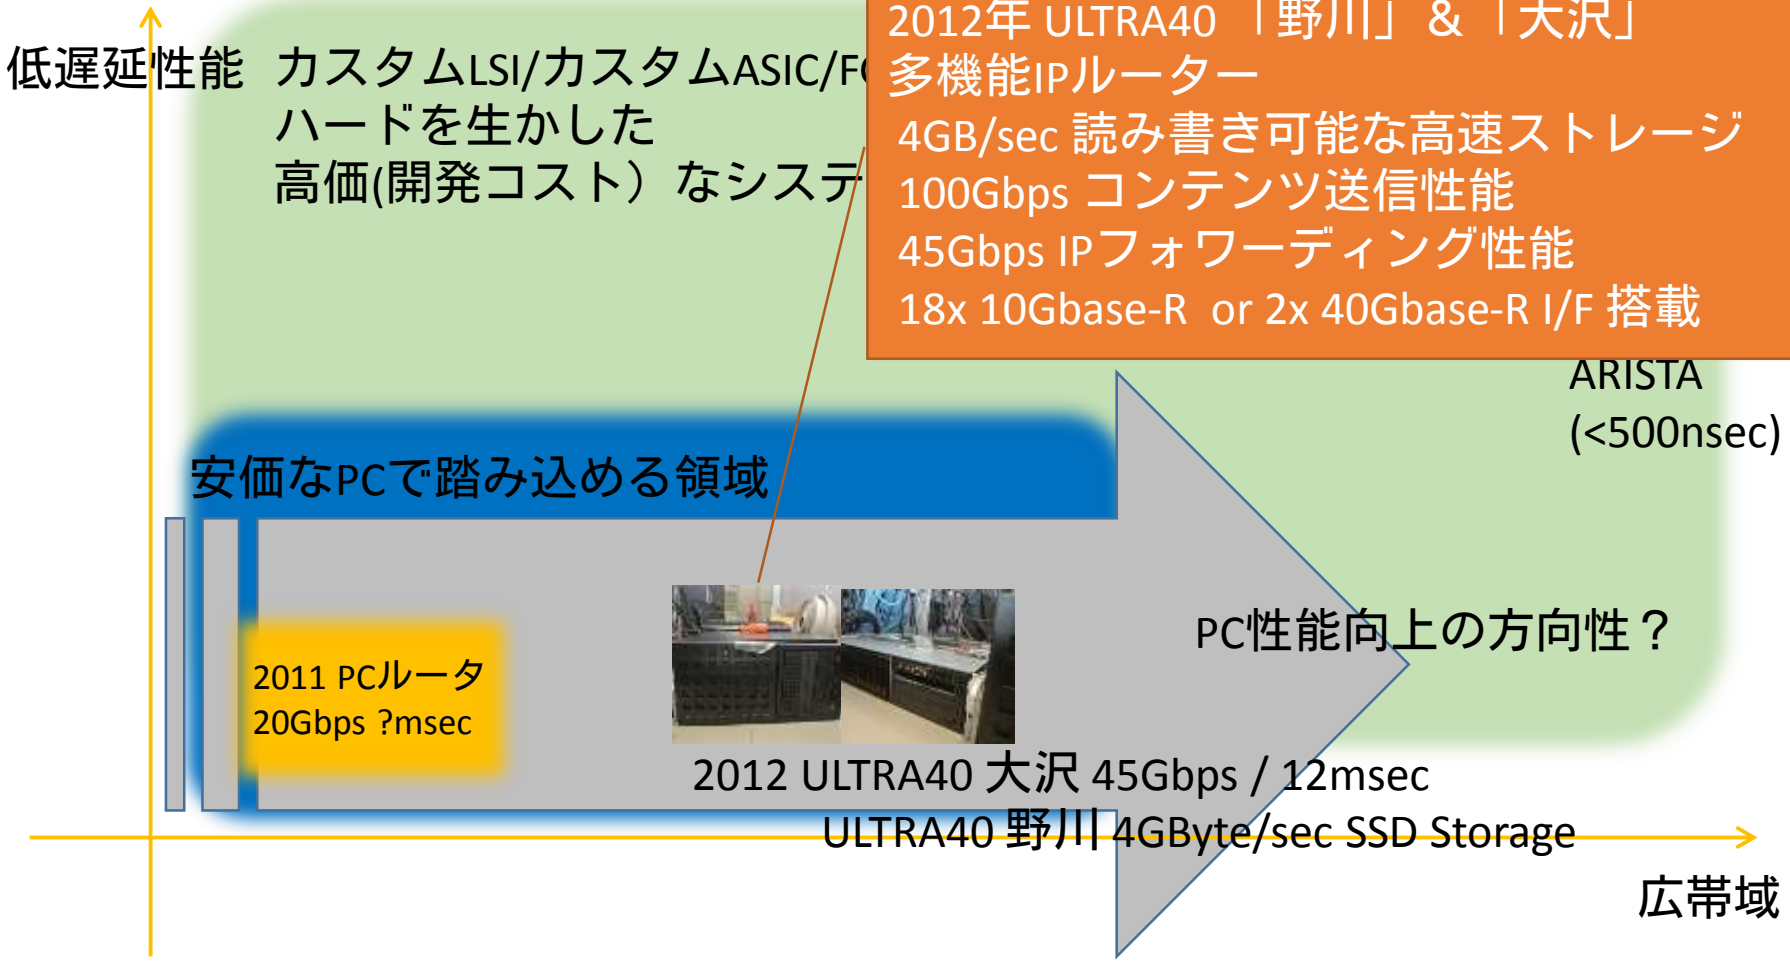


Intel DPDK

2012 第1世代 ULTRA40 大沢
(割り込みモデル)
IPフォワーディング 45Gbps
100Gbpsコンテンツ送信性能

広帯域

コストの観点から見る開発・構築ゾーン



コストの観点から見る開発・構築ゾーン



PCサーバの性能
「連雀」：高機能PCサーバ・ルータ基盤



Intel SandyBridge-E overclock

PCI-E 2.0 2x 10GbE-SFP+ x 10 (最大12port)

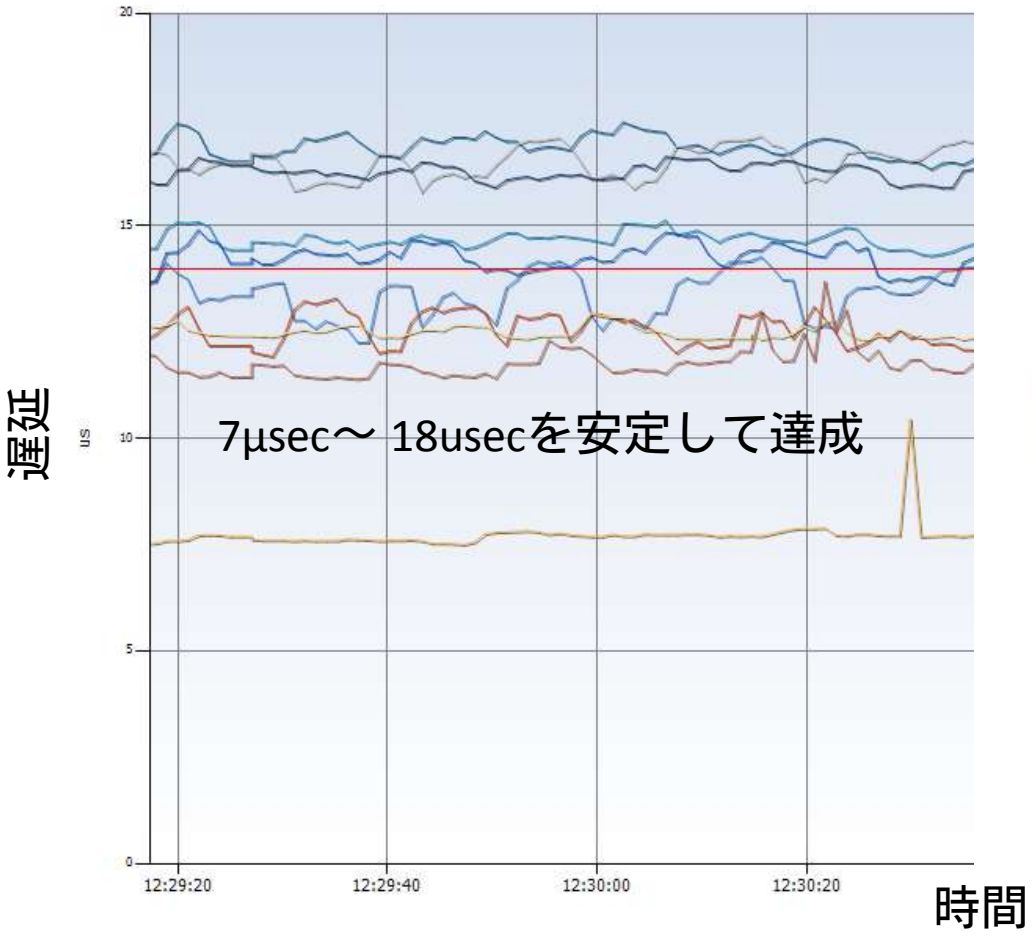
Interop2013 オープンルーターコンペティション(ORC)
富士通賞受賞

国立天文台が天文データ処理用のPCサーバ / ルーター プラットフォームとして開発

Linux OSを基に低遅延・広帯域処理能力を目標に設計・開発

「連雀」の性能：低遅延＆広帯域の両立

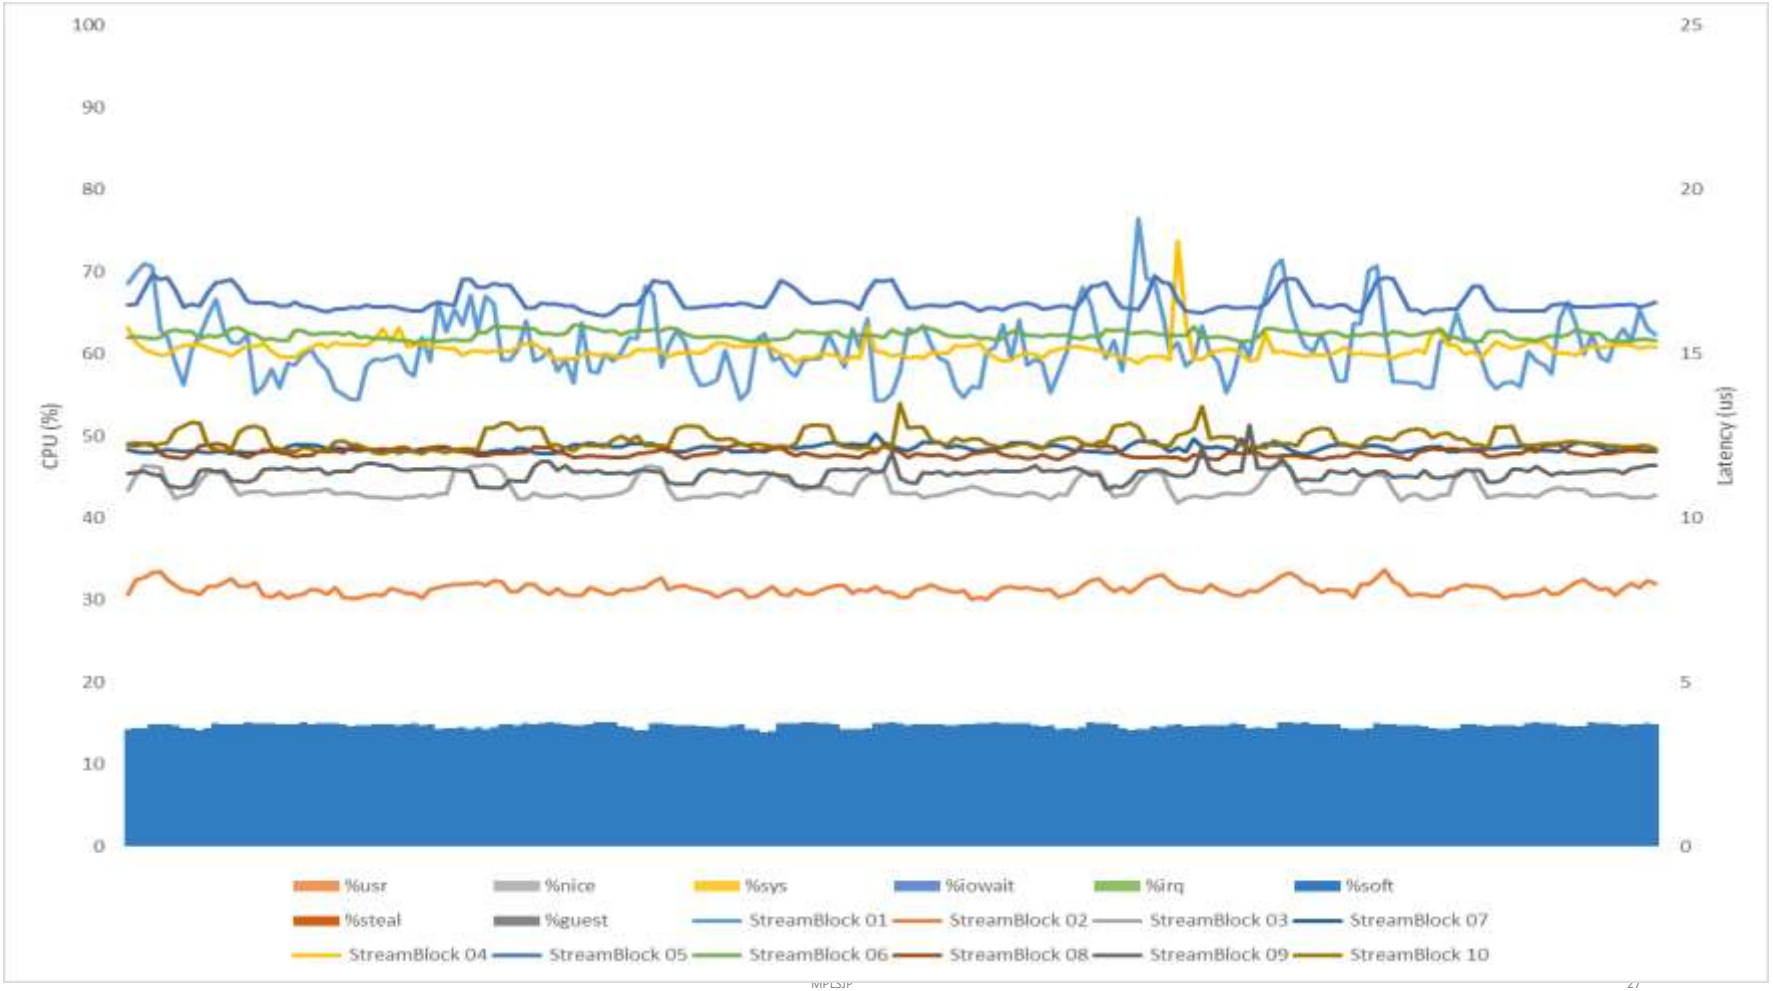
フルメッシュＩＰフォワーディング性能を計測器で長時間検証



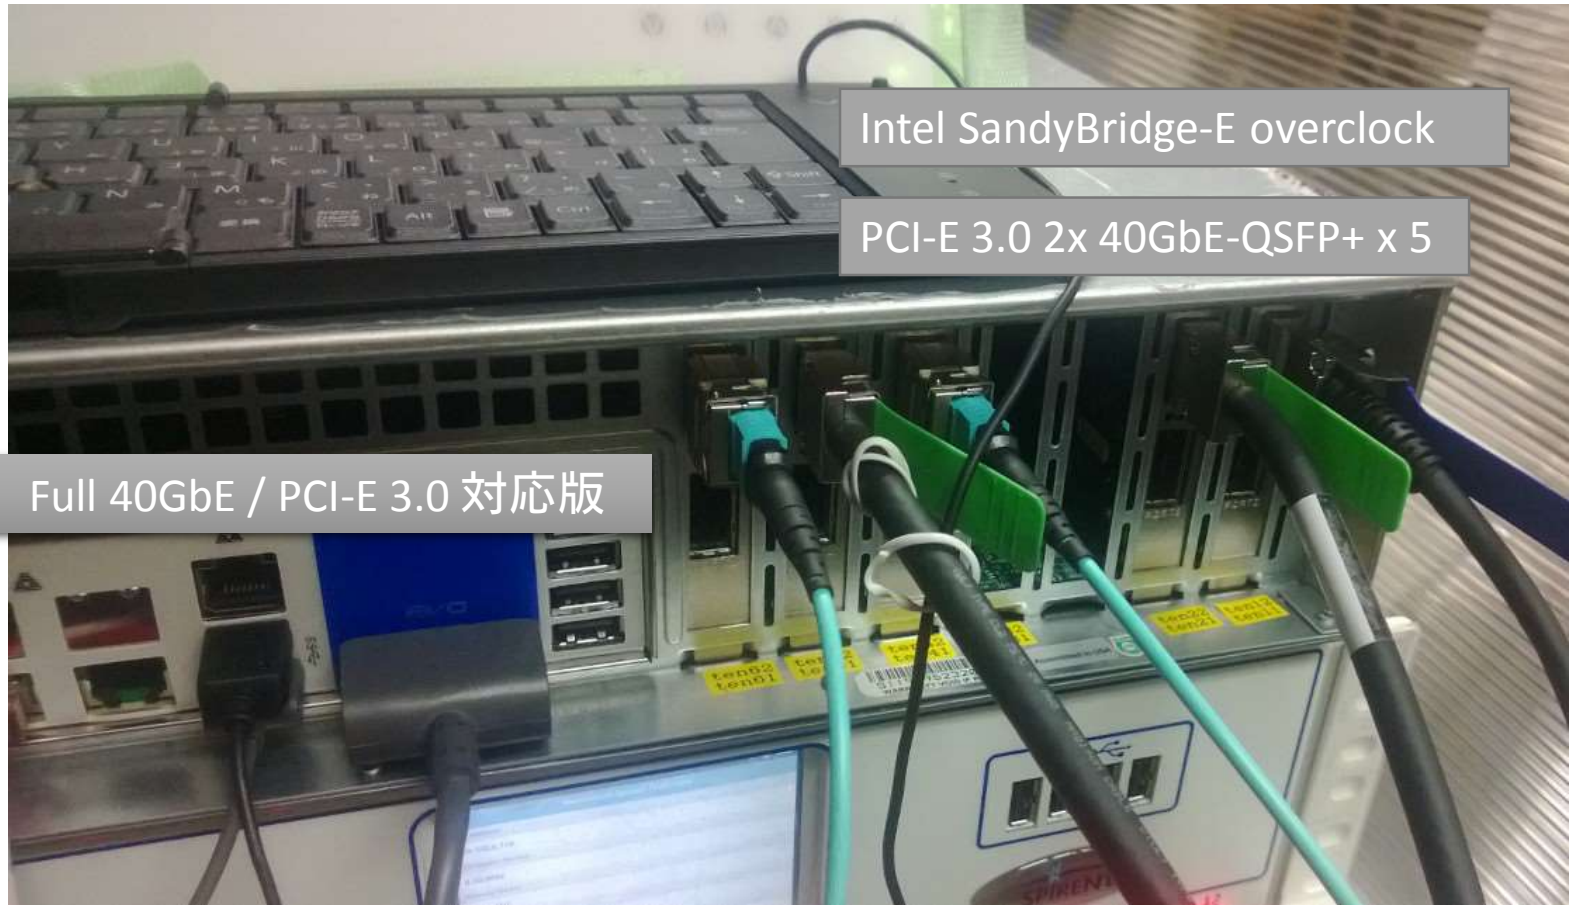


広帯域＆低遅延を両立

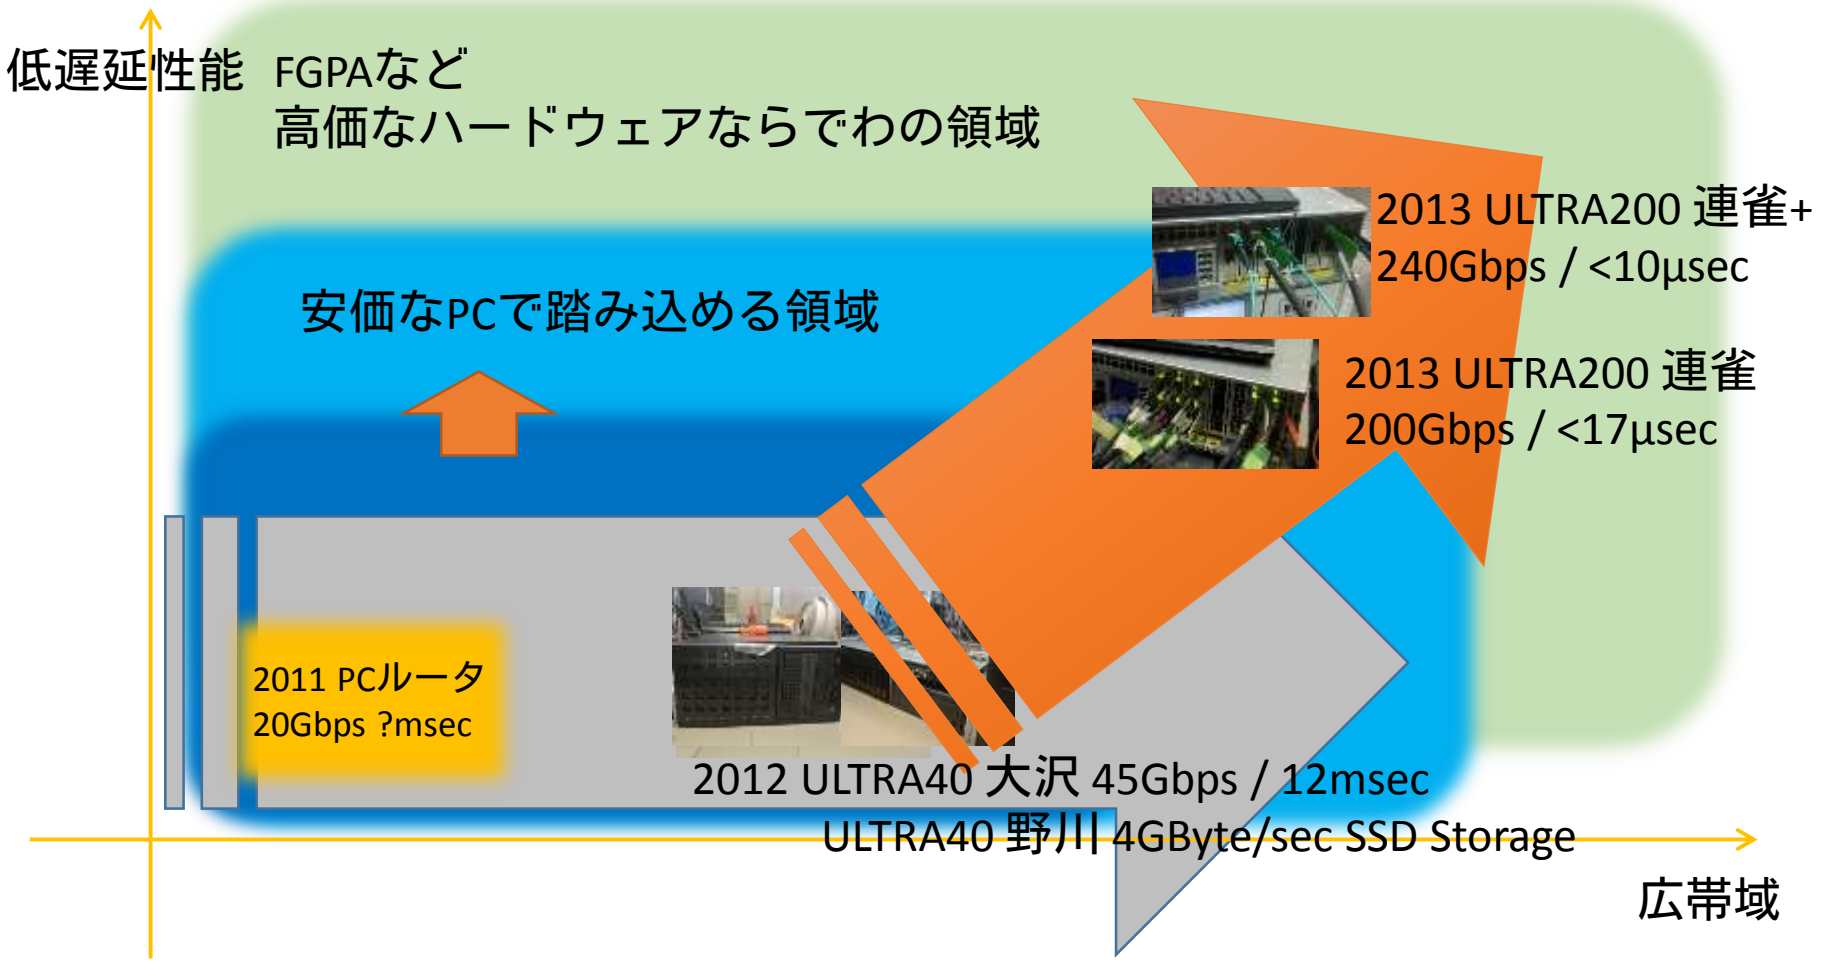
「連雀」NIC オフロードの効果：
200Gbpsのトラフィック処理をおこなっていても
15%のCPUリソース消費に抑えられている



「連雀＋」: L3 120Gbps(=240Gbps)
40GbE対応 / 広帯域・低遅延の追及



PCサーバの性能向上


低遅延性能
FGPAなど
高価なハードウェアならでわの領域
安価なPCで踏み込める領域
2013 ULTRA200 連雀+
240Gbps / <10µsec
2013 ULTRA200 連雀
200Gbps / <17µsec
2011 PCルータ
20Gbps ?msec
2012 ULTRA40 大沢 45Gbps / 12msec
ULTRA40 野川 4GByte/sec SSD Storage
広帯域

PCサーバの性能向上は今後も続く，手段を問わず研究開発を継続

2011年 ?? Intel Core + PCI-E2.0 1x10GbE NIC

- なんとか10Gbpsを絞り出せるレベル

2012年「大沢」「野川」（第1世代）Intel Nehalem + PCI-E2.0 2x10GbE NIC + Offload

- コンテンツ送信力は，100Gbps

2013年「連雀」（第2世代）Intel SandyBridge-E + PCI-E2.0 2x10GbE NIC + Offload
「連雀＋」

- その処理力は，200Gbpsへ向上

2014年（第3世代）Intel Haswell + PCI-E3.0 NIC Full 40GbE NIC + Offload

- その処理力は，400Gbpsへ？

- 機器は<50万円程度
- 10Gbpsどころか，誰もが100Gbps～200Gbpsを扱える時代

割り込みモデル
or
ポーリングモデル

おしらせ

＊国立天文台三鷹キャンパスでは，毎月2回公開天体望遠鏡を使った観望会を開催中！

詳しくは国立天文台ホームページをご覧ください.

ありがとうございました



TMT 完成予想図 (c) 2010 Thirty Meter Telescope

口径30m次世代超大型望遠鏡(TMT) 始動
http://tmt.mtk.nao.ac.jp/
1000円から参加できる
TMT 第二期寄付金募集中!