MPLS JAPAN

データプレーンのオープン化

Shishio Tsuchiya
shtsuchi@arista.com

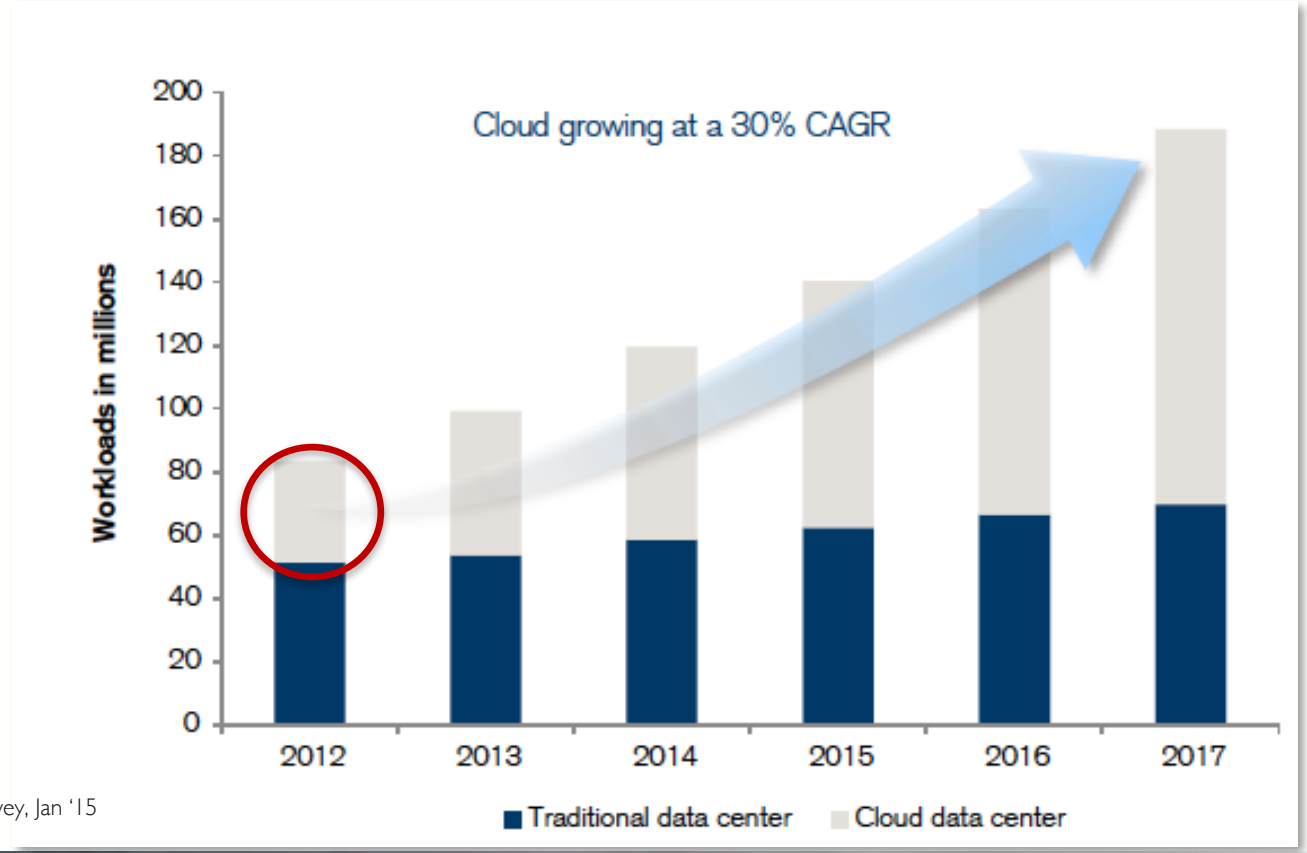
Copyright © Arista 2017. All rights reserved.
ARISTA

Agenda

- これまでのデータプレーン
- NVO3 Encapsulation Consideration
- これからのデータプレーン

Copyright © Arista 2017. All rights reserved.

Traditional data center vs Cloud data center

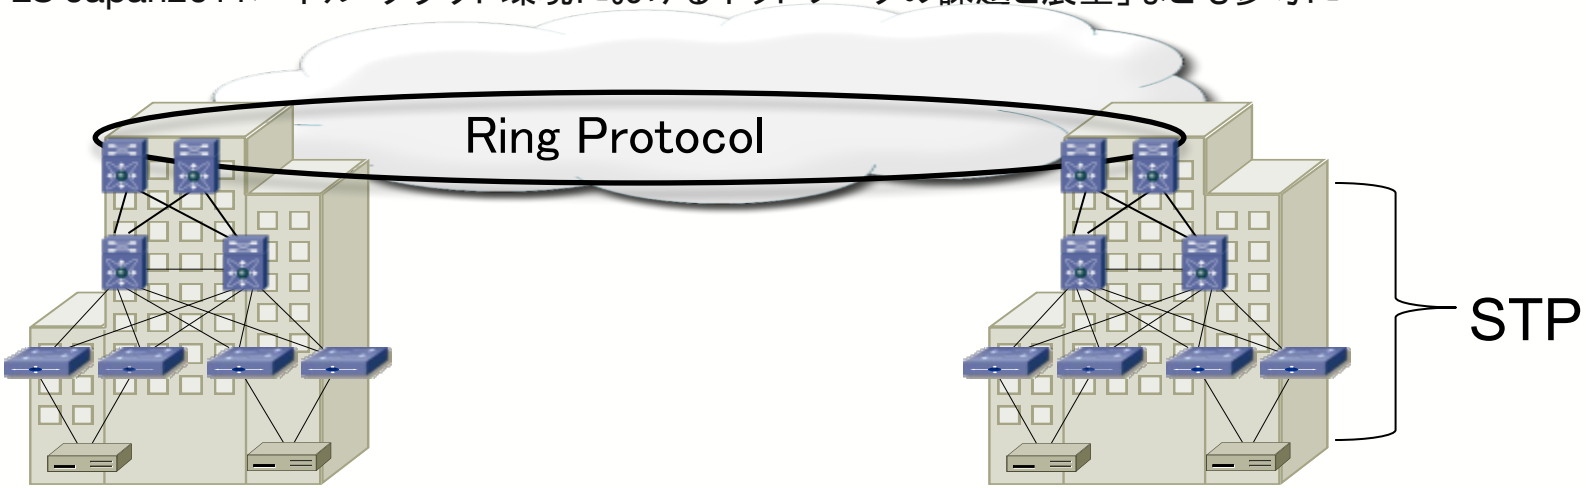


Source: Credit Suisse IT Survey, Jan '15

Copyright © Arista 2017. All rights reserved.
ARISTA

2011年ごろのデータセンターネットワーク

-MPLS Japan2011パネル「クラウド環境におけるネットワークの課題と展望」なども参考に-



- フラットなレイヤー2のネットワークデザイン
- データセンター内ではスパニングツリーが使用
- ベンダー独自のリングプロトコル (またはG.8032)がデータセンター間で使用される
- VMライブマイグレーションは必要 (GARPによって移動を通知)
- VLANがユーザ毎にアサインされる

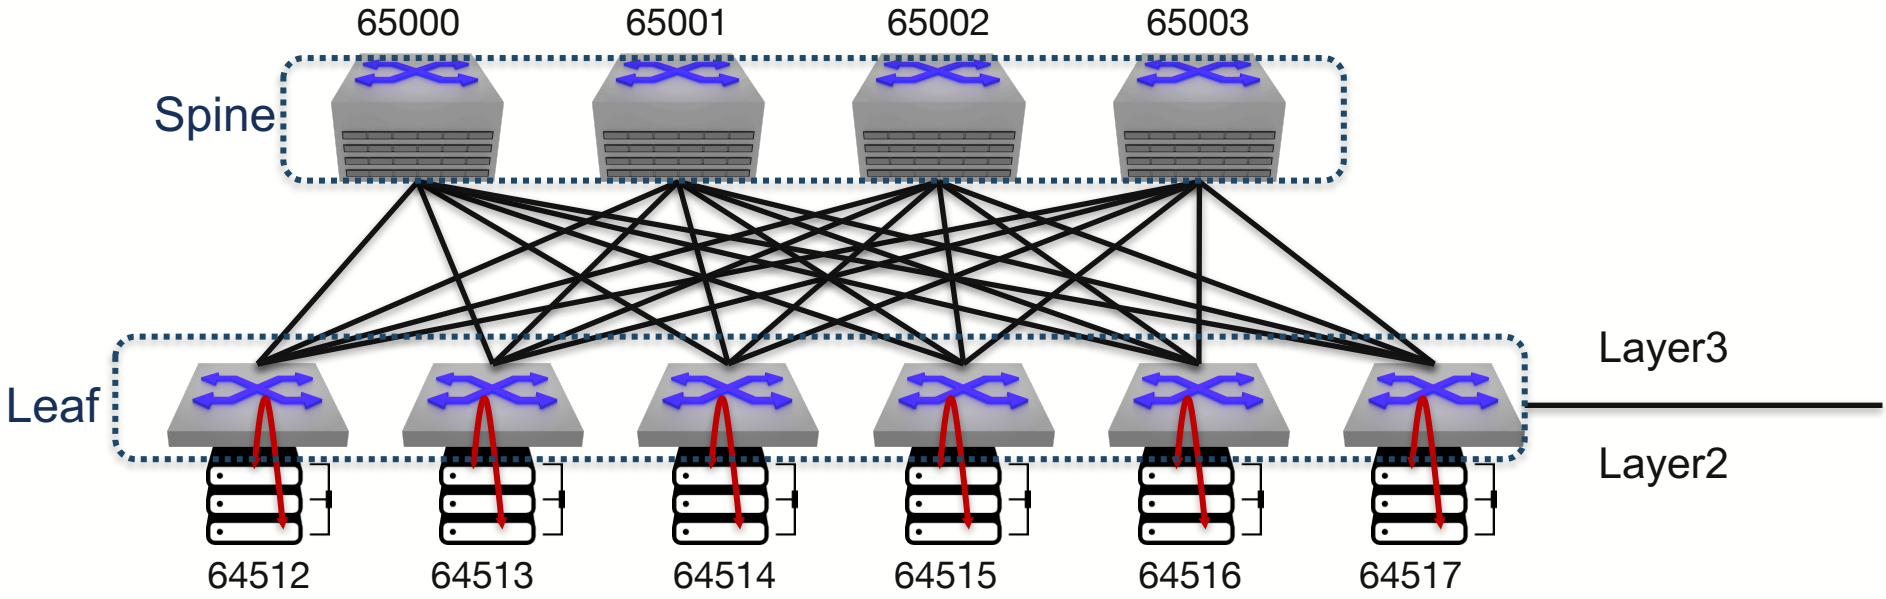
Copyright © Arista 2017. All rights reserved.

問題点

- データセンター間/データセンター内
  - VLANスケーラビリティ ＞ 4K
  - MACアドレステーブルのスケーラビリティ
  - VMライブマイグレーションや簡単に使うためのブロードキャストドメインの拡張
  - East / Westトラフィック帯域の増加
  - 高速収束
  - 自動化/オーケストレーション
- データセンター間
  - 要求に応じた帯域増強
  - ベンダーロックイン技術からの解放
  - 柔軟性のあるトポロジーデザイン
  - トラフィックエンジニアリング
  - BUM(Broadcast/Unknown unicast/Multicast) トラフィックの最適化
- ゲートウェイ
  - ARP/NDPスケーラビリティ
  - IETF ARMD(Address Resolution for Massive numbers of hosts in the Data center) Groupは一つの informational RFCを発行 **RFC6820 Address Resolution Problems in Large Data Center Networks**

Copyright © Arista 2017. All rights reserved.

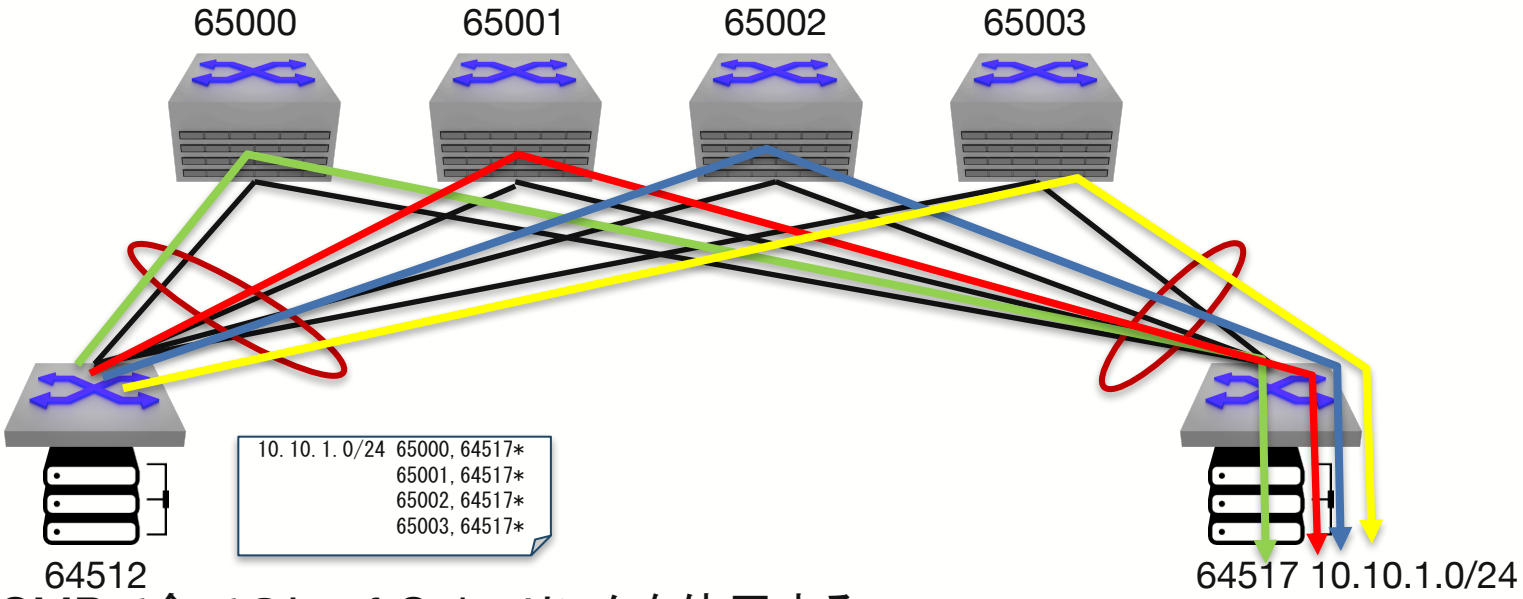
大規模データセンタールーティングでのBGPの使用



- スケールアウトするClosデザイン
- 安定した標準的なBGPプロトコルをToR/Leafスイッチに使用
- 安定性にフォーカスし、VMモビリティはラック内に留める

Copyright © Arista 2017. All rights reserved.
ARISTA

IP Closデザインの利点



- ECMPで全てのLeaf-Spineリンクを使用する
- それぞれのフローはECMPハッシュにてバランスされる(既に実装されている)
- ルーティングパスはBGPパス属性により可視化される

Copyright © Arista 2017. All rights reserved.

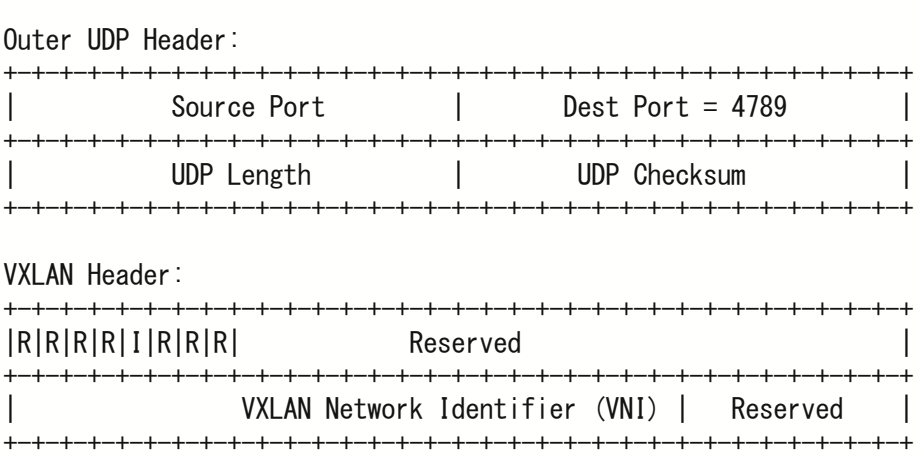
問題に関するソリューション

技術	VXLAN	NVGRE	STT	OTV
Intend to on 1st draft	Experimental 2011年8月	Informational 2011年9月	Informational 2012年2月	Standard 2010年4月
結果	RFC7348 (Information)	RFC7637 (Information)	expire	expire
特許	NA	Microsoft	Nicira	Cisco
実装	Linux 3.7 OVS Hyper-V DPDK Broadcom Trident2	Hyper-V DPDK Broadcom Trident2	OVS Hyper-V	Cisco NX
トランスポート	UDP	GRE	TCP Like	UDP
ロードバランス	○	△ 中間ノードの実装による Key Fieldまで計算	○	○

Copyright © Arista 2017. All rights reserved.

Virtual eXtensible LAN (VXLAN)フレームフォーマット

- フラグ(8 bits):
  - 有効なVXLANのネットワークIDの場合、Iフラグは1をセットしなければならない。他の7ビット(R)は予約フィールドで送信時に0をセットしなければならず、受信時に無視される
- VXLANセグメントID/VXLANネットワーク識別子 (VNI):
  - これは、通信するVMが配置されている個々のVXLANオーバーレイネットワークを指定するために使用される24ビットの値です。異なるVXLANオーバーレイネットワーク内のVMは互いに通信できません。
- 宛先ポート:
  - IANAはVXLANのポートとして4789をアサインした。このポートをデフォルトの宛先ポートとして使う
- 送信元ポート:
  - UDPソースポート番号は、ロードバランスの際のハッシュの計算に使用される。動的にプライベートポート範囲49152-65535である事が推奨される



Copyright © Arista 2017. All rights reserved.

まとめ

- 事実として
  - VXLANはRFC7348でInformationalで発行
  - Linux/OVS/Hyper-V/DPDK/ASICと多くの実装が存在
  - ECMPロードバランスやイーサチャネルでの実装も考慮
    - ≫(IP/UDP:送信元ポートのランダム化)
  - IPR(知的財産権: Intellectual Property Right)は特に無かった
  - VXLANは実質的な業界標準のプロトコルとは言えるが、IETF標準では無い

Copyright © Arista 2017. All rights reserved.

Agenda

- これまでのデータプレーン
- NVO3 Encapsulation Consideration
- これからのデータプレーン

Copyright © Arista 2017. All rights reserved.

IETF NVO3(Network Virtualization Overlays) WG

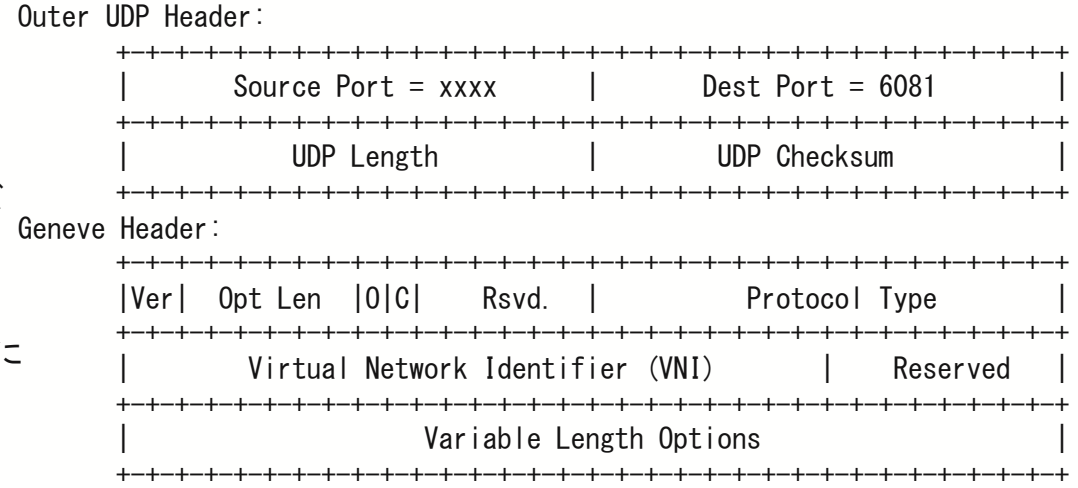
- NVO3 WGはデータセンター内の仮想化を可能にするIPベースのアンダーレイを基本としたプロトコル拡張を前提
- NVO3は仮想ネットワークにマルチテナントとワークロードの可動性にレイヤー2およびレイヤー3のサービスを提供

Copyright © Arista 2017. All rights reserved.

Geneve: Generic Network Virtualization Encapsulation

https://tools.ietf.org/html/draft-ietf-nvo3-geneve

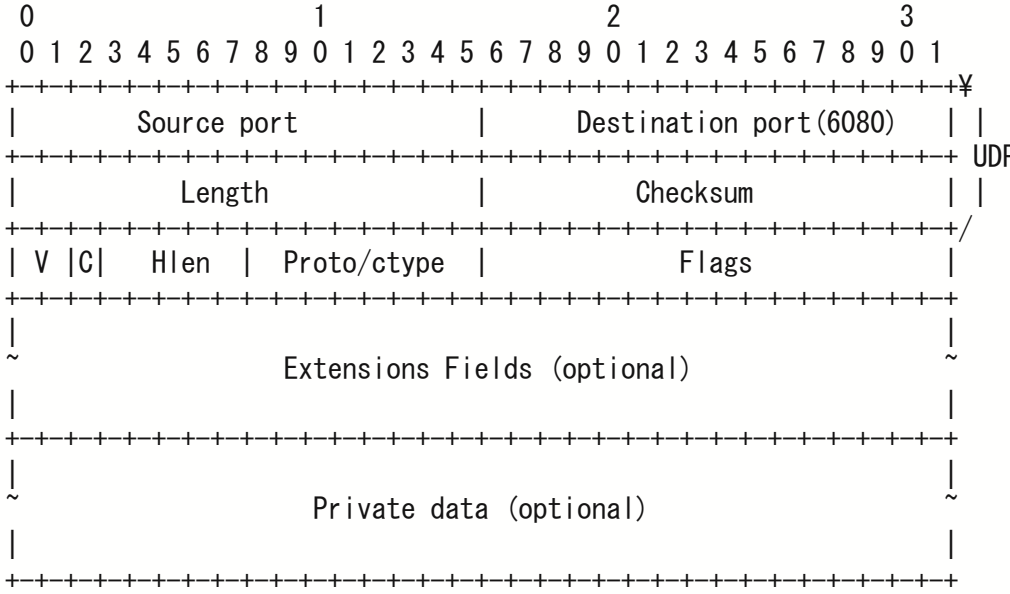
- Ver:
  - 0,知らないバージョンの際は破棄
- Opt Len:
  - オプションフィールドの長さ,Geneveの最小サイズは8バイト/最大サイズは260バイト
- Oビット:
  - OAMビット、パケットはデータペイロードの代わりにコントロールパケットを含む
- Cビット:
  - Critical Option,このビットが設定されている時にはエンドポイントは解析をしなければならない
- Protocol Type:
  - 続くプロトコルのイーサタイプを定義



Copyright © Arista 2017. All rights reserved.
ARISTA

Generic UDP Encapsulation
https://tools.ietf.org/html/draft-ietf-nvo3-gue

- Vビット:
  - 0:Version番号
- Cビット:
  - コントロールメッセージの際にセット、無い場合はデータメッセージ
- Hlen:
  - GUEヘッダーの長さ、オプション拡張ヘッダーを含むが最初の4バイトヘッダーは含まない。(header_len - 4) / 4で計算され、全てのGUEヘッダーは4の倍数となる。最大ヘッダー長は128バイト
- Proto/ctype:
  - Cビットが含まれてる場合には制御メッセージのタイプが表示される。Cビットが含まれていない場合はencapsulateされたプロトコル番号が入る



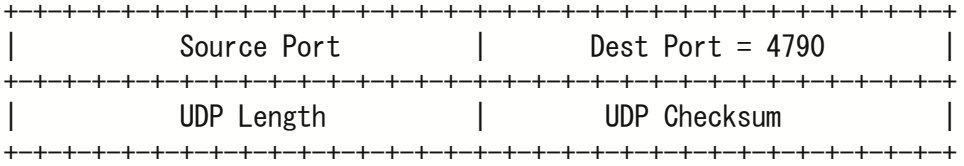
Copyright © Arista 2017. All rights reserved.
ARISTA

Generic Protocol Extension for VXLAN

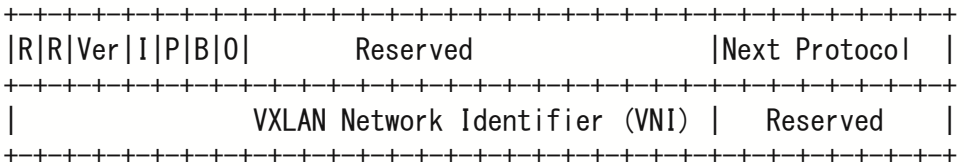
https://tools.ietf.org/html/draft-ietf-nvo3-vxlan-gpe

- Ver:
  - 0:VXLAN GPEバージョン
- Instance ビット(Iビット):
  - VNIが正常の時にセットする
- Next Protocol Bit(Pビット):
  - Next Protocolフィールドが存在する時セット
- BUM Traffic Bit (Bビット)
  - BUM(Broadcast/Unknown Unicast/Multicast)の際にセット
- OAM Flag Bit (Oビット) :
  - OAMパケットの時にセット
- Next Protocol:
  - 続くプロトコルヘッダを提示

Outer UDP Header:



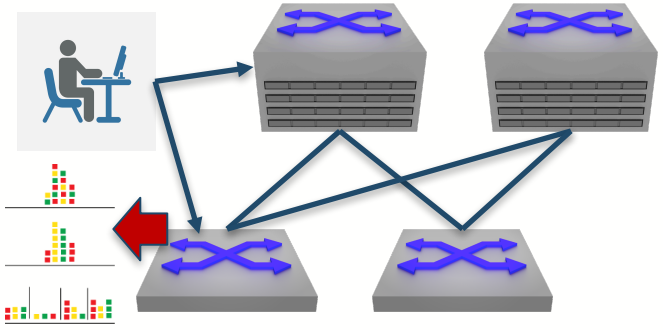
VXLAN GPE Header:



0x1 : IPv4
0x2 : IPv6
0x3 : Ethernet
0x4 : Network Service Header
0x5 : Multiprotocol Label Switching

Copyright © Arista 2017. All rights reserved.
ARISTA

NVO3スタンダードEncapsulationで話されてる事







- 管理性
  - ICMP/ECMPなど既存の仕組みを実装可能か？
- 拡張性
  - 将来的な拡張:Telemetry/Security/GBP(セキュリティ/QoS)に適用可能か?

Copyright © Arista 2017. All rights reserved.

NVO3 Encapsulation Considerations

https://tools.ietf.org/html/draft-ietf-nvo3-encap

技術	Geneve	GUE	VXLAN-GPE
トランスポート	IP/UDP	IP/UDP	IP/UDP
基本ヘッダー長	8バイト	4バイト	8バイト (NSHとの組み合わせで16バイト
拡張性	可変長オプション	拡張フィールド	単独では拡張性がない NSHと組み合わせる必要がある
最大ヘッダー長	260バイト	128バイト	8バイト (264 バイト NSH)
Next Protocol 識別子	Ether type	Protocol ID	New Registry

- NVO3はデザインチームを構成し、提案中のencapsulationを比較検討した
- 現状のプロトコルにはハードウェアの実装やVXLANとの下位互換に問題
- デザインチームではGeneveがもっともNVO3の最初の標準化プロコトルにふさわしいと推薦した

Copyright © Arista 2017. All rights reserved.

まとめ

- IETF NVO3 WGではスタンダードなencapsulation方式を検討
- Geneve/GUE/VXLAN-GPEの3つの候補があり、何れもハードウェア対応やVXLANとの下位互換には問題があるが、Geneveを最初の標準プロトコルを目標にすると合意した

Copyright © Arista 2017. All rights reserved.

Agenda

- これまでのデータプレーン
- NVO3 Encapsulation Consideration
- これからのデータプレーン

Copyright © Arista 2017. All rights reserved.

NVO3プロトコル、ハードウェアで大変なところ

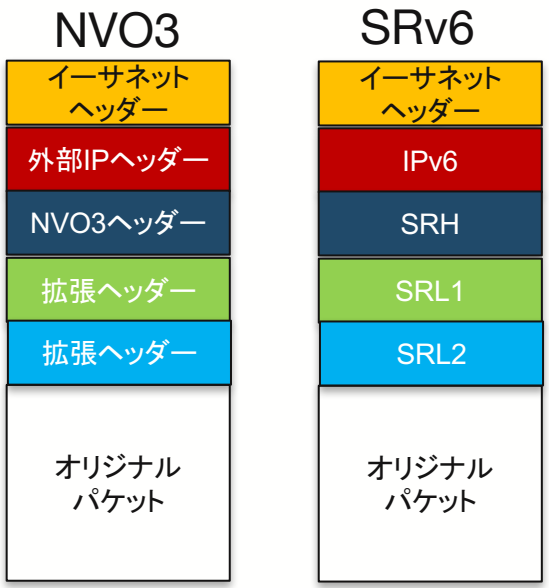


技術	Geneve	GUE	VXLAN-GPE
筆者	Intel vmware	Facebook Huawei Microsoft	Cisco Intel
IPR	vmware (Royalty-Free)	cisco	N/A
最大ヘッダー長	260バイト	128バイト	8バイト (264 バイト NSH)
Next Protocol 識別子	Ether type	Protocol ID	New Registry

- 固定長のヘッダーと違い、可変長
- ものによっては並列に処理をしなければいけない
- どれがメインになるのかが分からない

Copyright © Arista 2017. All rights reserved.

ソフトウェアインプリメンテーション

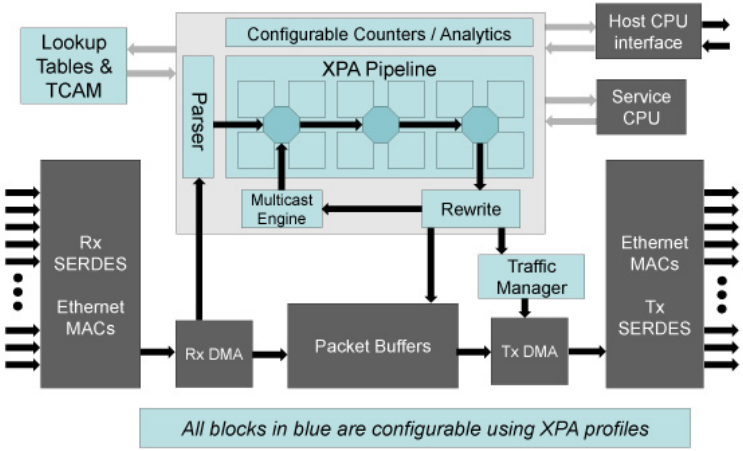


技術	Geneve	GUE	VXLAN-GPE
筆者	Intel vmware	Facebook Huawei Microsoft	Cisco Intel
実装状況	3.18 OVS DPDK Hyper-V	3.18	4.6 OVS DPDK

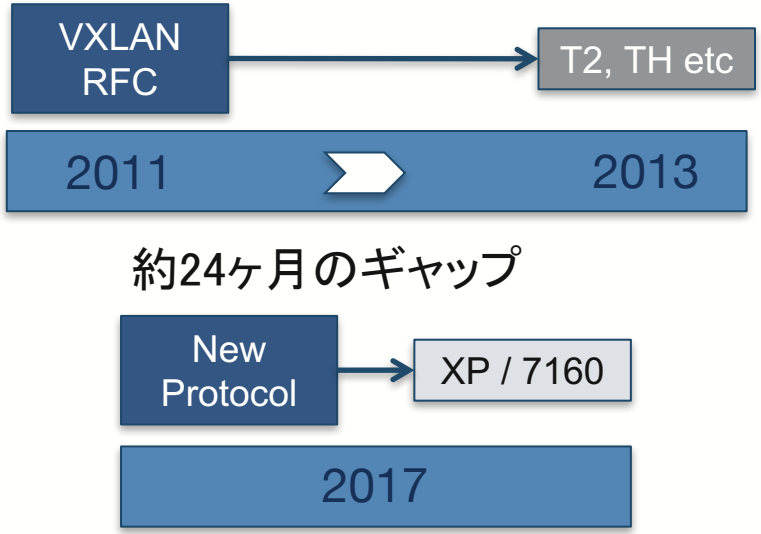
- この3つだけで十分か？
- SRv6とかもやりたいの？

Copyright © Arista 2017. All rights reserved.

Cavium XPliant Packet Architecture



http://www.cavium.com/XPliant-Ethernet-Switch-Product-Family.html



ソフトウェアアップグレードによる
迅速なサポート

- 各ヘッダー毎に並列処理を実施
- フィールドアップグレード可能なチップセット
- XPAをプログラム可能にするAPIのオープン化 OpenXPS

Copyright © Arista 2017. All rights reserved.

Broadcom BCM56870 SERIES

High-Capacity StrataXGS® Trident 3 Ethernet Switch Series





Instrumentation	New Overlay/Formats	Forwarding Schema
• In-Band Telemetry	• Service Function Chaining	• Segment Routing
• In-situ OAM	• VXLAN-GPE, Geneve	• Source Routing
• Streaming Flow Tracker	• MPLS over GRE/UDP	• Routing into/out of Tunnels
• Microburst Detection	• Security Tagging (SGT)	• Policy Based Routing
• Latency & Drop Monitor	• ILA Routing	• Inner Header Processing
• Flexible Mirror/ERSPAN	• QUIC	• Flex Multipathing

- Triden3は既存のTrident2/Triden2+の機能と互換性を持ちつつ、フィールドアップグレード可能なシリコン
- GENEVE, NSH, VXLAN, GPE, MPLS, MPLS over GRE/UDP, GUE, ILA ,PPPoEなど新しいプロトコルもサポート
- XGSファミリーはOpenNSL(Open Network Switch Library)も提供

https://www.broadcom.com/blog/new-trident-3-switch-delivers-smarter-programmability-for-enterp

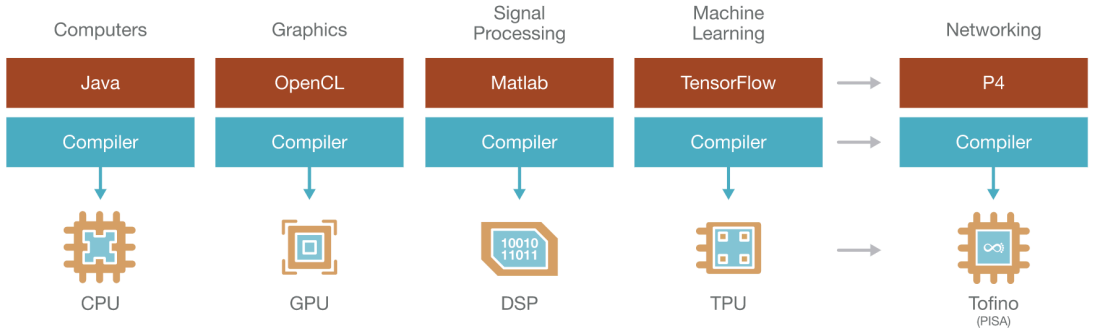
Copyright © Arista 2017. All rights reserved.

P4+Barefoot Capilano/Tofino

https://p4.org/

```
table routing {
    reads {
        ipv4.dstAddr : lpm;
    }
    actions {
        do_drop;
        route_ipv4;
    }
    size: 2048;
}

control ingress {
    apply(routing);
}
```

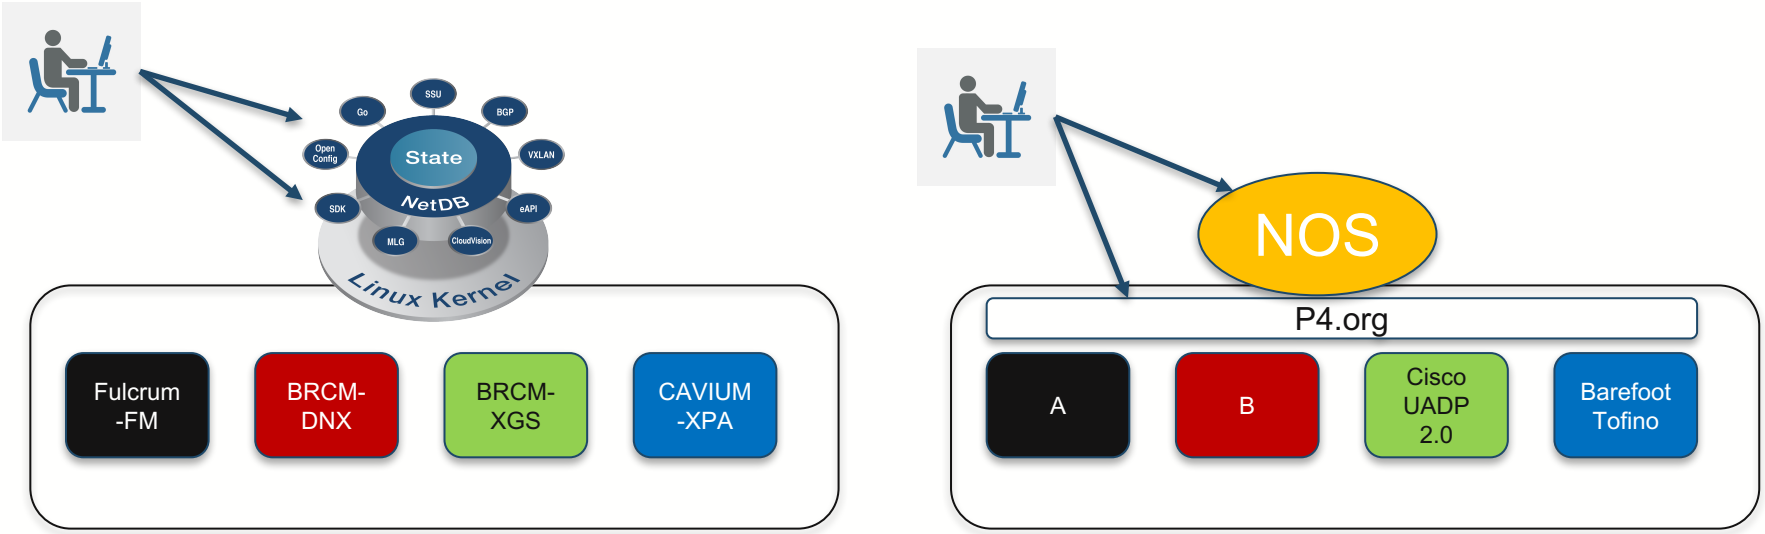


https://barefootnetworks.com/technology/

- P4:Programming Protocol-Independent Packet Processors
- ターゲット非依存:CPU/FPGA/SOC/NPU/ASIC
- プロトコル非依存:ヘッダー情報などを直接記載する
- 再構成可能:ターゲットが変わってもそのまま使用出来る様にする
- TofinoはスイッチングASICS / Capilano SDE(Software Development Environment)と使用する事でP4記載のコードを利用可能

Copyright © Arista 2017. All rights reserved.

Arista EOS Vision and P4 Vision



- Arista EOSは既に4種類のシリコンファミリーで単一バイナリーでサポート
- またSDKやOpen APIを提供する事で多くのプログラム性を提供
- P4はターゲット非依存なネットワークプログラム言語を提供する事でサポートSDK内での柔軟性を提供

Copyright © Arista 2017. All rights reserved.

まとめ

- ヘッダーチェーニングなどの今後の拡張性を踏まえて、各シリコンベンダーはプログラマブルパイプラインおよびフィールドアップグレード可能なチップをリリース
- P4では更にプロトコル非依存/ターゲット非依存のプログラム言語を定義する事で多くのユースケースで使用が可能か!?

Copyright © Arista 2017. All rights reserved.



Copyright © Arista 2016. All rights reserved.

ARISTA