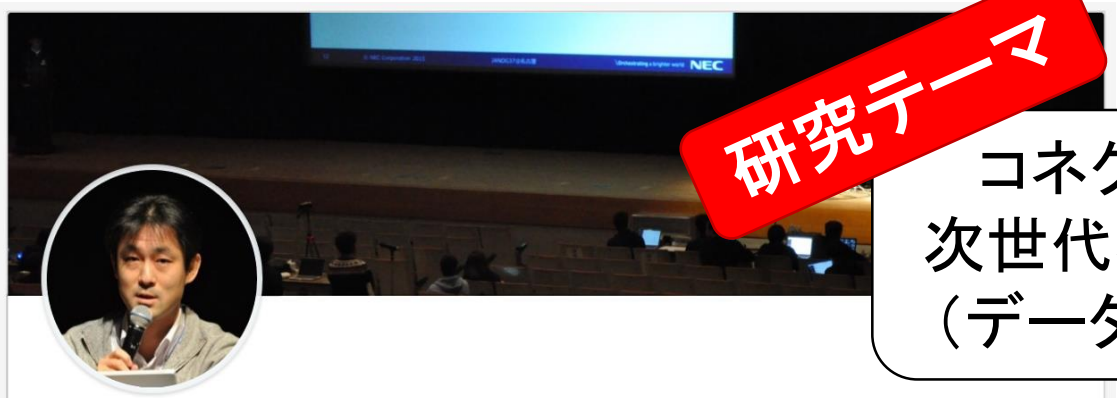
Data Plane Programmability
現状と展望

MPLS Japan 2018年11月19日
「Network Programmability」セッション

株式会社トヨタIT開発センター
海老澤 健太郎

https://www.linkedin.com/in/ebiken/



研究テーマ

Kentaro Ebisawa

Connected Cars | In Network Computing | Dataplane programing | Open Source NOS

日本 東京都 23 区内

Toyota InfoTechnology Center Co., Ltd.

東京工業大学

連絡先情報を表示

職歴

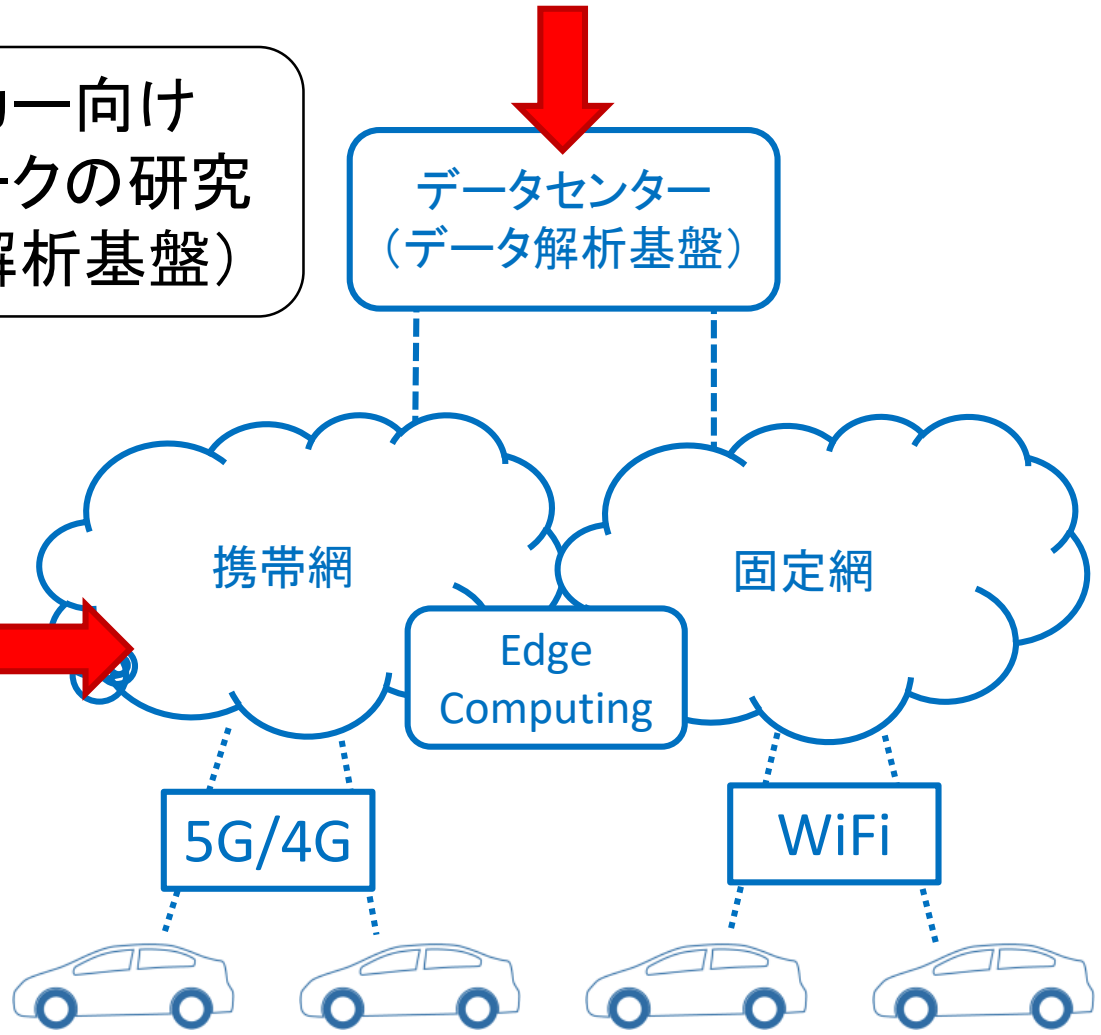
Principal Researcher
Toyota InfoTechnology Center Co., Ltd.
2016年11月 – 現在 · (2年)
Tokyo, Japan
Visiting researcher specialized in NETWORKING technology.

Independent Internet Professional
Terrasence
2010年4月 – 現在 · (8年7ヶ月)
Privately owned entity for consultancy work.
Technical consultancy / development and research in IP networking, Cloud and Data Center area.

コネクティッドカー向け
次世代ネットワークの研究
（データ収集＆解析基盤）

プロトタイピング

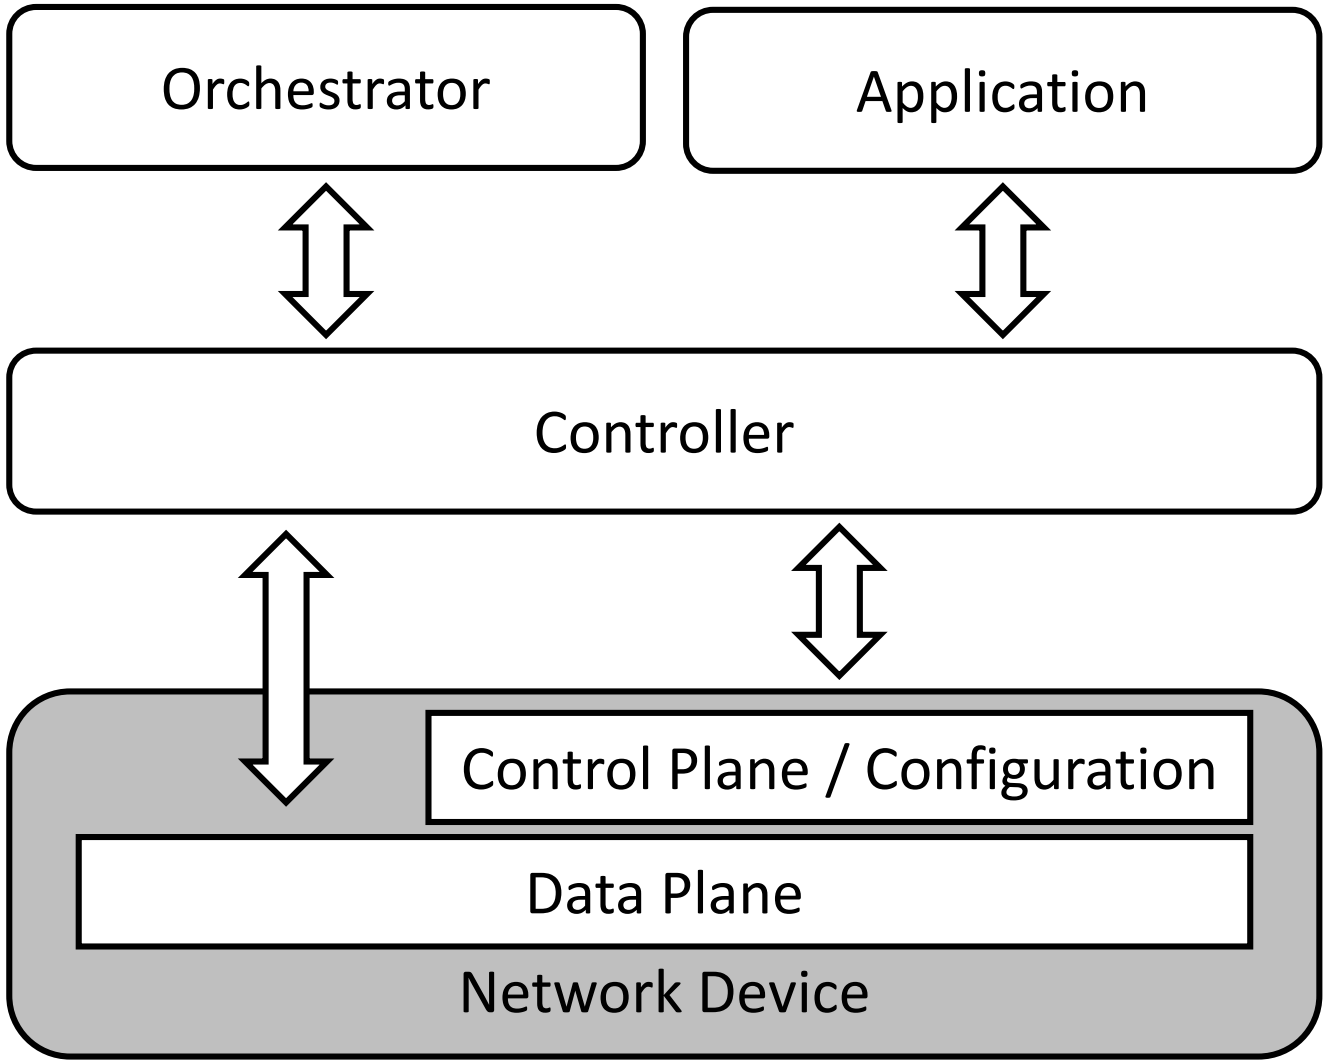
In Network Computing

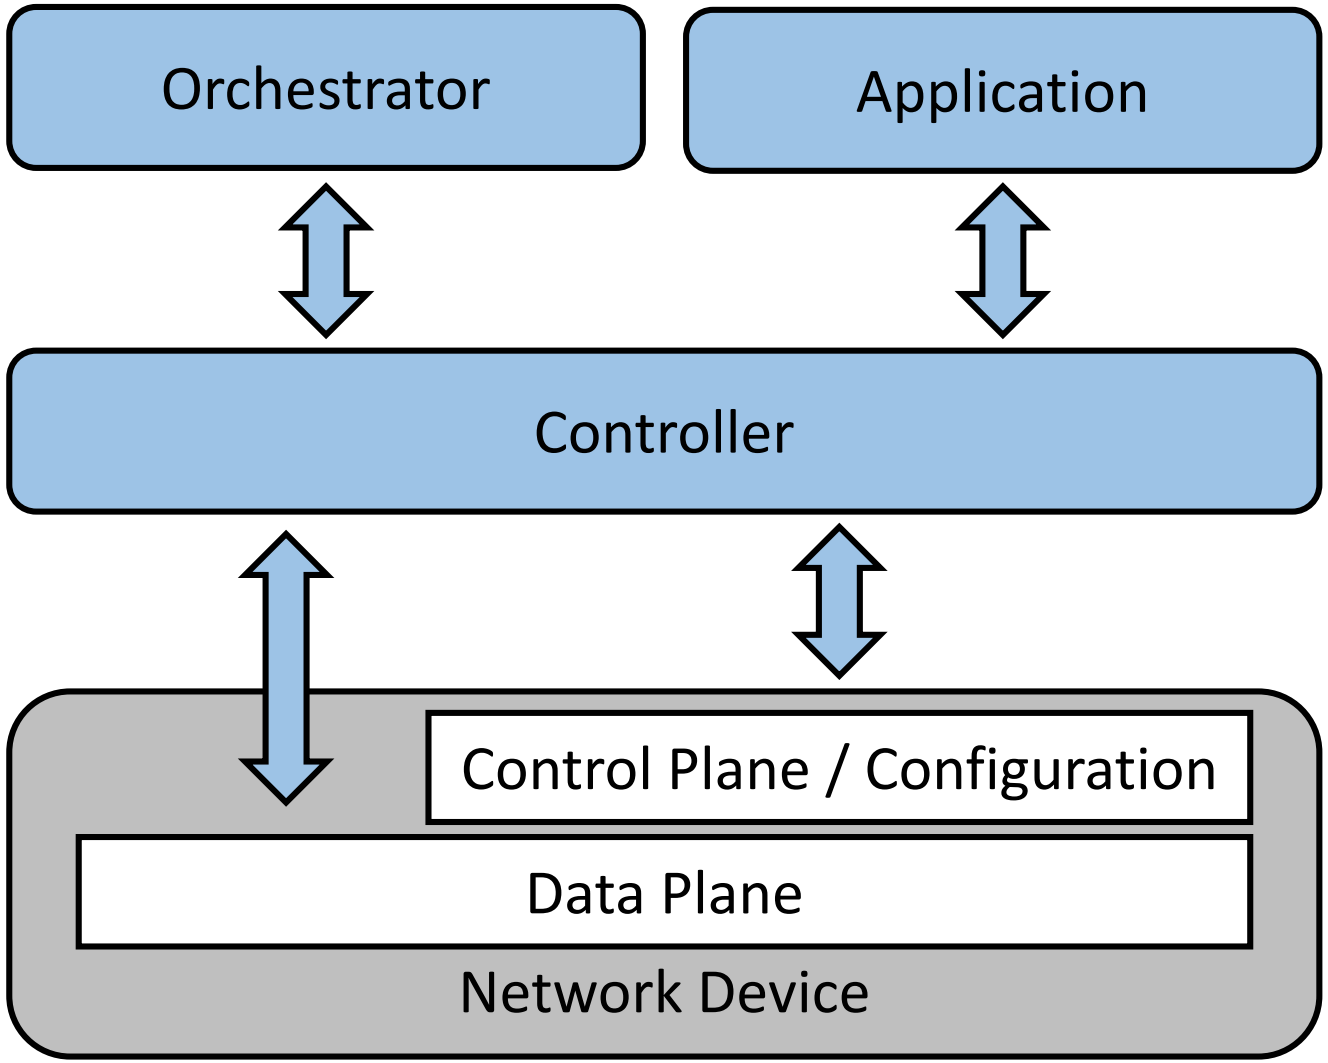


TOYOTA INFOTECH

ネットワーク プログラマビリティ ？？

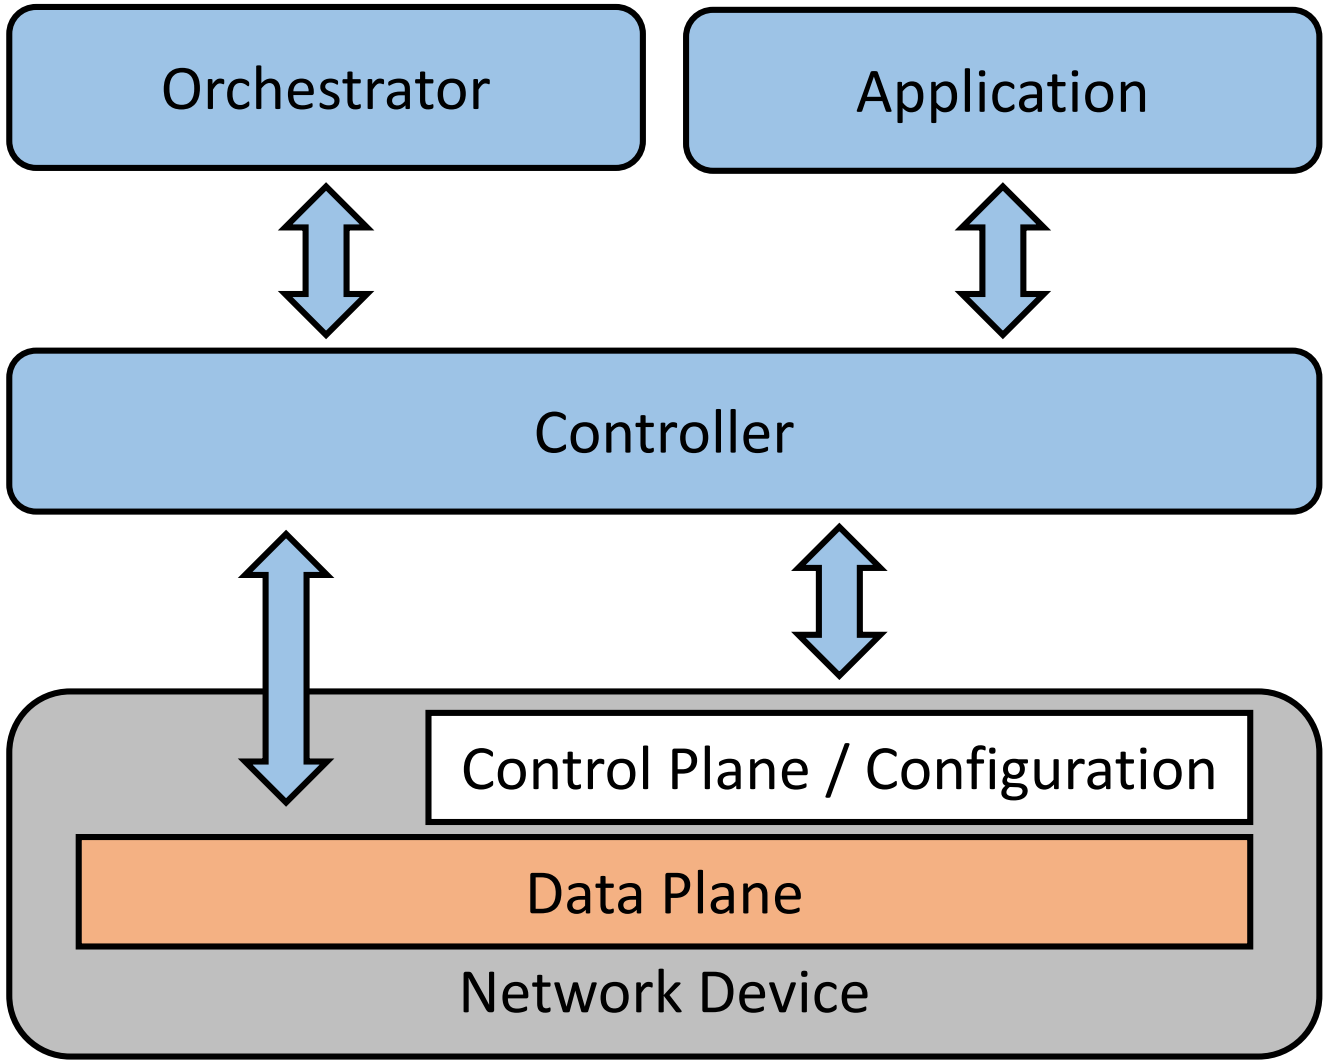
データプレーン プログラマビリティ ？？


Orchestrator
Application
Controller
Control Plane / Configuration
Data Plane
Network Device



ネットワーク
プログラマビリティ

自動化（非CLIな設定管理）
Software Defined (SDN)



ネットワーク
プログラマビリティ

自動化（非CLIな設定管理）
Software Defined (SDN)

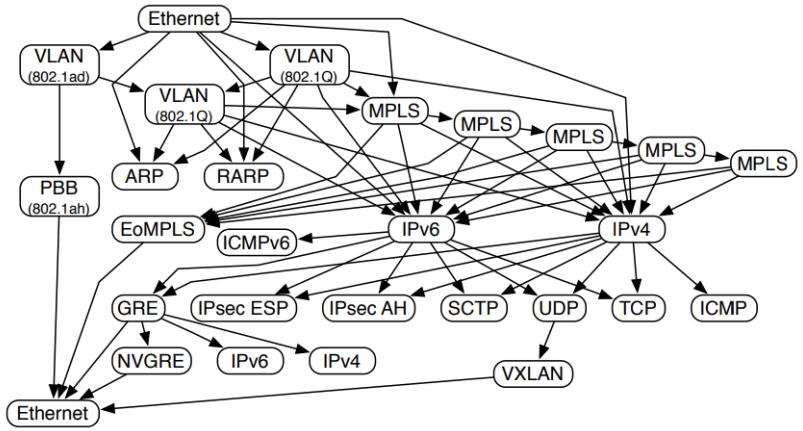
データプレーン
プログラマビリティ

パケット処理

本日は Switch ASIC を中心に

データープレーンをプログラムする

ヘッダ フォーマットの定義
パースグラフの構築



マッチフィールドの定義
テーブルタイプの定義
（Exact / Masked）

- MAC address
- IPv4 address
- proto + TCP ports
- (any header fields)

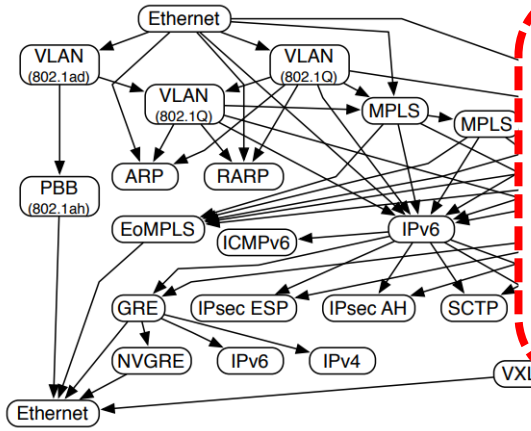
アクションの定義
フィールド操作ロジック

- drop
- forward
- copy
- push / pop
- add(+) sub(-) multiple(*)
- bit shift (<<) (>>)

→ ヘッダ解析（Parse） → テーブル参照（Match） → 変更・転送（Action） →

データープレーンをプログラムする

ヘッダ フォーマットの定義　マッチフィールドの定義　アクションの定義
パースグラフの構築　テーブルタイプの定義　フィールド操作ロジック
（Exact / Masked）



パケット処理「パイプライン」

forward
push / pop
(-) multiple(*)
shift (<<) (>>)

ヘッダ解析（Parse）
テーブル参照（Match）
変更・転送（Action）

データプレーン プログラマビリティで可能になる事

機能追加サイクルの短縮

新機能のプロトタイピング

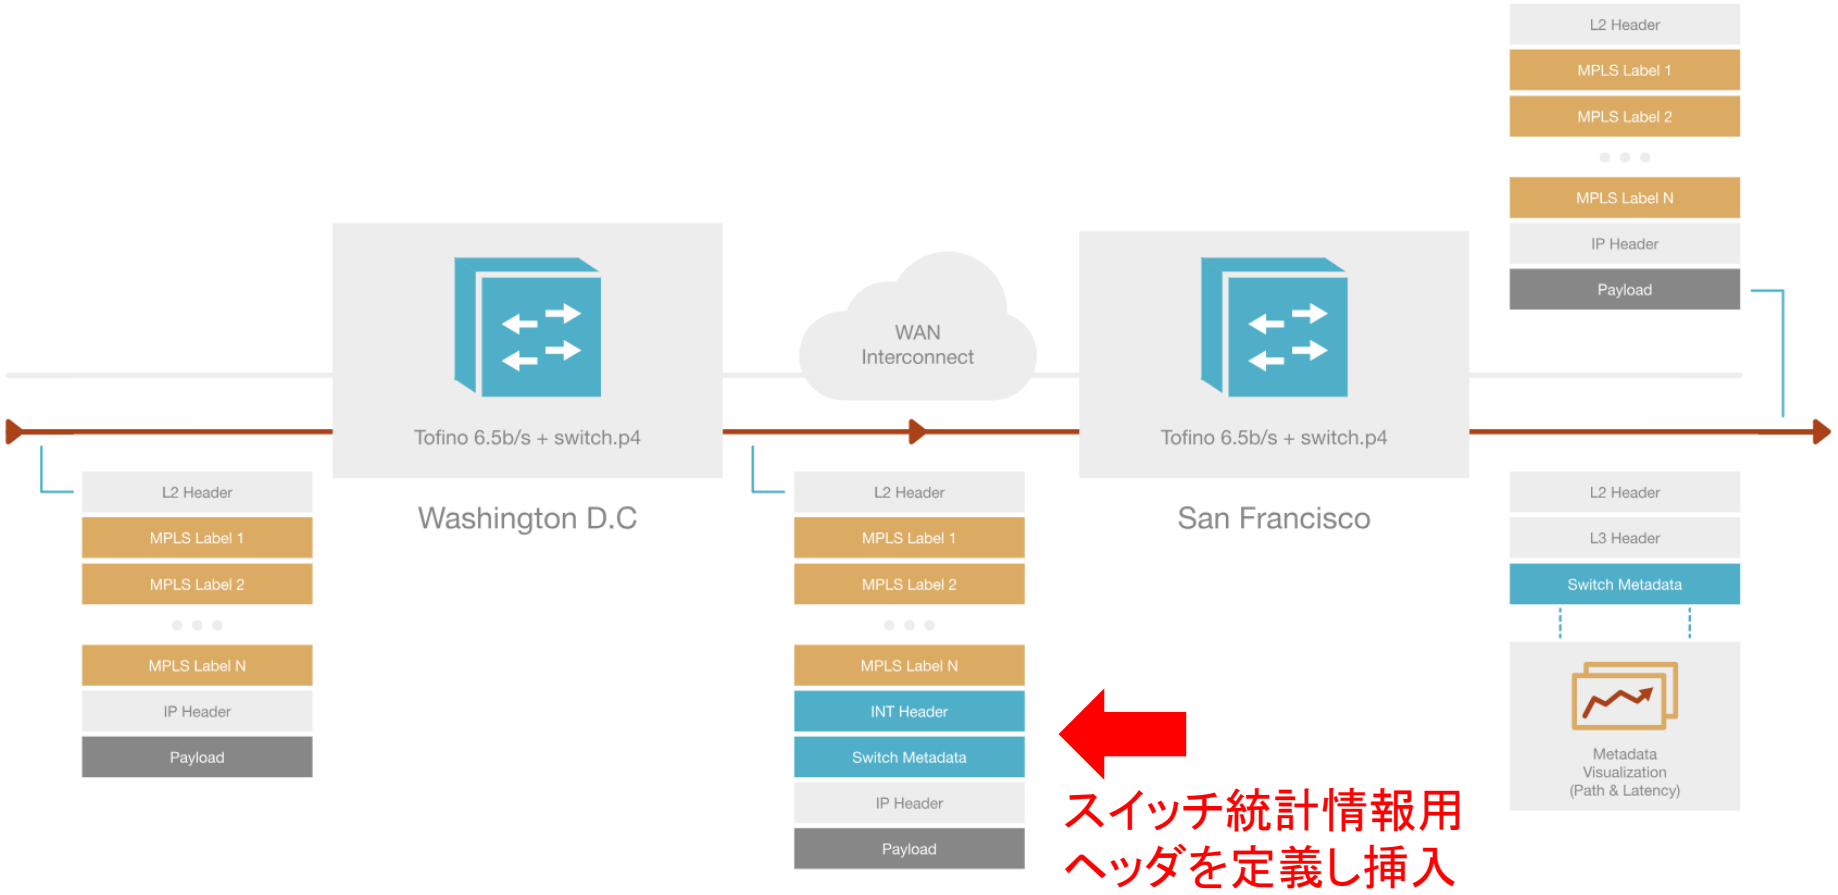
リソース配分最適化による
スケーラビリティの向上

ユーザー固有のカスタマイズ

パケット転送以外の処理
In Network Computing の実現

TOYOTA INFOTECH

Advanced Network Telemetry use-case: AT&T



スイッチ統計情報用
ヘッダを定義し挿入

https://www.barefootnetworks.com/use-cases/ad-telemetry/

データプレーンプログラマビリティを用いたプロトタイプ実装例

README.md

p4srv6 ... proto-typing SRv6 functions with P4 lang.

The objective of this project is to implement SRv6 functions still under discussion using P4 Lang to make running code available for testing and demo. Since there is no Open Source P4 switch implementation supporting SRv6, this should include basic switch features required to test SRv6.

List of SRv6 functions of interest and status:

- draft-filsfils-spring-srv6-network-programming-04
  - T.Insert
  - T.Encaps, T.Encaps.Red
  - End, End.DT6
- draft-ietf-dmm-srv6-mobile-uplane-01
  - End.MAP (future)
  - End.M.GTP6.D
  - End.M.GTP6.E
  - End.M.GTP4.E (future)
  - T.M.Tmap (future)
  - End.Limit (not planned)

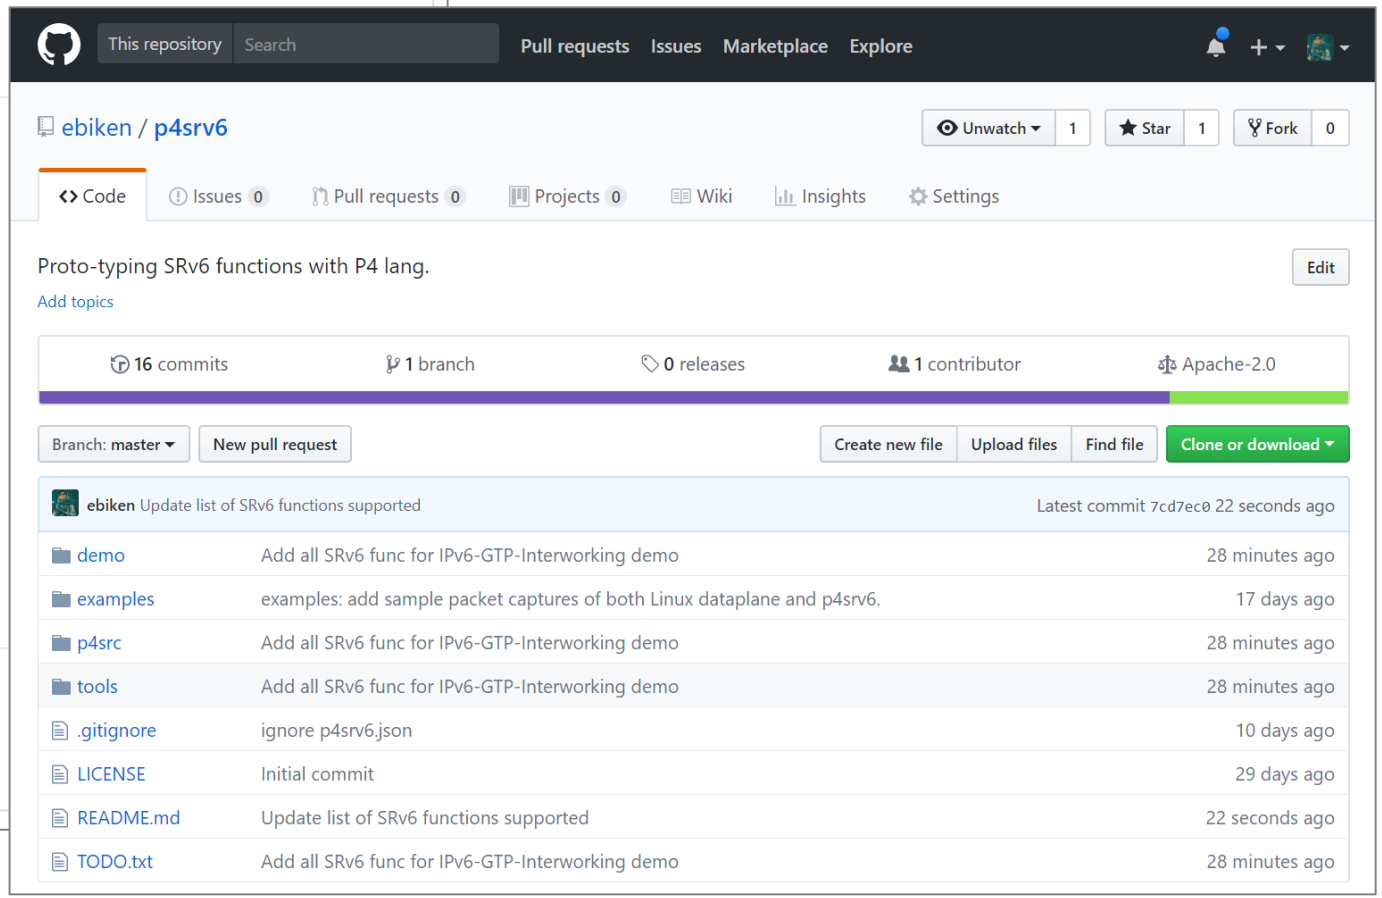
List of helper actions:

- GTP
  - Encap/Decap GTP-U

P4-14 によるSRv6プロトタイプ

https://github.com/ebiken/p4srv6

Barefoot社協力のもと P4-16版も準備中
（100GbE x32port のスイッチでテスト可能）



データプレーン プログラマビリティ 現状と展望

データプレーン プログラマビリティ「3つの視点」

データプレーンプログラミングは普及するのか？

どこまで自作するのか？できるのか？
サポートしてくれる人はいるのか？

プログラマブルな Switch ASIC は
この先、生き残り進化していくのか？

データプレーン プログラマビリティ「3つの視点」

データプレーンプログラミングは普及するのか？

どこまで自作するのか？できるのか？
サポートしてくれる人はいるのか？

プログラマブルな Switch ASIC は
この先、生き残り進化していくのか？

プログラミングの普及に必要な事は？

誰もが利用できるプログラミング言語

多用な動作環境

身近に利用者がいる

これまでのプログラム言語・開発環境

ベンダー	タイプ	開発環境：言語
Cisco	ASIC？	非公開
Juniper	ASIC？	非公開
Cavium	ASIC	XDK（CLOSED）
Netronome	NPU	Network Flow C Compiler：Embedded C
Xilinx	FPGA	Vivado：Verilog, System C（高位合成）

プラットフォーム毎に異なる言語や開発環境

過去の学習・Code資産が生かされない

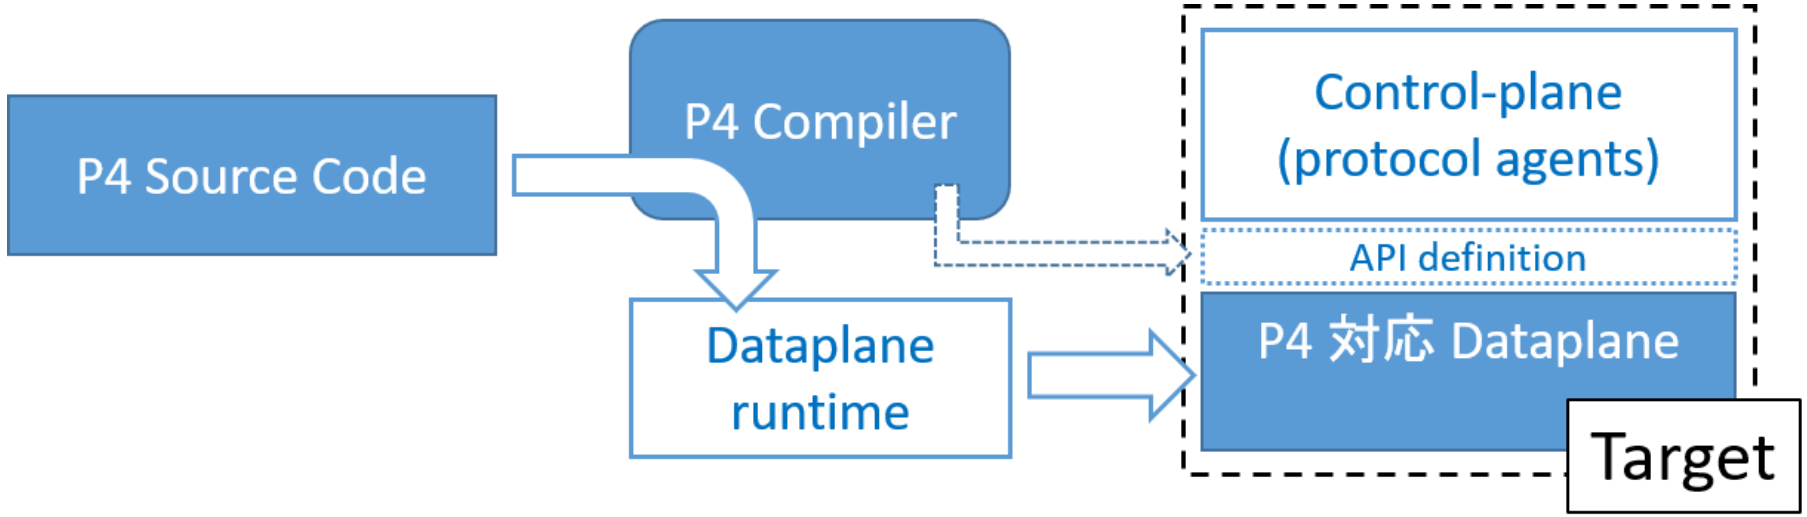
P4：オープンなドメイン特化型プログラム言語

"Programming Protocol-Independent Packet Processors"

P4 Source Code	パケット処理パイプラインの定義 パーサーやテーブル、アクション、など
P4 Compiler	P4をTarget上で実行可能な形式にコンパイル Target毎に提供される
Target (P4対応Dataplane)	P4 Dataplane runtime に従いパケットを処理 Hardware: ASIC, NPU, FPGA | Software: CPU

https://p4.org/





P4に対応した動作環境

ベンダー	タイプ	ASICや開発環境名
Barefoot	ASIC	Tofino（ASIC）P4 Studio（開発環境）
Mellanox	ASIC	Spectrum（ASIC）
Netronome	NPU	Agilio P4C SDK（開発環境）
Xilinx	FPGA	SDNet（開発環境）
Netcope	FPGA	P4 Cloud （開発環境） Online P4 to FPGA synthesis

eBPF	CPU	p4c-ebpf (Open Source)
BMv2 (Software Switch)	CPU	p4c (Open Source)

P4 Workshop 2018 in Tokyo
【データプレーンプログラミングの世界】

主催：P4.org、Barefoot Networks、ネットワンシステムズ株式会社(協賛)

講演企業

Barefoot Networks
Net One Systems
P4.org
Arista
Cisco
Apresia & Edgecore
Kaloom Software

10月23日当日の風景｜参加者100名以上

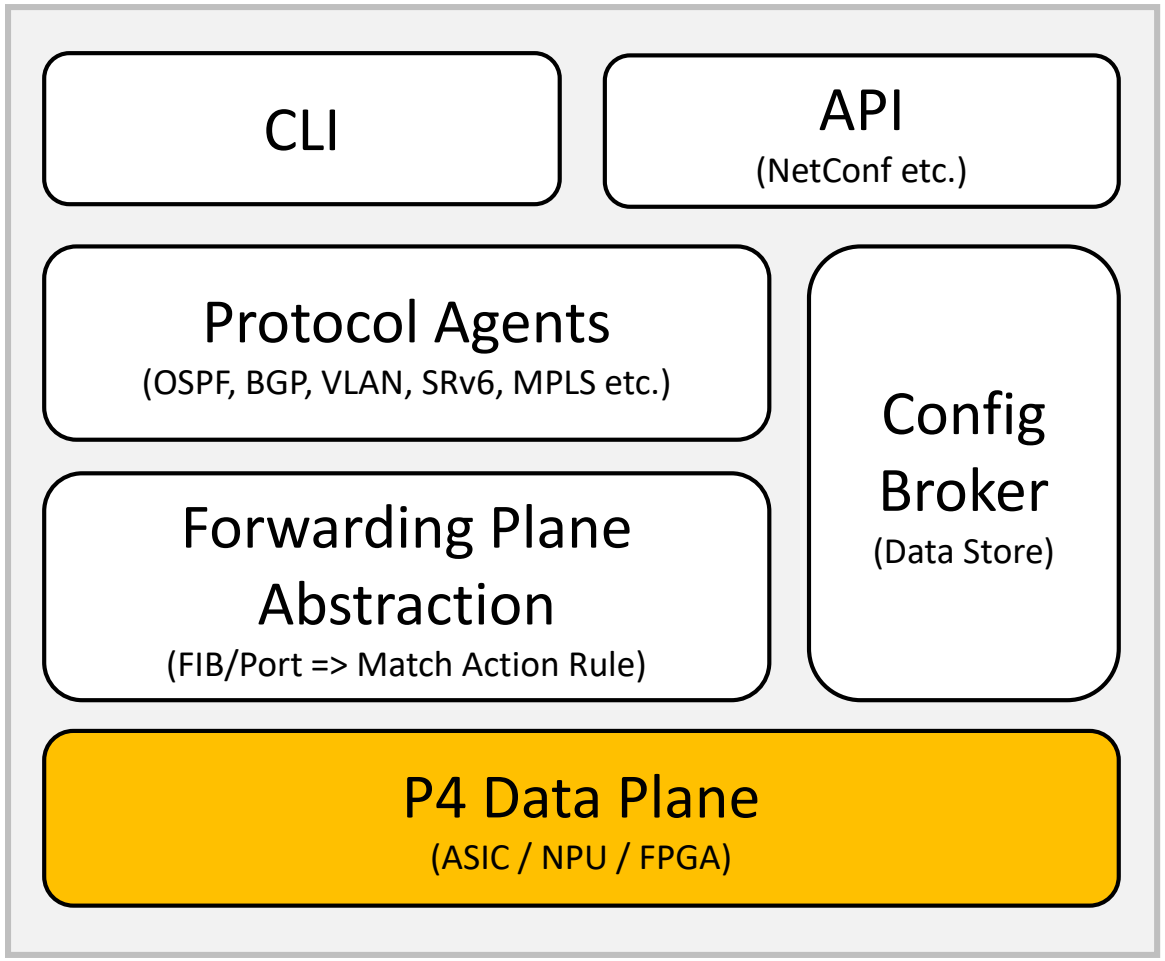
データプレーン プログラマビリティ「3つの視点」

データプレーンプログラミングは普及するのか？

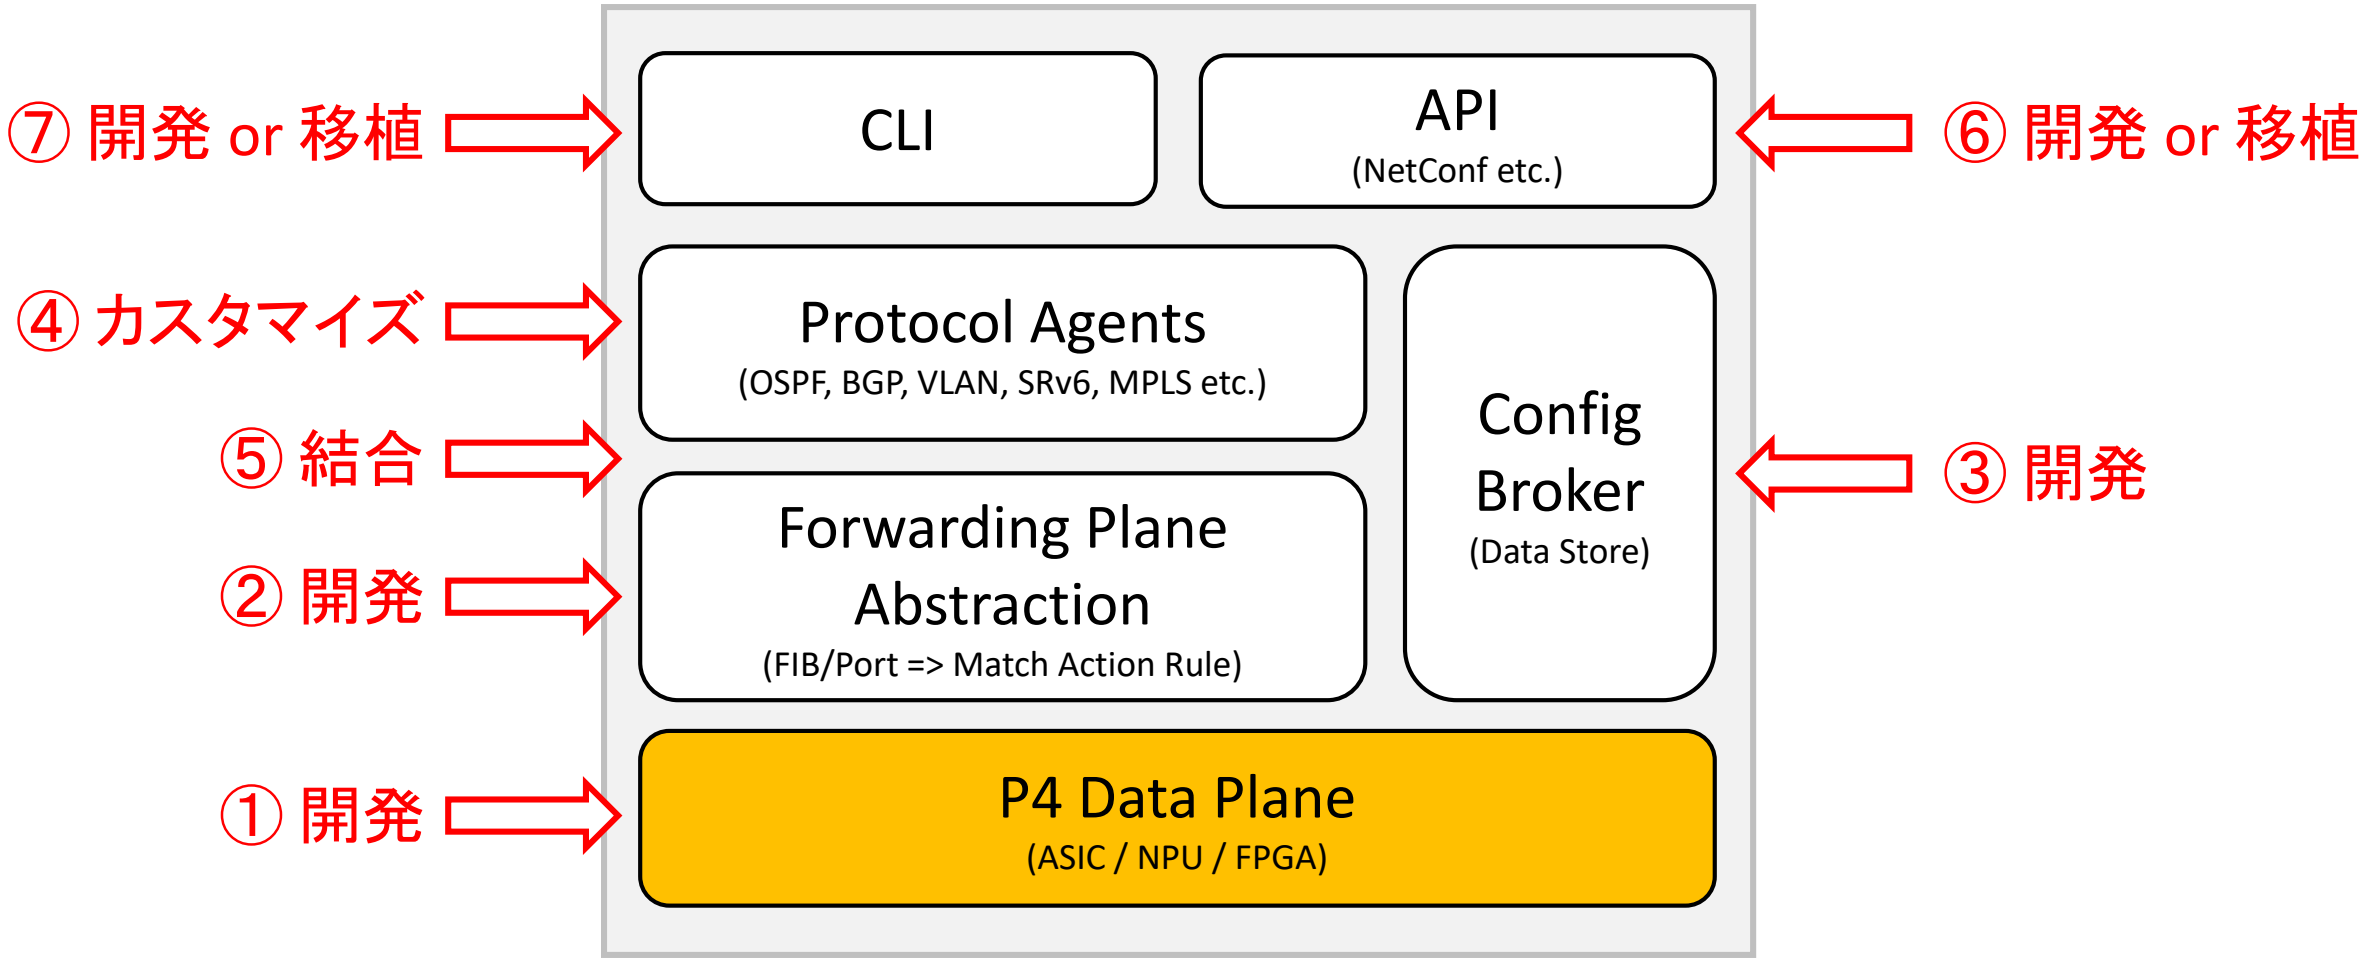
どこまで自作するのか？できるのか？
サポートしてくれる人はいるのか？

プログラマブルな Switch ASIC は
この先、生き残り進化していくのか？

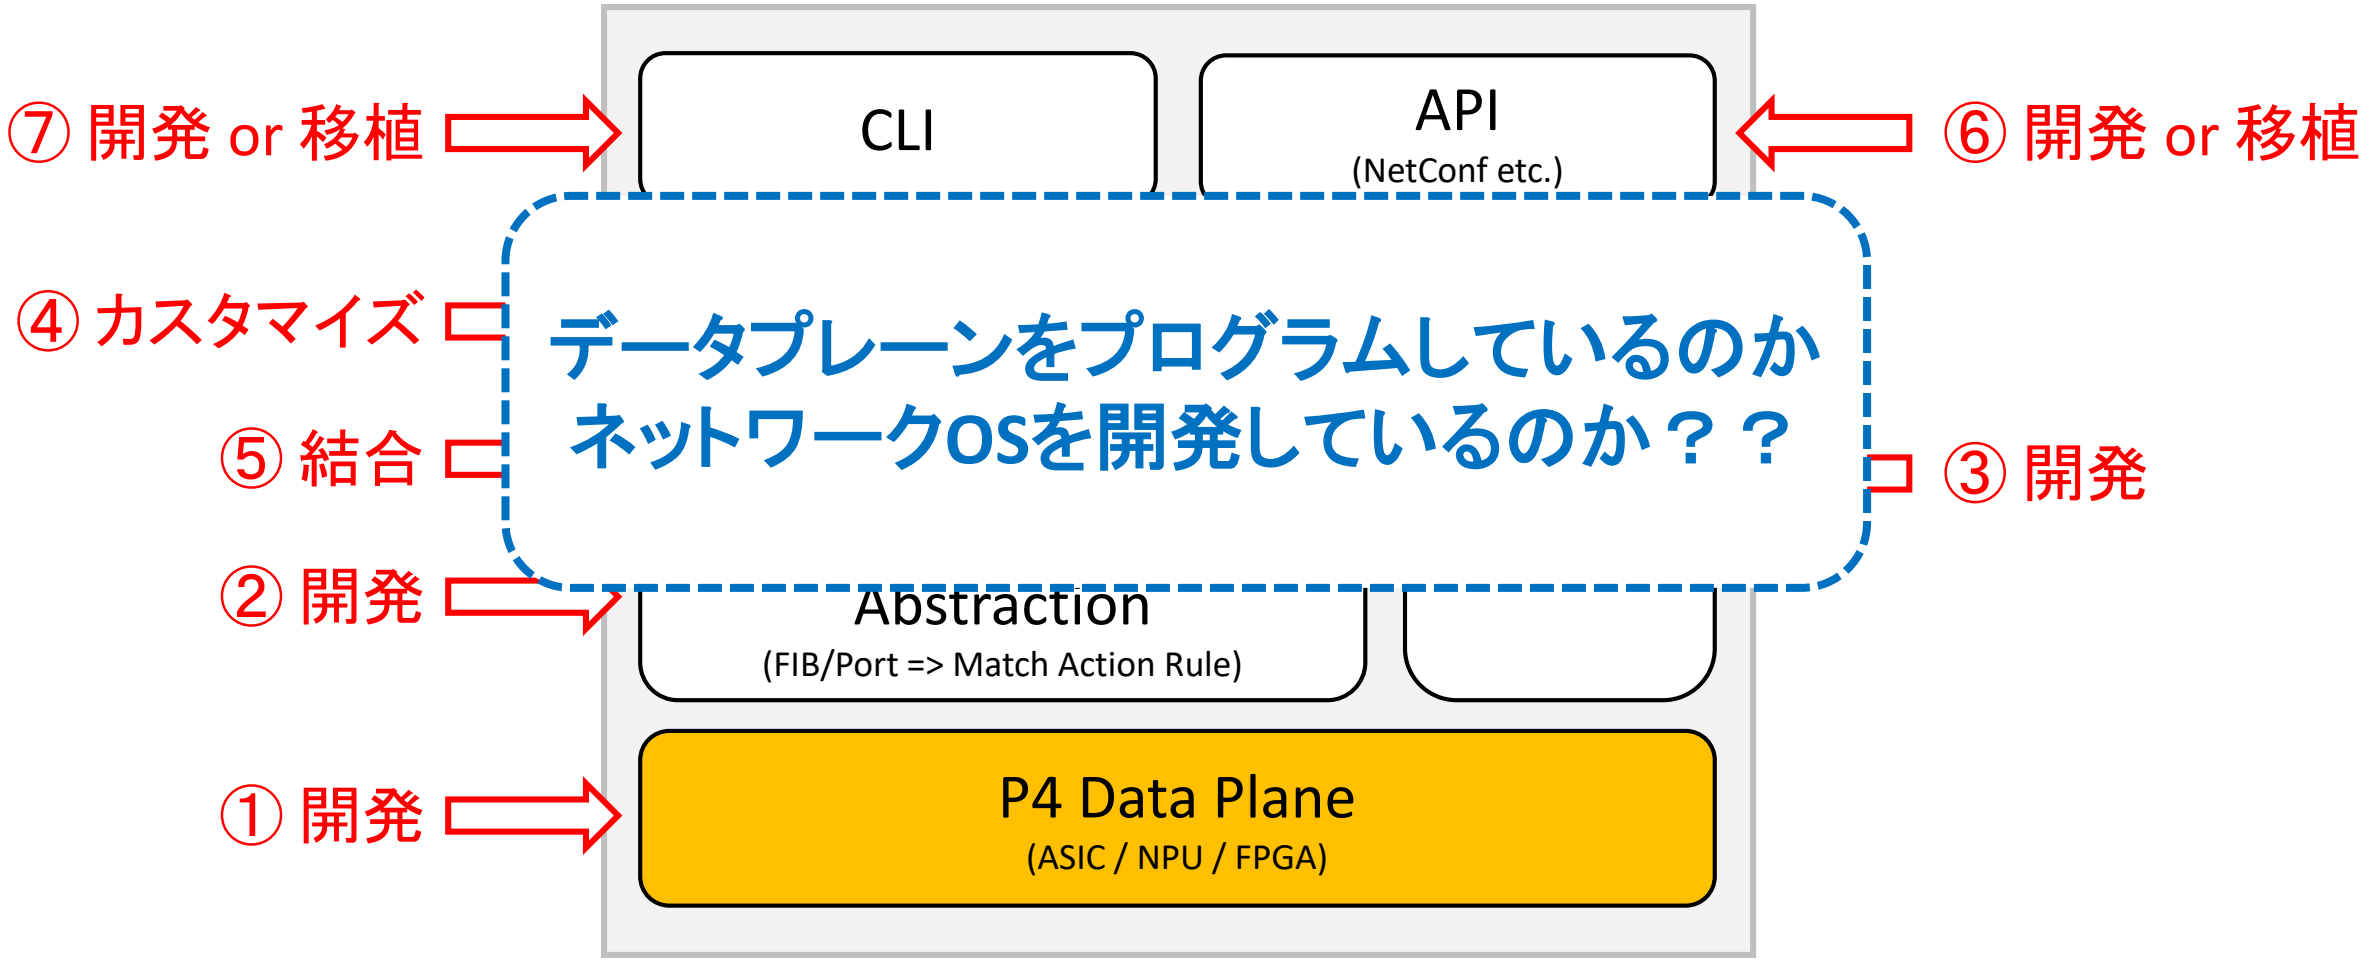
ネットワーク機器に必要な機能



動かすまでに「最低限」必要な作業

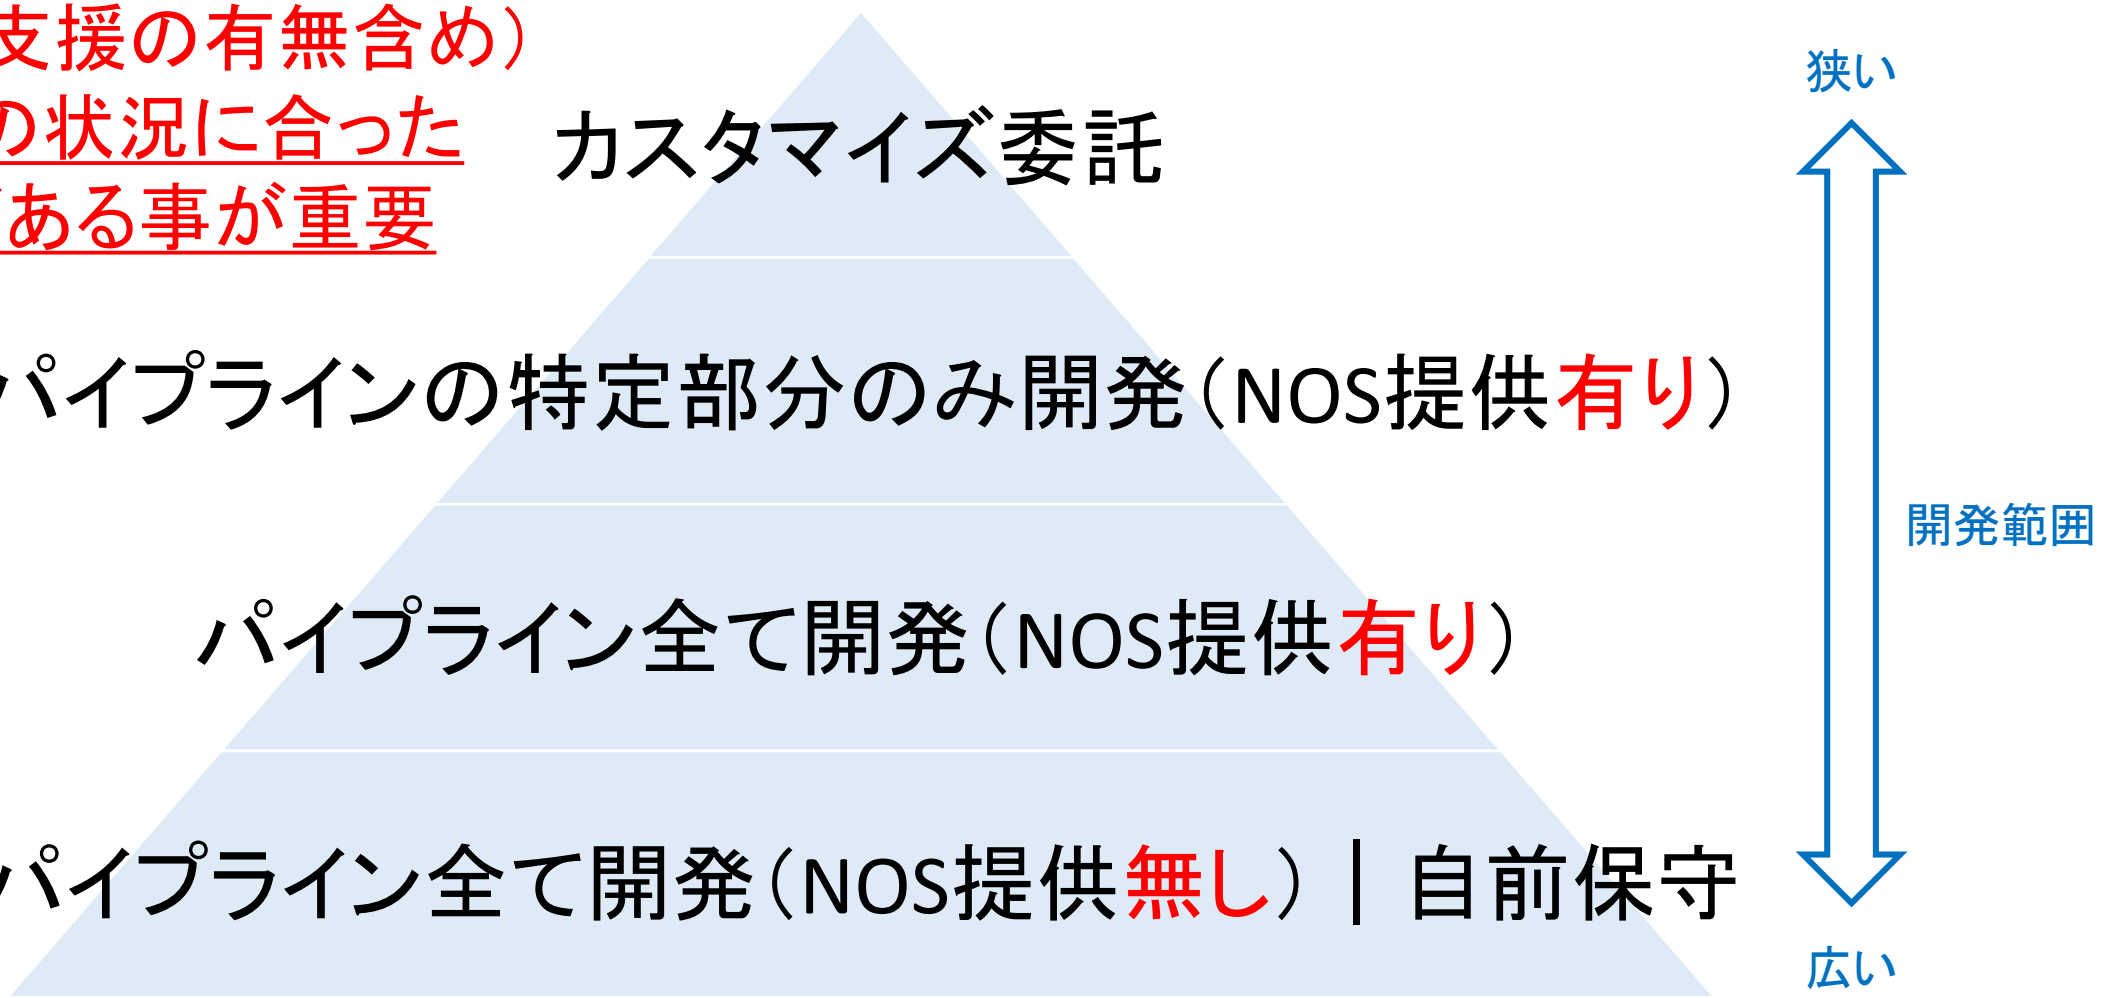


動かすまでに「最低限」必要な作業



データープレーン プログラミングの範囲

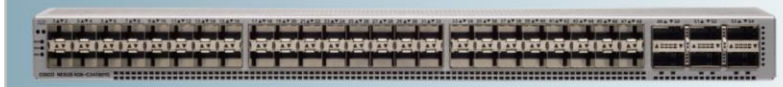
（開発・保守支援の有無含め）
ユーザーの状況に合った
選択肢がある事が重要



商用ベンダーのP4対応状況

ベンダーの状況 | Cisco

Nexus 3400 Programmable Switches
Barefoot Tofino ASIC



1 RU
48p 10/25G SFP + 6p 40/100G QSFP
Nexus 34180YC

Q4 CY18 — *General Availability*

Key Features

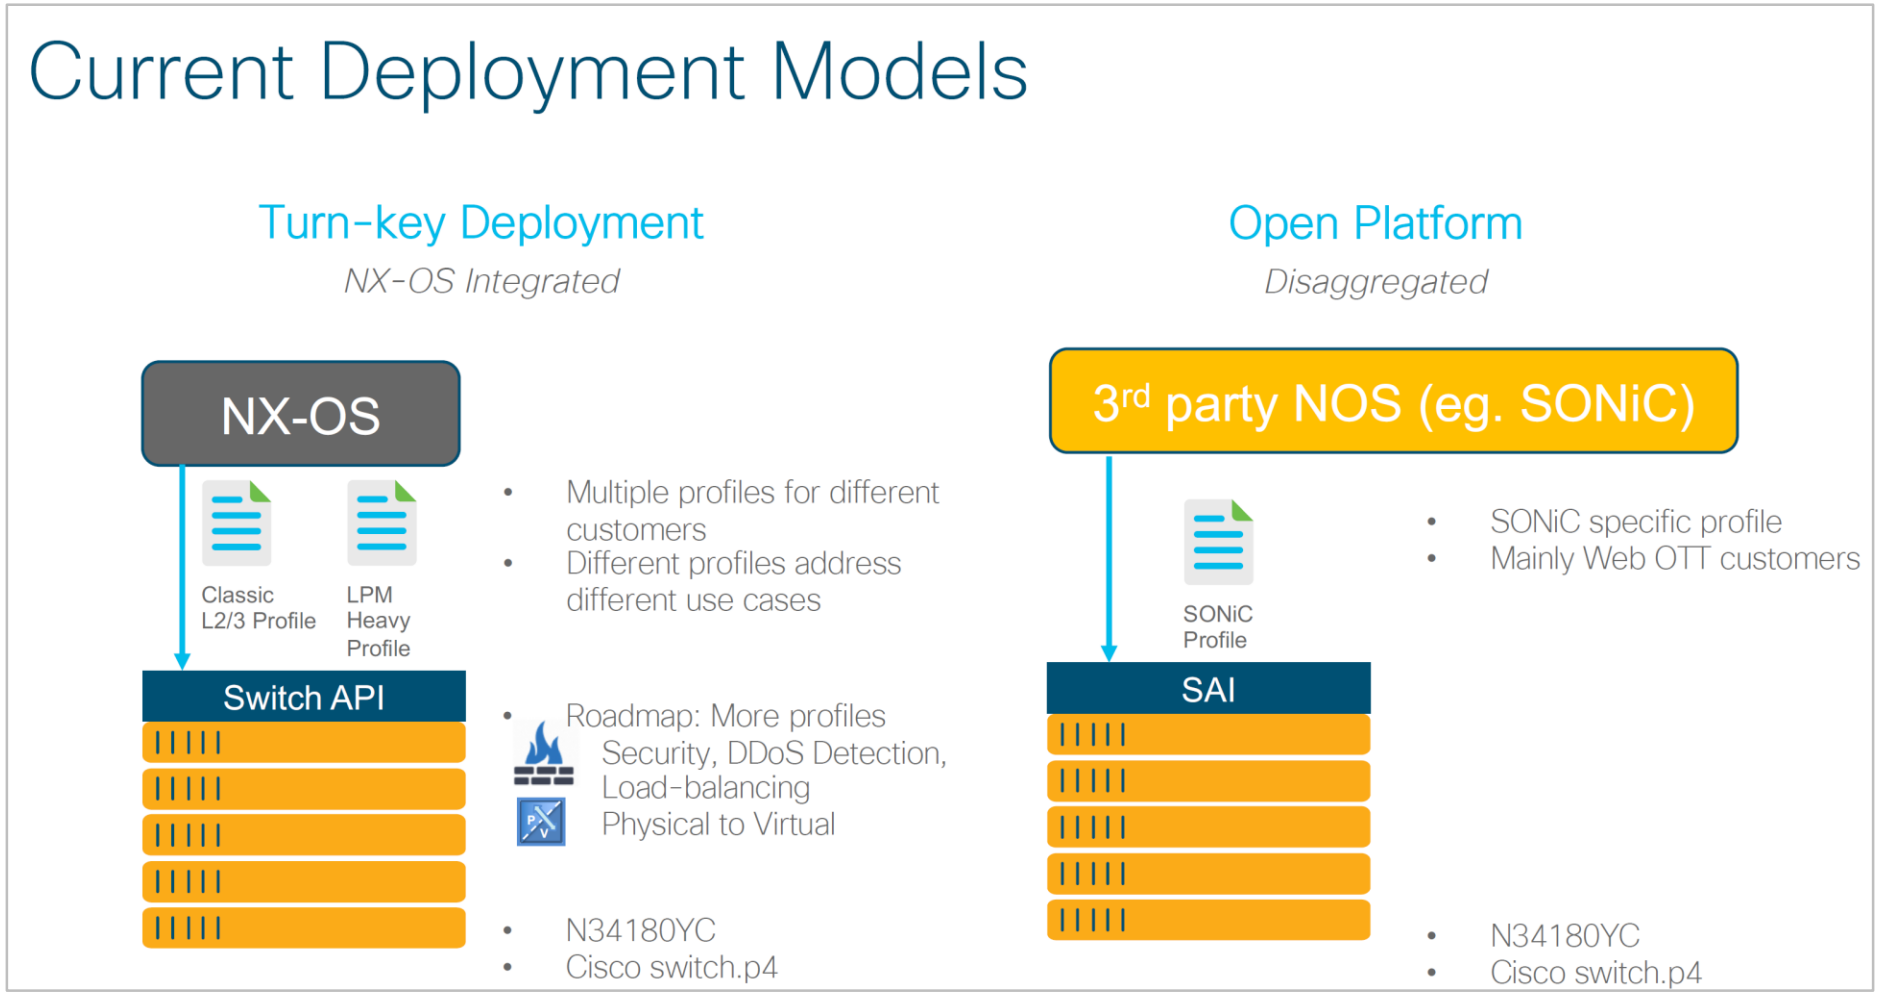
- NXOS switch with P4-programmable pipeline
- Flexible Parser, Meta-Data, Lookups, Memory allocations and Actions
- Flexible port configurations and scale profiles
- 1.8T core bandwidth, 20MB Packet Buffer
- 25G RS-FEC support
- Inband Network Telemetry (INT)

Roadmap — 64p 40/100G Platform

Roadmap — 100G/400G Platforms

© 201 ates. All rights reserved. Cisco Confidential

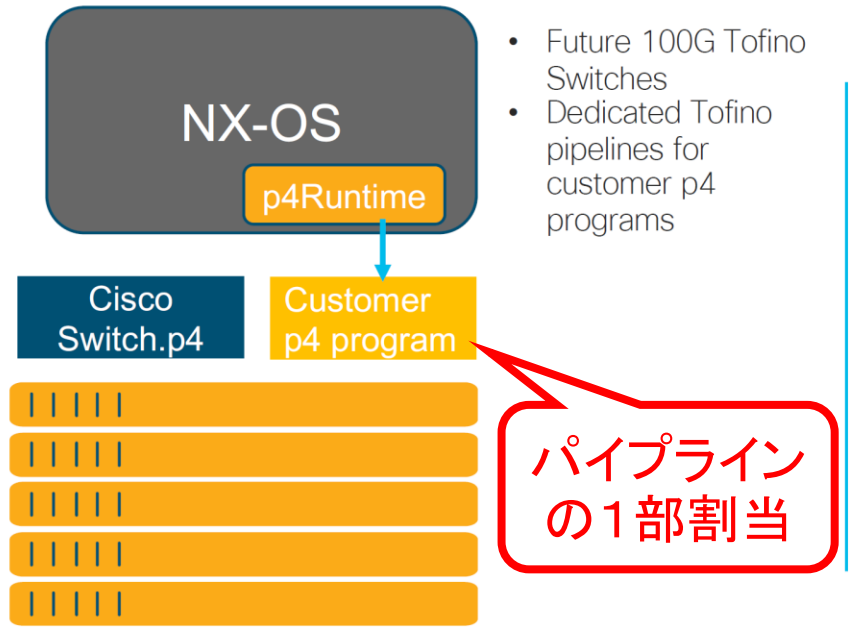
Reference: P4 Workshop 2018 in Tokyo
"Cisco Nexus 3400 Series P4-Programmable Switches | P4 Benefits, Deployment Models and Use Cases" Slide 5



Reference: P4 Workshop 2018 in Tokyo
"Cisco Nexus 3400 Series P4-Programmable Switches | P4 Benefits, Deployment Models and Use Cases" Slide 7

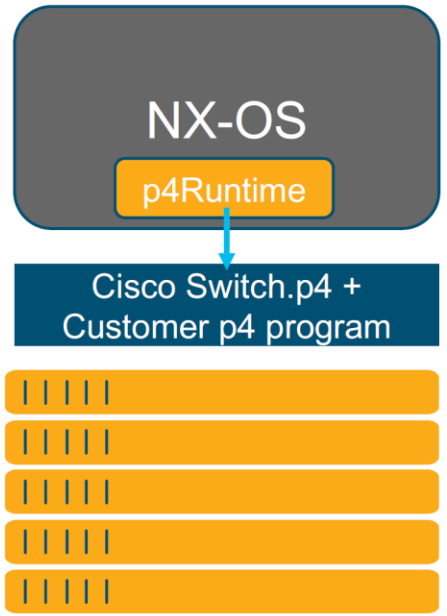
Future Deployment Models

Hybrid Deployment

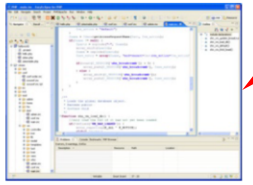


- Future 100G Tofino Switches
- Dedicated Tofino pipelines for customer p4 programs

パイプラインの1部割当



- N34180YC & Future 100G Tofino Switches
- Single p4 program – customer can add parsers/table to existing Cisco data plane implementation
- Cisco p4 IDE to safeguard collision/conflict

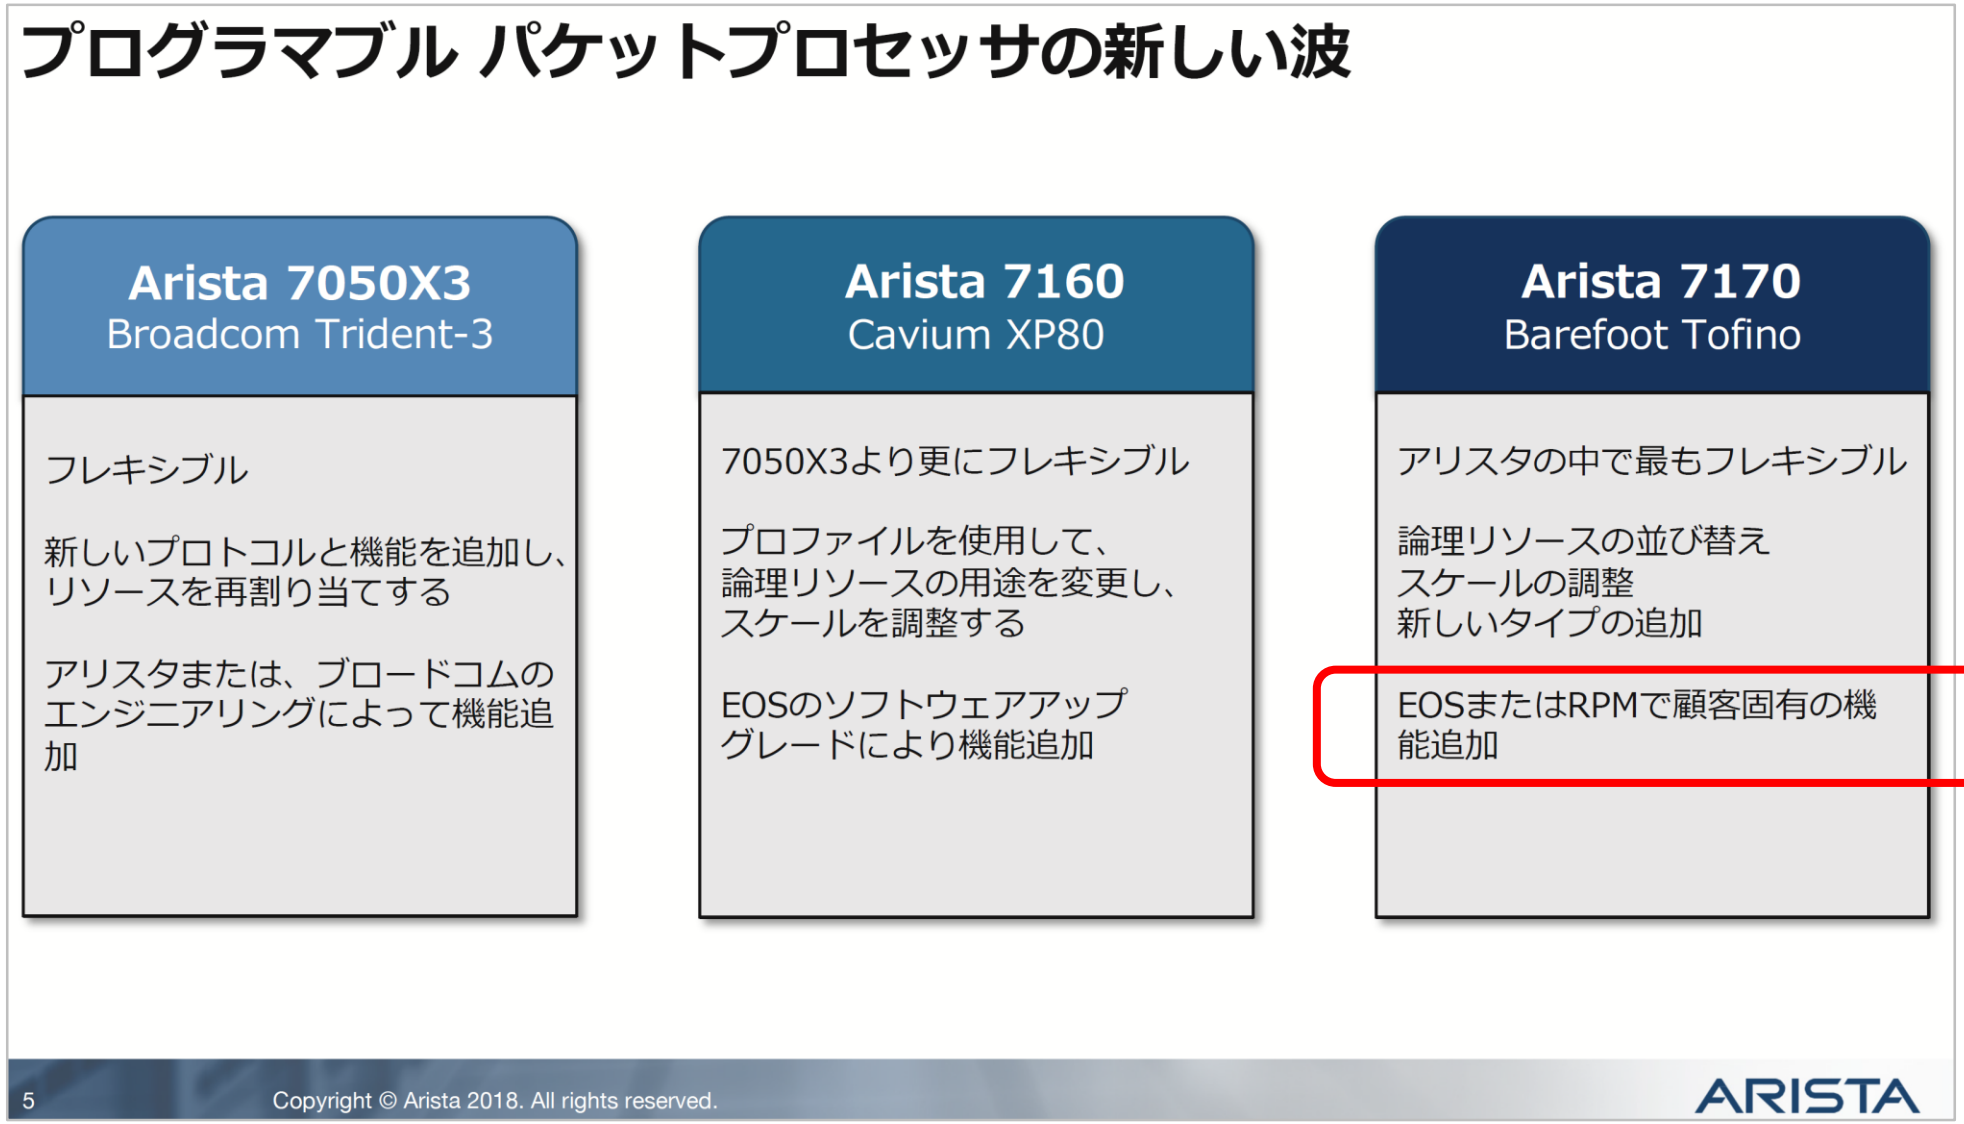


統合された開発環境

daPIPE

Data Plane Incremental Programming Environment

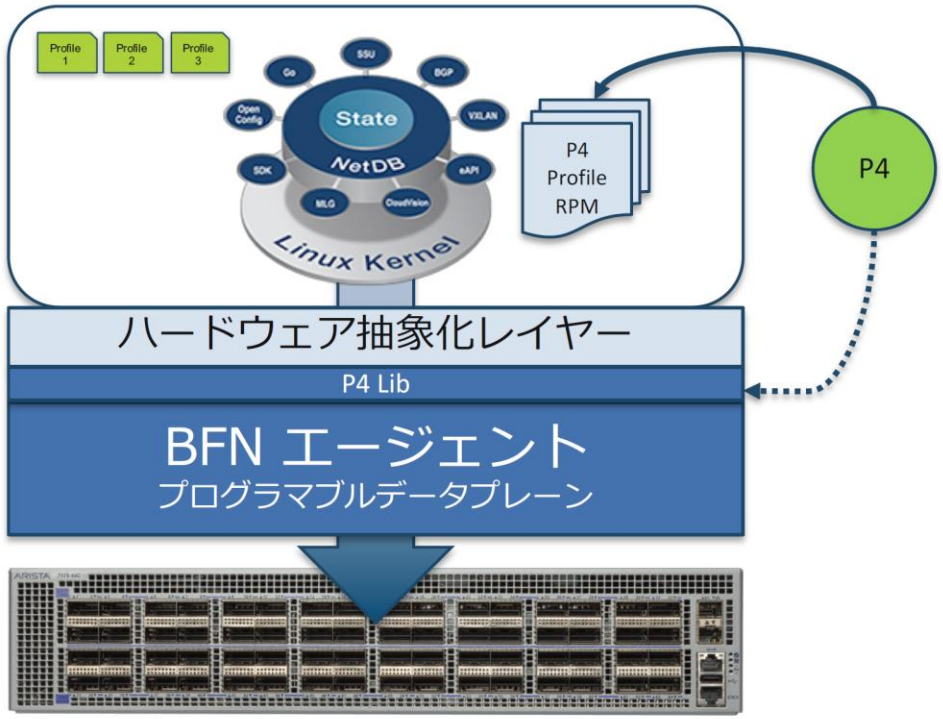
Reference: P4 Workshop 2018 in Tokyo
"Cisco Nexus 3400 Series P4-Programmable Switches | P4 Benefits, Deployment Models and Use Cases" Slide 8



Reference: P4 Workshop 2018 in Tokyo
"Arista 7170 Introduction and Demonstration" Slide 5

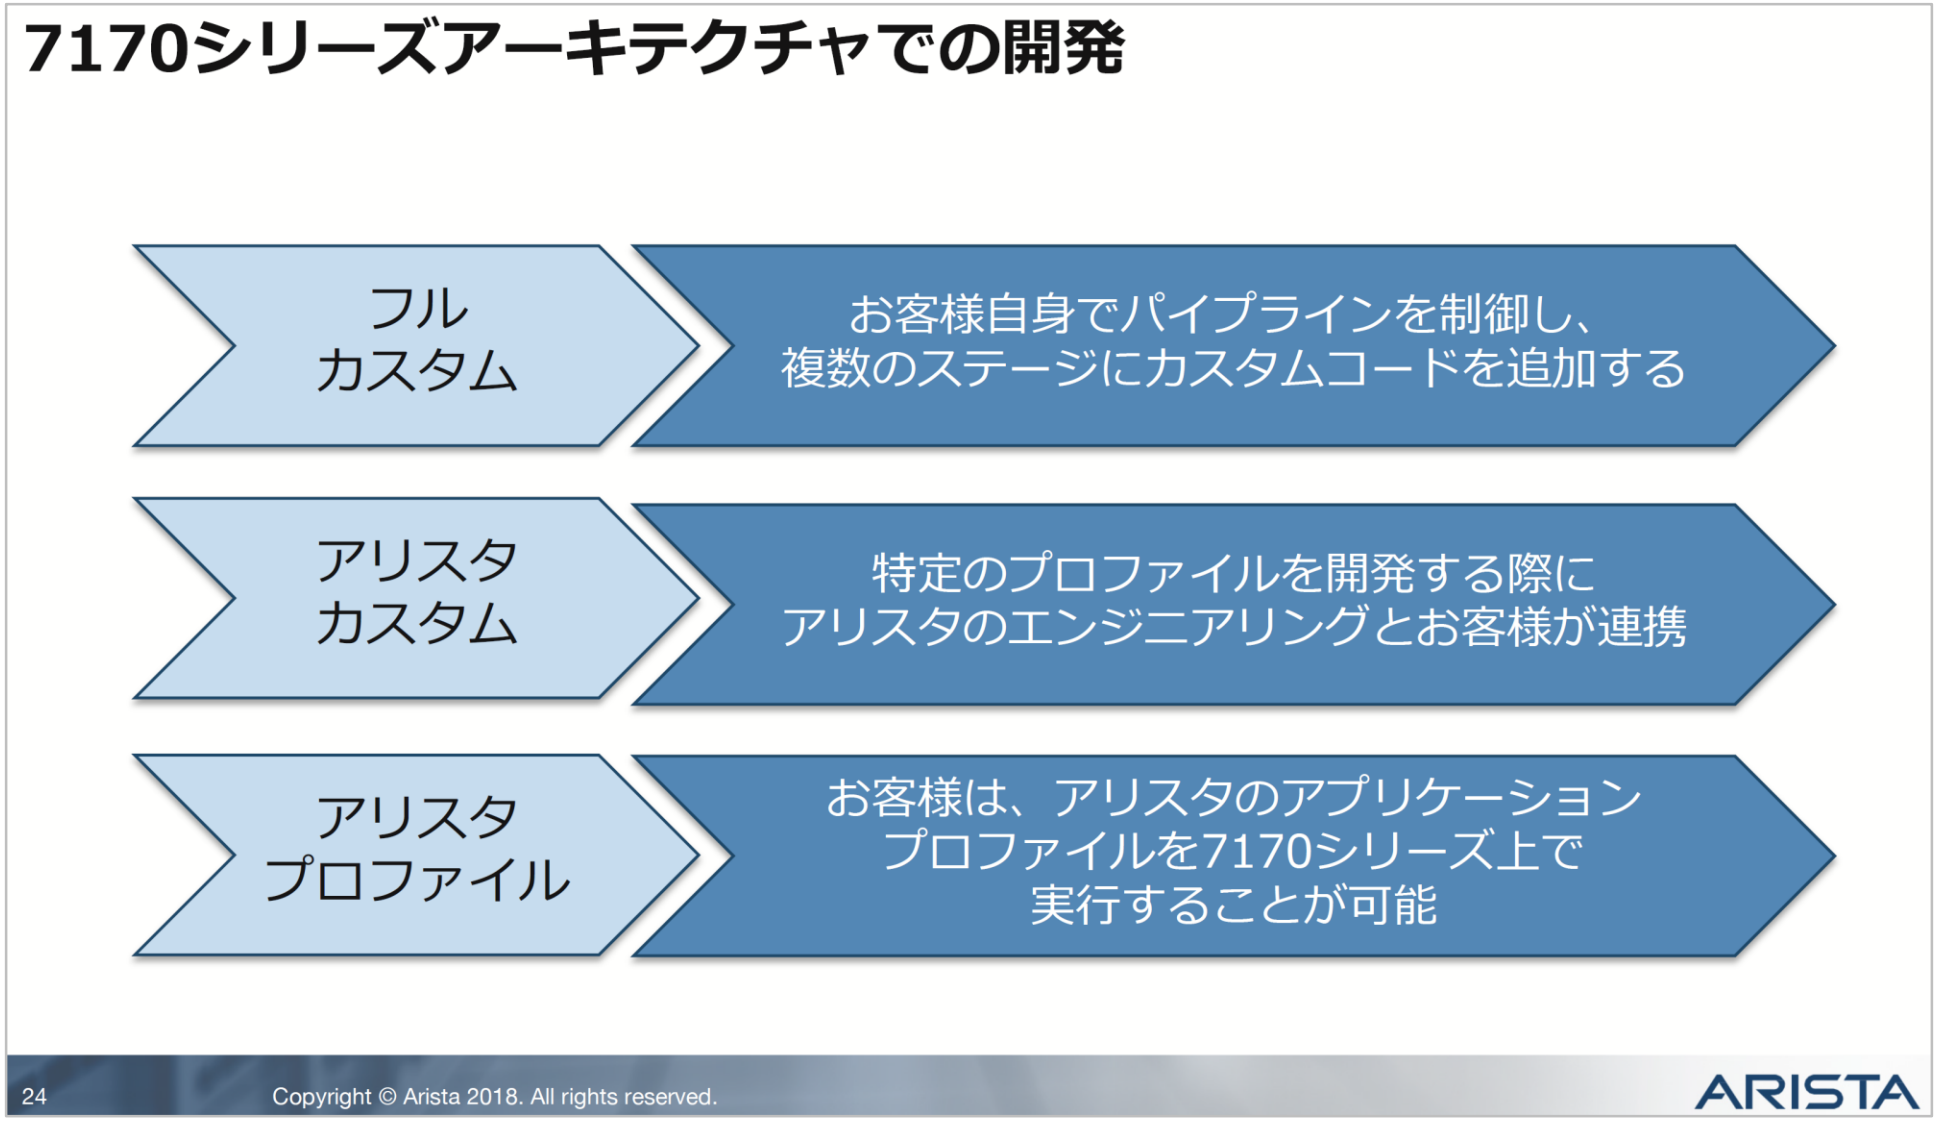
1つのスイッチ – 複数の個性

- **複数のプロファイルを活用**
  - プロファイルの変更はヒットレスで、短時間の停止のみ
  - クラウドプロファイルには、クラウド構築のための多くの豊富な機能
  - 追加のプロファイルが機能を追加したり、スケールを変更したりする
  - EOSのアップグレードや新しいRPMのロードによって追加された新しいプロファイル
- **未使用のステージに、顧客コントリビューションコードを利用可能**
  - アリスタのエンジニアリングの関与が必要
- **お客様自身でP4で開発し、システムハードウェアに直接ロードすることが可能**
  - お客様はローカルで開発されたコードを実行可能
  - フルカスタマイズが可能



23 Copyright © Arista 2018. All rights reserved. ARISTA

Reference: P4 Workshop 2018 in Tokyo
"Arista 7170 Introduction and Demonstration" Slide 23



Reference: P4 Workshop 2018 in Tokyo
“Arista 7170 Introduction and Demonstration” Slide 24

ベンダーの状況 | Arista

```
[admin@Arista7170 ~]$ ls /mnt/flash/*.rpm
/mnt/flash/p4-ar-switch-nat.i686.rpm
[admin@Arista7170 ~]$ sudo rpm -i /mnt/flash/p4-ar-switch-nat.i686.rpm
[admin@Arista7170 ~]$ exit
logout
Arista7170.15:00:27#show platform barefoot profile
     Profile    Chips
-------------- -----
   baremetal    Bfn0
     default
         nat
----------------------
Arista7170.15:00:35#show platform barefoot profile nat description
Nat switch pipeline with L2/L3 and full NAT capabilities
Limited capability for IPv4 tables
Minimal capability for IPv6 tables
Support for static and dynamic NAT feature
```

新しいプロファイルも
rpmコマンドでインストール可能

```
Arista7170.15:00:51#conf t
Arista7170.15:00:53(config)#platform barefoot profile nat
Arista7170.15:01:00(config)#show platform barefoot profile
     Profile    Chips
-------------- -----
   baremetal
     default
         nat    Bfn0
----------------------
Arista7170.15:01:07(config)#
```

通常のプロファイルと同様に
設定変更により即座に反映

詳細はArista 7170ホワイトペーパー参照
https://www.arista.com/assets/data/pdf/Whitepapers/7170_White_Paper.pdf

Reference: P4 Workshop 2018 in Tokyo
“Arista 7170 Introduction and Demonstration” Slide 35,36

Mellanox の P4 対応 ASIC

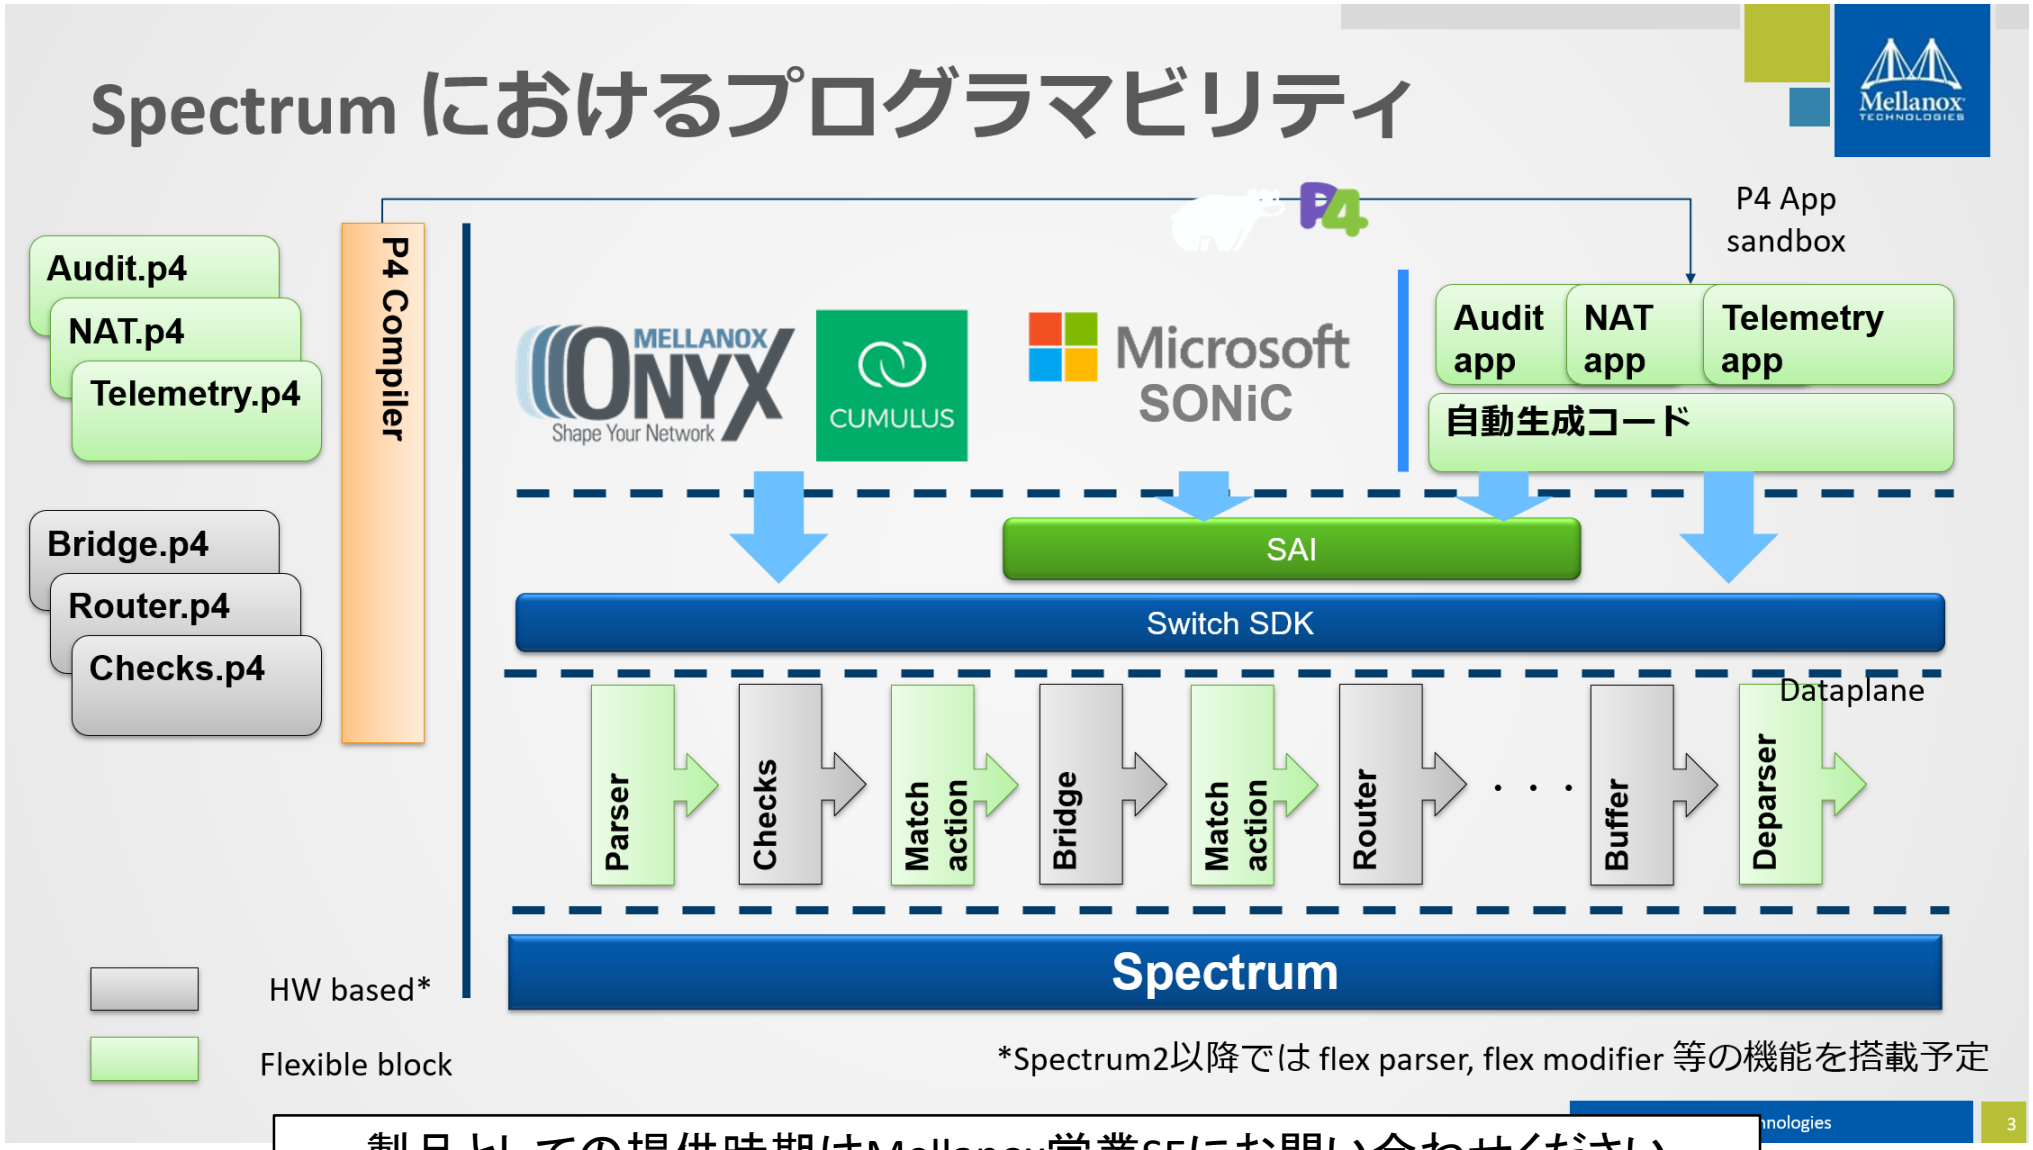


25G Serdes 搭載 ASIC
(2018/11現在、現行最新世代)
フレキシブルパイプライン搭載



50G Serdes 搭載 ASIC
(2019年製品出荷開始予定)
フレキシブルパイプライン搭載
フレキシブルパーサー搭載

© 2018 Mellanox Technologies



製品としての提供時期はMellanox営業SEにお問い合わせください

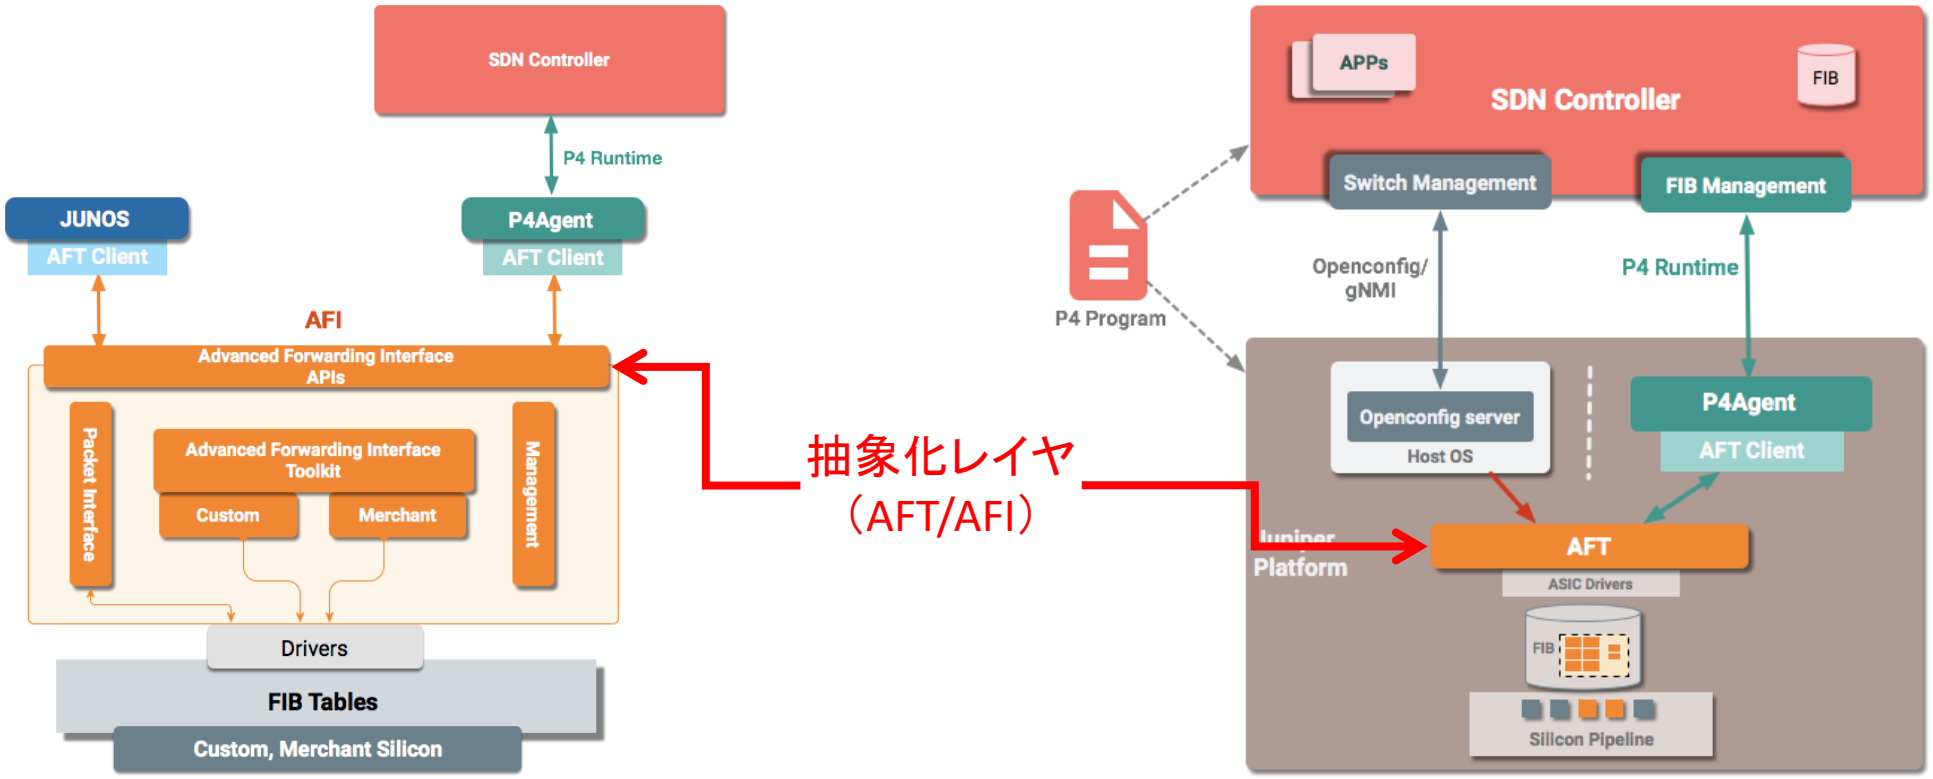
ベンダーの状況 | Juniper

Data/Control Plane 間のインターフェース（Contract）を記述するために P4 を利用

“P4 as the language that describes the contract between the control plane and the data plane”

ASICに依存しない抽象化レイヤを用意 P4Agent を分離する形で既存NOSと統合

“The architecture applies uniformly to devices across different ASIC families”
“The P4 Agent is sufficiently decoupled from the on-box operating system”



BLOG: Juniper Advancing Disaggregation Through P4 Runtime Integration (Feb 20, 2018)
https://forums.juniper.net/t5/Engineering-Simplicity/Juniper-Advancing-Disaggregation-Through-P4-Runtime-Integration/ba-p/319195

Juniper P4Runtime 実装 on GitHub

注：VMX tarball (jnprP4vmx.tgz) を Juniper から入手する必要あり

https://github.com/Juniper/JP4Agent

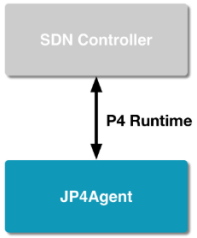
README.md

build passing

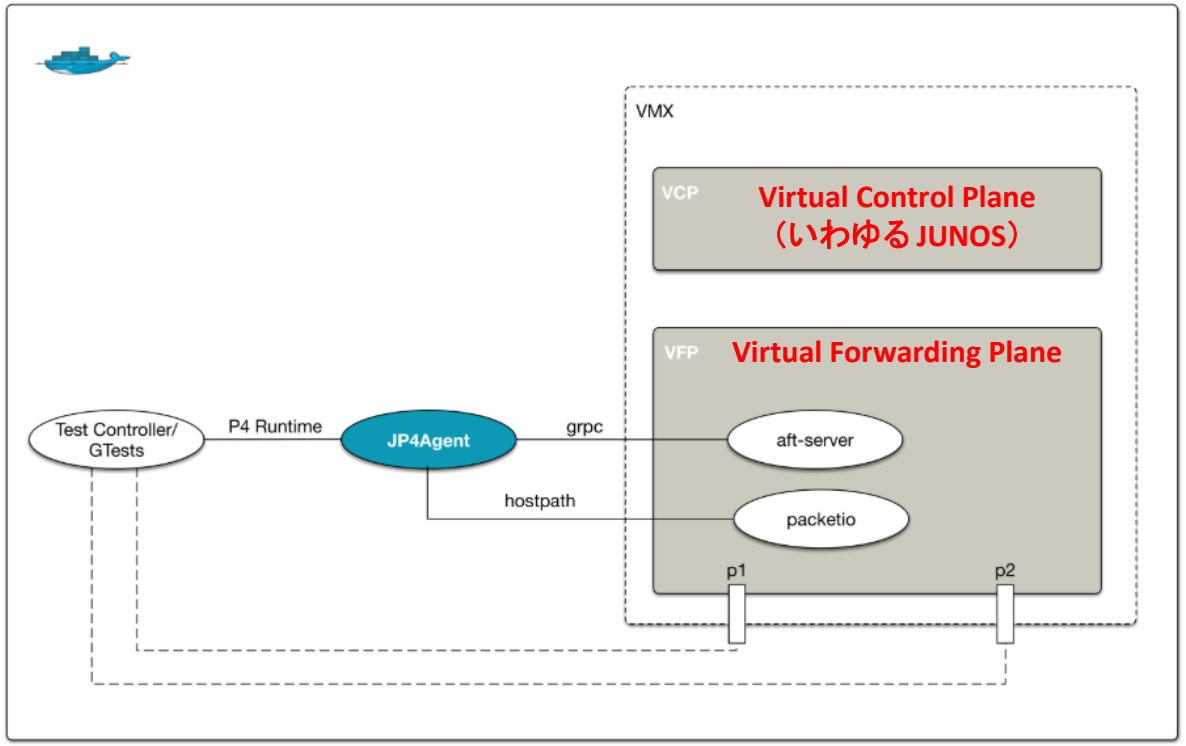
Note: Use of this software is governed by an Apache 2.0 license, and can be found in the “LICENSE” file.

JP4Agent (Juniper P4 Agent)

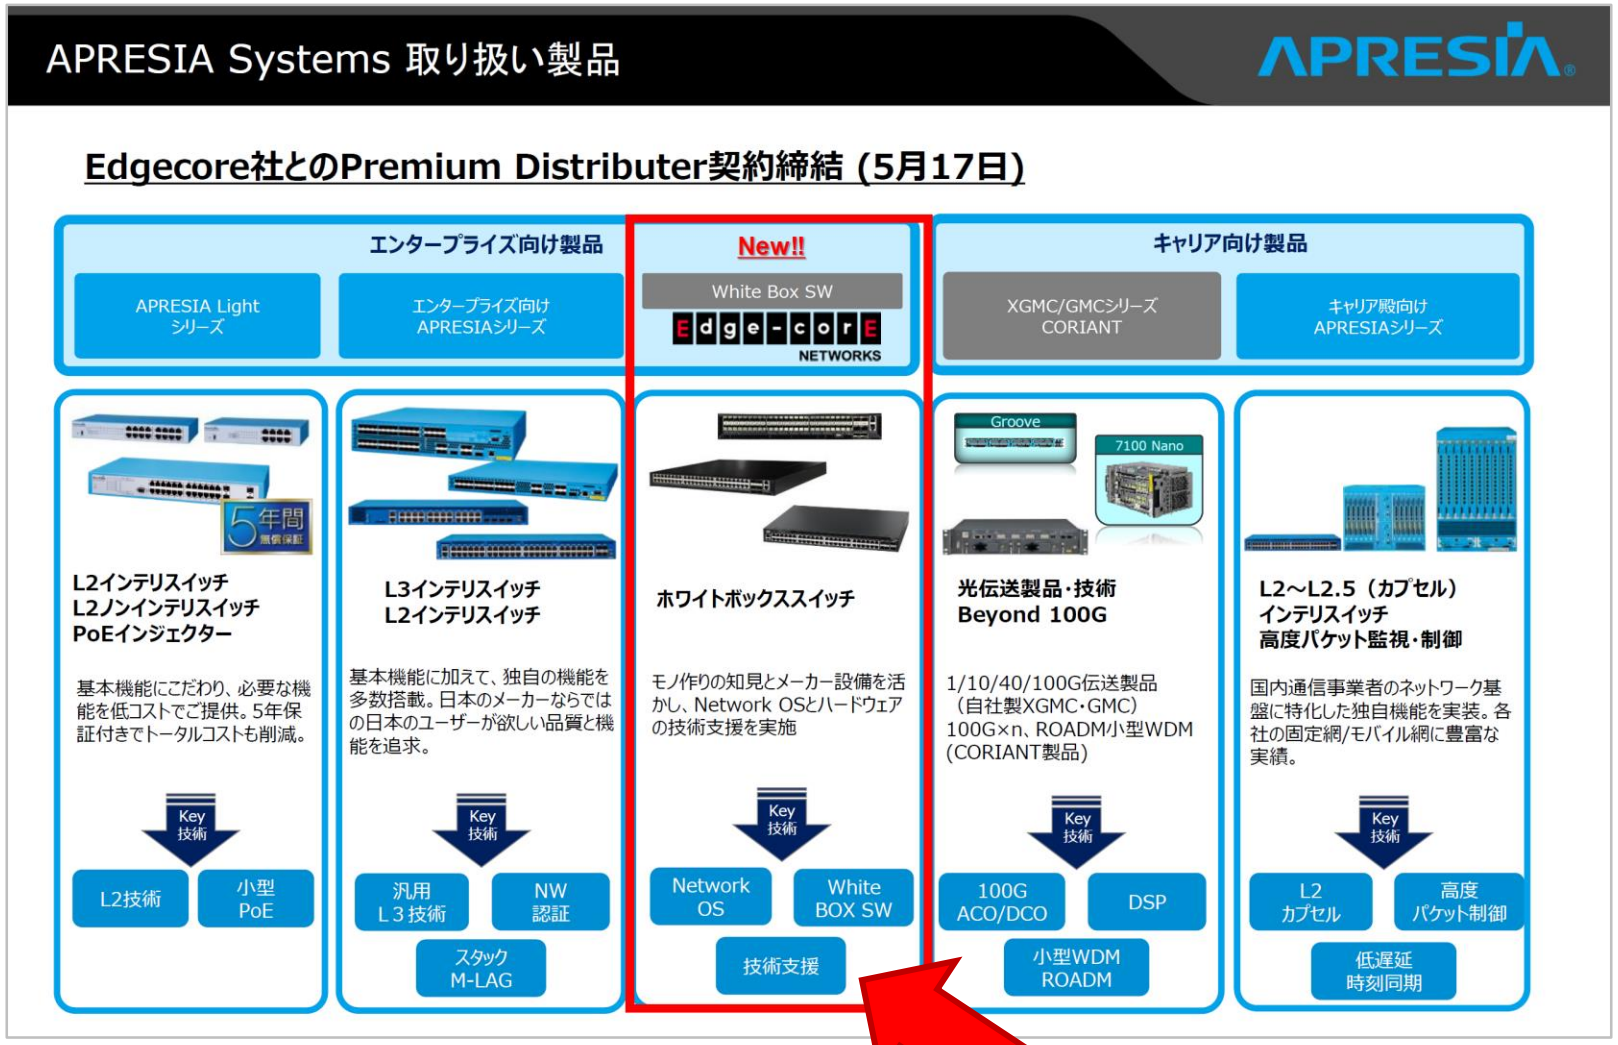
Juniper's P4 Runtime server implementation.



Docker 実行環境



ベンダーの状況 | APRESIA Systems



Reference: P4 Workshop 2018 in Tokyo
“Wedge 100 BF Switch Introduction and SRv6 Demonstration | APRESIA Systems & Edgecore” Slide 6

ベンダーの状況 | APRESIA Systems

Wedge100BF Series ～Programmable Switch

■ OCP Partner Designs
- Wedge100BF-32X（Barefoot/Tofino）
- Wedge100BF-65X（Barefoot/Tofino）

New!! ～対応NOS～
ip infusion ONL SONIC

Wedge100BF-32X



QSFP28	×	32	Port
100/1000Base-T（マネージメント）	×	1	Port

モジュール構成 スロット数。（）内は必須数	電源	ファン	ラインカード
	1 + 1	4 + 1	0

Wedge100BF-65X



QSFP28	×	65	Port
100/1000Base-T（マネージメント）	×	1	Port

モジュール構成 スロット数。（）内は必須数	電源	ファン	ラインカード
	1 + 1	9 + 1	0

- インタフェース：100/50/40/25/10GbEに対応
- 管理：USB Type A x 1 , シリアルコンソール x 1
- プログラマブル LSI：Barefoot Tofino
- CPU：Intel x86 Broadwell-DE, Pentium D-1517
- P4 SDE（Software Development Environment）

- 性能：
  - ✓ スイッチング容量：3.2Tbps(32X)/6.5Tbps(65X)
  - ✓ フォワーディング：4.7Bpps(32X)/9.5Bpps(32X)
  - ✓ ジャンボフレーム：9216 Bytes
  - ✓ パケットバッファ：22 MB

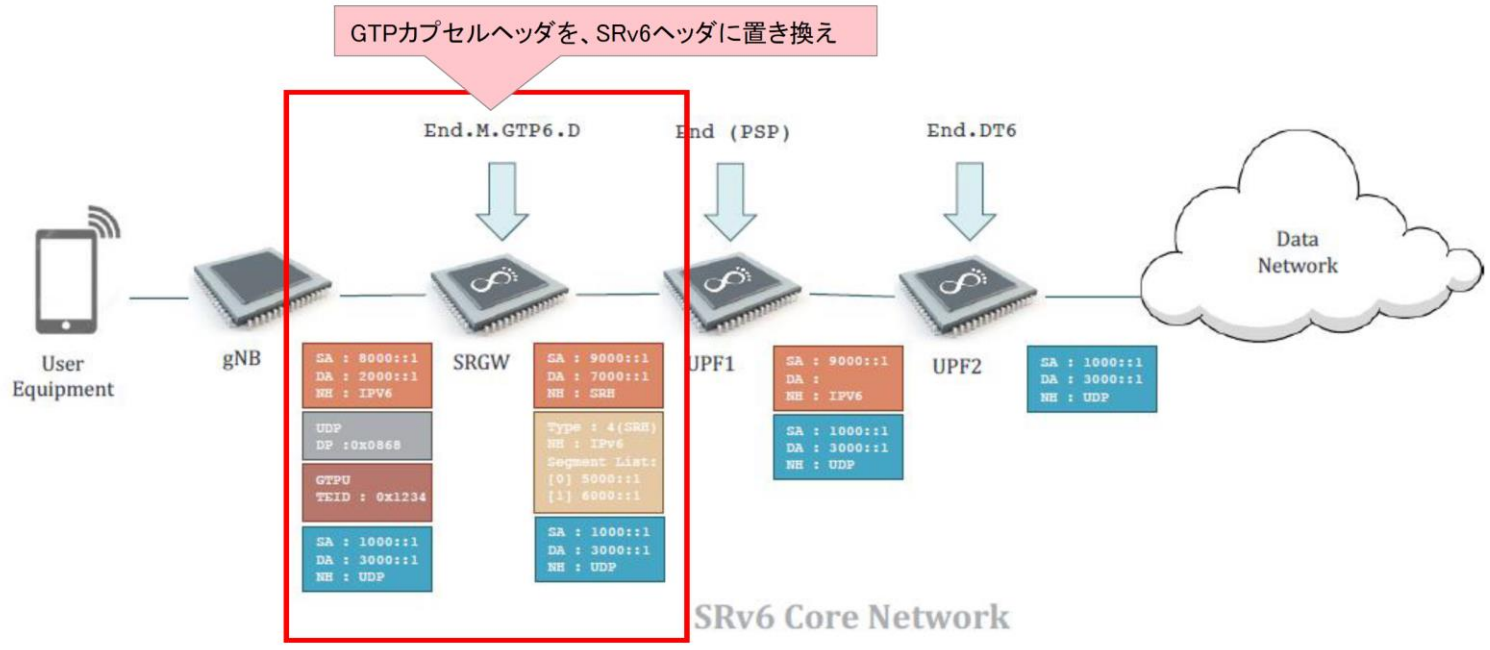
Reference: P4 Workshop 2018 in Tokyo
“Wedge 100 BF Switch Introduction and SRv6 Demonstration | APRESIA Systems & Edgecore” Slide 8

ベンダーの状況 | APRESIA Systems

デモユースケース

APRESIA

SRv6 Traffic Flow – Enhanced with unchanged gNB



https://tools.ietf.org/html/draft-ietf-dmm-srv6-mobile-uplane-02#page-11

BAREFOOT NETWORKS

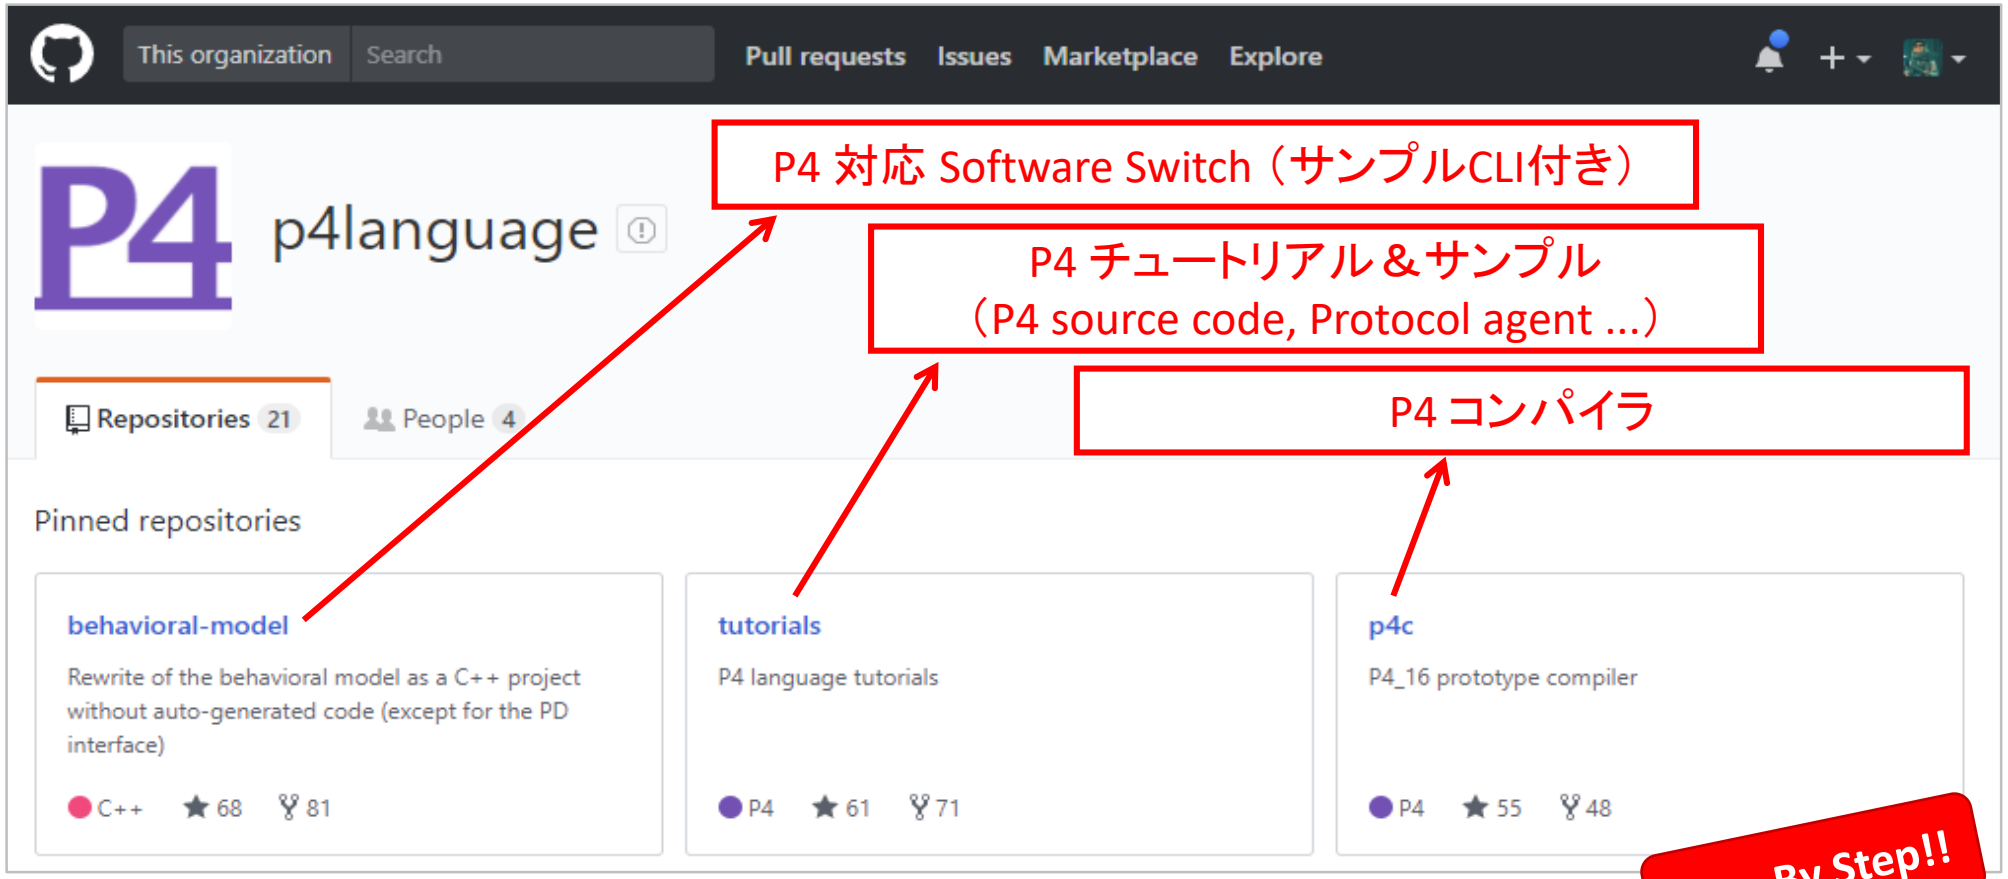
Reference: P4 Workshop 2018 in Tokyo
"Wedge 100 BF Switch Introduction and SRv6 Demonstration | APRESIA Systems & Edgecore" Slide 16

オープンソースのP4状況

コミュニティ開発の可能性

P4.org

https://github.com/p4lang



P4 ソフトウェア実装｜ビルド・実行手順サンプル

Step By Step!!

https://www.slideshare.net/kentaroebisawa/how-to-run-p4-bmv2

TOYOTA INFOTECH

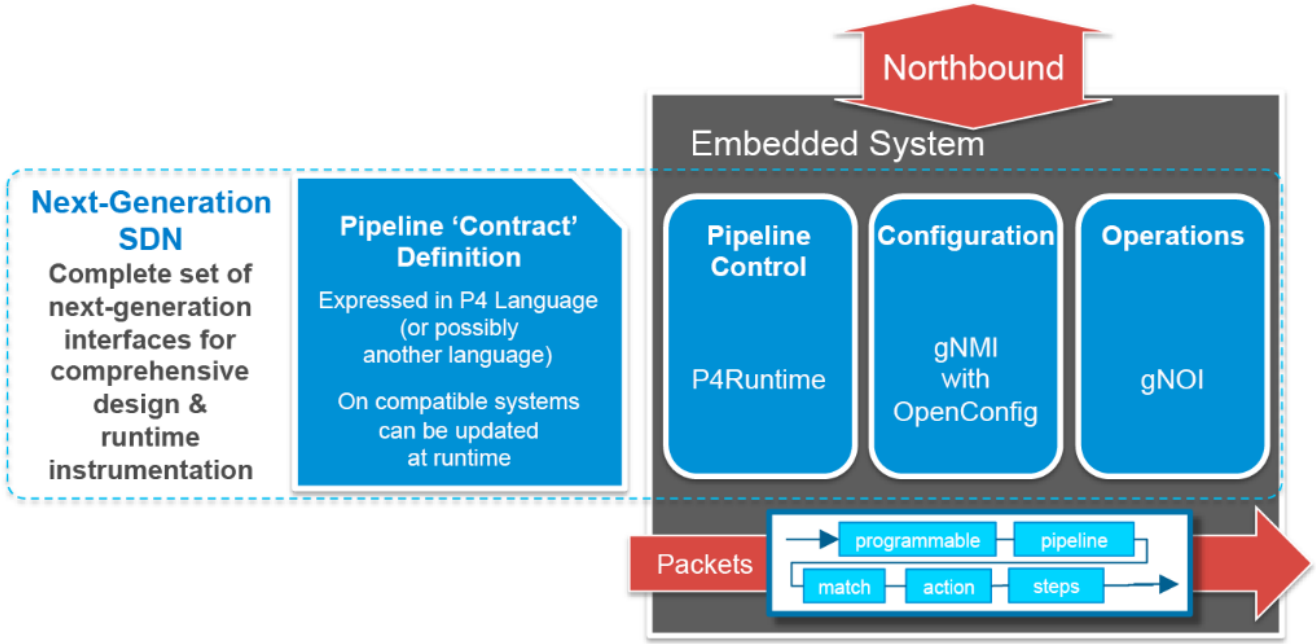
STRATUM

https://www.opennetworking.org/stratum/

TRAINING & CERTIFICATION | NEWS & EVENTS | CONTACT

ABOUT | REFERENCE DESIGNS | EXEMPLAR PLATFORMS | PROJECTS | SOFTWARE DEFINED STANDARDS | GET INVOLVED

INFORMATION MODELING | MININET | ONOS | OTCC | P4 | STRATUM | VOLTHA | XOS



The Stratum project broadens the scope of SDN to include full lifecycle control, configuration and operations interfaces.

Envisioned as a key software component of SDN solutions of the future, Stratum implements the latest SDN-centric northbound interfaces, including P4, P4Runtime, gNMI/OpenConfig, and gNOI. It does not embed control protocols, but instead is designed to support either an external Network OS or to work with NOS functions running on the same embedded switch.

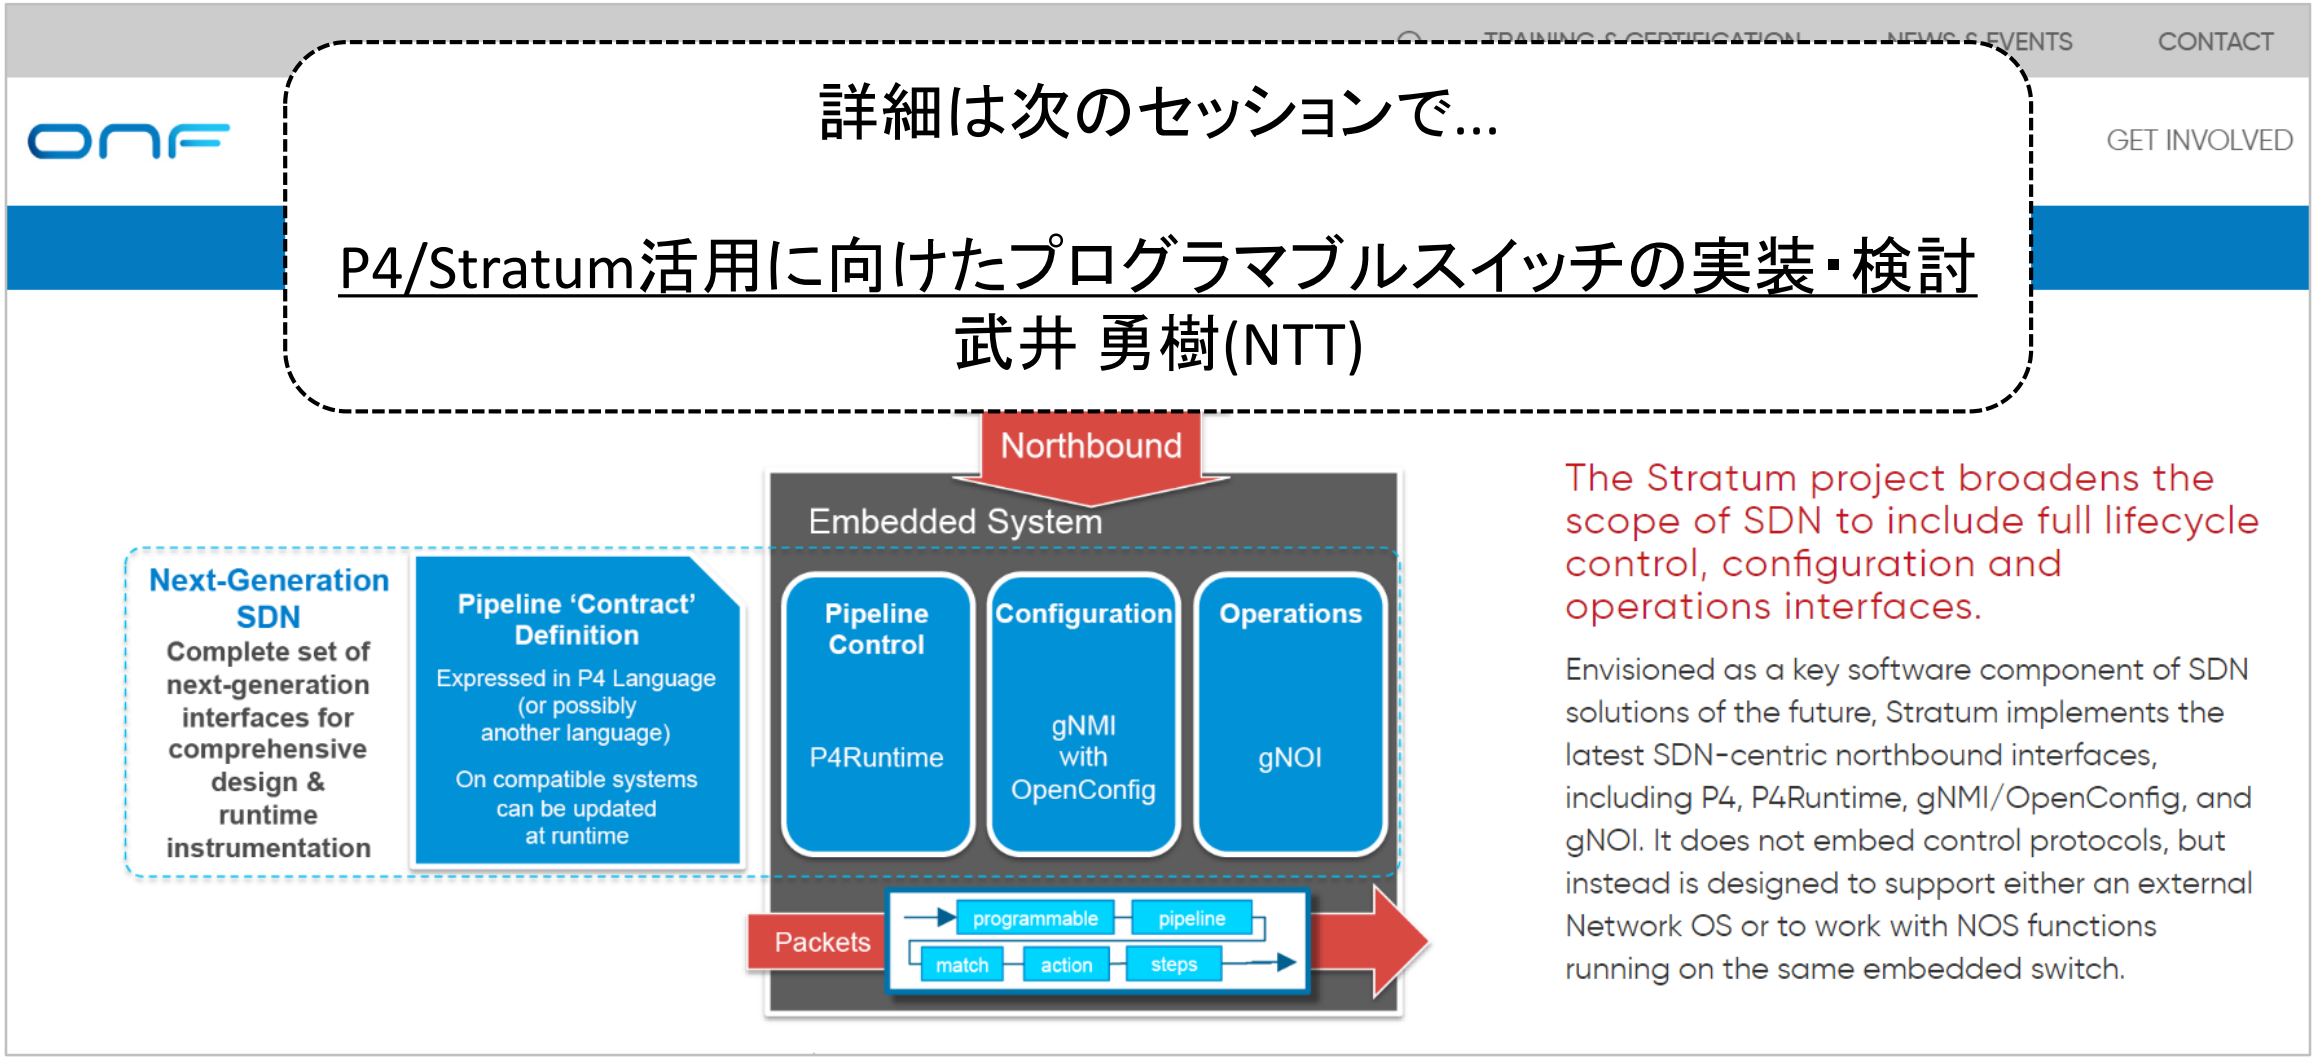
TOYOTA INFOTECH

STRATUM

https://www.opennetworking.org/stratum/

詳細は次のセッションで…

P4/Stratum活用に向けたプログラマブルスイッチの実装・検討
武井 勇樹(NTT)



データプレーン プログラマビリティ「3つの視点」

データプレーンプログラミングは普及するのか？

どこまで自作するのか？できるのか？
サポートしてくれる人はいるのか？

プログラマブルな Switch ASIC は
この先、生き残り進化していくのか？

プログラマブルな
Switch ASIC は生き残るのか？

プログラマブルな Switch ASIC は生き残るのか？

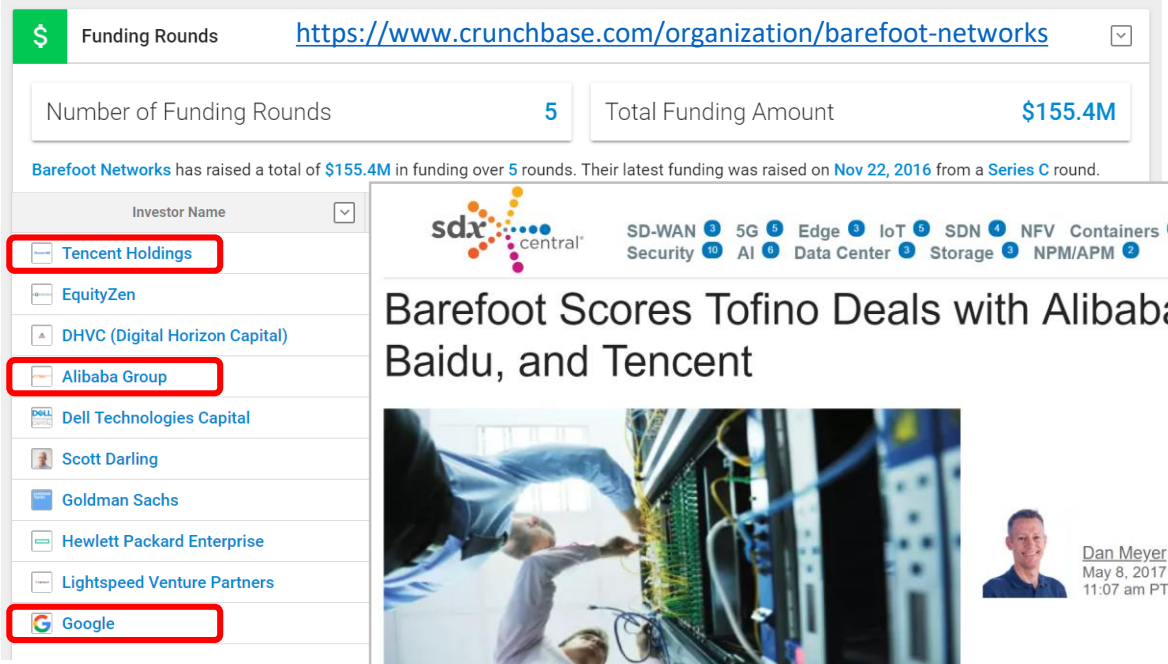
開発コスト（膨大）＜ ASIC単価 × 出荷数

⬇ASIC単価 ＝ 開発コスト（膨大）÷ 出荷数⬆

生き残るためには「数」が重要

「数」を増やすために必要な事

ユーザー企業による利用・投資



https://www.sdxcentral.com/articles/news/barefoot-scores-tofino-deals-with-alibaba-baidu-and-tencent/2017/05/

ネットワーク機器ベンダーに採用

- Cisco
- Arista

ODM

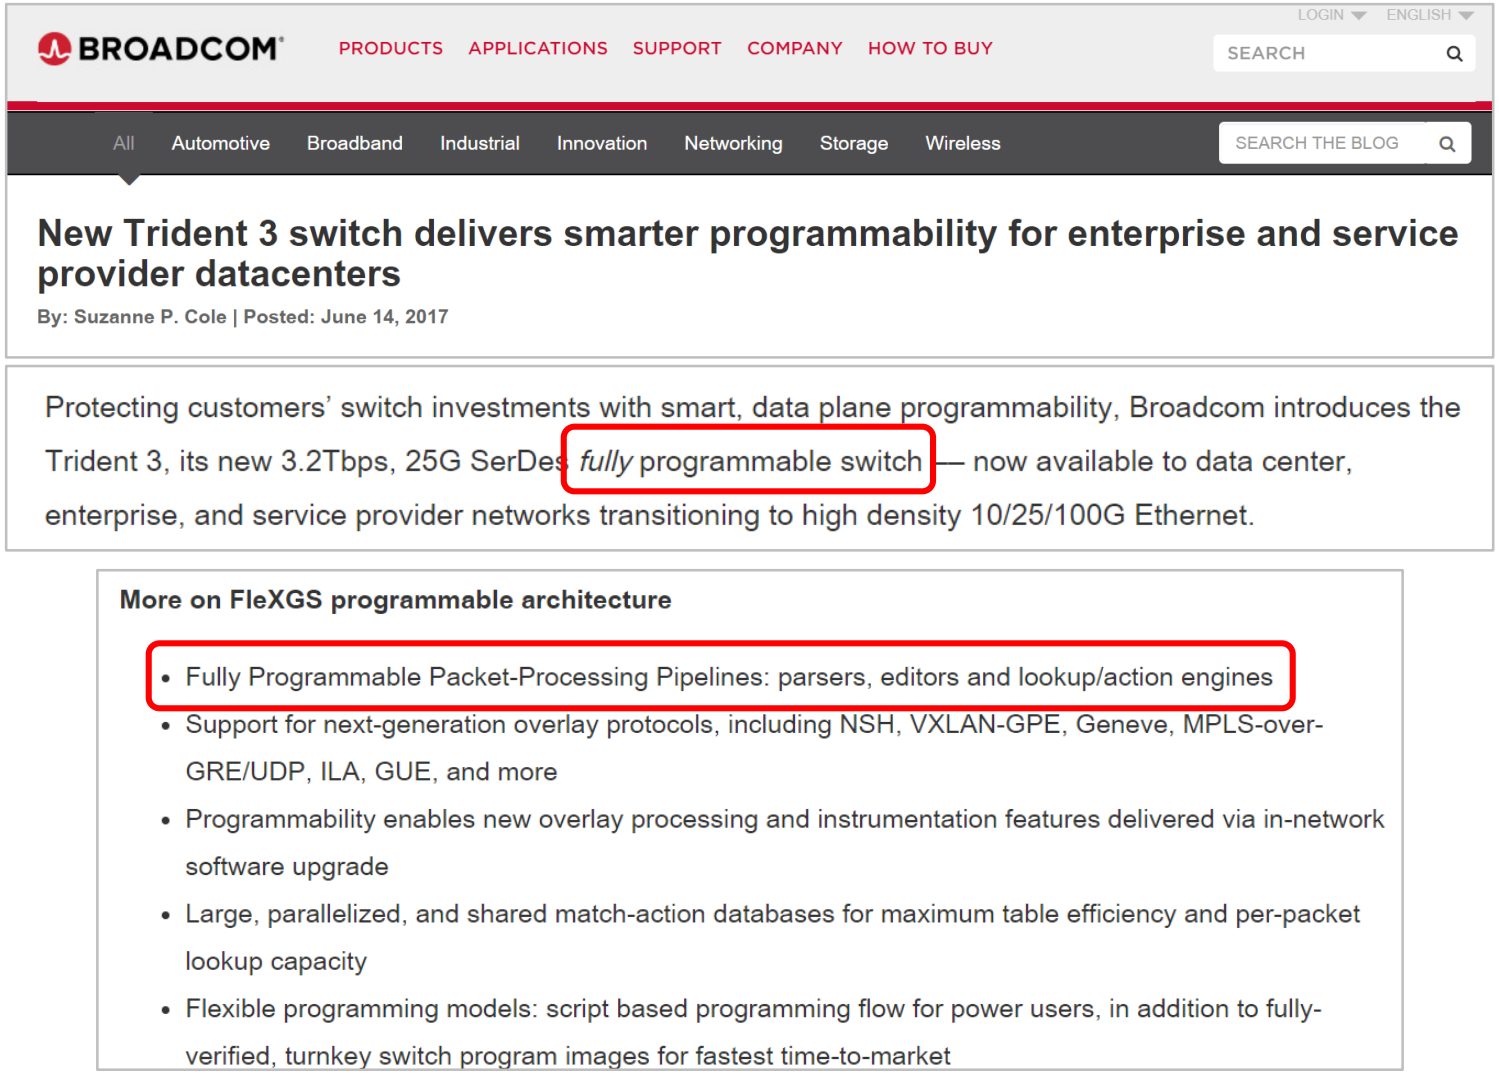
BareMetal Switch

Edge-corE　Inventec　WNC Wistron NeWeb Corp.

https://www.barefootnetworks.com/products/getting-started/

Barefoot Tofino ASIC の状況

プログラマビリティはASICの基本機能に



BROADCOM PRODUCTS APPLICATIONS SUPPORT COMPANY HOW TO BUY

LOGIN ENGLISH SEARCH

All Automotive Broadband Industrial Innovation Networking Storage Wireless SEARCH THE BLOG

New Trident 3 switch delivers smarter programmability for enterprise and service provider datacenters

By: Suzanne P. Cole | Posted: June 14, 2017

Protecting customers' switch investments with smart, data plane programmability, Broadcom introduces the Trident 3, its new 3.2Tbps, 25G SerDes *fully* programmable switch — now available to data center, enterprise, and service provider networks transitioning to high density 10/25/100G Ethernet.

More on FleXGS programmable architecture

- Fully Programmable Packet-Processing Pipelines: parsers, editors and lookup/action engines
- Support for next-generation overlay protocols, including NSH, VXLAN-GPE, Geneve, MPLS-over-GRE/UDP, ILA, GUE, and more
- Programmability enables new overlay processing and instrumentation features delivered via in-network software upgrade
- Large, parallelized, and shared match-action databases for maximum table efficiency and per-packet lookup capacity
- Flexible programming models: script based programming flow for power users, in addition to fully-verified, turnkey switch program images for fastest time-to-market

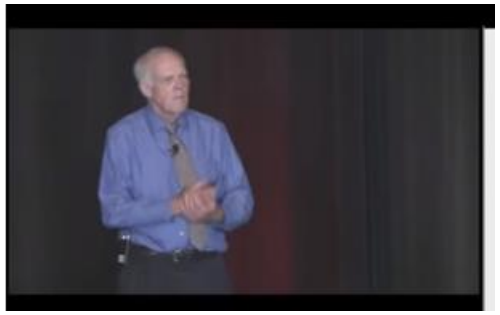
https://www.broadcom.com/blog/new-trident-3-switch-delivers-smarter-programmability-for-enterprise-and-service-provider-datacenters

"Programmable" を売りにしていない
Broadcomもプログラマビリティをサポート
（Juniper / Mellanox だけでなく）

Time To Market の重要性
先行者の圧力
（Cavium XPliant / Barefoot Tofino etc.）

プログラマブルな
Switch ASIC 進化の可能性

ドメイン特化型アーキテクチャの必要性



"A New Golden Age for Computer Architecture:
Domain-Specific Hardware/Software Co-Design,
Enhanced Security, Open Instruction Sets, and Agile Chip Development,"
Hennessy and David Patterson Deliver Turing Lecture at ISCA 2018
https://www.acm.org/hennessy-patterson-turing-lecture

Fundamental Changes in Technology

- Technology
  - End of Dennard scaling: power becomes the key constraint
  - Ending of Moore's Law: transistors improvement slows
- Architectural
  - Limitation and inefficiencies in exploiting instruction level parallelism end the uniprocessor era in 2004
  - Amdahl's Law and its implications end "easy" multicore era
- Products
  - PC/Server⇨ IoT, Mobile/Cloud

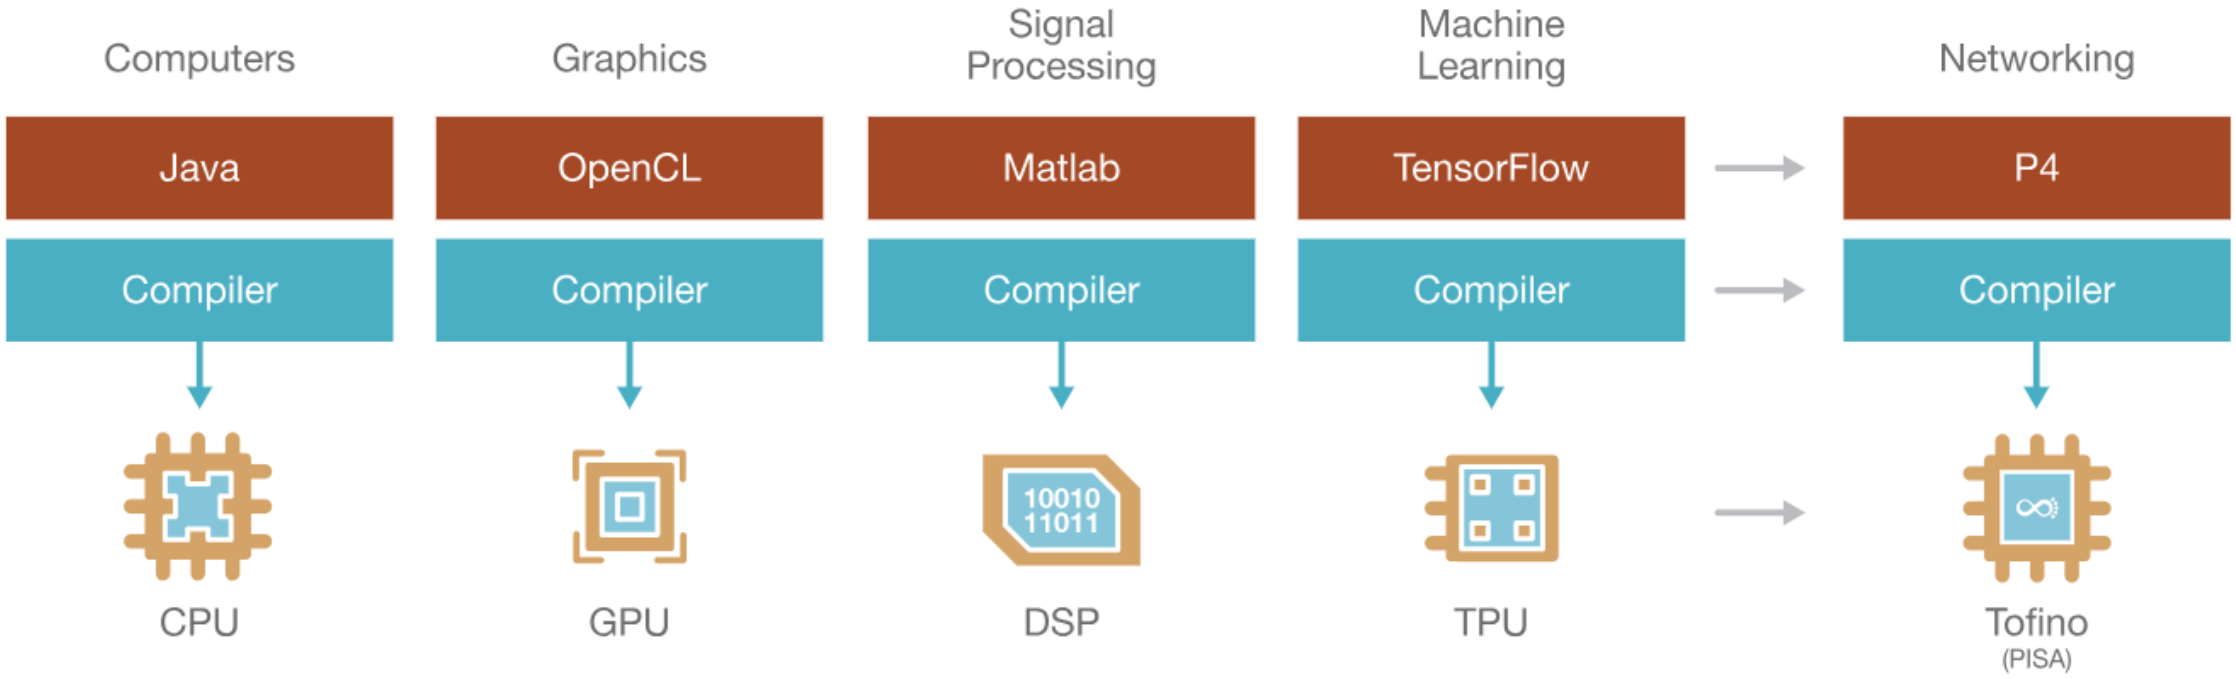
21

Domain Specific Architectures (DSAs)

- Achieve higher efficiency by tailoring the architecture to characteristics of the domain
  - Not one application, but a domain of applications
    -Different from strict ASIC
  - Requires more domain-specific knowledge then general purpose processors need
- Examples:
  - Neural network processors for machine learning
  - GPUs for graphics, virtual reality
  - Programmable network switches and interfaces

33

Switch ASIC 進化の可能性



Reference: https://www.barefootnetworks.com/technology/

「パケット転送」以外のユースケースへの適用

Key-value store

NetCache : Balancing Key-Value Stores with Fast In-Network Caching Key-value stores power online services.

Jin, Xin; Li, Xiaozhou; Zhang, Haoyu; Soule, Robert; Lee, Jeongkeun; Foster, Nate; Kim, Changhoon; Stoica, I. (2017). Sosp, (Figure 1), 121?136. https://doi.org/10.1145/3132747.3132764

Map Reduce

Network Map Reduce.

Song, H., Gong, J., & Chen, H. (2016).
Retrieved from http://arxiv.org/abs/1609.02982

DAIET ... Data Aggregation In nETwork

https://sands.kaust.edu.sa/daiet/
Poster: Amedeo Sapio, Ibrahim Abdelaziz, Marco Canini and Panos Kalnis.
“DAIET: A System for Data Aggregation Inside the Network.”
In ACM Symposium on Cloud Computing 2017, Santa Clara, California, USA.

コンセンサス（合意）

Paxos Made Switch-y.

Dang, H. T., Canini, M., Pedone, F., & Soule, R. (2016).
ACM SIGCOMM Computer Communication Review, 46(1), 18~24. https://doi.org/10.1145/2935634.2935638

Eris: Coordination-Free Consistent Transactions Using In-Network Concurrency Control.

Li, J., Michael, E., K Ports, D. R., & K, D. R. (2017).
Sosp. https://doi.org/10.1145/3132747.3132751

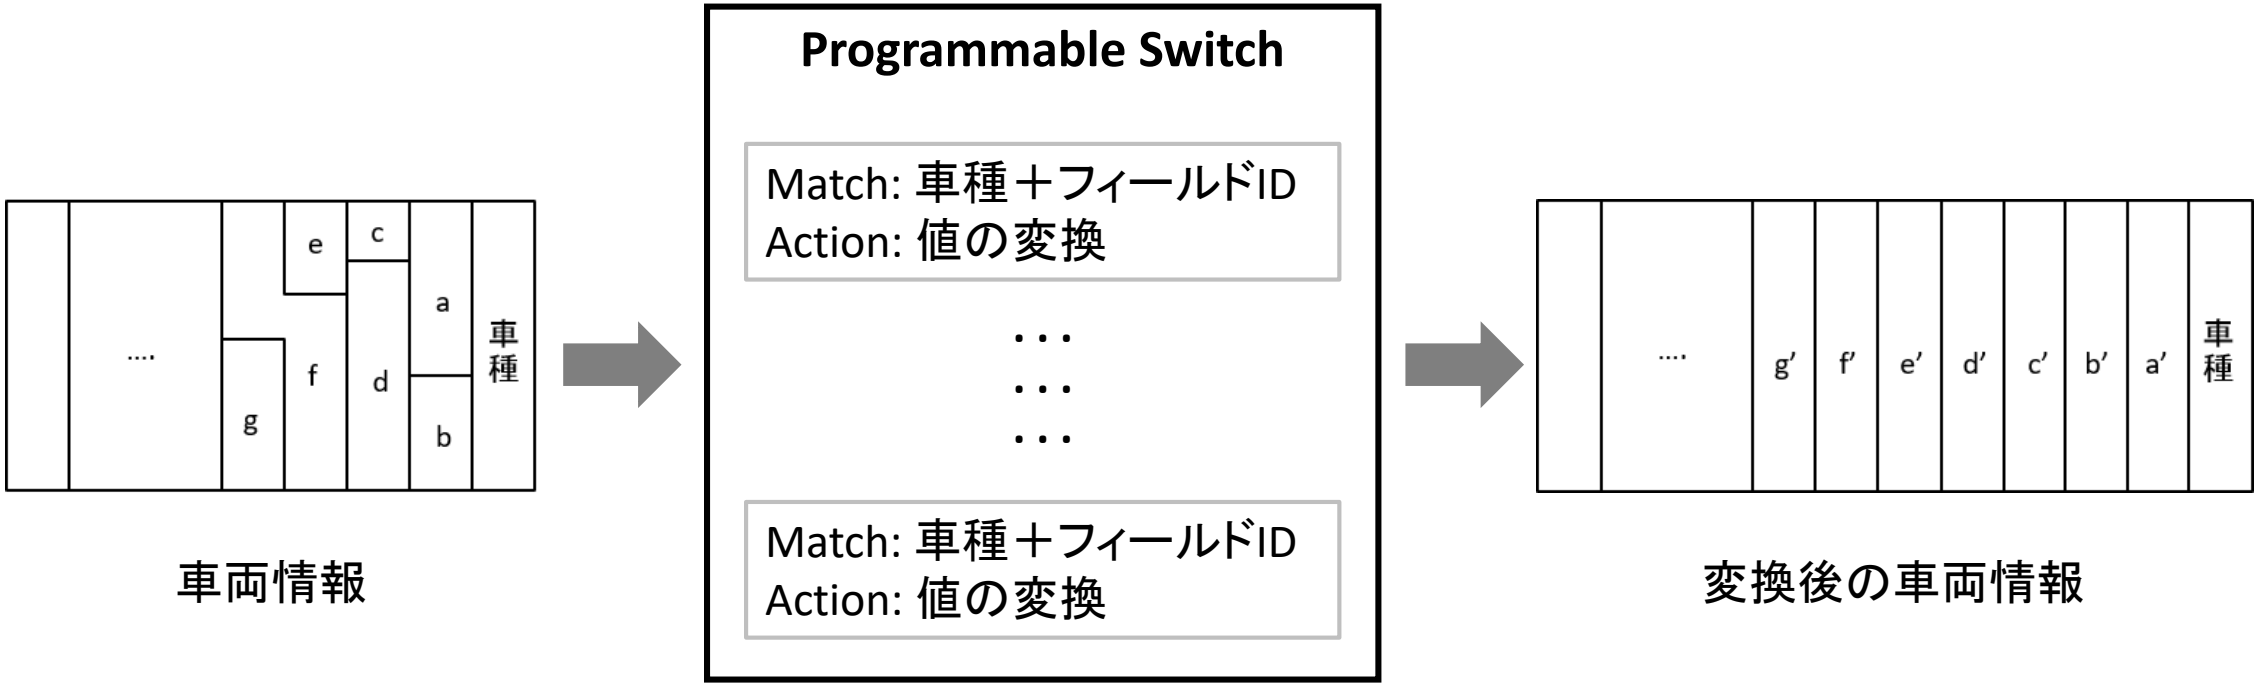
NetPaxos: Consensus at Network Speed.

Dang, H. T., Sciascia, D., Canini, M., Pedone, F., & Soule, R. (2015).
Proceedings of the 1st ACM Sigcomm Symposium on SDN Research (SOSR), 5:1--5:7.
https://doi.org/10.1145/2774993.2774999

NetChain: Scale-Free Sub-RTT Coordination.

Nsdi, 35~49. Retrieved from http://dl.acm.org/citation.cfm?doid=3132747.3132761

CANデータ物理量変換（試作）



BYTEアライメントではないデータの超高速ストリーム処理

IRTF Computing in the Network (COIN)

Our goal:

Foster research in computing in the network to improve performance and allow new networked applications

https://trac.ietf.org/trac/irtf/attachment/wiki/coin/coin_ietf103_chair_slides%20-%20Finalv3.pptx

性能の向上と新たなネットワーク化されたアプリケーションを実現可能にすべく
ネットワーク内コンピューティングの研究を育成・促進する

Initial Meeting: IETF 103 Bangkok（2018年11月9日）
Wiki: https://trac.ietf.org/trac/irtf/wiki/coin
Mailing List: https://www.irtf.org/mailman/listinfo/coin

TOYOTA INFOTECH

アーキテクチャの違いによる制約

チューリング完全（ではない）

メモリサイズの制約

演算処理の制約（例：浮動小数点）

パケット毎に適用可能な処理（Action）制約

複数パケットにまたがる処理の難しさ

プログラミングモデルやアーキテクチャによる制約を意識した
適用場所（アプリケーション）の研究が必要

今後の予定

チャーターの議論（メーリングリストなどを通じて）

Interim Meeting の実施（未定：2019年1月頃？）

Research Group としての承認取得

Meeting at IETF104 Plague（RG承認された場合）

まとめ

Data Plane Programmability 現状と展望

現在

商用利用が可能な
環境の整備が進む

オープンなプログラム言語の普及
商用ベンダーのサポート
商用NOSへ部分的適用も可能に

近未来

プログラマビリティは
ASIC の標準機能に

ASIC仕様としてプログラマブルな
部分が増加傾向

将来

パケット転送以外
の分野への適用も

アカデミアでの研究は盛んに
Switch ASIC の進化
GPGPUと同じ道をたどれるか？