Microsoft

FPGAとネットワークインフラストラクチャ

日本マイクロソフト株式会社
業務執行役員 ナショナル テクノロジー オフィサー

田丸 健三郎





世界最大のインフラストラクチャー

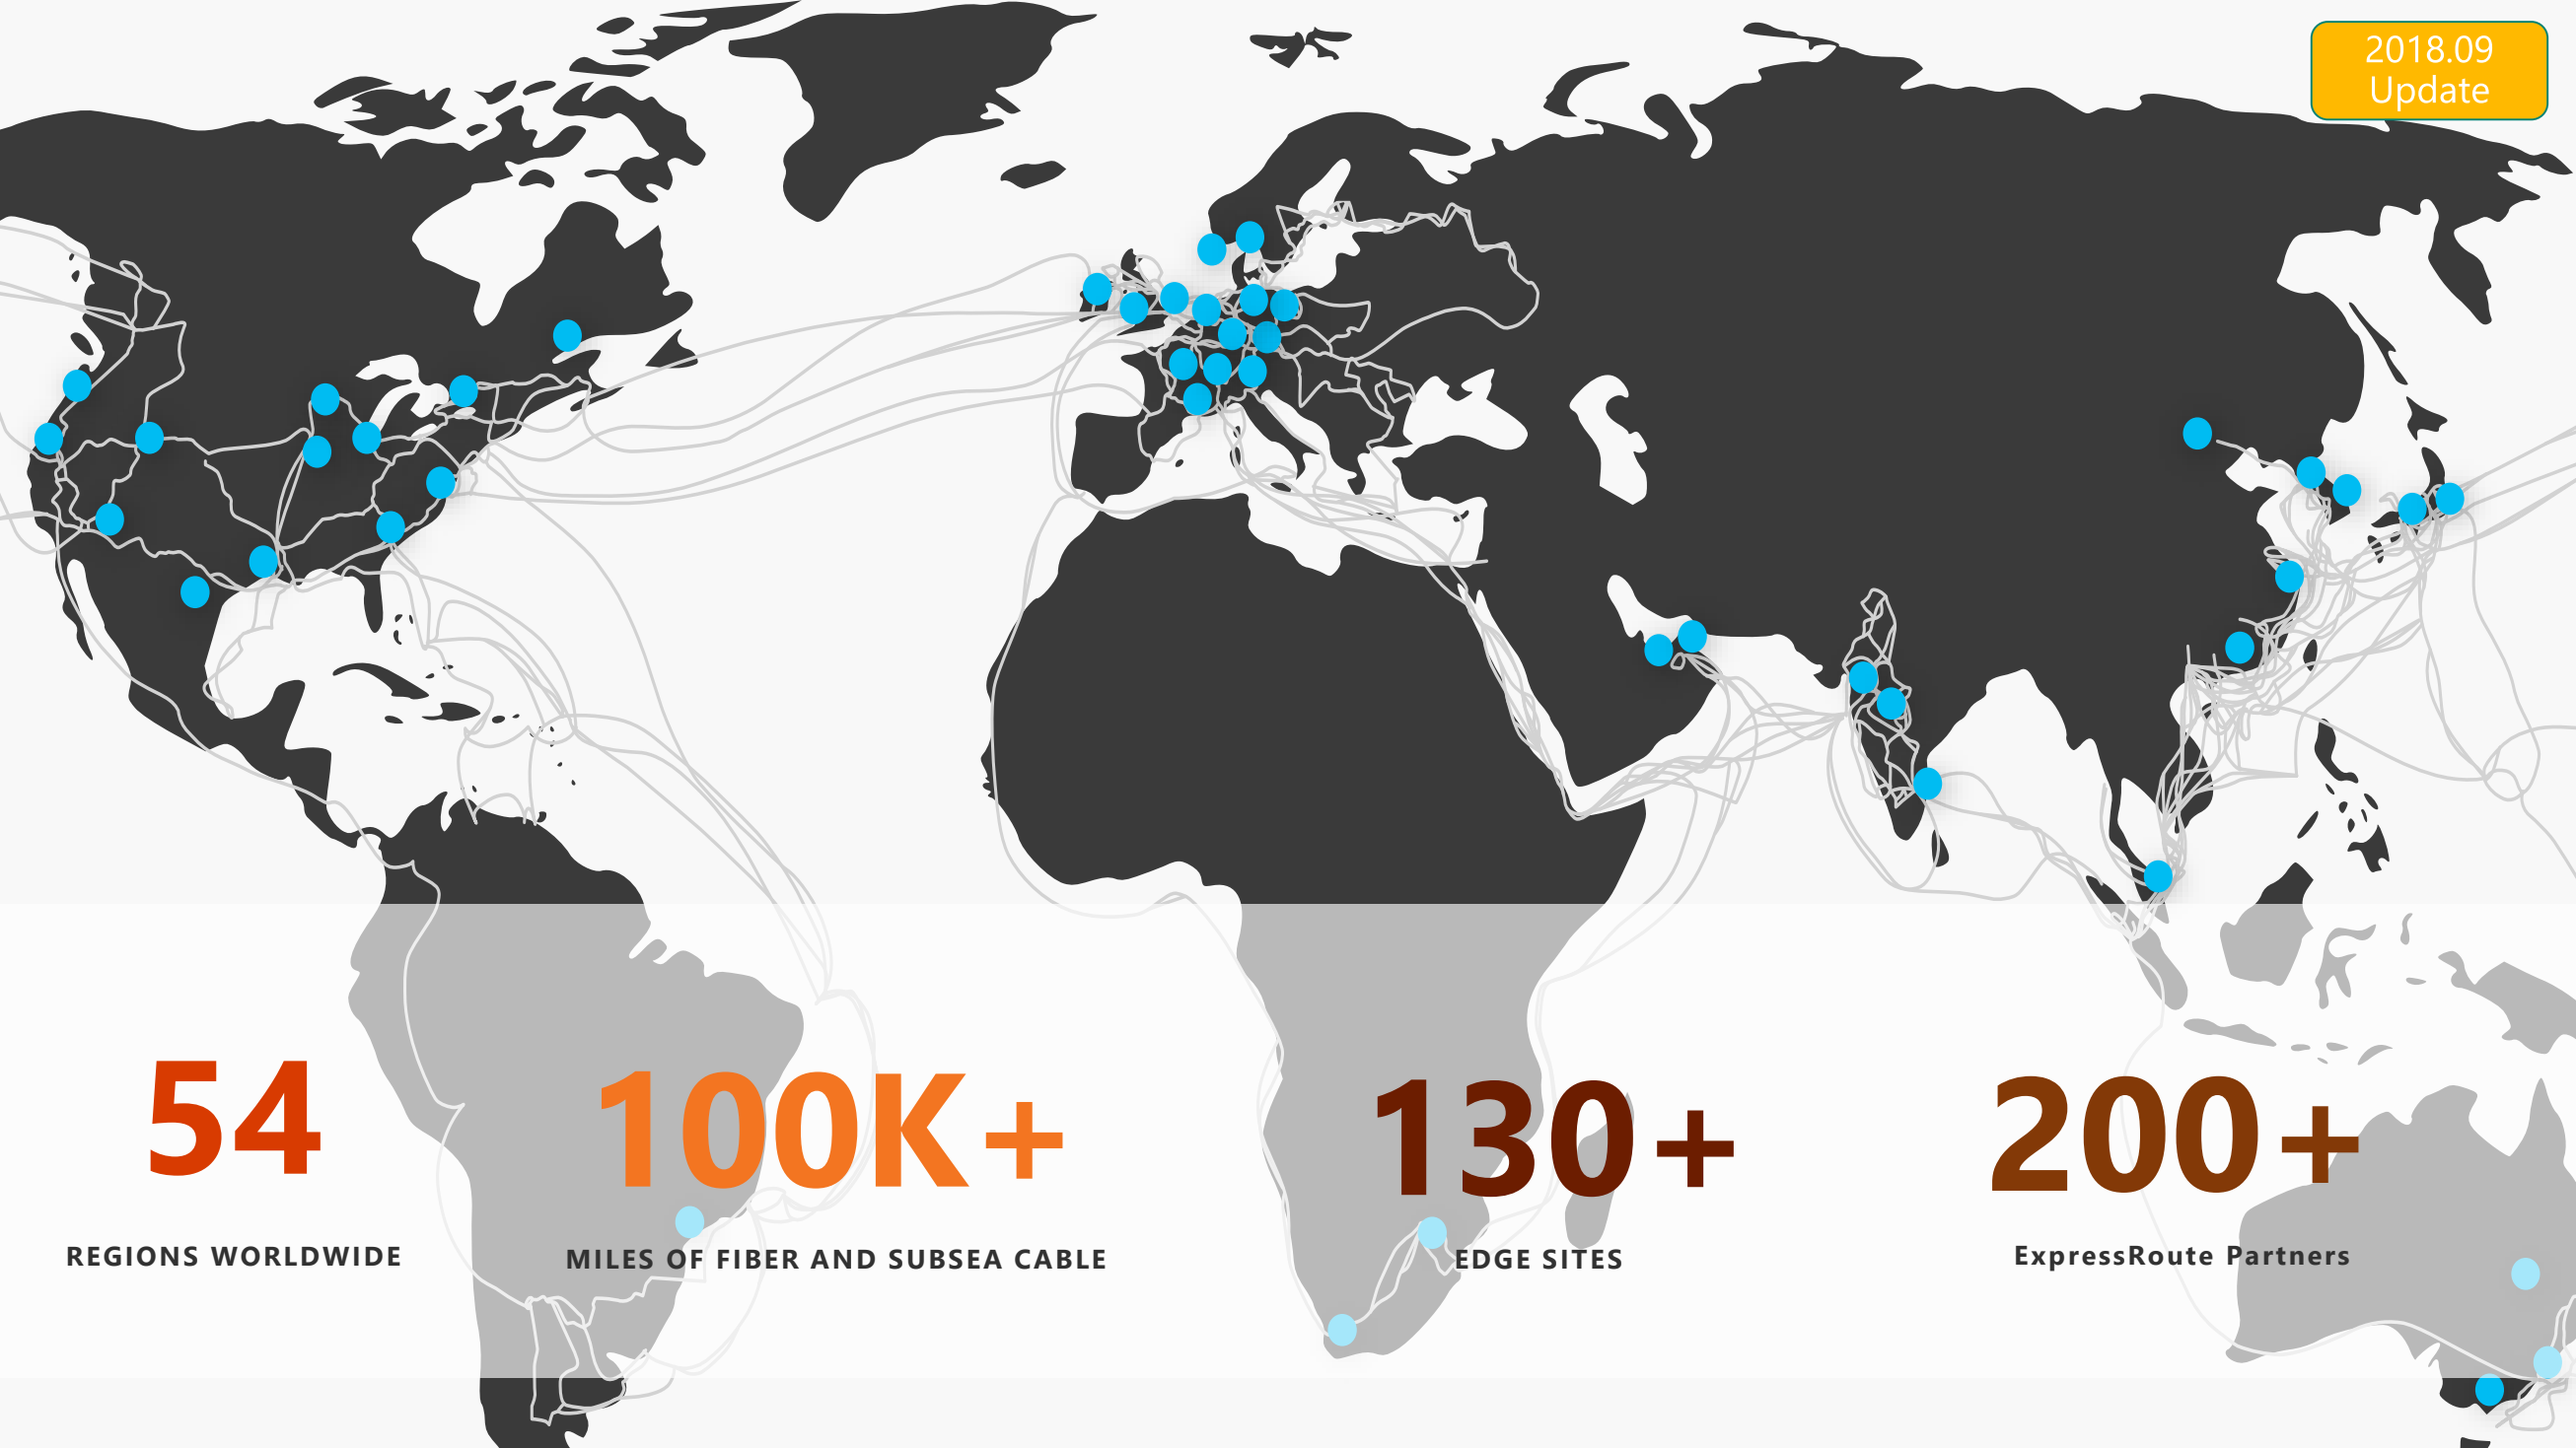
2018.06 Update

54 リージョン 世界全域

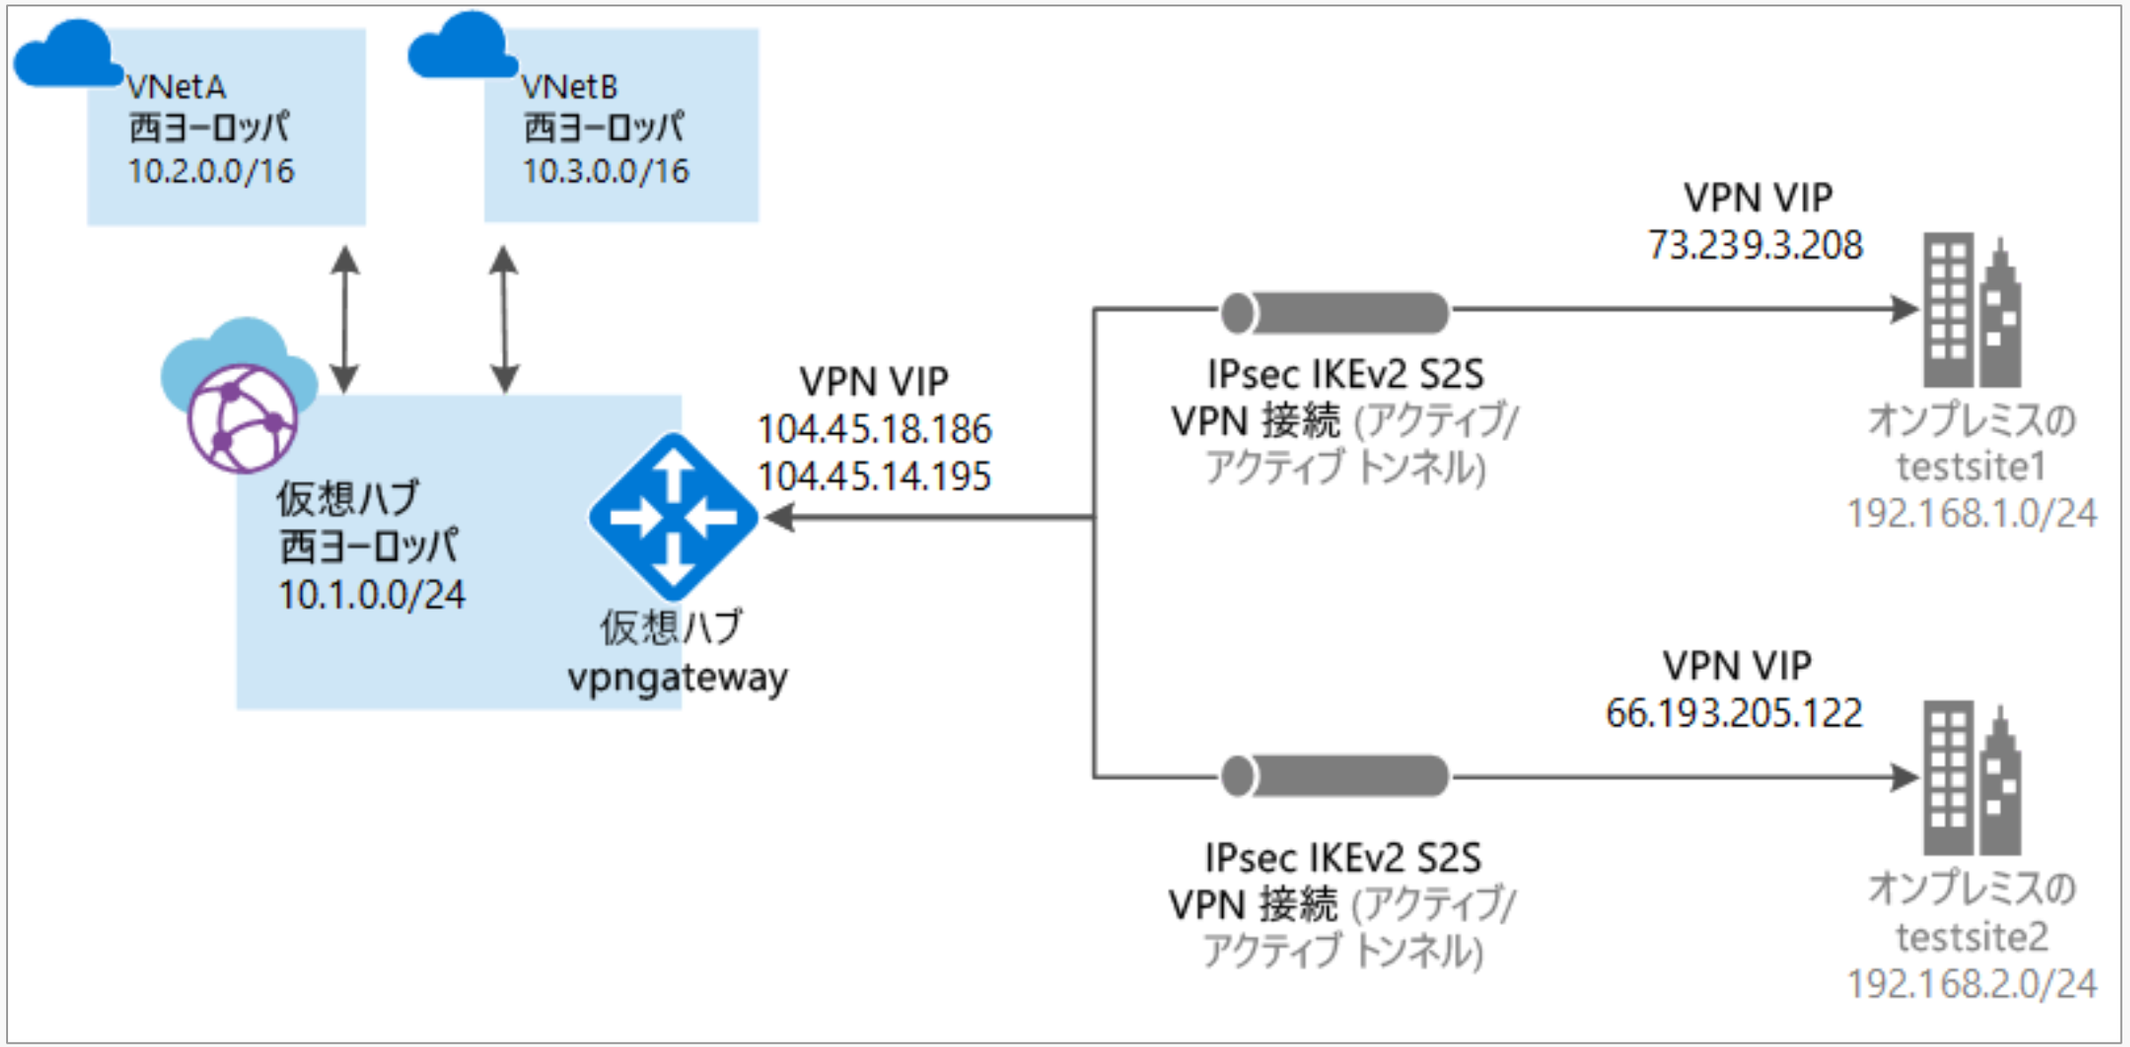
140 利用可能な国は 140 か国

2018.06 updates




2018.09
Update
54
REGIONS WORLDWIDE
100K+
MILES OF FIBER AND SUBSEA CABLE
130+
EDGE SITES
200+
ExpressRoute Partners

Azure Virtual WAN



The Azure Platform

Platform Services

Security & Management
- Portal
- Azure Active Directory
- Azure AD B2C
- Multi-Factor Authentication
- Automation
- Scheduler
- Key Vault
- Store/ Marketplace
- VM Image Gallery & VM Depot

Services Compute
- Cloud Services
- Service Fabric
- Batch
- RemoteApp

Integration
- Storage Queues
- BizTalk Services
- Hybrid Connections
- Service Bus

Media & CDN
- Media Services
- Content Delivery Network (CDN)

Web and Mobile
- Web Apps
- API Apps
- Mobile Apps
- Logic Apps
- API Management
- Notification Hubs

Developer Services
- Visual Studio
- Azure SDK
- VS Online
- App Insights

Data
- SQL Database
- Data Warehouse
- DocumentDB
- Redis Cache
- Azure Search
- Storage Tables

Analytics & IoT
- HDInsight
- Machine Learning
- Stream Analytics
- Data Lake
- Data Factory
- Event Hubs
- Data Catalog
- IoT Hub
- Mobile Engagement

Hybrid Operations
- Azure AD Health Monitoring
- AD Privileged Identity Management
- Domain Services
- Backup
- Operational Analytics
- Import/Export
- Azure Site Recovery
- StorSimple

Infrastructure Services

OS/Server Compute
- Virtual Machines
- Container Service

Storage
- BLOB Storage
- Azure Files
- Premium Storage

Networking
- Virtual Network
- Load Balancer
- DNS
- Express Route
- Traffic Manager
- VPN Gateway
- App Gateway

Datacenter Infrastructure (34 Regions, 26 Generally Available)



Azure Cosmos DB

The world's first globally distributed database service



動画へのタグ付け


Basketball
Skiing
Ice Skating
Wedding Reception
Non-music Performance
Baseball
Swimming
Birthday Celebration
Wedding Ceremony
Music Performance
Soccer
Biking
Graduation
Wedding Dance
Parade
Bird
Cat
Dog
Beach
Playground


surfing:0.1114
swimming:0.0568
kayaking:0.0534

動画から文章へ



A car is running



A man is cutting a piece of meat



A man is performing on a stage



A man is riding a bike



A man is singing



A panda is walking

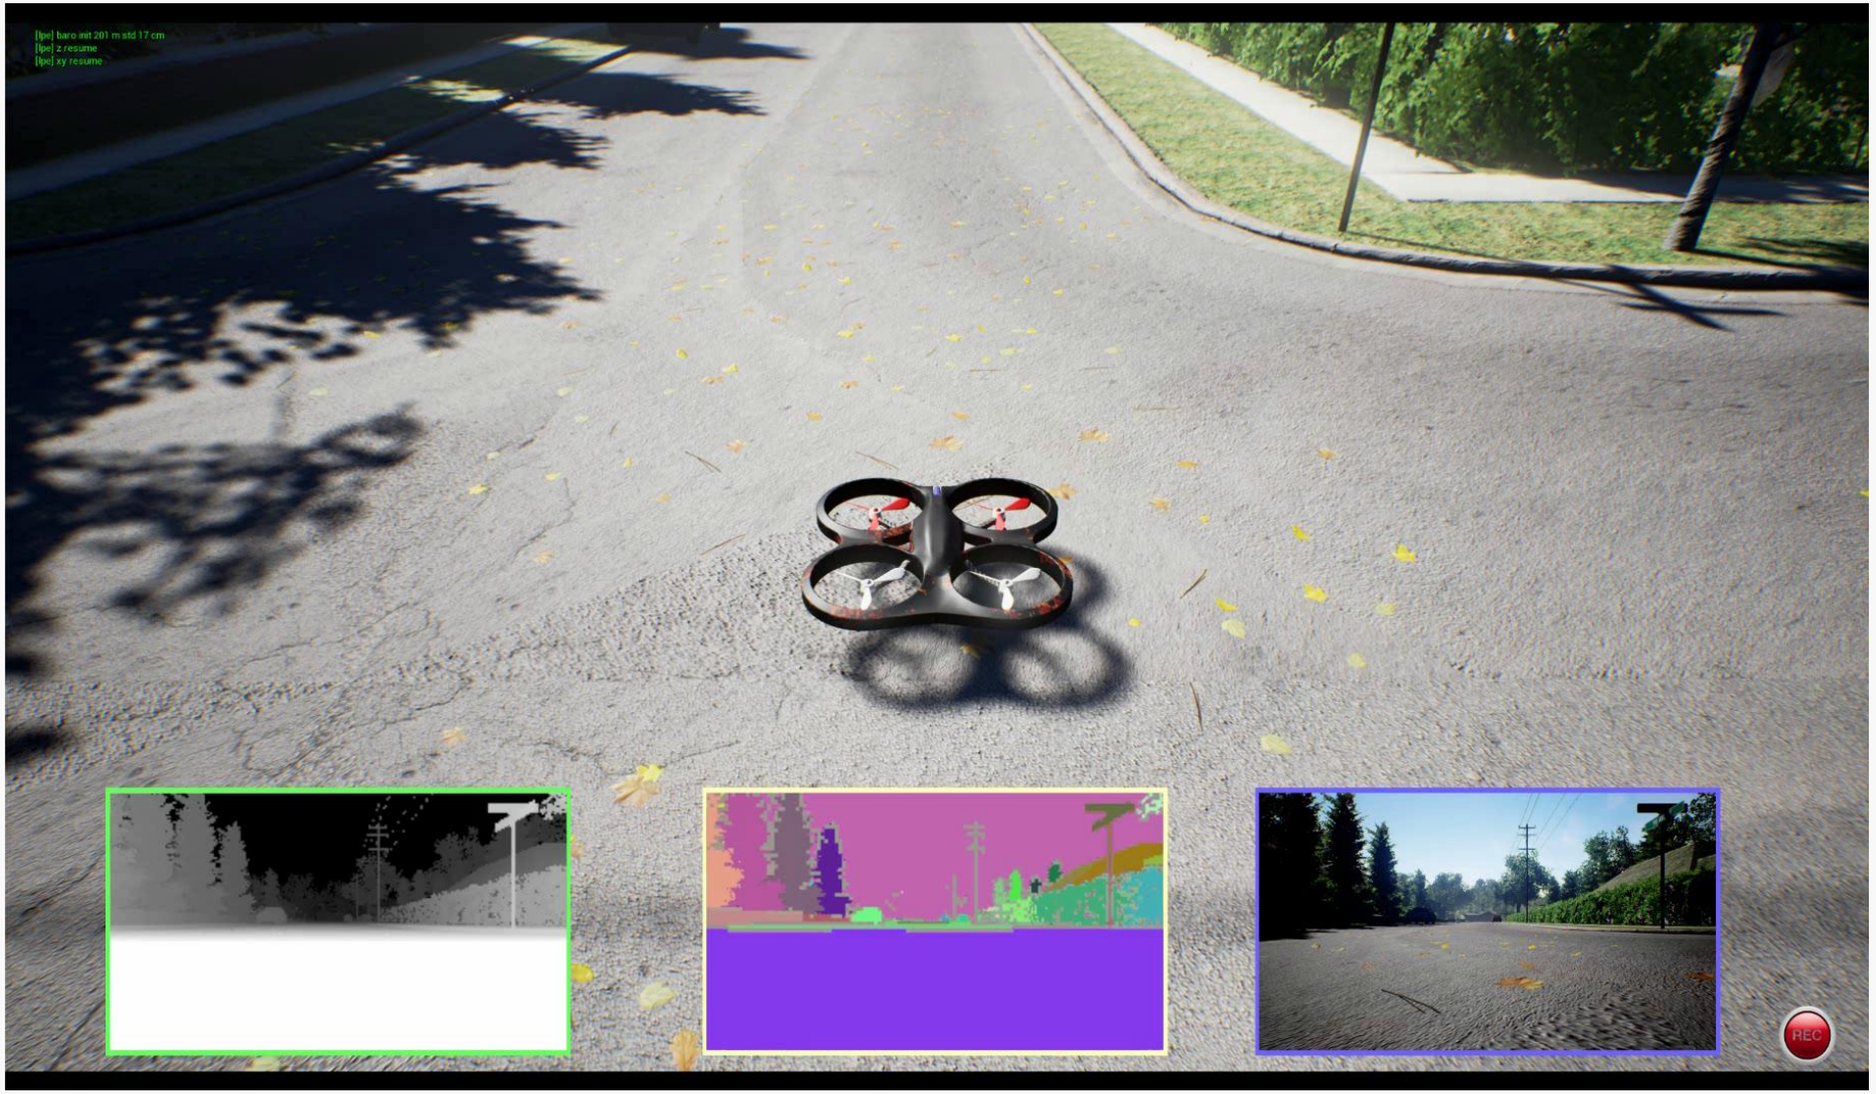


A woman is riding a horse



A man is flying in a field

深層学習と仮想環境



Microsoft Cognitive Services



Vision	Speech	Language	Knowledge	Search
Video Indexer	Speaker Recognition	Text Analytics	QnA Maker	Bing Entity Search
Computer Vision	Bing Speech	Bing Spell Check		Bing Autosuggest
Face	Translator Speech	Translator Text		Bing Search
Emotion	Unified Speech			Bing Statistics add-in
Content Moderator				Bing Visual Search

Customization

Custom Vision	Custom Speech	Language Understanding (LUIS)	Custom Decision	Bing Custom Search

課題となるのが

- ルーティング
- 帯域・遅延
- セキュリティ
- ML/DL

高度化し続ける **データ通信** への要求

変わるシステムアーキテクチャー

- アルゴリズムをもとにした開発からデータとAIによる学習・モデル化による実装への変革

データ収集・分析を前提としたサービスの増加

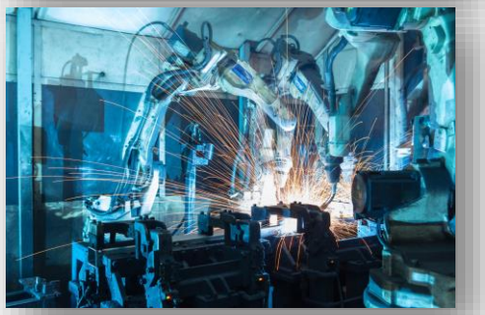
- 単一データから多種多様なデータの総合的活用へ

課題は・・

- シングルデータリポジトリの不在
- セキュリティとデータ通信の避けられない連携

多種多様な大規模データ









高まる リアルタイム AI への要求

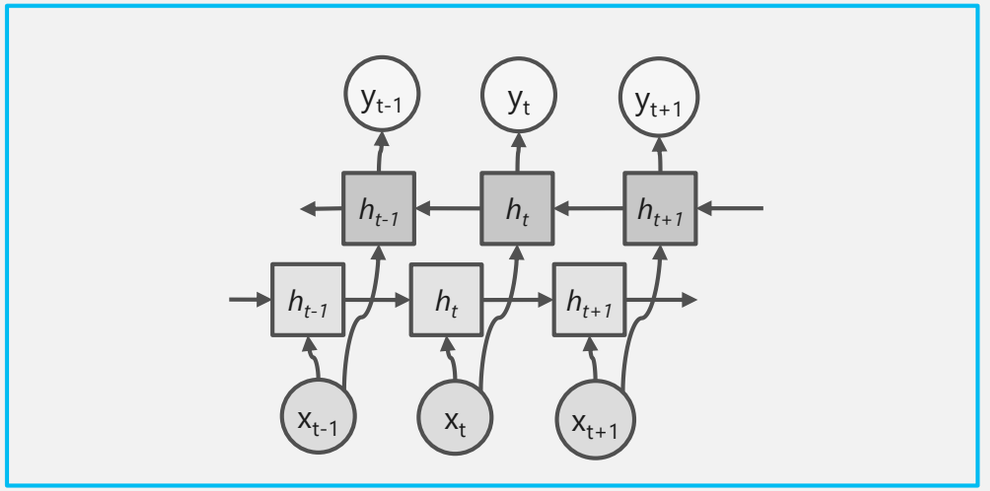
深層学習により得られた大きな進歩

- 画像処理
- 機械翻訳
- 音声認識
- QA
- 他

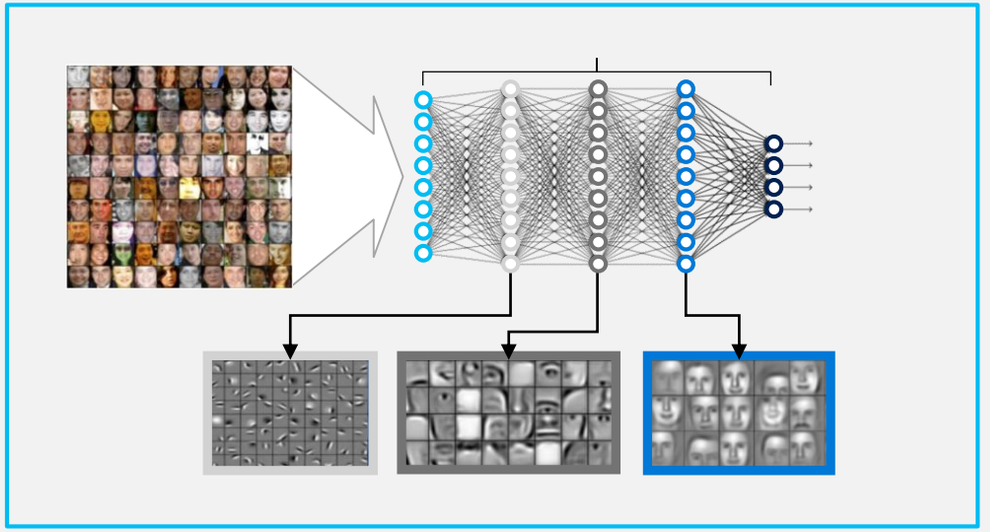
課題は・・

- オンラインサービスにおける運用、展開、そしてスケーラビリティ
- 遅延、帯域、コスト、処理能力
- CPUの進化を大幅に超える、サイズと複雑を増す対象

Recurrent Neural Networks



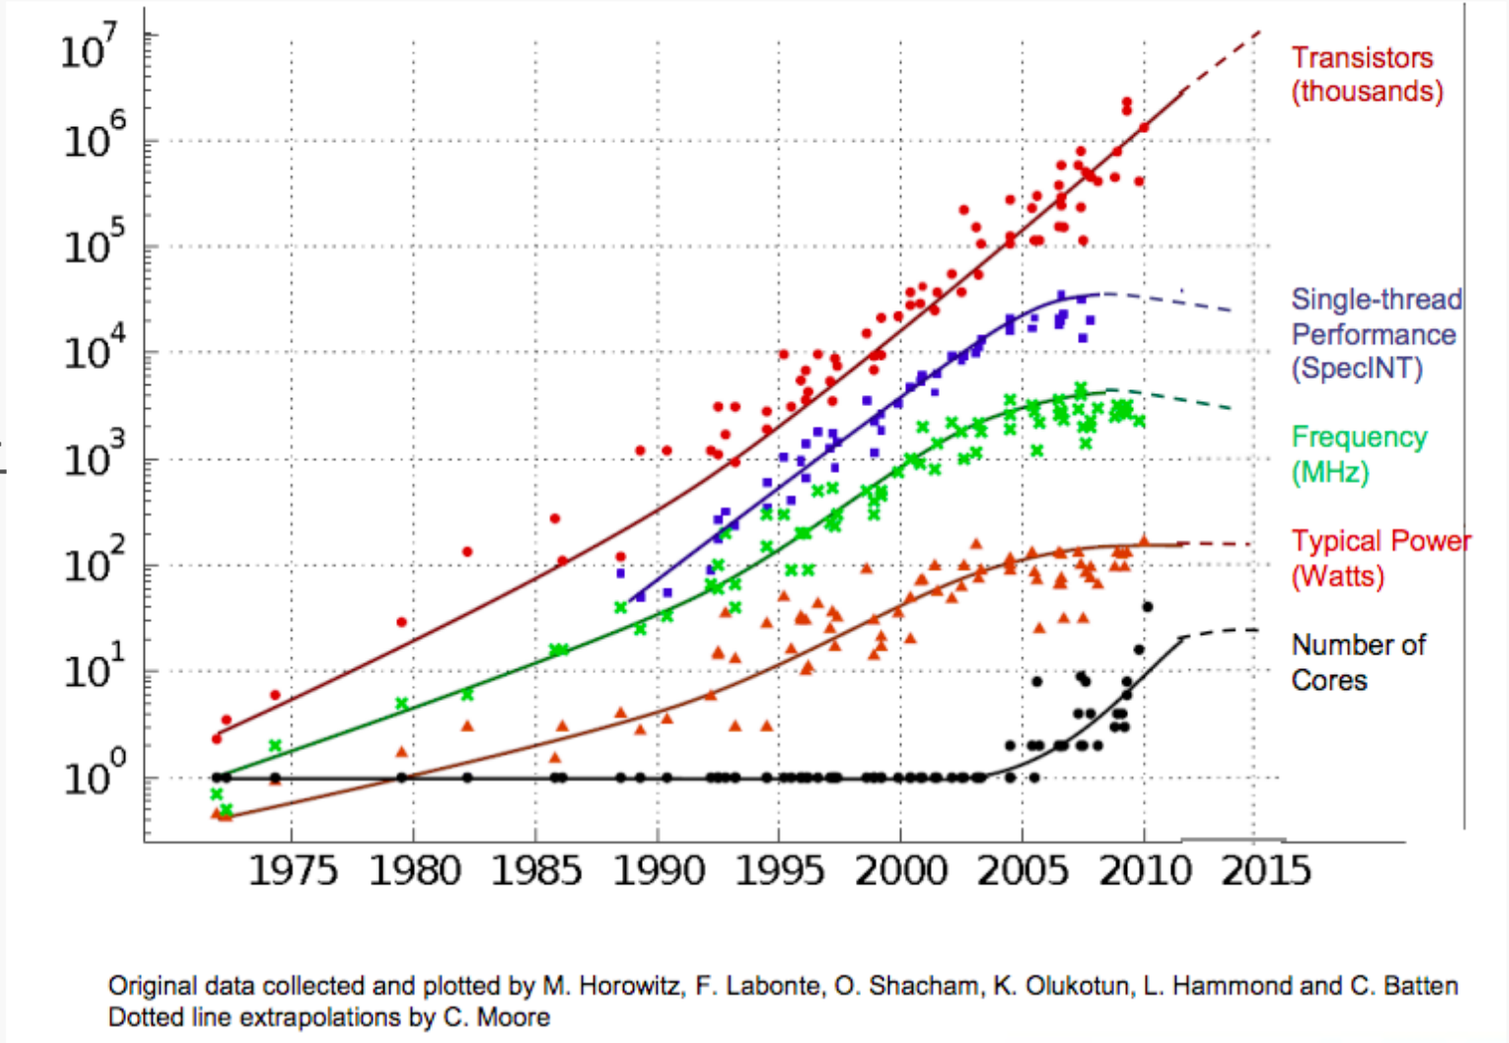
Convolutional Neural Networks



ハードウェア環境の変革
FPGAの活用

2010年ころ

- 有効なムーアの法則
  - より多くのコア
  - シングルスレッド
  - 緩やかになるパフォーマンスの向上
- 重要視されないデータセンターの高速化
- 旧来のマーケットで活躍するFPGA
  - 計算処理への活用についてはまだまだ未知数



高性能化を阻む熱とコストの問題

- 吸熱（排熱）の限界
  - 空気　　（1,000)
  - 石油　　（2,000)
  - 水　　（4,000）

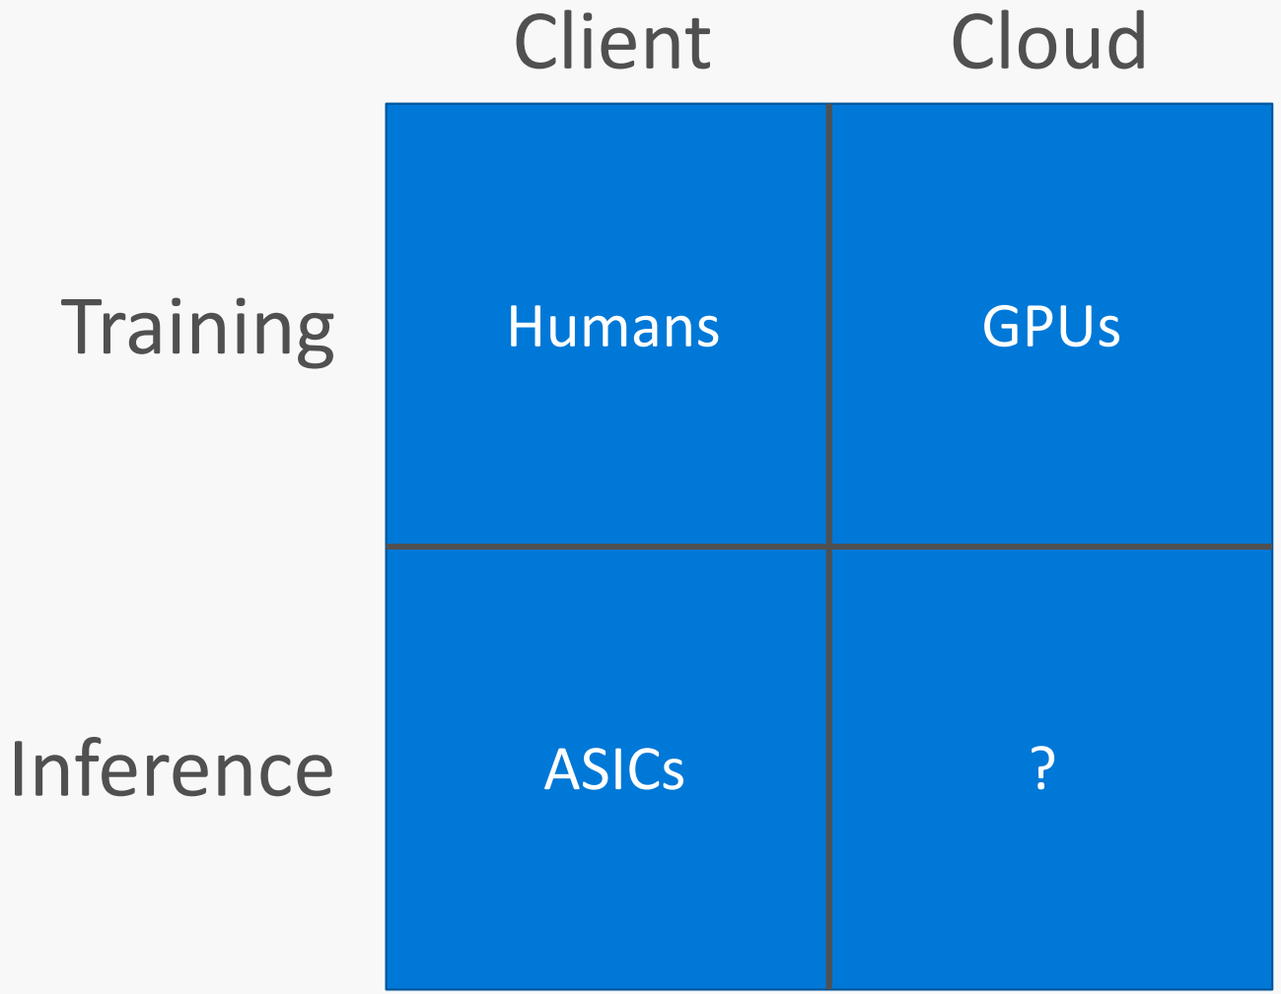
  <比熱容量>

- 30KW / Rack
- 150W ~ 200W / chip

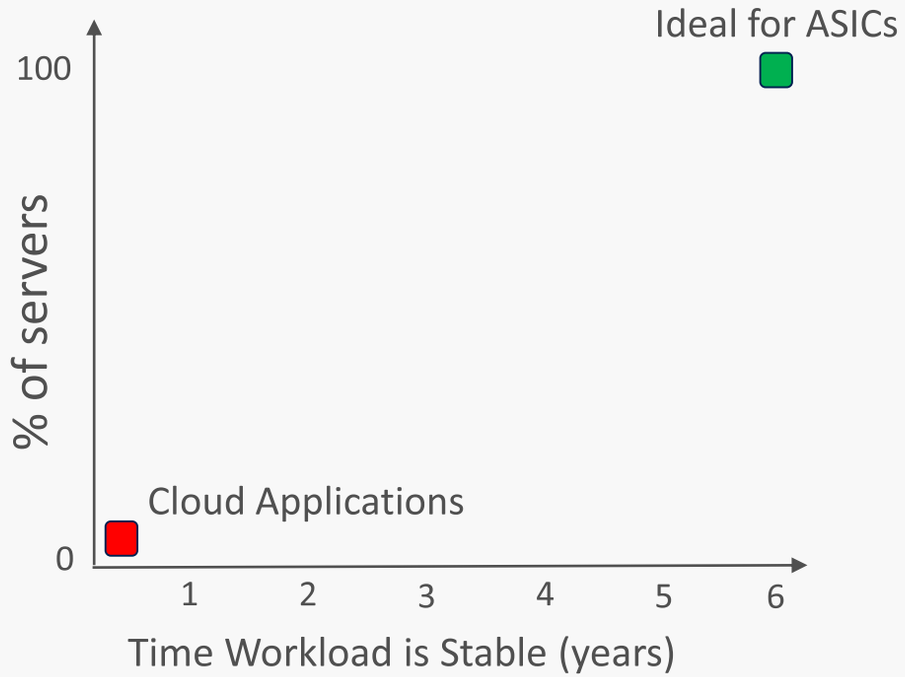


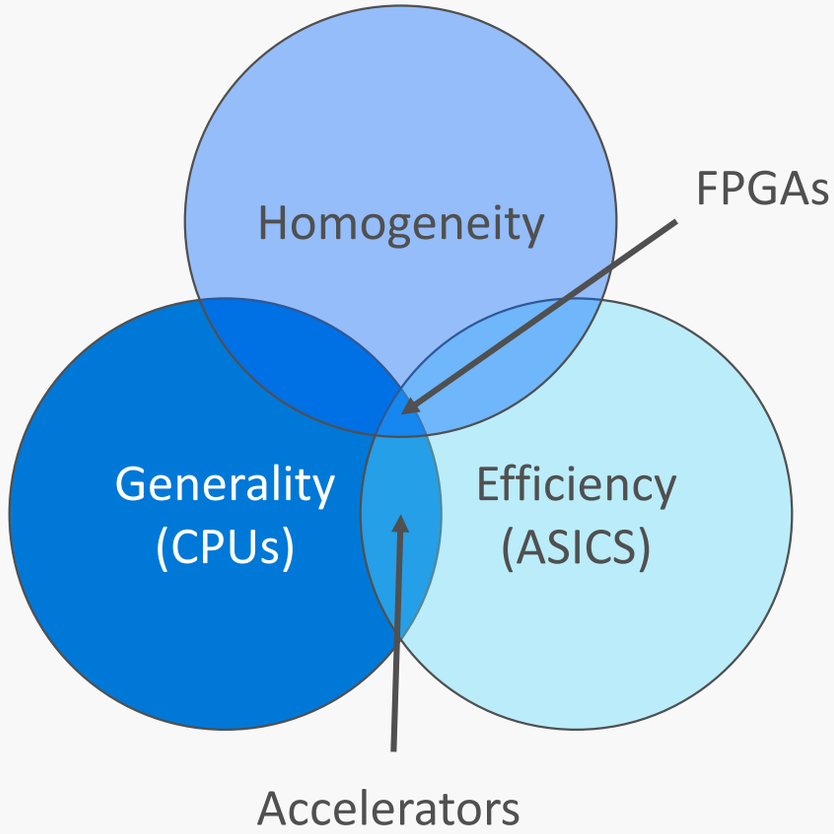





Client
Cloud
Training
Inference
Humans
GPUs
ASICs
?

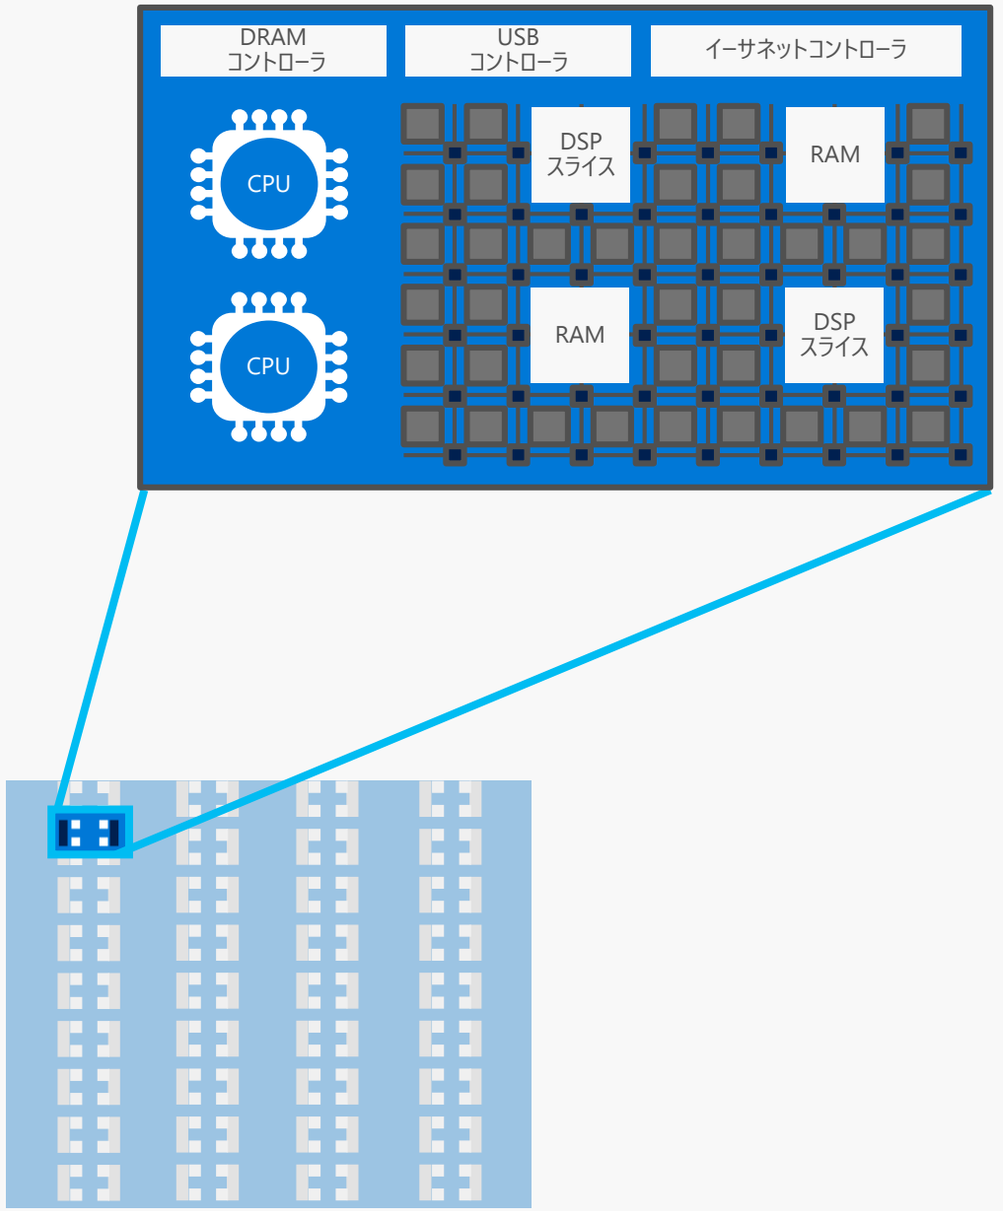
What Drives a Post-CPU “Enhanced” Cloud?





FPGA テクノロジ

- Field Programmable Gate Array
- プログラマブルハードウェア
  - 数秒で新しいイメージの書き込みが可能
- チップには大量のプログラマブルユニット
- 直接通信する特殊な回路をプログラミング
- FPGA チップは現在大規模な SoC という位置づけ
  - 数千の DSP ブロック、DRAM コントローラ、PCIeコントローラ、ARM コアなど



PGAの取り組み

2011

Catapult v0



2012

Catapult v1



2013

スケール v1



2014

Catapult v2



2015

本番展開

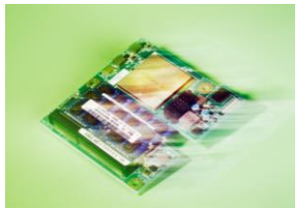


MICROSOFT SUPERCHARGES BING SEARCH WITH PROGRAMMABLE CHIPS

2016

Ignite

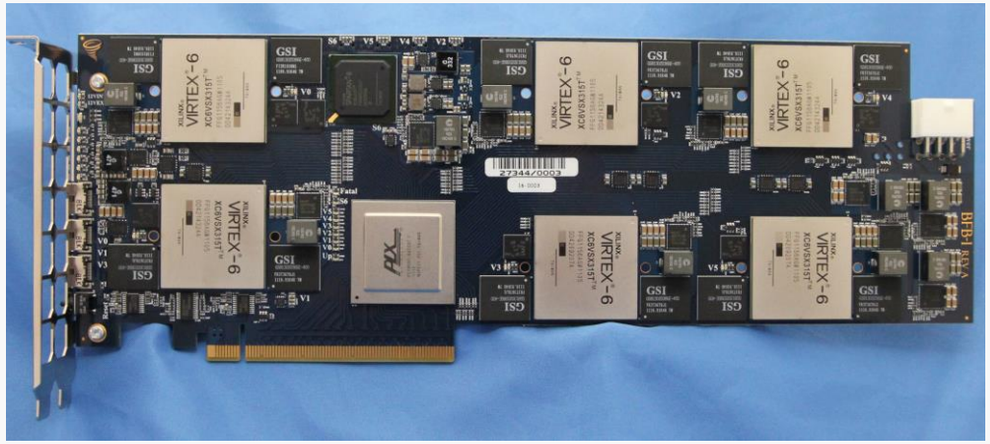
MICROSOFT BETS ITS FUTURE ON A REPROGRAMMABLE COMPUTER CHIP

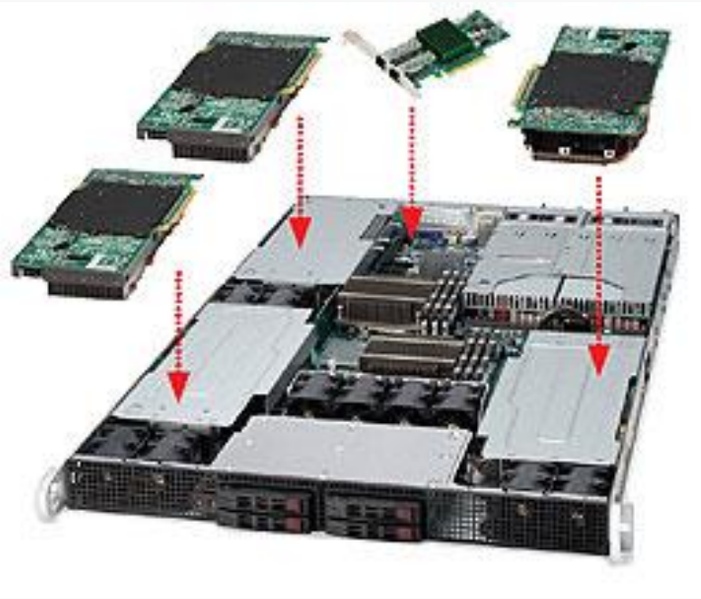


...

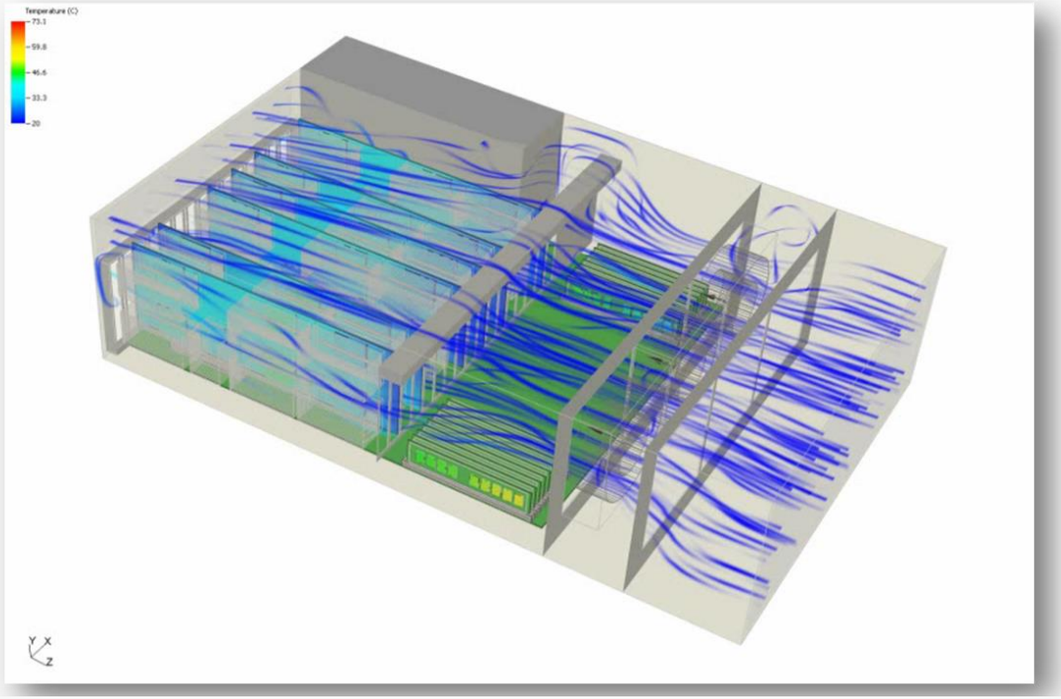
最初のトライ: v0

- 6 Xilinx LX240T FPGAs
- １つのラックに１つのアプライアンス
- 全てのサーバー間を1Gbで接続



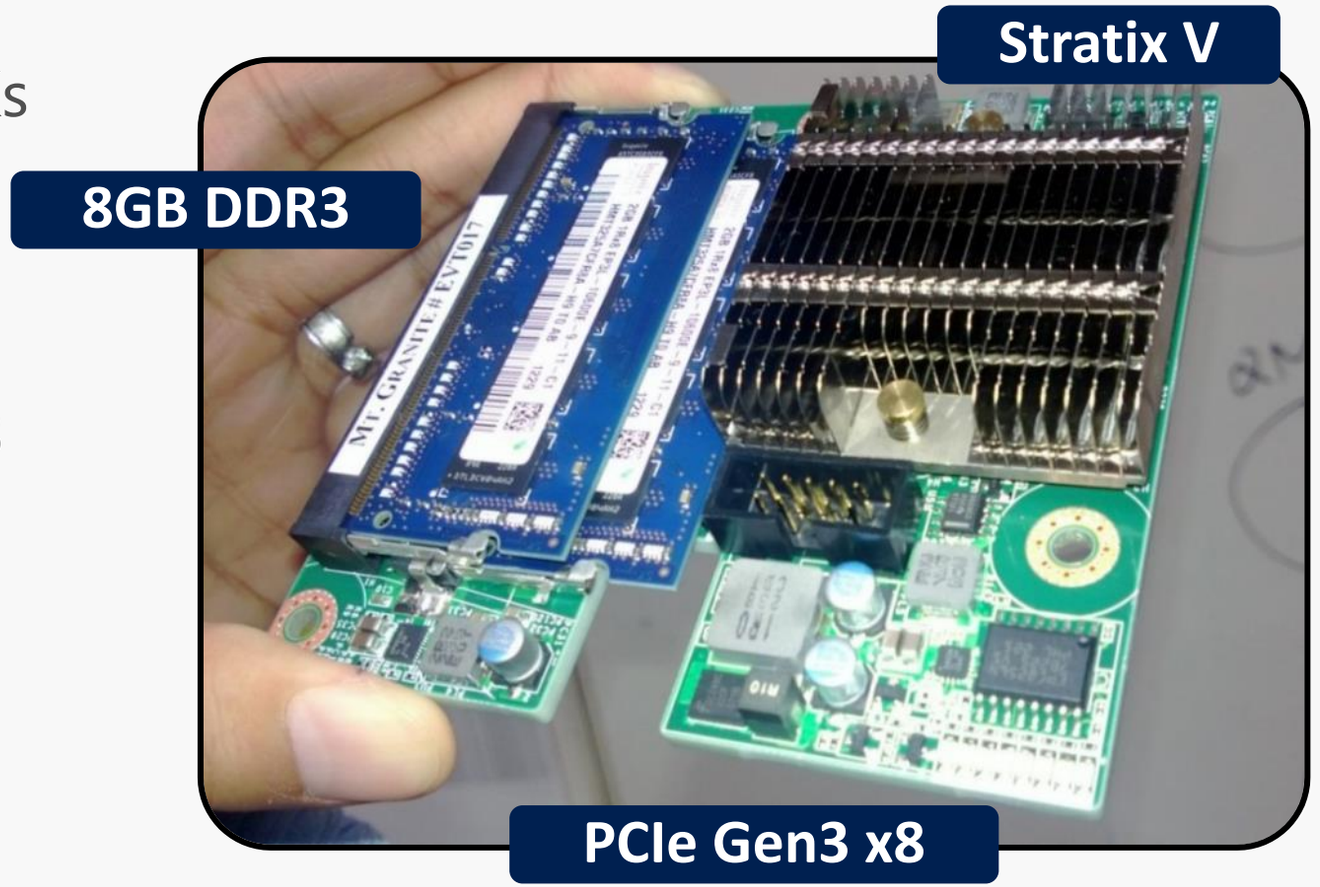


- 1U rack-mounted
- 2 x 10Ge ports
- 3 x16 PCIe slots
- 12 Intel Westmere cores (2 sockets)



セカンドトライ: V1

- Altera Stratix V D5
- 172.6K ALMs, 2014 M20Ks
  - 457KLEs
  - 1 KLE == ~12K gates
  - M20K w/2.5KB SRAM
- PCIe Gen 2 x8, 8GB DDR3
- FPGA間を20Gbで接続

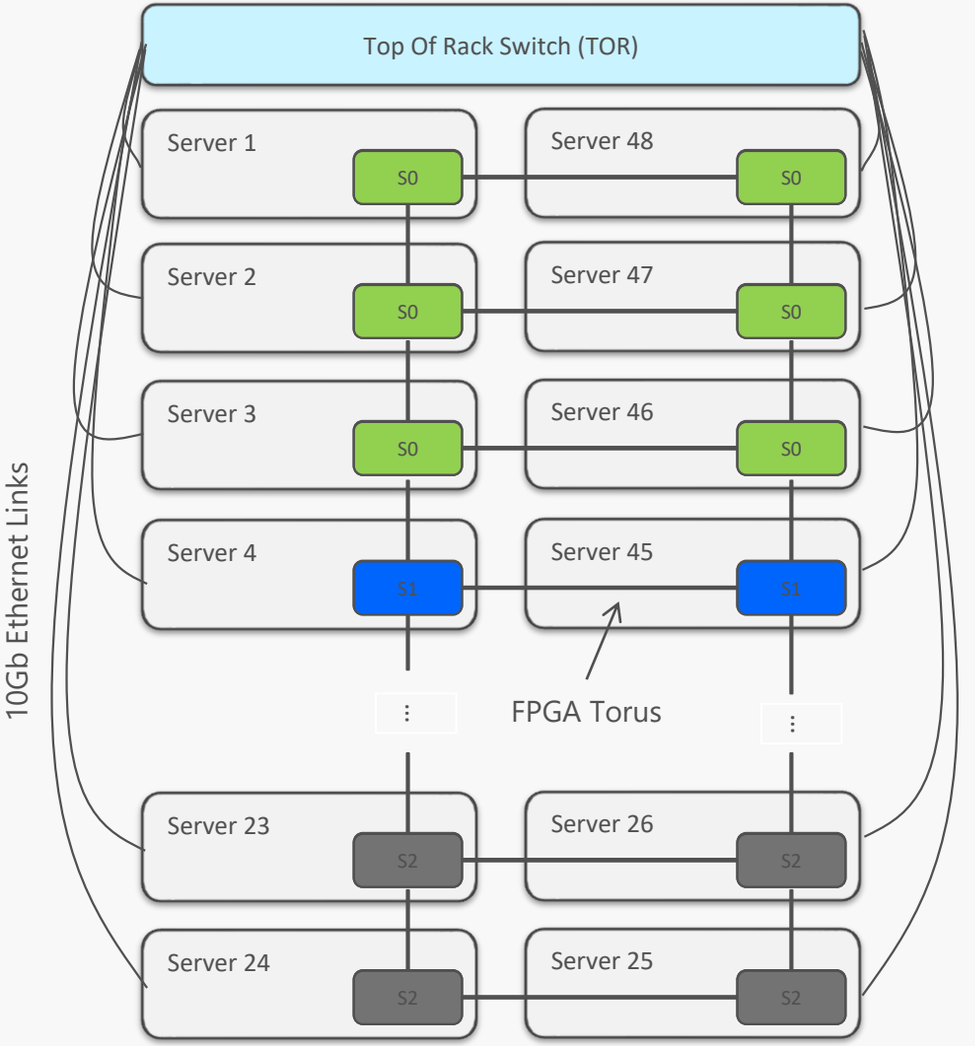


ALM : Adaptive Logic Module

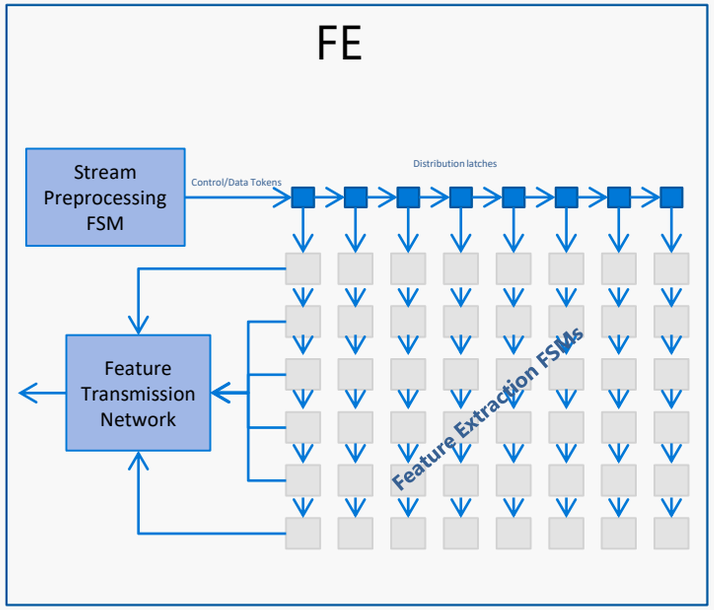
LE : Logic Element

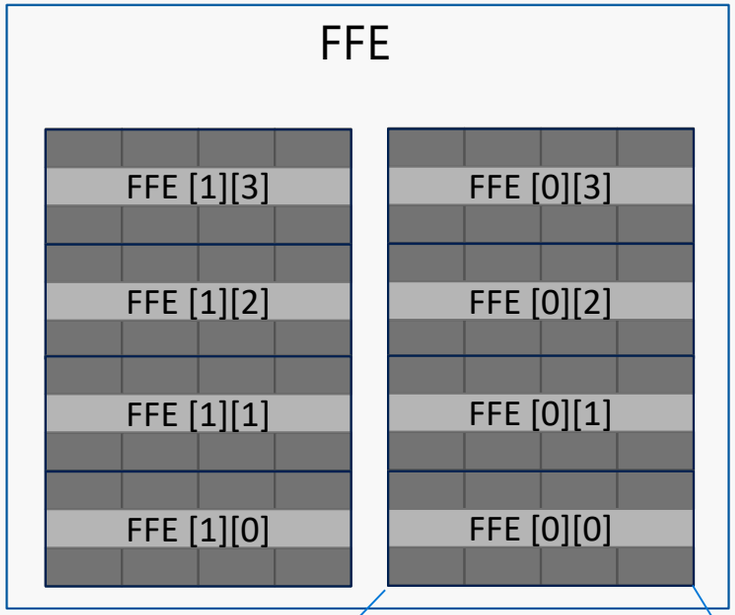
ファブリックをポッドにマップ

- 1 Pod = 48 servers
  - 1.5ラック
  - 48-port 10G ToR switch
  - 1 server = 2 ソケット, 64GB RAM, 2TB SSD ストレージ
- FPGA ネットワーク
  - 20Gb (2x10Gb) links to N/S/E/W neighbors
  - 2-D Torus Topology (6x8 torus)
- 提供された機能
  - FPGAへの低遅延アクセス
  - 複数FPGA構成による大規模処理の高速化
  - ストレージ、メモリを複数ノード間で共有（低遅延、高帯域）



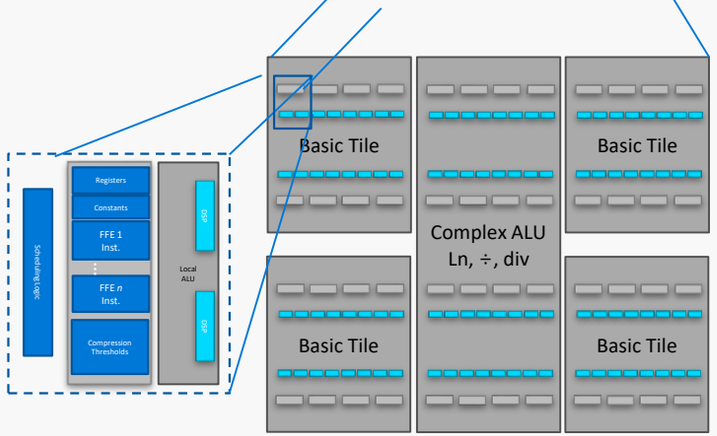
Bing用に構築された3種のエンジン





DTS

DTT [3][11]	DTT [2][11]	DTT [1][11]	DTT [0][11]
DTT [3][10]	DTT [2][10]	DTT [1][10]	DTT [0][10]
DTT [3][9]	DTT [2][9]	DTT [1][9]	DTT [0][9]
DTT [3][8]	DTT [2][8]	DTT [1][8]	DTT [0][8]
DTT [3][7]	DTT [2][7]	DTT [1][7]	DTT [0][7]
DTT [3][6]	DTT [2][6]	DTT [1][6]	DTT [0][6]
DTT [3][5]	DTT [2][5]	DTT [1][5]	DTT [0][5]
DTT [3][4]	DTT [2][4]	DTT [1][4]	DTT [0][4]
DTT [3][3]	DTT [2][3]	DTT [1][3]	DTT [0][3]
DTT [3][2]	DTT [2][2]	DTT [1][2]	DTT [0][2]
DTT [3][1]	DTT [2][1]	DTT [1][1]	DTT [0][1]
DTT [3][0]	DTT [2][0]	DTT [1][0]	DTT [0][0]



FE0

89 Non-BodyBlock Features
34 State Machines
55 % Utilization

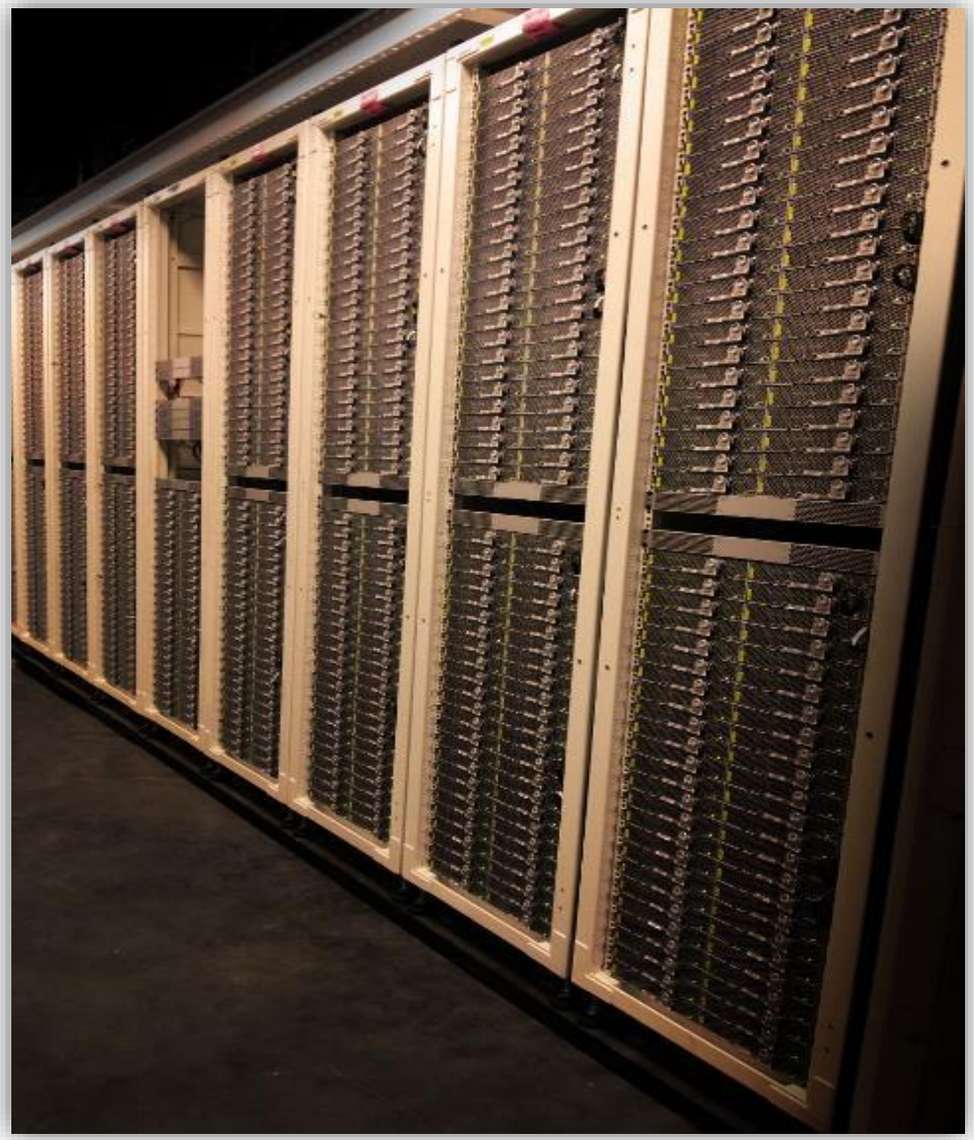
FE1

55 BodyBlock Features
20 State Machines
45 % Utilization

FFE: 64 cores / chip
256-512 threads
DTT: 48 DTT tiles/chip
240 tree processors
2880 trees/chip



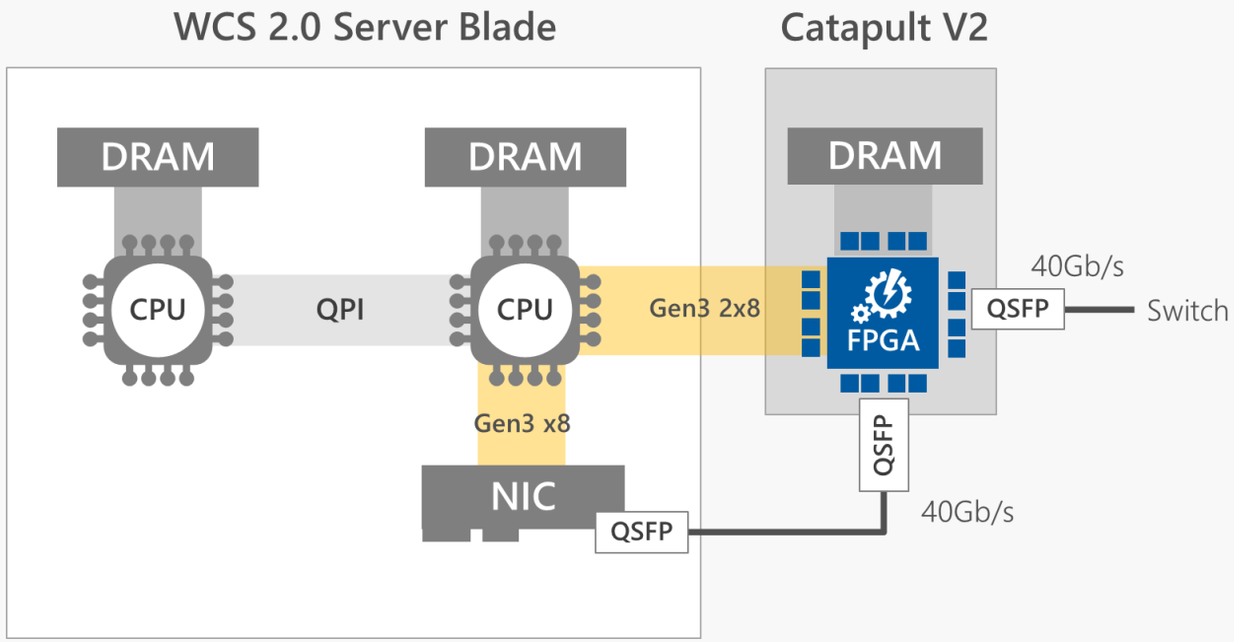






1,632 サーバー（パイロット環境）

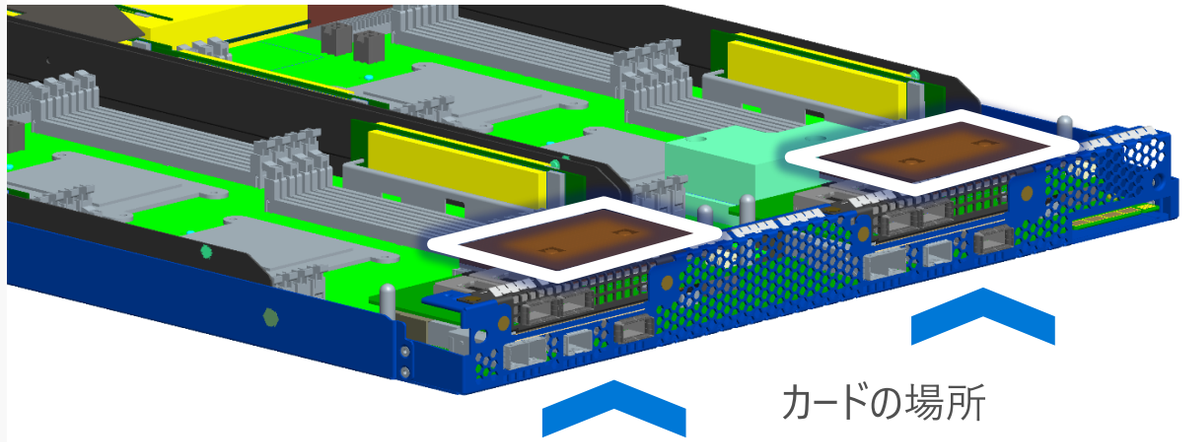
世界中のサーバに FPGA を配備



Catapult v2 Mezzanine カード



WCS Gen 4.1 ブレードと NIC と Catapult FPGA



- 大きな経済的メリット
  - ローカルコンピューターアクセラレーター
  - ネットワーク、ストレージアクセラレーター
  - リモート演算アクセラレーター

[ISCA'14, HotChips'14, MICRO'16]

ネットワーク＋AI＋セキュリティ

深層学習、機械学習分野への活用

FPGA での深層学習の価値

パフォーマンス

数万TOPでの、低ロットサイズでの効果的な推論スループット
超低遅延による最新の DNN の提供
CPUやGPU と比較して10倍以上
単一の DNN サービスで多くの FPGA に拡張

柔軟性

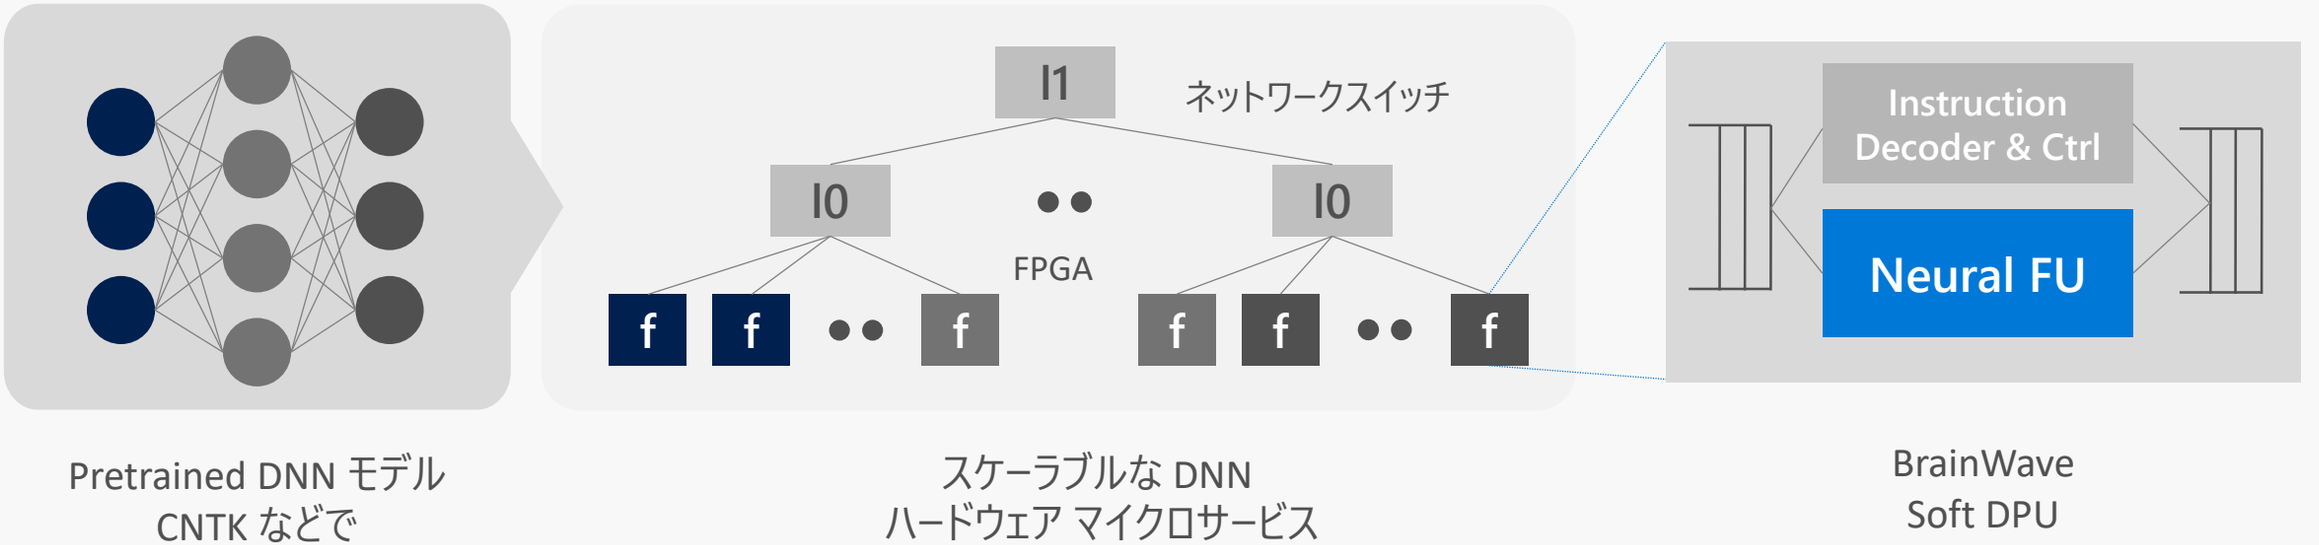
急速に進化する ML への対応
CNN、LSTM、MLP、強化学習、特徴抽出、デシジョンツリーなど
推論に最適化された数値精度
カスタム値、複数化、極小精密ネット
より大きい、より速いモデルのための更なる圧縮

スケール

マイクロソフトは、FPGA に対して世界最大のクラウド投資
人工知能の容量を複数のExa-Ops で
FPGA ファブリック上で強力な DNN サービスプラットフォーム

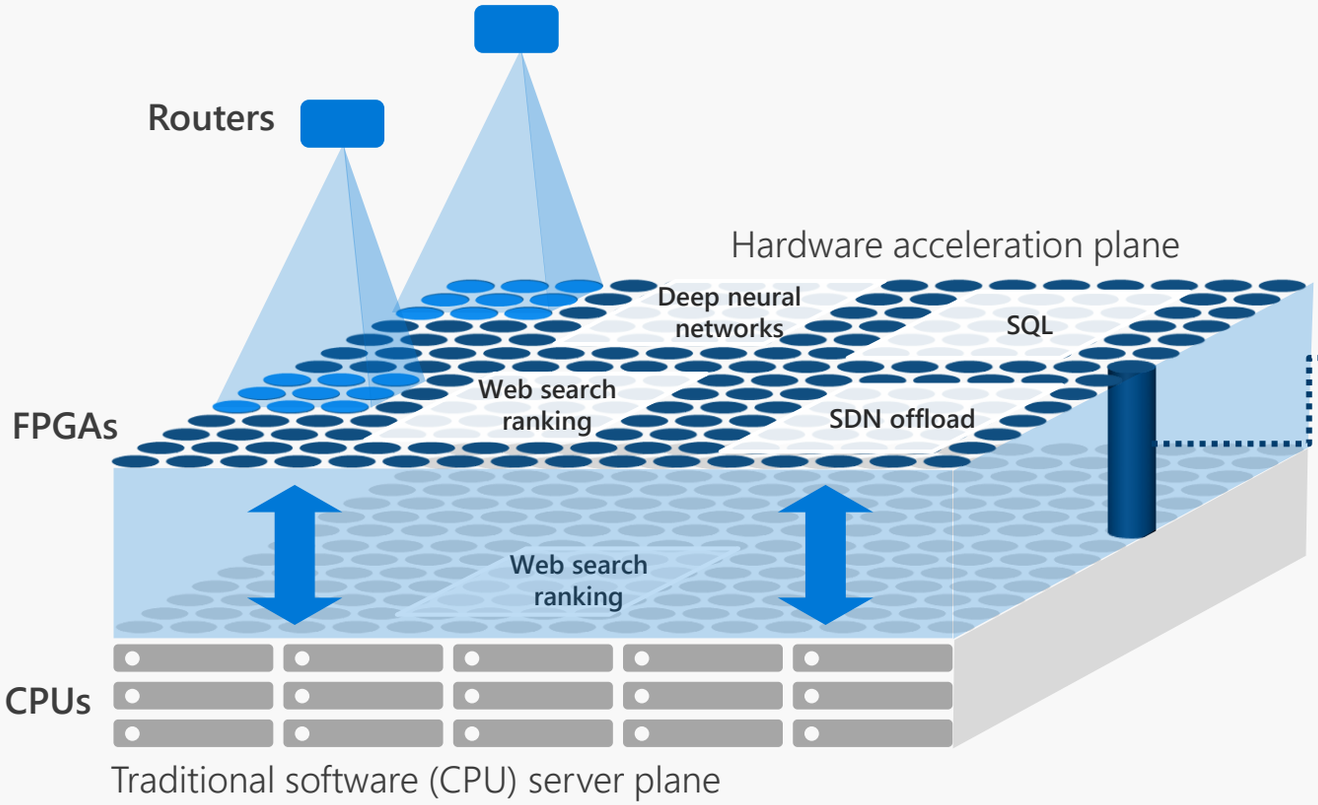
Project BrainWave

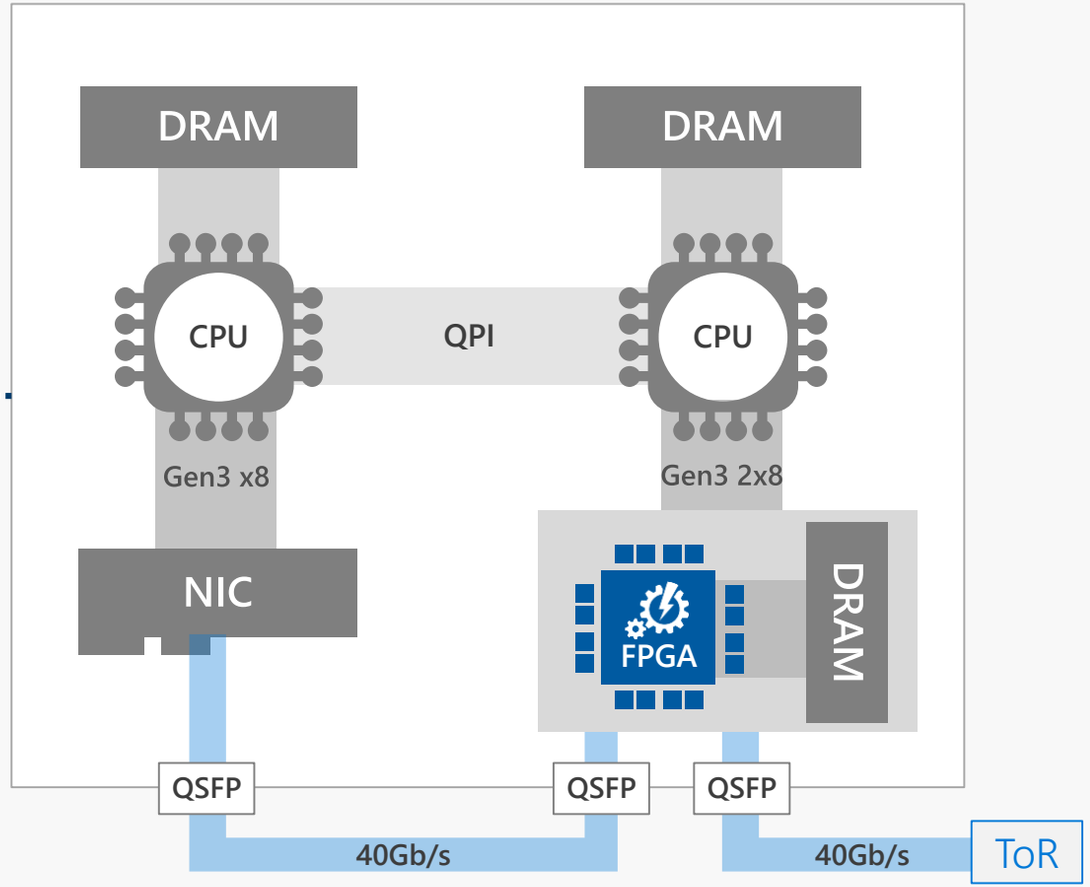
- スケーラブルな FPGA 搭載 DNN サービスプラットフォーム
  - 高速: 超低レイテンシ、低ロットサイズでの DNN モデルの高スループットサービス
  - フレキシブル: アダプティブな数値精度とカスタム演算子
  - 高い親和性: CNTK/Caffe/TF などの の迅速な展開



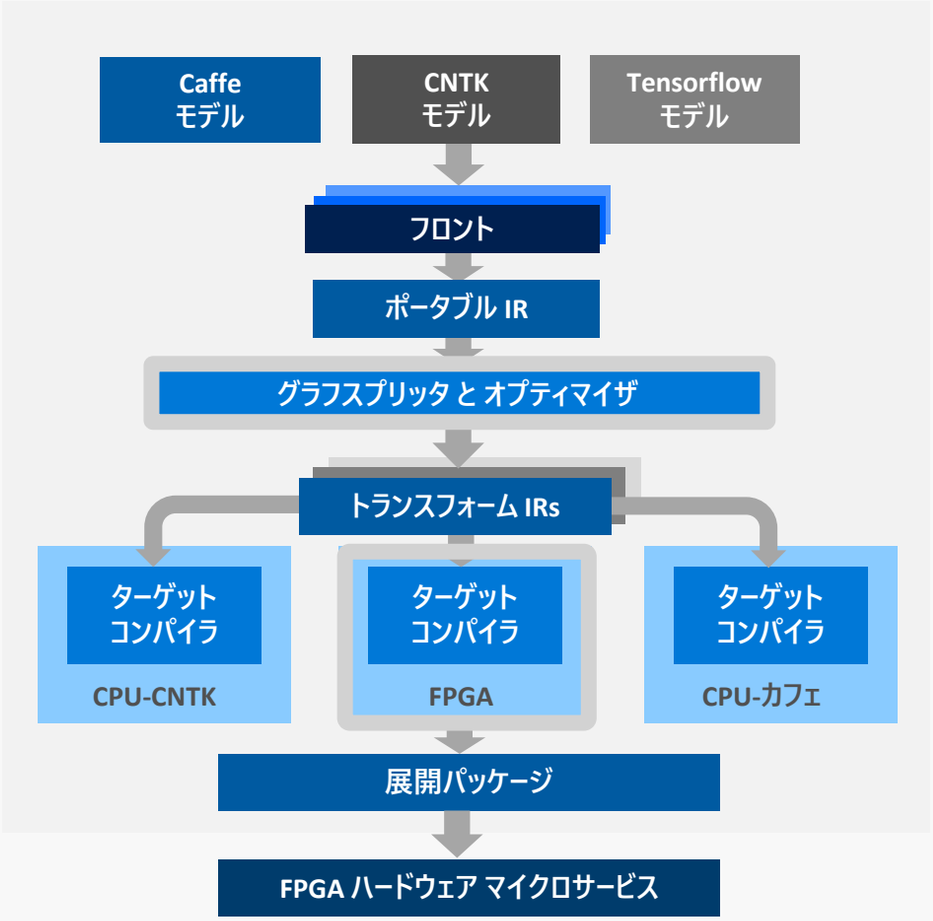
Hardware Microservices on FPGAs [MICRO'16]

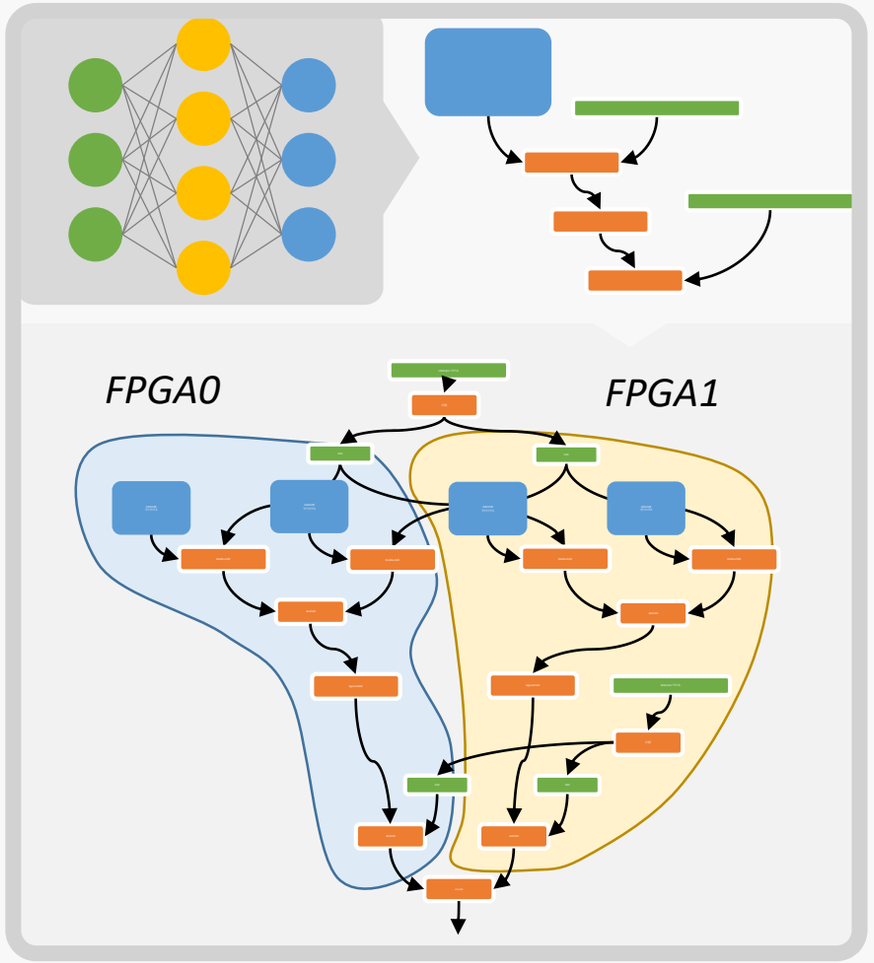
- Compute Workload 毎に分離された中でFPGA同士が相互連携
- CPU とは独立して管理



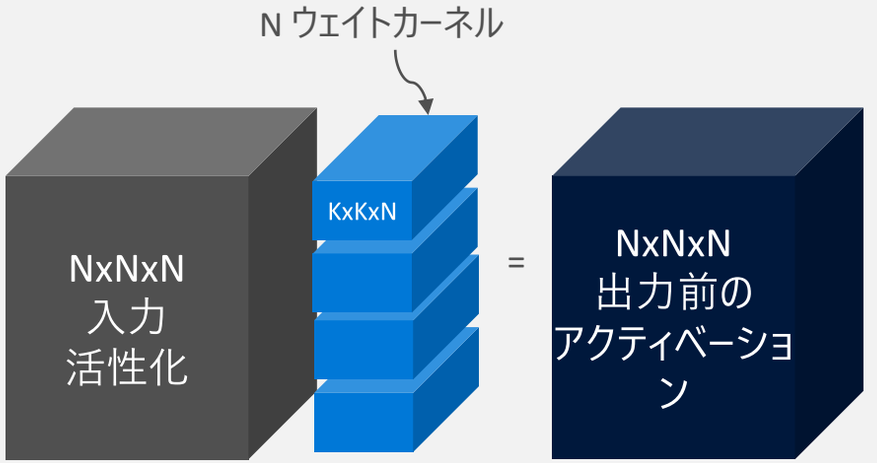


BrainWave コンパイラとランタイム



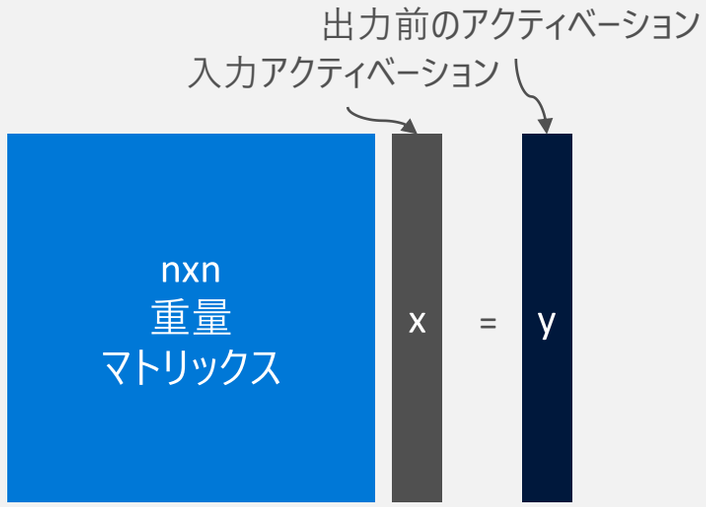


一般的なシナリオ



$O(N^3)$ data
$O(N^4K^2)$ compute

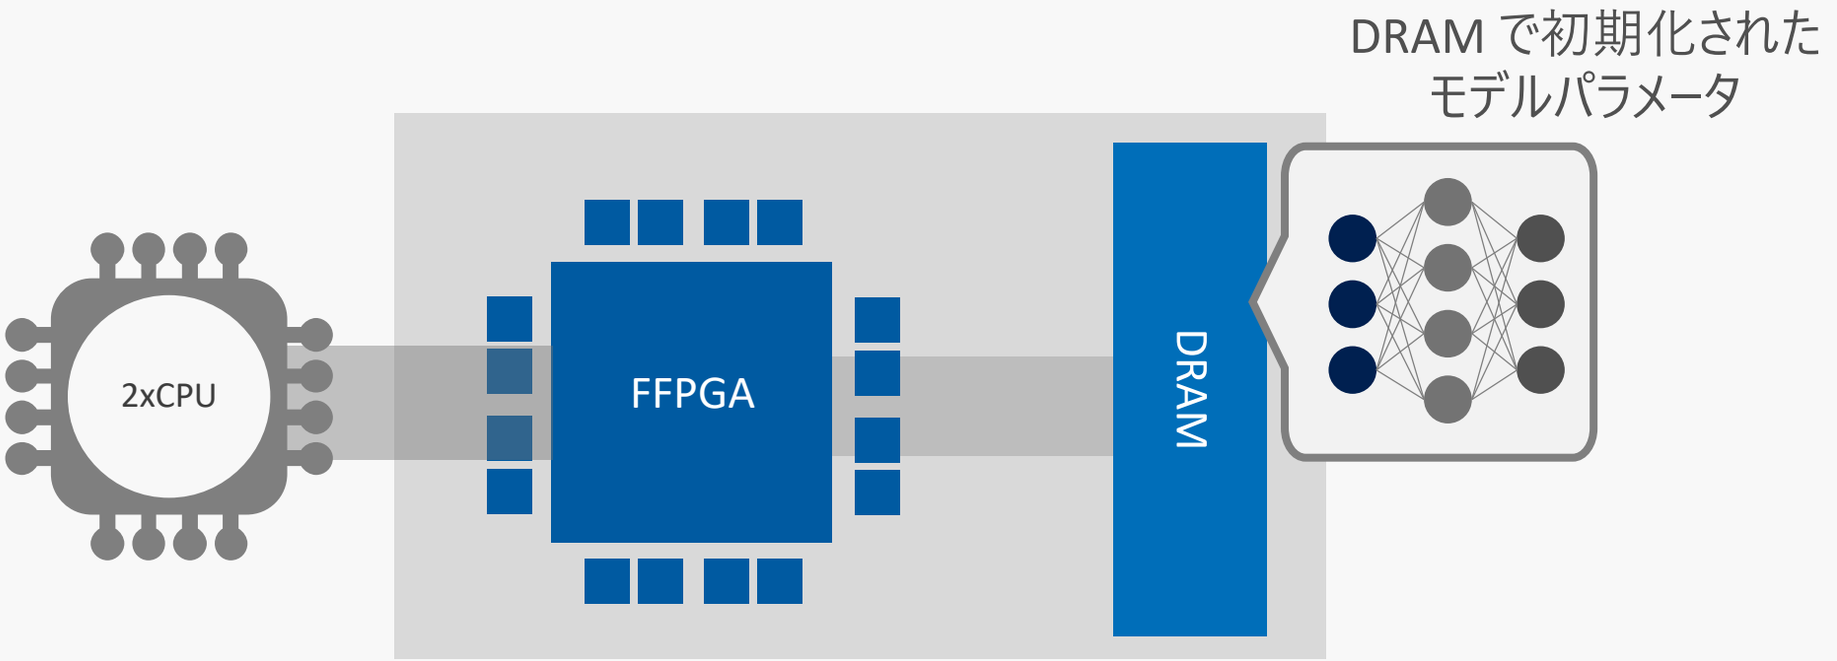
Convolutional Neural Network (CNN)
高演算-データ比率



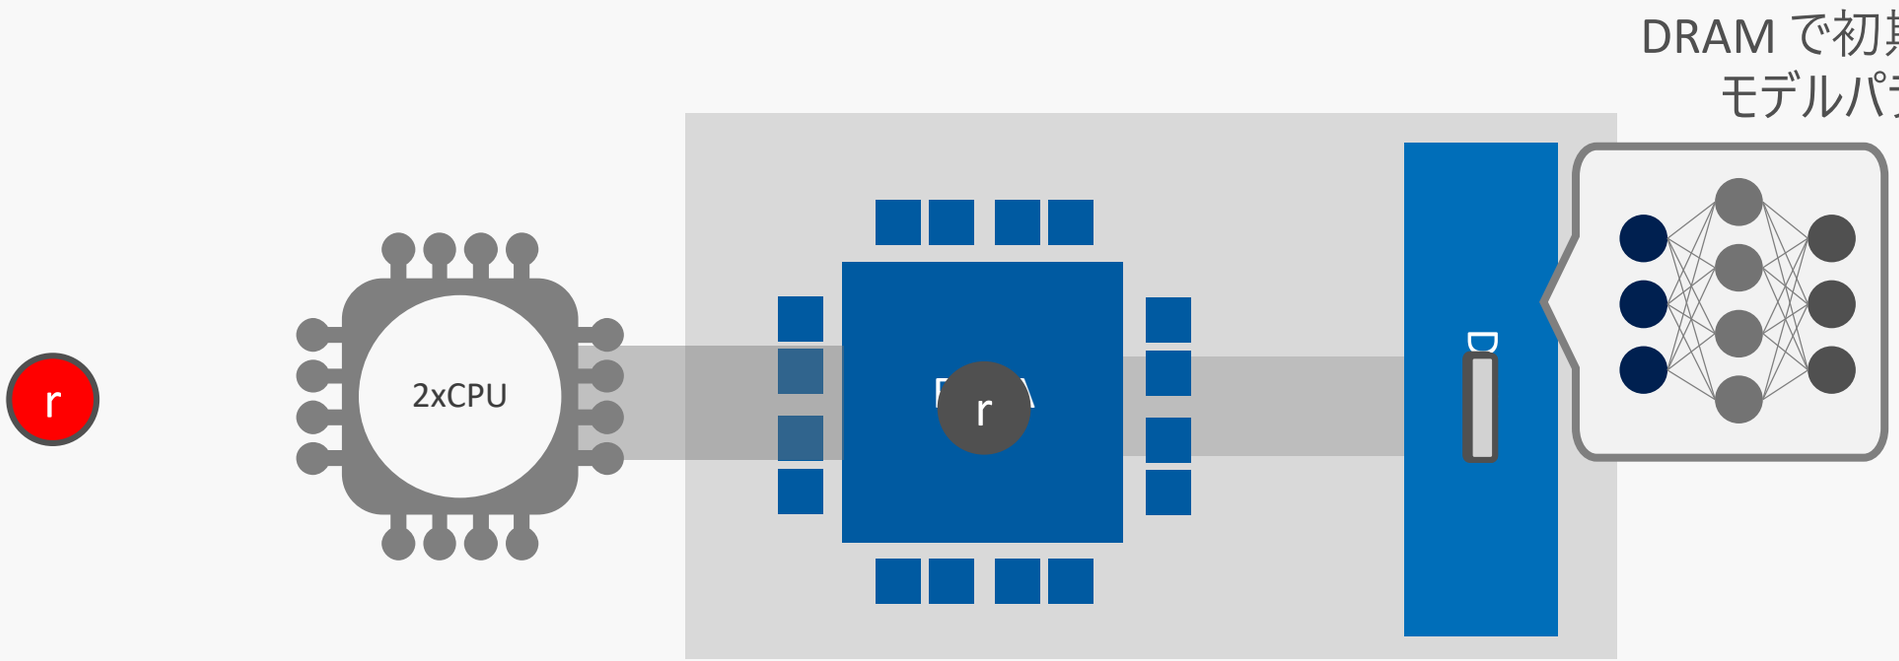
$O(N^2)$ data
$O(N^2)$ compute

MLPs, LSTMs, GRUs
低演算/データ比率

従来の加速度アプローチ:
ローカルのオフロードとストリーミング

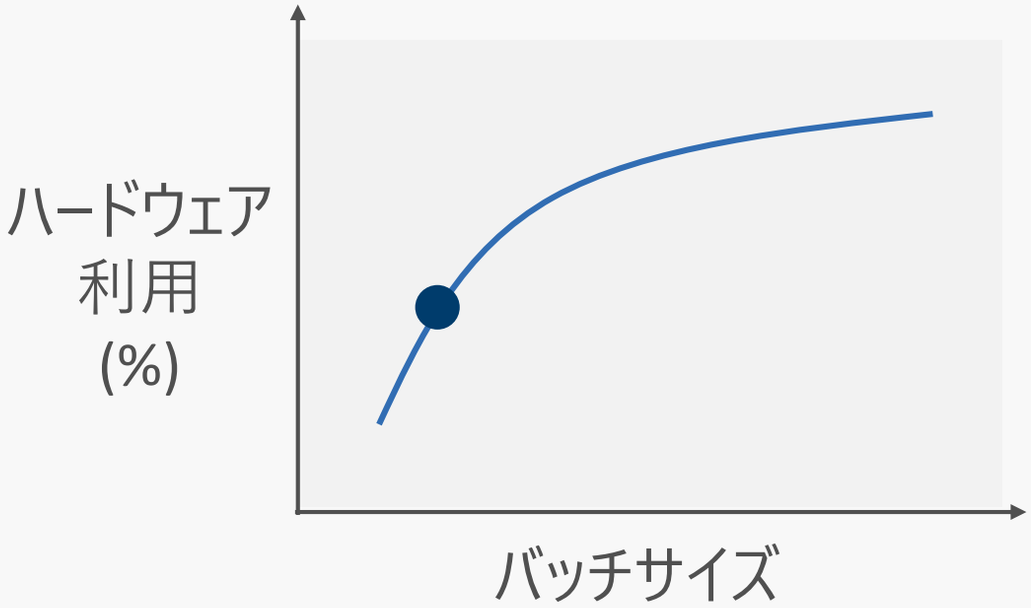


従来の加速度アプローチ:
ローカルのオフロードとストリーミング

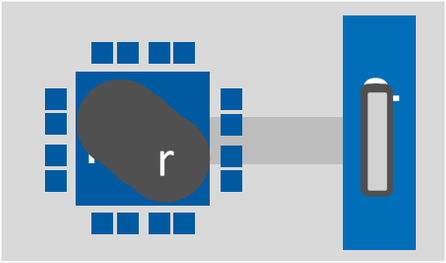


低演算/データ比率でメモリを集中的に使用する DNNs
(例: LSTM)、オフチップ DRAM 帯域幅による HW 利用制限

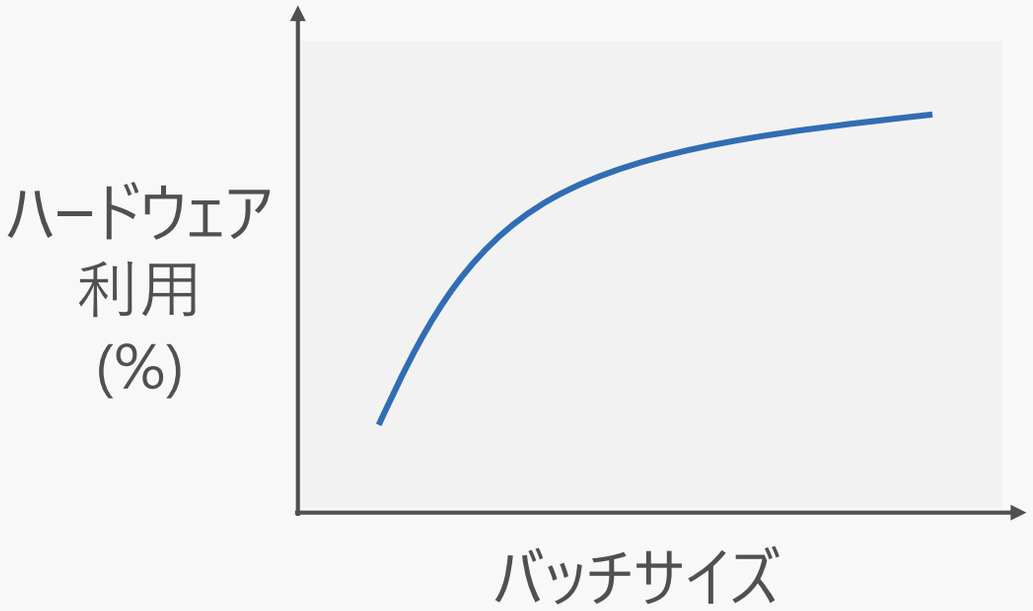
バッチ処理による HW 使用率の向上

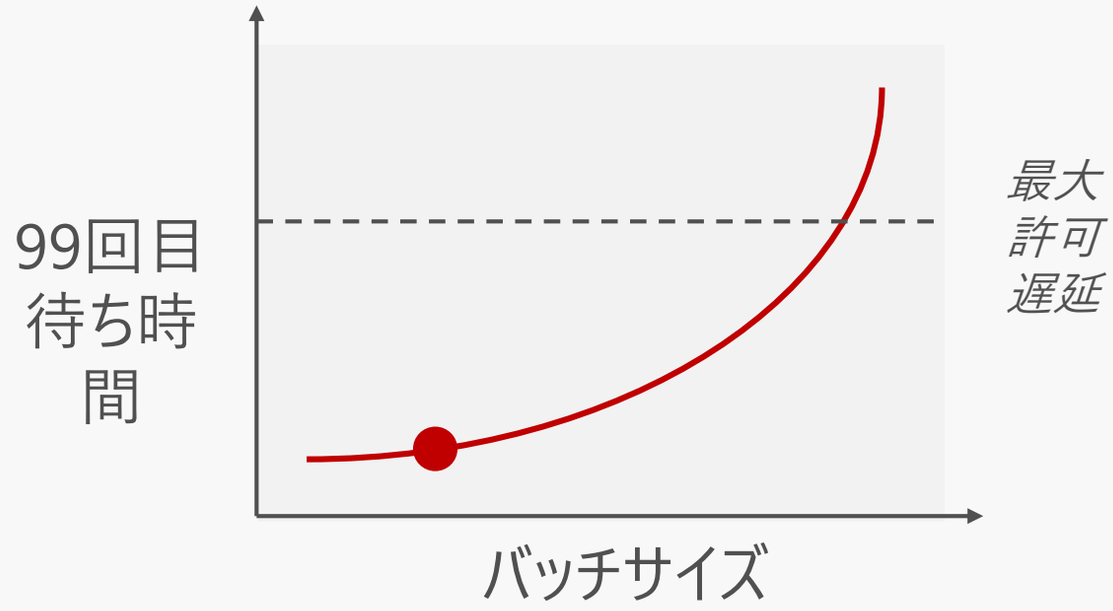






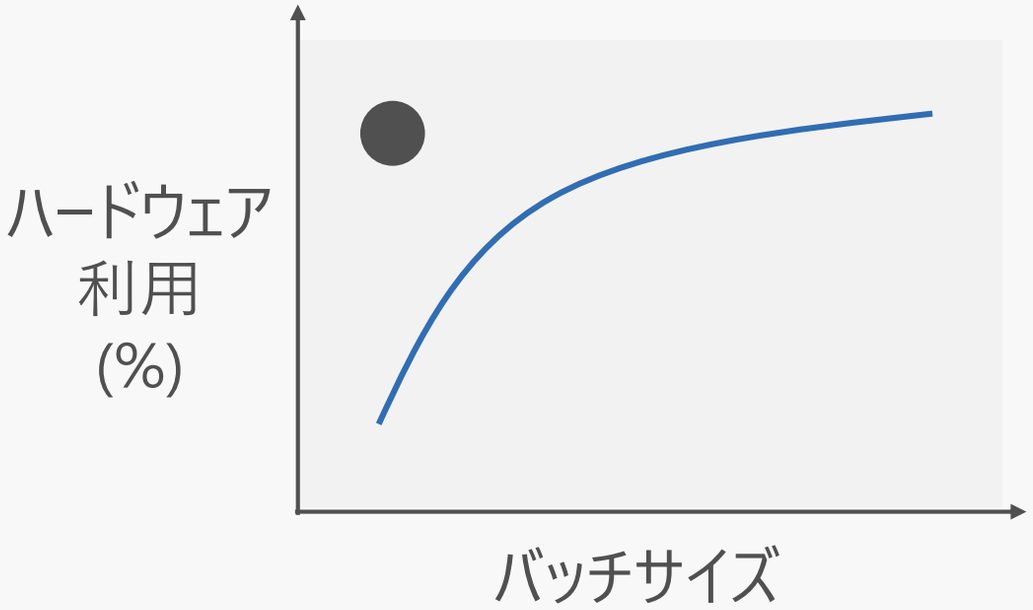
バッチ処理による HW 使用率の向上

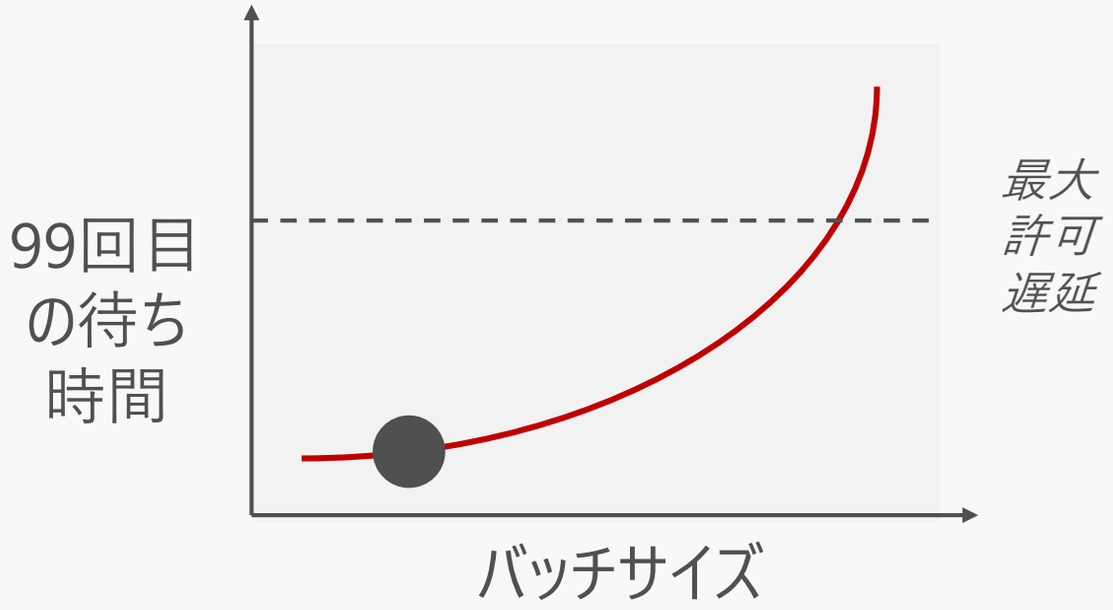




バッチ処理により HW の使用率が向上するが、待ち時間は増加

バッチ処理による HW 使用率の向上

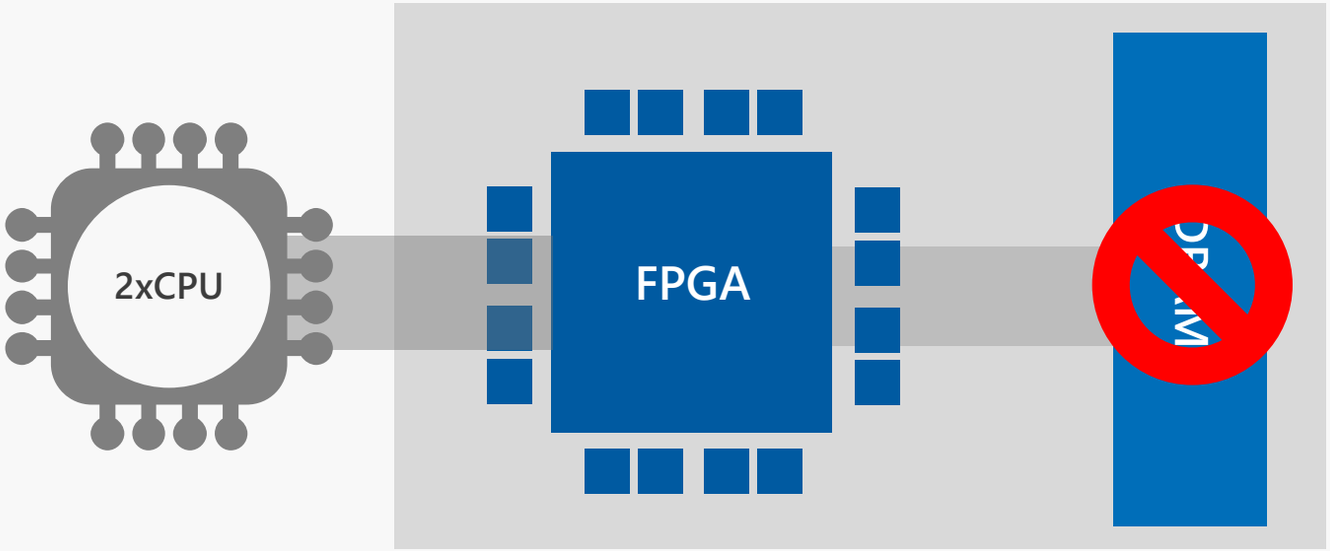




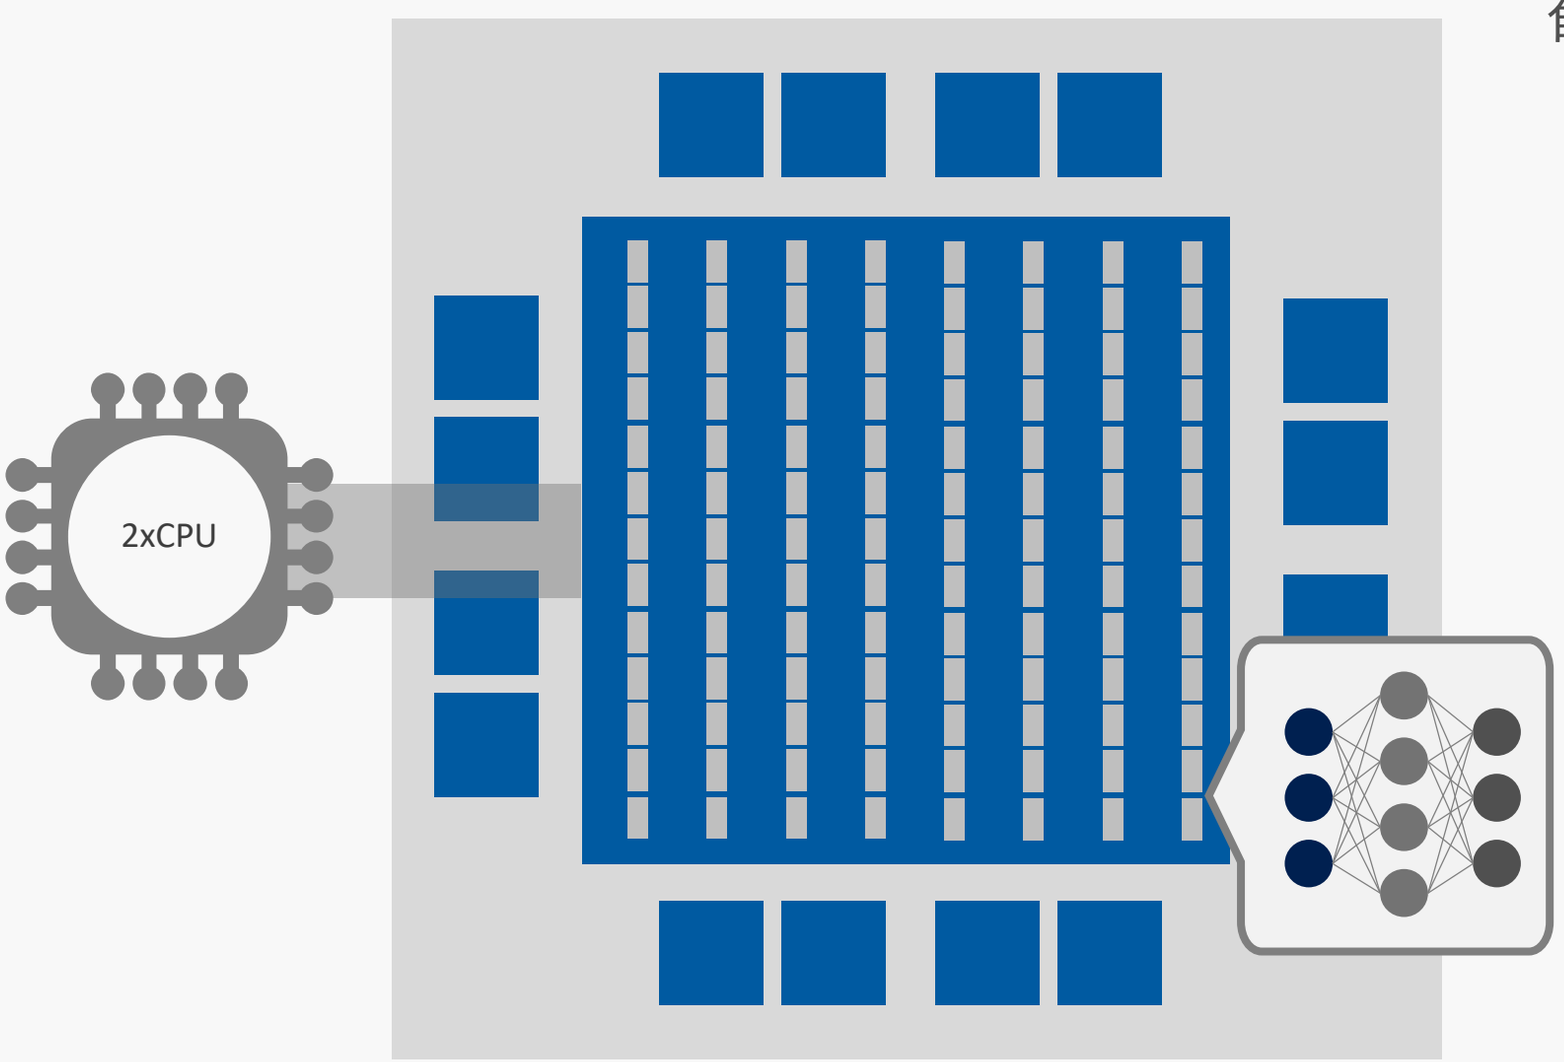
バッチ処理により HW の使用率が向上するが、待ち時間が増加

理想的には、小さいバッチ・サイズで高い HW 使用率を達成したい

代替: "永続的な" ニューラルネット



代替: "永続的な" ニューラルネット



観測

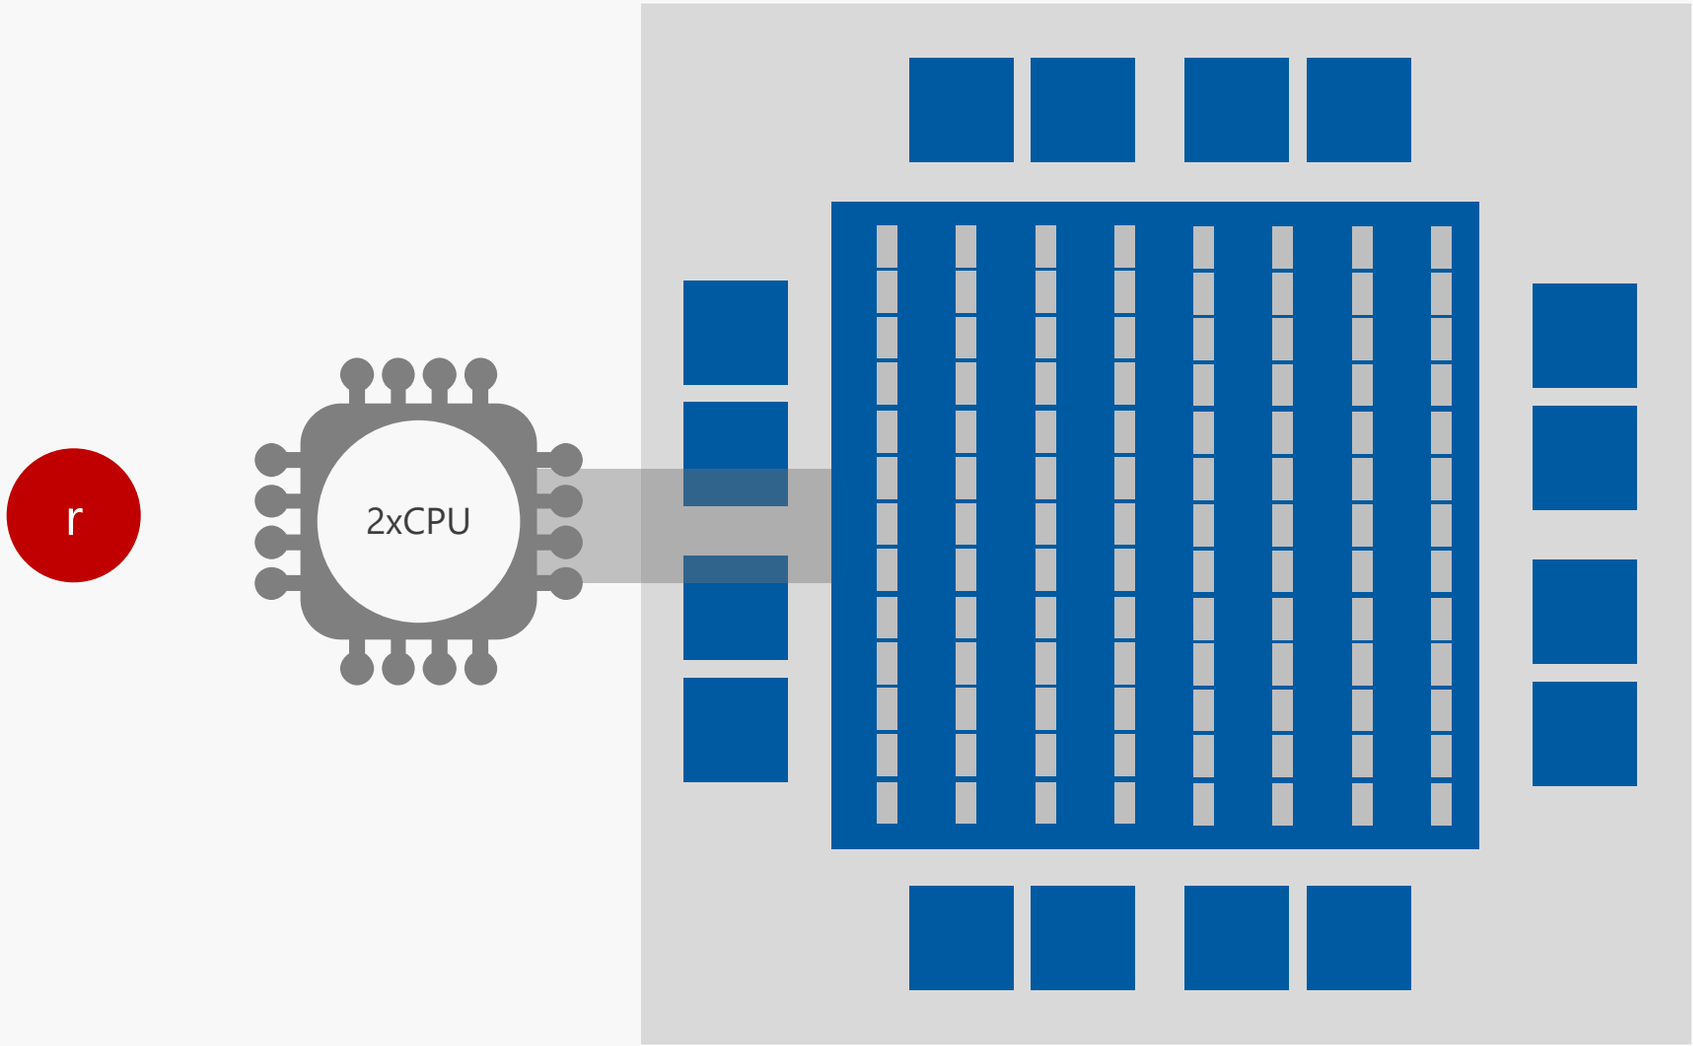
最先端の FPGA には O (10k) 分散ブロック RAM O (10mb) がある

➔数十 TB/秒のメモリ帯域幅

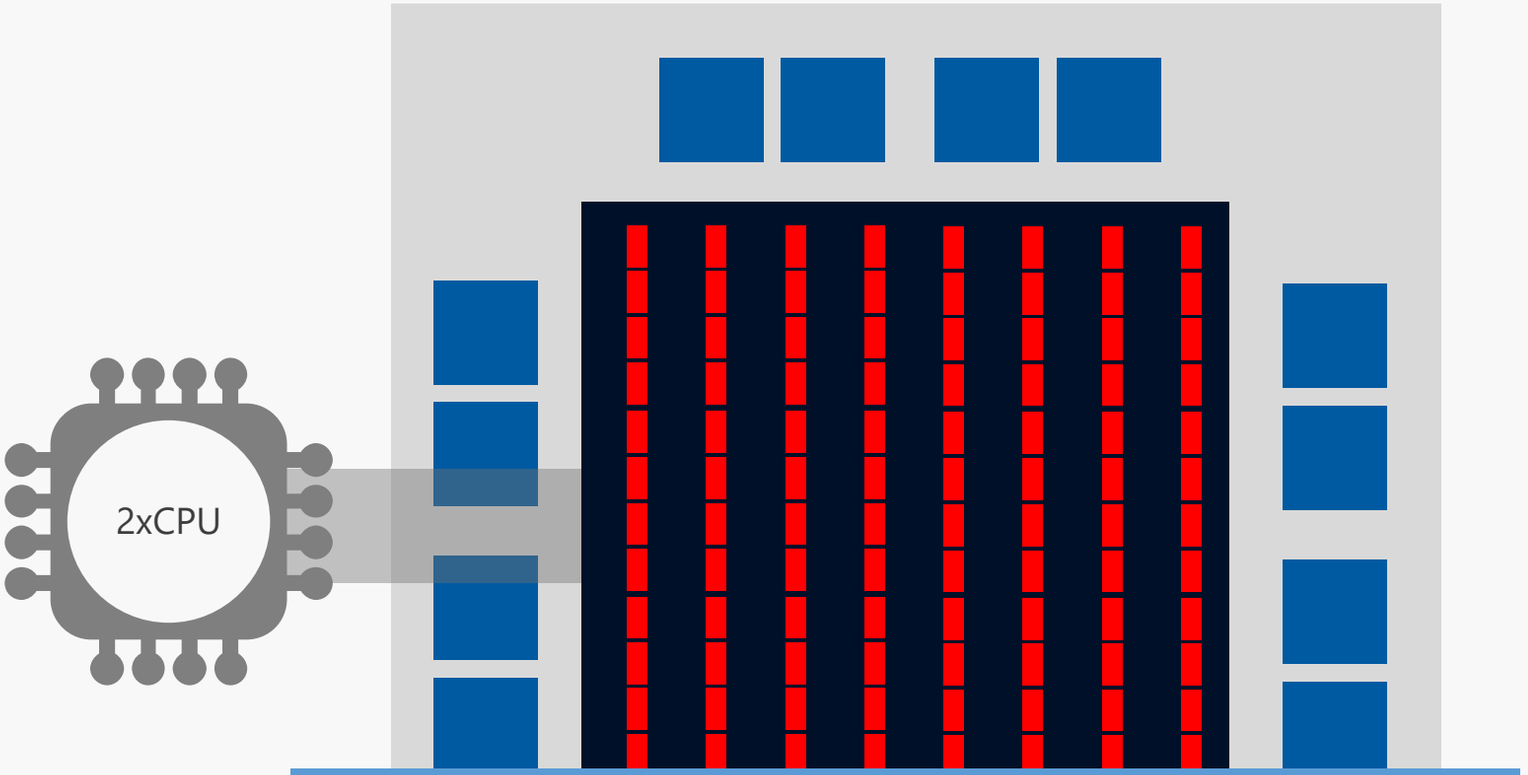
大規模なクラウドサービスと
DNN モデルが永続的に実行される

解決方法: サービスの有効期間中に、FPGA 上のすべてのモデルパラメータをオンチップメモリに保持

代替: "永続的な" ニューラルネット

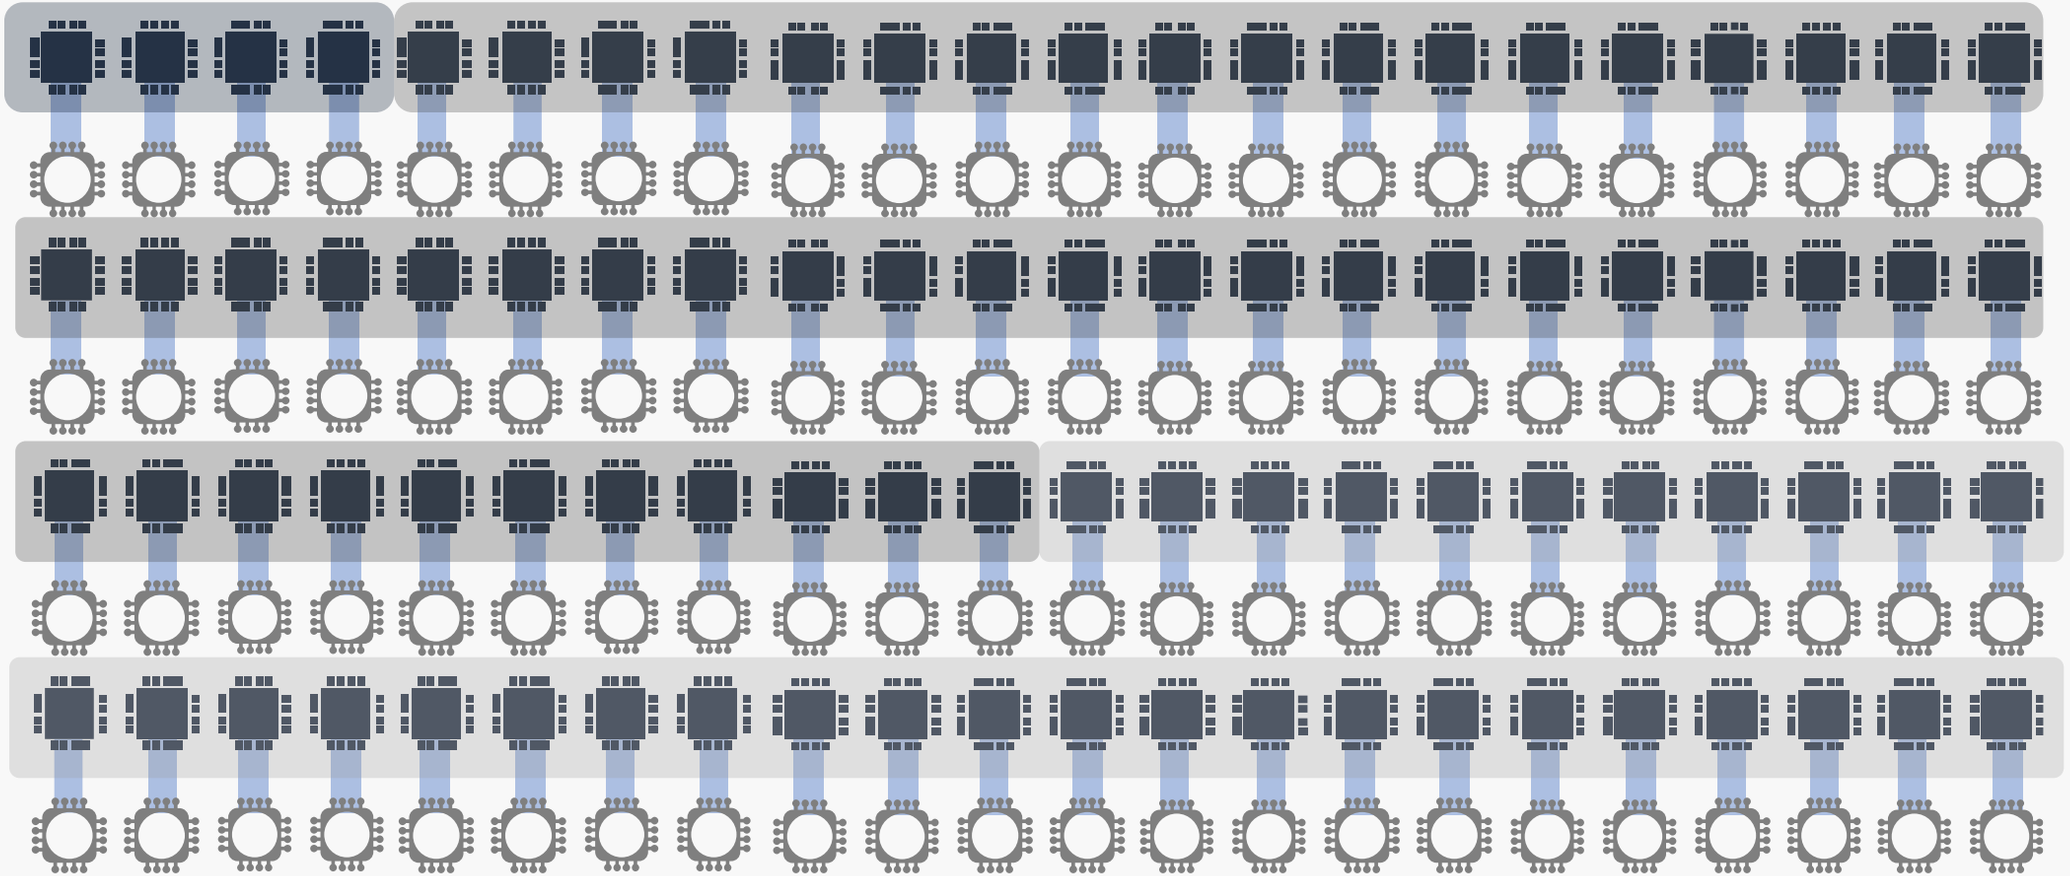


代替: "永続的な" ニューラルネット



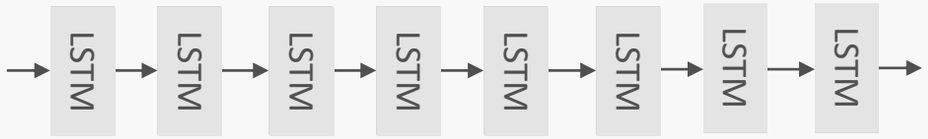
単一の要求が到着すると、1つのクエリを処理するために
全てのチップリソース (オンチップメモリと計算単位) が
使用される (バッチ処理は不要)。

解決方法:データセンター規模での永続化

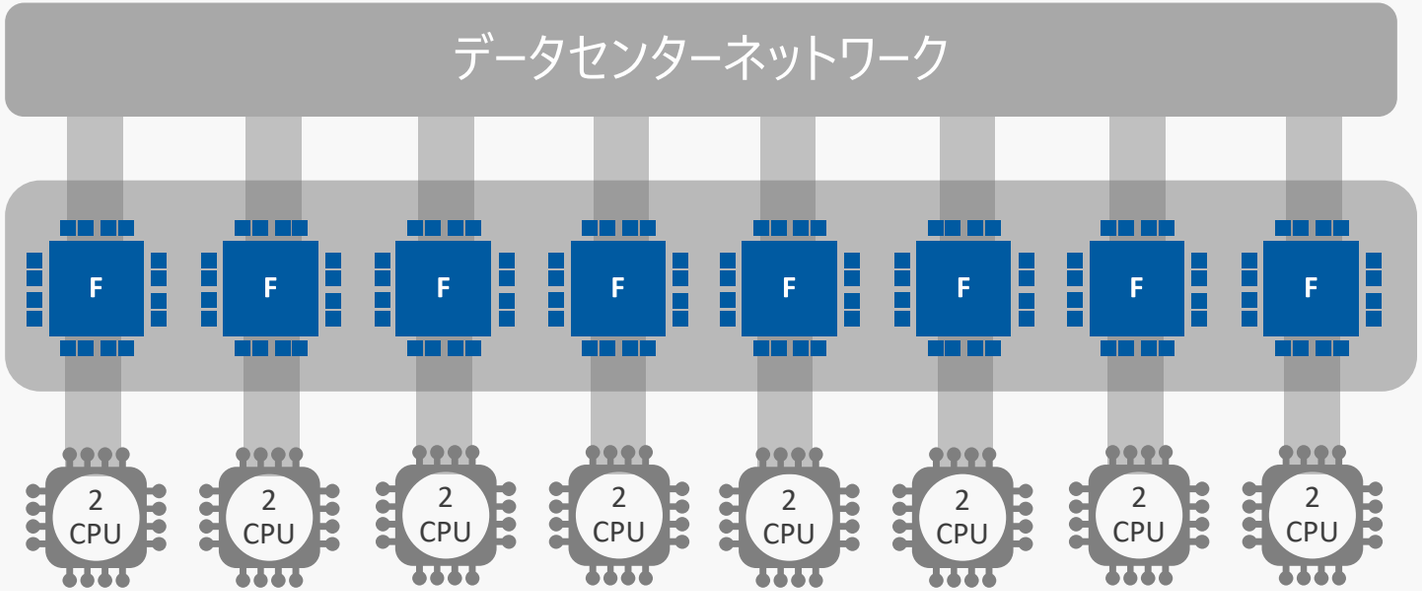


データセンタースケールでの複数の FPGA が永続的な DNN を形成できる
HW マイクロアーキテクチャにより、超低レイテンシでのモデルのスケールアウトが可能

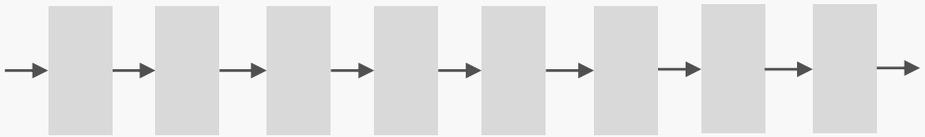
Inter-Layer パイプラインの並列処理

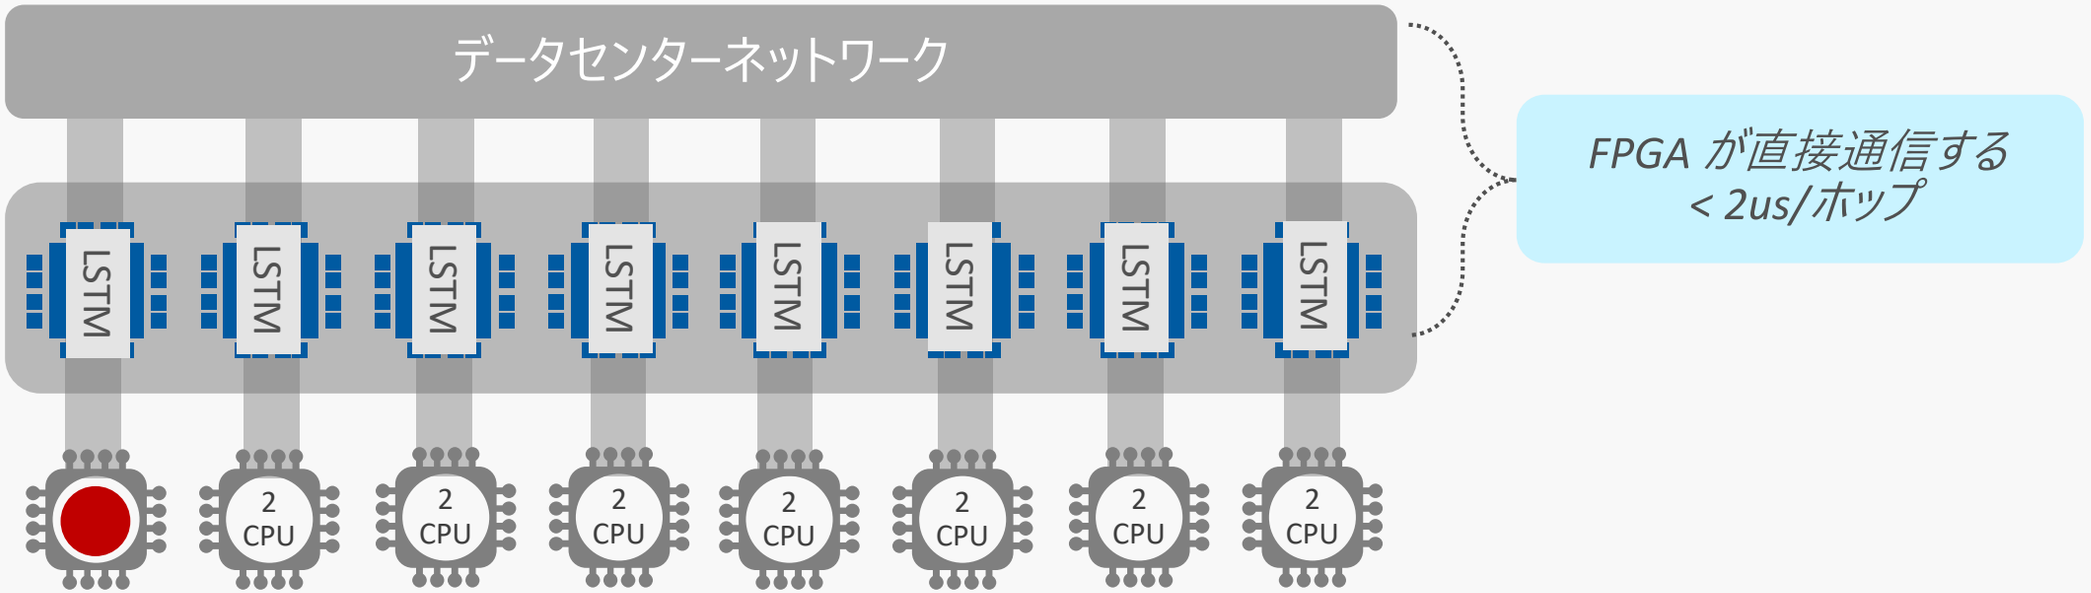


$$
\begin{aligned}
f_t &= \sigma_g(W_f x_t + U_f h_{t-1} + b_f) \\
i_t &= \sigma_g(W_i x_t + U_i h_{t-1} + b_i) \\
o_t &= \sigma_g(W_o x_t + U_o h_{t-1} + b_o) \\
c_t &= f_t \circ c_{t-1} + i_t \circ \sigma_c(W_c x_t + U_c h_{t-1} + b_c) \\
h_t &= o_t \circ \sigma_h(c_t)
\end{aligned}
$$

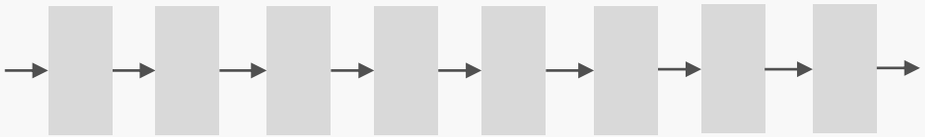


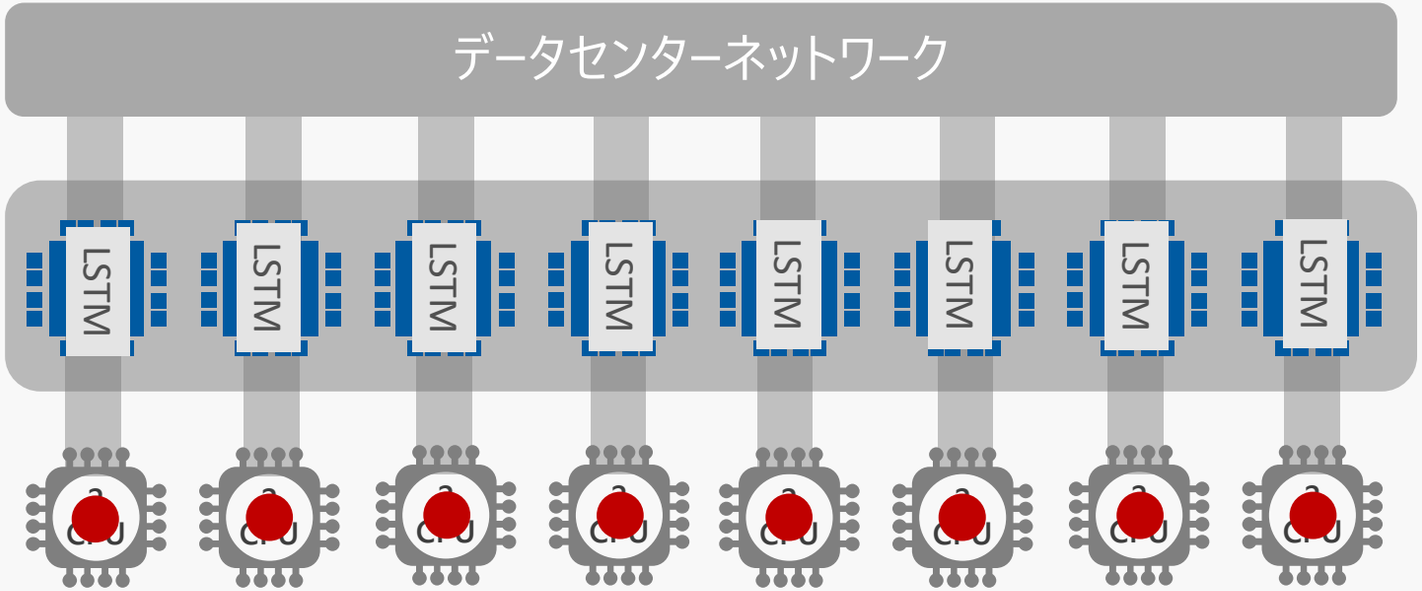
Inter-Layer パイプラインの並列処理





Inter-Layer パイプラインの並列処理

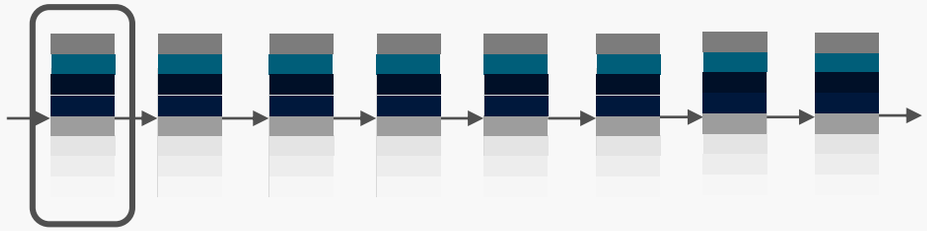


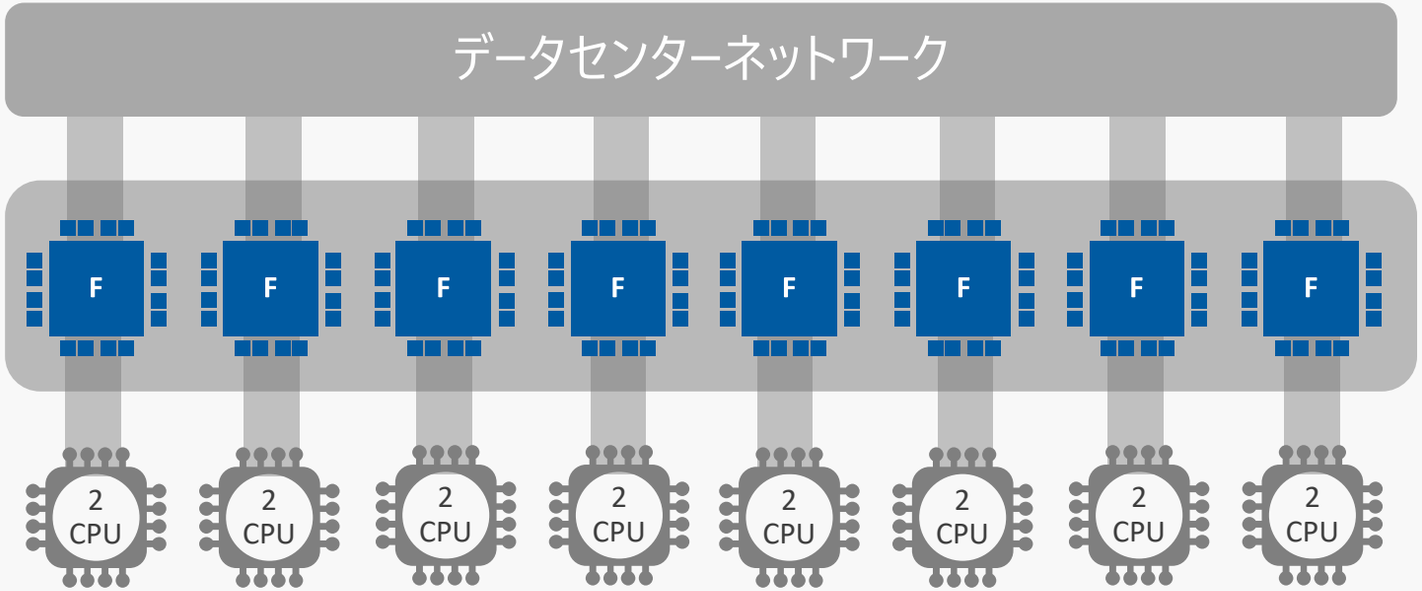


DNN HWMS
すべての CPU で共有

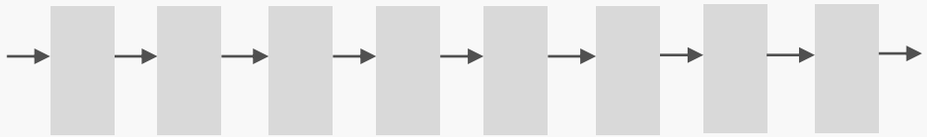
Intra-Layer の並列処理

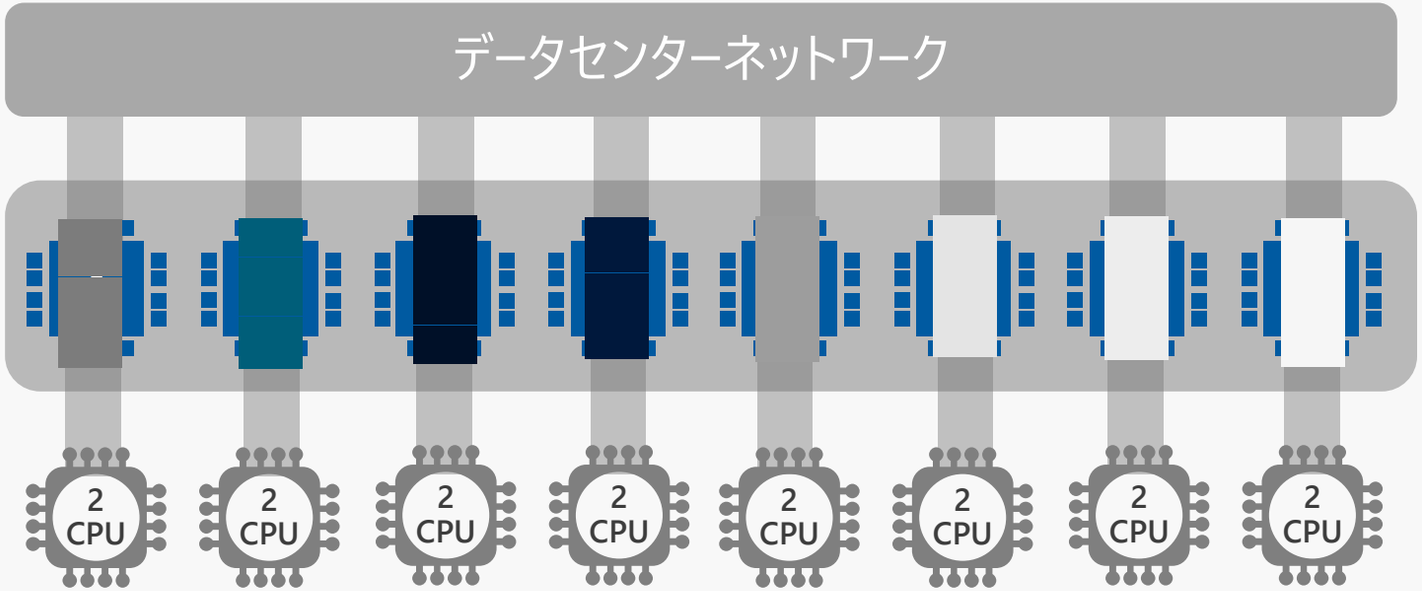
単一の密なマトリックス



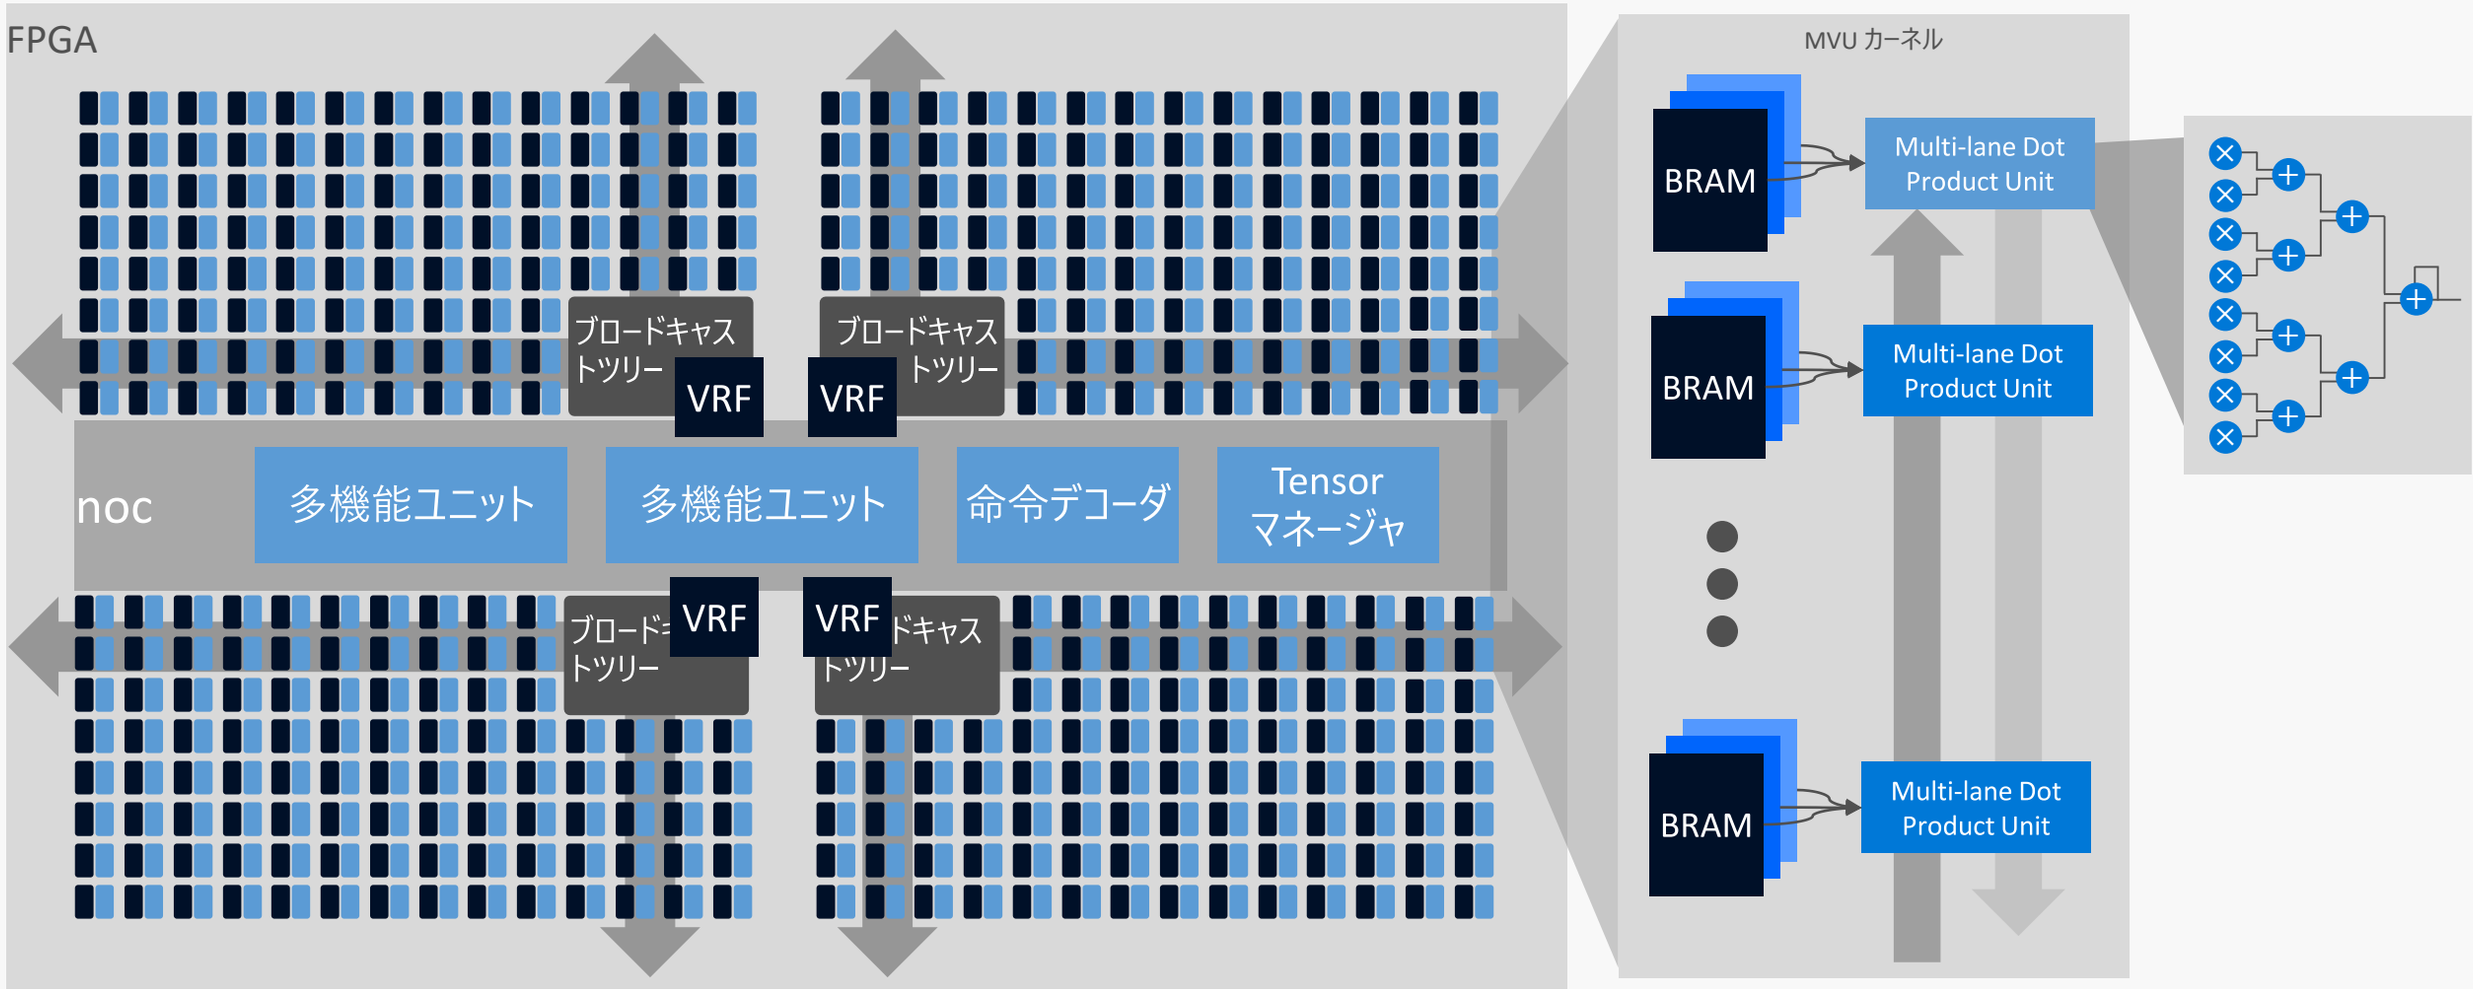


Intra-Layer の並列処理





Matrix Vector Unit

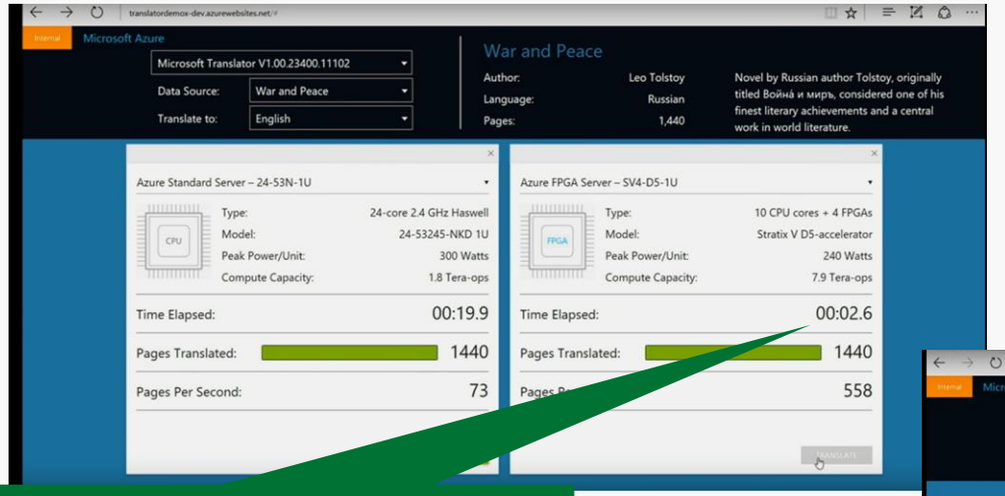


Deep Learning on FPGA

Microsoft製FPGAボード

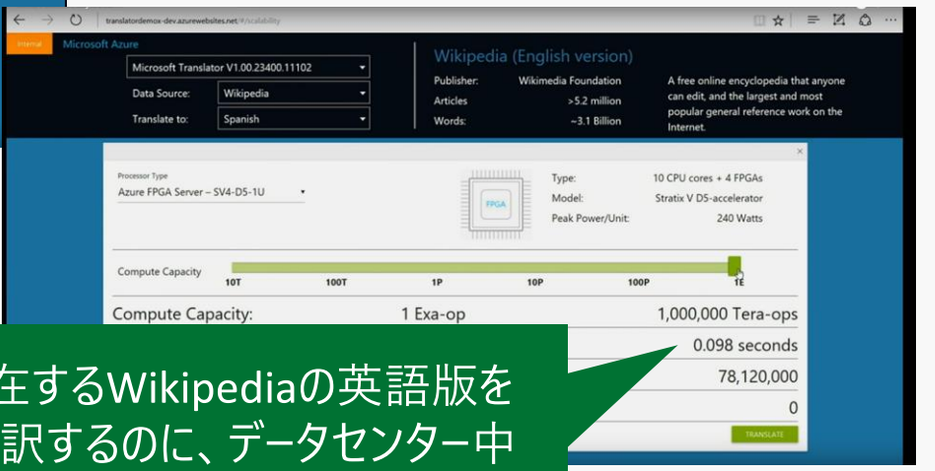


「戦争と平和」　露→英 訳



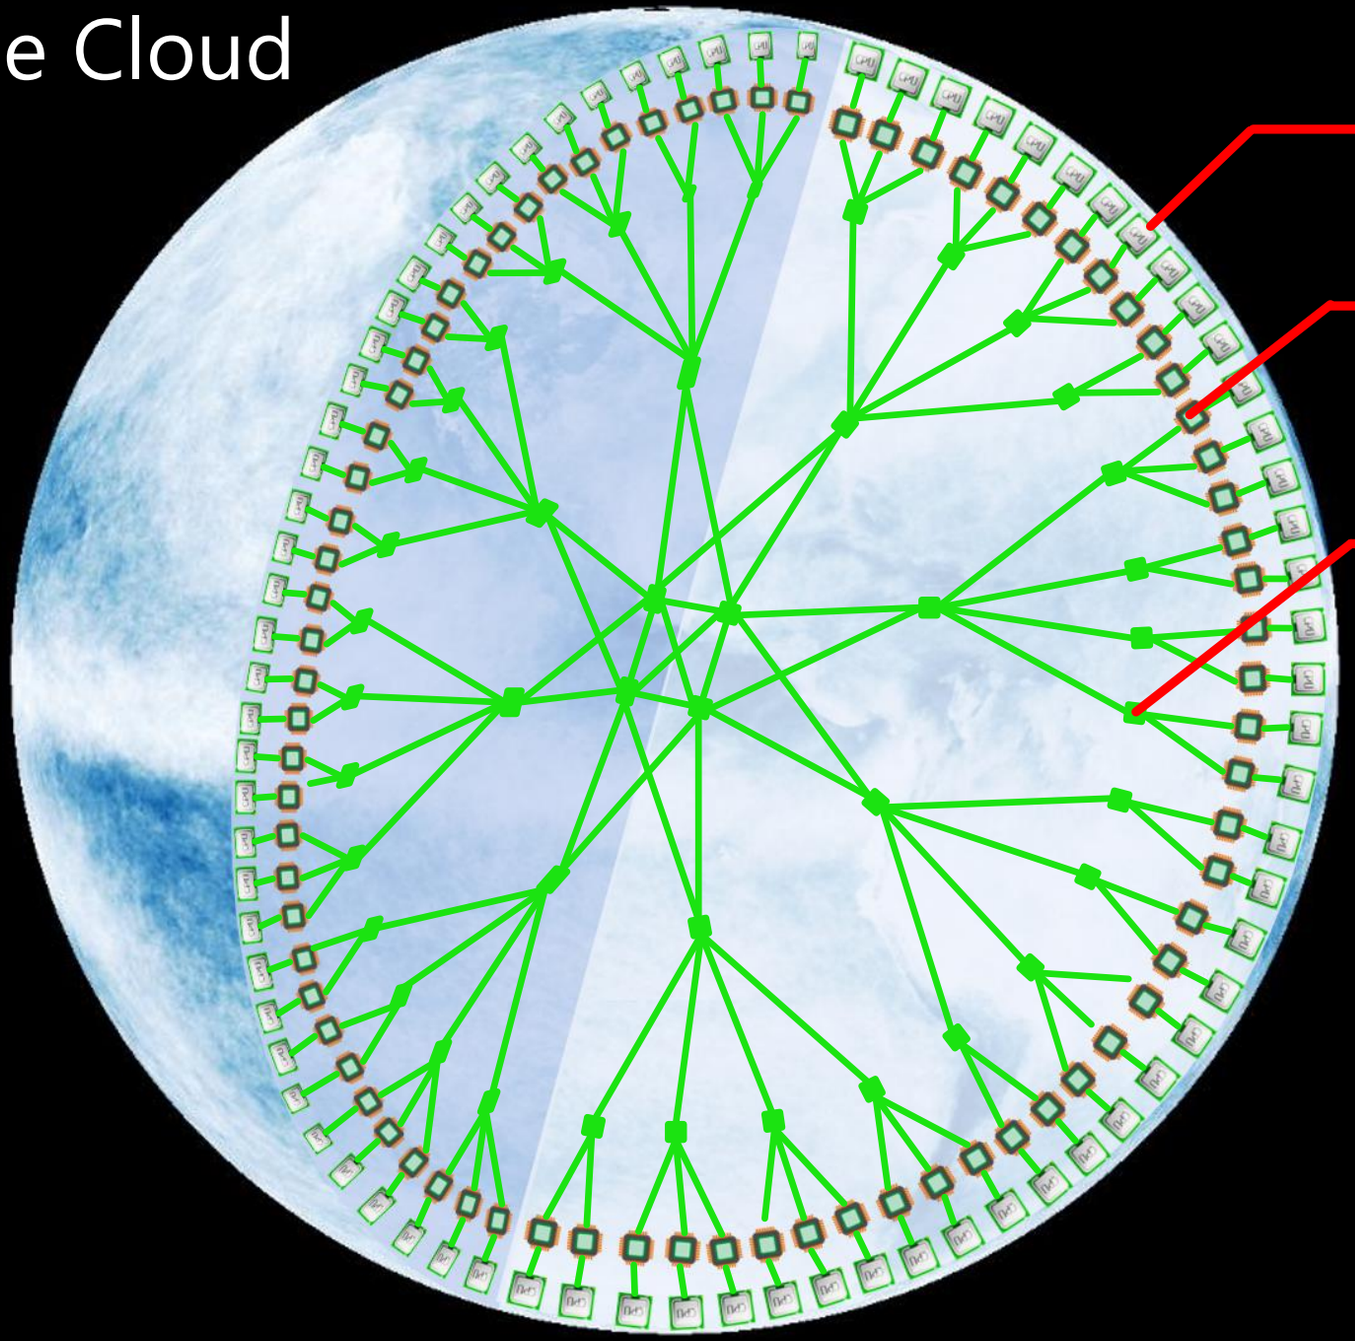
1,440ページの文学大作の翻訳に
CPU 24コアで19.9秒かかるところを
CPU 10コア+ 4FPGAを使うと2.6秒で完了

「Wikipedia」　英→西 訳



500万記事存在するWikipediaの英語版を
スペイン語に翻訳するのに、データセンター中
のFPGAサーバーを動員し、1Exa-OPSまで
スケールさせると、1秒以下で完了する

Configurable Cloud



CPU compute layer

Reconfigurable compute layer

Converged network

増え続けるデータ、高度化するニーズ

- ネットワークエッジへのオフロード
  - SDN
  - Security
  - AI・ML
- デバイス
  - FPGA
  - CPU

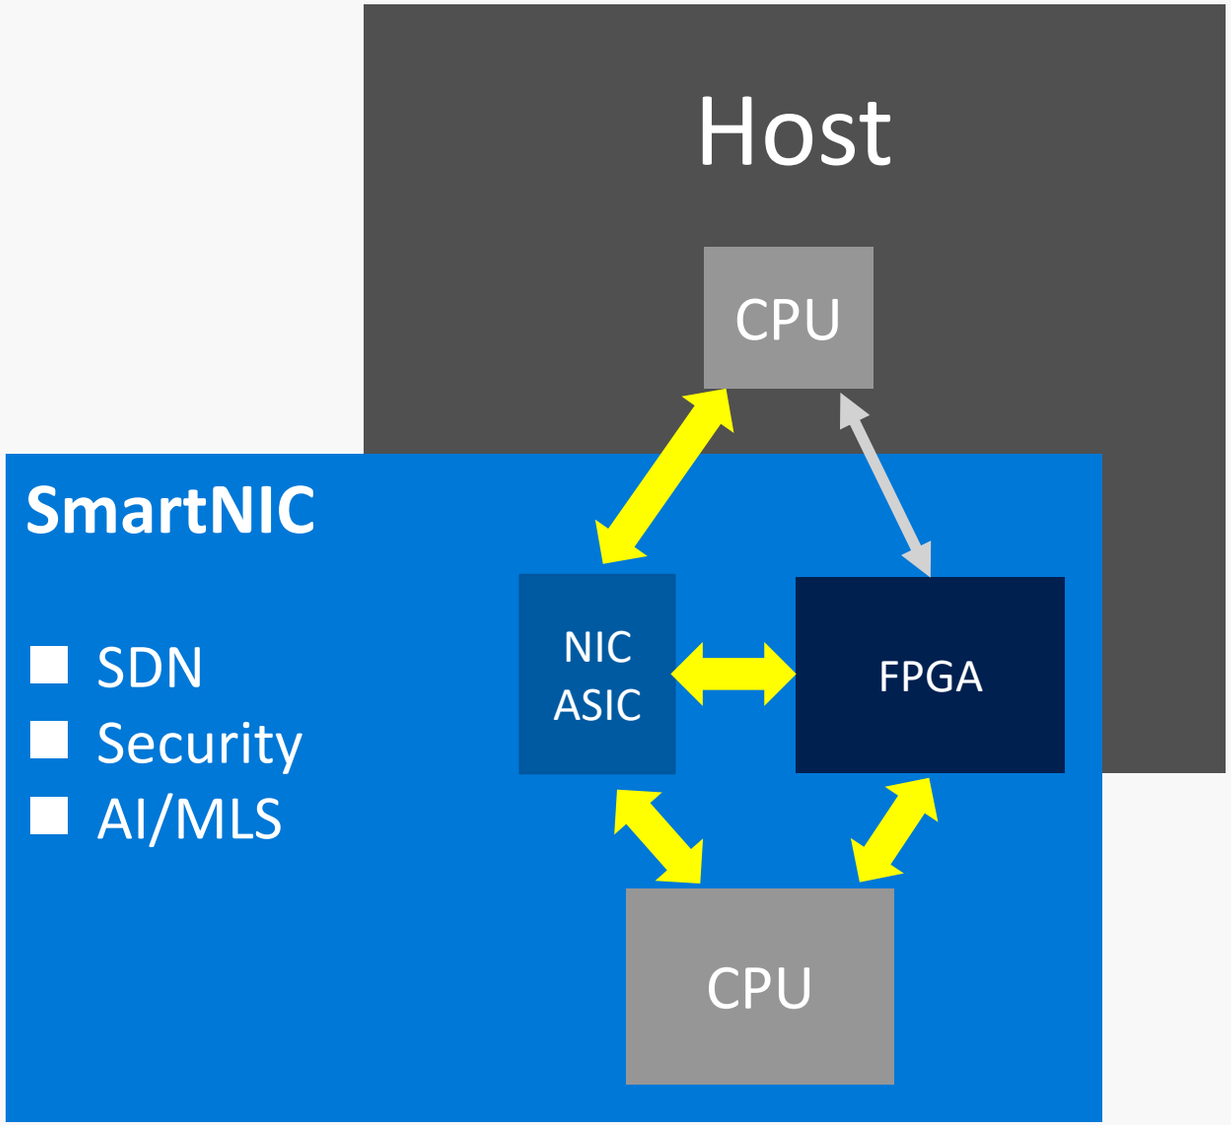




より多くNICへオフロード

- 限界を迎えるネットワークデバイスによる処理
  - ハンドリングの多様化
  - 高い更新頻度
  - 密接な相互連携
    （SDN/Security/AI・ML)

- 1 VM 10Gbps時代
  (Hostは>100Gbps以上)




Microsoft