MPLS Japan 2019 | 2019年10月15日(火)
「Disaggregation ホワイトボックス/OSS」セッション

ホワイトボックスとSmartNICで実装するVNFサーバ

株式会社インターネットイニシアティブ
プロダクト本部 SDN開発部長
白崎 博生

© Internet Initiative Japan Inc.

前回 昨年のおさらい

昨年のテーマ

ホワイトボックス革命
「期待と現実」



- **IIJ でホワイトボックスを使おうとして迷走したお話**
  - 独自NOS作る？ ⇒ NOS作らない（方向転換）
  - SDKのSLA締結 ⇒ 文面の解釈方法に悩む・・・
  - SDK入手 ⇒ ドキュメントが少ない・・・
  - Cavium XPliant ASICで開発 ⇒ ASIC開発中止（！？）
  - ホワイトボックス買う ⇒ 突然EoS、開発中止（！！？？）
    - 人気のない機種は容赦がない。。。

- **Rack as a Service**
  - 物理ラックから仮想ラックを作り、（社内）サービスチームへ払い出す
  - 仮想ベアメタルと仮想L3スイッチ

- **後日談**
  - テスト中に BIOS Flash 内容破壊 ⇒ 予備機からコピーして復旧！！
  - 蓋を開けたら mSATA スロットが ⇒ mSATA SSD を挿して容量大幅アップ

文鎮回避

（参考）文鎮化した際のBIOSメッセージ

```
******************************************************

(C)Copyright 1985-2009, American Megatrends, Inc.
            All Rights Reserved.
            AMI  Serial Recovery.
******************************************************

Press space to start recovery from Serial Address 0x2F8
 or 'N' to try Next Serial Device or 'Q' to quit
Send BIOS image using XMODEM protocol


  Aborting Serial Recovery


******************************************************

(C)Copyright 1985-2009, American Megatrends, Inc.
            All Rights Reserved.
            AMI  Serial Recovery.
******************************************************

Press space to start recovery from Serial Address 0x2F8
 or 'N' to try Next Serial Device or 'Q'
```

ある日のこと

部下：白崎さん、rebootしたらブートしなくなっちゃいました～

私：　そんなわけないだろう、どれどれ

リカバリ？！XMODEM？

別の日のこと

部下：AMI に BIOS を吸い出すツールがあったので同型スイッチからコピーして復旧しました

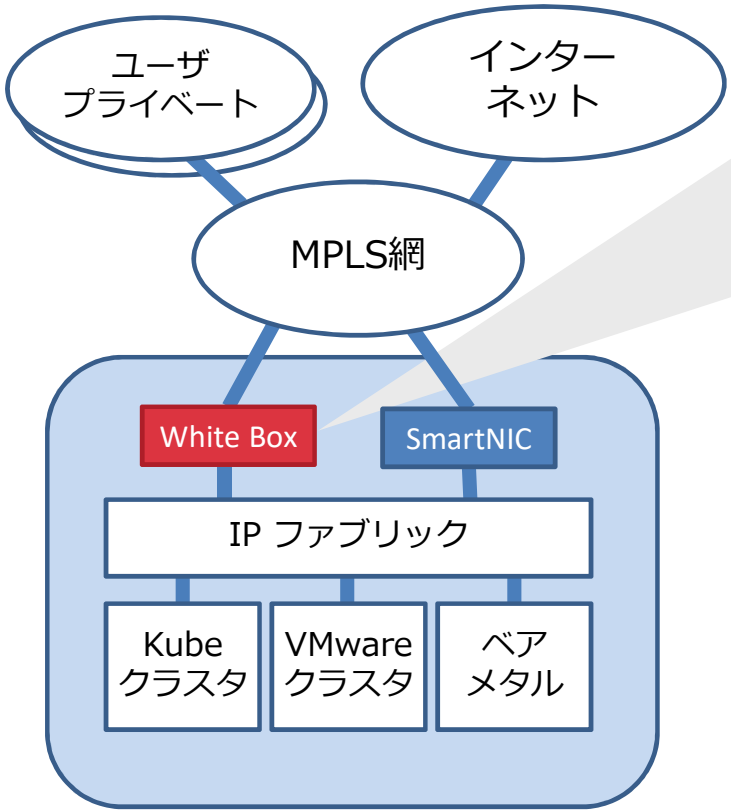
私：　見た目はスイッチでも PC なんやねぇ

実際は書き込むタイミング等にコツが必要だったそうです

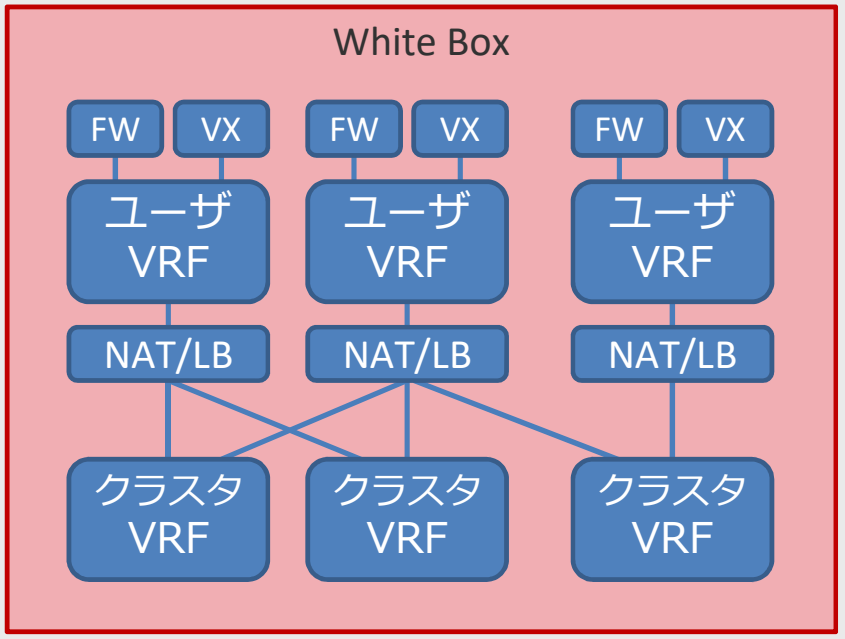
色々学んだ１年でした✨

1. 私目線の「ホワイトボックス動向」
2. 私目線の「Dataplaneプログラミング動向」
3. IIJでのシステム開発動機
4. 本日のまとめ

物理構成



White Boxの内部構成（仮）



１．私目線の「ホワイトボックス動向」

- **100GbE が現実的価格になった**
  - 本体価格が100～150万円
  - 種類が増えた　⇒　選択肢が増えた　⇒　逃げ先確保（重要）
  - トランシーバーの価格低下が激しい（100GbE SRが１～５万円）
- **200GbE, 400GbE が見えてきた**
  - トランシーバーはまだ高い（きっと100GbEのように下がっていく）
  - 遠くない印象
- **SONiC サポート**
  - フリー NOS は SONiC に集約されてきた
  - ASIC メーカーもスイッチメーカーも SONiC サポートに積極的
  - バイナリが公開されている機種にインストールする場合は超簡単
  - 開発中コードが公開されていることもあるので要注意
  - ドキュメントが実装に追い付いていない

- **事例が増えてきた**
  - スイッチメーカーさんもNOSメーカーさんも元気（良いことです）
- **IIJ社内でもホワイトボックス容認派の声が出てきた**
  - えっ？！
  - 容認派 ≠ 推進派（デスヨネー）

２．私目線の「Dataplaneプログラミング動向」

「いまSmartNICがアツい！」



主な SmartNIC メーカー

- Intel、Broadcom、Mellanox、Marvell(Cavium)、Netronome、Xilinx
- 他いろいろ

FPGAベースだったり、ASICベースだったり

オフロード機能

- TSO、QoS、DPDK、OVS、VXLAN、MPLS、IPsec、conntrack、tc (eBPF)
- 他いろいろ

開発環境

- DPDK API、P4、OpenCL、Verilog

- **Dataplane プログラミングの課題**
  - 統一されないオープンな開発環境
  - それぞれ習得が必要
  - ホワイトボックスもSmartNICも同じ状況

- **汎用環境できるか？**
  - OpenDataPlane ⇐ 参加企業少ない
  - P4 ⇐ 一歩先行く開拓者、Intel買収の影響あるか？
  - NPL ⇐ 挑戦者（ひと波乱あるかも）6/12 リリース！ http://nplang.org/
  - tc、eBPF ⇐ Linuxオンリー
  - DPDK ⇐ SmartNIC上のアプリ開発はDPDK APIの流れ

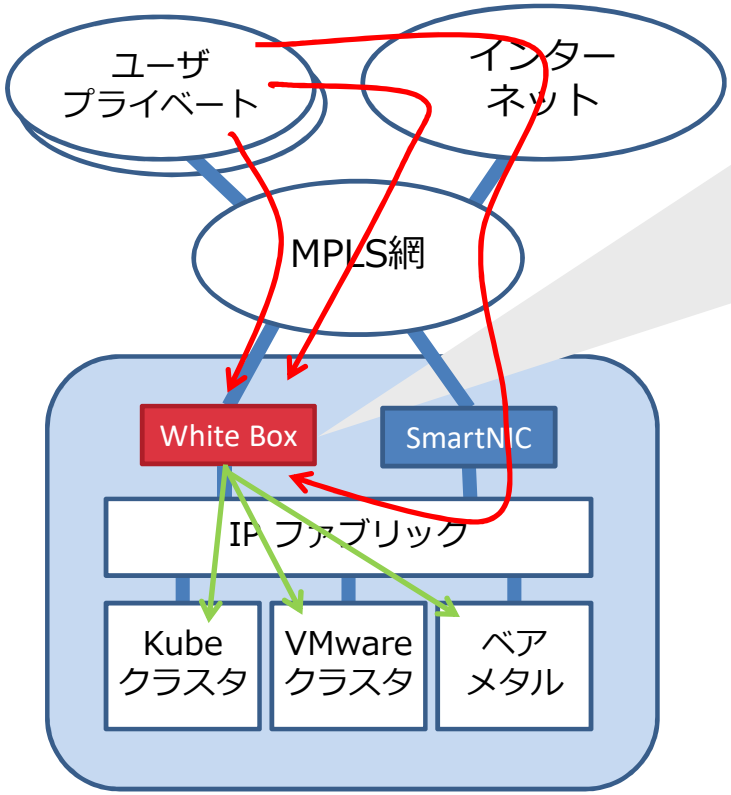
３．IIJでのシステム開発動機

- **サービスシステムの変化**
  - 10年くらい前まではグローバル向けにサービス提供
  - いまはプライベート向けサービスもある
- **システム設計のズレを手でカバー（オペミス怖い）**
  - 機器の設定作業だけでなく、ID 管理も手作業
- **サーバ環境の変化**
  - ベアメタル ⇒ VM ⇒ コンテナ
- **「ネットワーク」がめんどくさくなってきた**
  - 調整、申請、調整、申請、設定、テスト、ドキュメント・・・
- **“イマドキ”の環境を目指す有志が集まってきた**

- **サービスプロバイダーの事情**
  - 多段構造
    - インフラ ⇒ サービス ⇒ 契約
  - お客様のアドレス空間が混在
    - VLANタグで分離できないこともある
  - マルチシステム
    - サービスホストがフラットな設計ではない
  - アクセスログ
    - ProxyやSourceNATできない。戻りパケットの経路問題
  - DCの引っ越し
    - サービスホストは４～５年でリプレースする
    - サービス停止せずに移動する（少しずつ手作業で）

目指すシステム

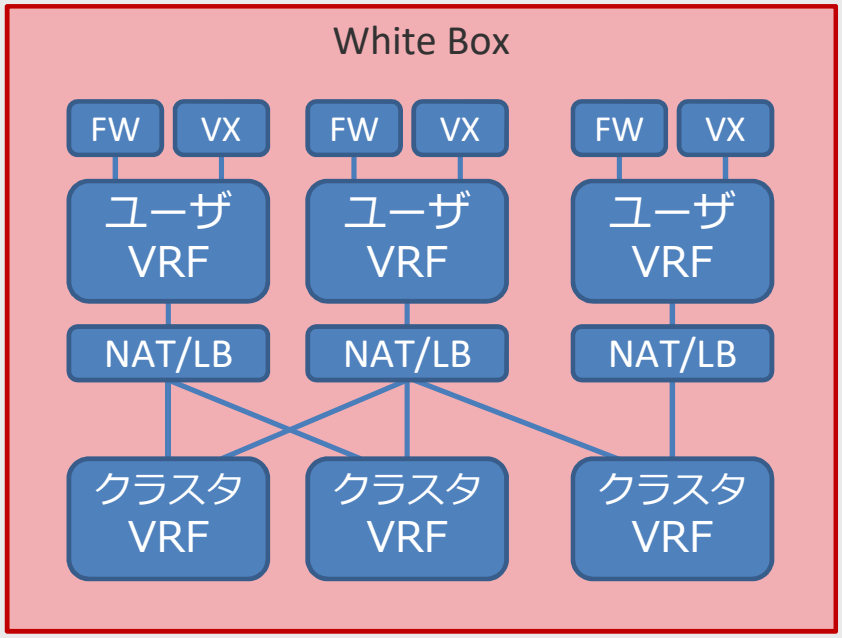
物理構成



White Boxでできないことを
SmartNICへオフロード

White Boxの内部構成（仮）

- サービスエンドポイントと
  サービスシステムを結ぶルータ
（構成の意図は推し量ってください）



- **“ボタンぽちっ”でネットワーク開通するシステム**
  - 現実は紙ベースの処理もあるので難しい
- **Phase1 は Kubernetes ベースのサービスクラスタ**
  - Auto ScaleやAuto Healing等による運用自動化
  - VMwareとベアメタルは今後対応
- **ユーザにも開発者にもネットワークを意識させないシステム**
  - VRF、NAT、VXLAN、PBR、LBで隠せるものは隠す
  - サービスホストはデフォルトに流すだけ（あとはなんとかする）
  - Kubernetes クラスタは L2 排除
- **ASICとSmartNICを併せて活用するシステム**
  - ASICで対応できないIPsec、NAPT、L7 LB等の機能はSmartNICで実装

ホワイトボックス買いました

（開発用）

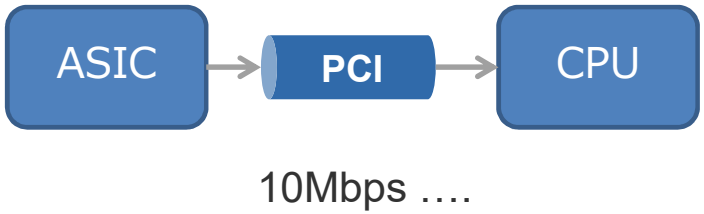
購入したのは「EdgeCore AS7726-32X、DELL S5232F-ON、DELTA AG9032 v2」

- **Trident3 を選んだ理由**
  - NAT 機能があること
  - テーブルサイズが大きいこと
  - テーブルサイズが可変であること

- **「WB はサーバー」**
  - だから蓋開けた⇒mSATA挿した＝サーバ環境構築

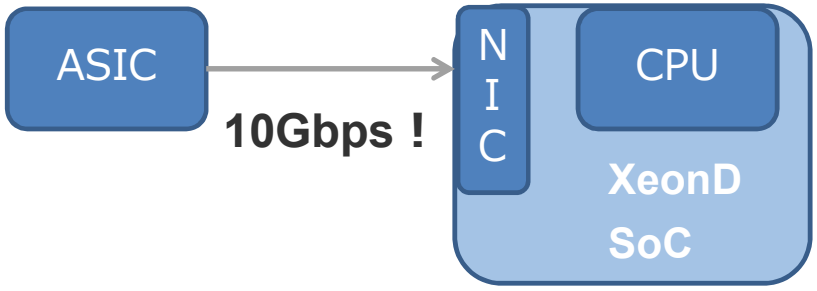
- **Broadwell-DE CPUは10GBaseKRでASICが繋がる。eBPFも動く。**
  - ヒャッハー！
  - Linux カーネルからは ixgbe で 2 ポート見える

ASICとCPU間でEthernetパケットを流す場合



- PCI バスを介してデータを送受信する
- 専用のプロトコルでカプセル化する（オーバーヘッド大）
- アプリは SDK の API を呼び出して送受信する（CPU回す）
- 転送速度は 10Mbps くらい
- サーバ屋が意味なくARP を流すとネットワーク屋が怒る理由はこういうこと

10GBase-KRでASICとCPUを直結



- PCI を介さない配線
- Broadwell-DEのSocはNICを含む
- Ethernetパケットを送受信（オーバーヘッドなし）
- アプリは普通のソケットプログラム
- Linuxのネットワーク機能を活用可能
- 転送速度は 10Gbps くらい

（参考）購入製品のスペック

	AS7726-32X	S5232F-ON	AG9032 v2
CPU	Xeon D-1518@2.20GHz	Atom C3538@2.10GHz	Xeon D-1527@2.20GHz
Memory	16GB	16GB	32GB
Storage	64GB M.2 SSD	64GB M.2 SSD	128GB SATA SSD
BMC	(Intel ME)	IPMI	IPMI
Switch ASIC	BCM56870-A0	BCM56870-A0	BCM56870-A0
Front panel ports	32 x 100GbE(QSFP28)	32 x 100GbE(QSFP28)	32 x 100GbE(QSFP28)

そして開発

- **昨年の反省から SAI （SONiC）ベースの開発**
- **SONiC と SAI がサポートしない機能（NAT、NAPT）の作り込み**
- **モデル設計とAPI設計とコントローラ作成**
- **他チームとのインタフェース設計**
- **Trident3 以外の ASIC の選定**
  - 某社も買収され、昨年の記憶が甦る・・・

４．本日のまとめ

- ホワイトボックスで開発する環境ができてきた
- SmartNIC もアツい！
- Dataplane プログラミングは見極めが必要
- ホワイトボックスでネットワークアプリ開発
  - NOS じゃないよ！
- ASIC + SmartNIC でパワーアップ

Internet Initiative Japan

日本のインターネットは1992年、IIJとともにはじまりました。以来、IIJグループはネットワーク社会の基盤をつくり、技術力でその発展を支えてきました。インターネットの未来を想い、新たなイノベーションに挑戦し続けていく。それは、つねに先駆者としてインターネットの可能性を切り拓いてきたIIJの、これからも変わることのない姿勢です。IIJの真ん中のIはイニシアティブ――――――――IIJはいつもはじまりであり、未来です。

本書には、株式会社インターネットイニシアティブに権利の帰属する秘密情報が含まれています。本書の著作権は、当社に帰属し、日本の著作権法及び国際条約により保護されており、著作権者の事前の書面による許諾がなければ、複製・翻案・公衆送信等できません。本書に掲載されている商品名、会社名等は各会社の商号、商標または登録商標です。文中では™、®マークは表示しておりません。本サービスの仕様、及び本書に記載されている事柄は、将来予告なしに変更することがあります。

IIJ-BKLT999-0001